

| ANÁLISE PREDITIVA

TEMA 1 – MINERAÇÃO DE DADOS E ANÁLISE PREDITIVA

A mineração de dados surgiu em meados da década de 1990, como área de pesquisa e aplicação independente. Ela ganhou evidência nos anos recentes, após o surgimento do conceito de *Big Data*, sendo a responsável pela parte analítica, ou seja, pela preparação e análise de grandes quantidades de dados (Castro; Ferrari, 2016).

Serão abordadas nesta aula as medidas estatísticas para o resumo de um conjunto de dados, etapa fundamental da tarefa descritiva da mineração de dados.

1.1 Mineração de dados

A mineração de dados é o processo de exploração de grandes quantidades de dados, na busca de padrões e conhecimentos relevantes.

De forma geral, as tarefas da mineração de dados podem ser classificadas em duas categorias: descritiva e preditiva.

Tarefas de mineração descritivas buscam encontrar padrões que descrevem os dados observados. A análise descritiva (ou sumarização) de dados é a etapa inicial do processo de mineração, por meio da utilização de ferramentas capazes de explorar, medir e descrever características inerentes aos dados. Nessa etapa, incluem-se as medidas resumo (medidas de tendência central, dispersão e forma da distribuição), distribuições de frequências e histogramas de frequências (Castro; Ferrari, 2016).

Incluem-se, ainda, nas tarefas descritivas, as tarefas de agrupamento (*clustering*) e associação. A tarefa de agrupamento ou *clustering* trata de agrupamento de observações (elementos) em grupos (*clusters*) com características semelhantes. Os elementos pertencentes ao mesmo grupo são muito parecidos e distintos daqueles pertencentes aos outros grupos. A tarefa de associação para mineração de dados é o trabalho de descobrir quais atributos estão relacionados, procurando identificar regras para quantificar o relacionamento entre dois ou mais atributos.

As tarefas de mineração preditivas buscam prever valores futuros ou desconhecidos com base em dados passados e atuais.

As tarefas de análise preditiva consistem em utilizar técnicas de predição, que são a classificação e a estimação (chamada de *análise de regressão* em estatística). A classificação é utilizada para prever valores de variável

quantitativa discreta, e a estimação para prever valores de variável quantitativa contínua (Castro; Ferrari, 2016).

1.2 Análise preditiva

A análise preditiva é o processo para retirar informações de um conjunto de dados com vistas a obter estimativas e fazer previsões sobre os resultados futuros.

A análise preditiva compreende várias tendências estatísticas e técnicas como o aprendizado de máquina, modelagem preditiva e mineração de dados, para analisar com eficiência os dados históricos e as informações, com o objetivo de fornecer previsões sobre eventos futuros desconhecidos (Swani; Tyagi, 2017).

TEMA 2 – TIPOS DE DADOS

Os dados são a base para os processos de mineração e podem basicamente ser de duas formas: estruturados e não estruturados. A forma como os dados estão disponíveis é importante para definir o tipo de tarefa de mineração que é possível conduzir. É importante também observar a quantidade e a qualidade dos dados disponíveis, pois o sucesso da mineração é dependente desses fatores.

2.1 Dados estruturados

As bases de dados utilizadas em sistemas convencionais são organizadas de forma estruturada, sendo que as linhas armazenam uma ocorrência de um evento (observação), caracterizado por um conjunto de colunas, que representam características que descrevem o evento (atributo ou variável). Tem-se, na Tabela 1, o exemplo de dados estruturados.

Tabela 1 – Exemplo de dados estruturados

Id	Experiência	Gênero	Escola	Salário (U\$/hora)
1741	10	M	11	4,81
2982	5	M	12	8,36
2578	10	M	12	3,83
1356	8	F	11	3,15
908	6	F	13	7,88

(continua)

(Tabela 1 – conclusão)

3158	6	M	10	7,66
1034	8	F	12	4,06
133	10	F	12	7,35
2761	7	M	11	0,42
663	9	F	15	15,31
1120	6	F	9	3,54
3136	5	M	11	7,47

Fonte: adaptado Sistema R, 2020.

No exemplo, as linhas representam o registro, que identifica uma observação, nesse caso, representado por Id. Tem-se, nas colunas, os atributos ou variáveis, que são: tempo de experiência (Experiência), gênero (Gênero), anos de estudos (Escola) e salário (em U\$/hora).

O valor assumido pela variável pode ser quantitativo (numérico) ou qualitativo (categórico). Quando assume um valor numérico, a variável pode ser discreta ou contínua, sendo a primeira resultante de contagem, assumindo somente valores inteiros, e a última de medições, assumindo qualquer valor no intervalo dos números reais.

A variável qualitativa (categórica) não assume valores numéricos, mas é definida por duas ou mais categorias.

2.2 Dados não estruturados

Muitos dados disponíveis não estão na forma estruturada, por exemplo, textos, imagens, vídeos e sons. Esse tipo de dado não fará parte desta aula.

TEMA 3 – MEDIDAS DE TENDÊNCIA CENTRAL E DISPERSÃO

As medidas de tendência central e de dispersão ou variabilidade, juntamente com outras medidas como as separatrizes, fazem parte da estatística descritiva. O objetivo da estatística descritiva é organizar os dados e apresentá-los de forma a possibilitar a compreensão destes de maneira mais rápida. As técnicas estatísticas e gráficas podem ser aplicadas a qualquer conjunto de dados, sejam para dados populacionais ou amostrais.

A população ou universo é o conjunto de todos os elementos que apresenta alguma característica de interesse em comum; amostra é um subconjunto, representativo da população.

A medida que representa de forma resumida uma característica da população ou universo é chamada de *parâmetro*. Por exemplo, a média populacional (μ) e da amostra, estimativa do parâmetro ou medida amostral, como a média amostral ($\bar{X}$).

3.1 Medidas de tendência central

As medidas de tendência central são utilizadas para representar um conjunto de dados por meio de um único valor, sendo as mais utilizadas a média aritmética, mediana e moda.

3.1.1 Média aritmética

A média aritmética é a medida de tendência central mais usada, no entanto, sua utilização requer cuidados, pois é influenciada pelos valores atípicos.

$$\text{Média aritmética populacional: } \mu = \frac{1}{N} \sum_{i=1}^N x_i \quad (1)$$

Em que:

- N é o número de observações na população ou universo;
- x_i são os valores assumidos pela variável.

$$\text{Média aritmética amostral: } \bar{X} = \frac{1}{n} \sum_{i=1}^n x_i \quad (2)$$

Em que:

- n é o número de observações na amostra;
- x_i são os valores assumidos pela variável.

3.1.2 Mediana

A mediana é o valor que ocupa a posição central do conjunto de observações de uma variável, dividindo o conjunto em duas partes iguais, sendo que 50% dos dados assumem valores menores ou iguais ao valor da mediana, e, 50%, acima do seu valor. A mediana não muito é afetada pelos valores atípicos, assim, segundo Morettin e Bussab (2017), é uma medida resistente (ou robusta).

Para obter o valor da mediana, deve-se ordenar os dados em ordem crescente (ou decrescente), calcular a posição da mediana por meio das expressões a seguir.

$$\text{Mediana populacional: } PosM_e = \frac{(N-1)}{2} + 1 \quad (3)$$

Em que:

- N é o número de observações na população ou universo.

$$\text{Mediana amostral: } PosM_e = \frac{(n-1)}{2} + 1 \quad (4)$$

Em que:

- n é o número de observações na amostra.

O valor da mediana é o valor da variável que ocupa o lugar (ou posição) $PosM_e$.

3.1.3 Moda

A moda é o valor que apresenta maior frequência. Pode não apresentar nenhum valor mais frequente, ter somente um valor, ou pode ter dois ou mais valores.

3.2 Medidas de dispersão ou variabilidade

Para descrever adequadamente um conjunto de dados, além da informação do valor representativo da variável – por meio de uma medida de tendência central –, é necessário indicar também o quanto esses valores são dispersos. Algumas das medidas de variabilidade mais utilizadas são a variância, o desvio padrão e o coeficiente de variação.

3.2.1 Variância e desvio padrão

$$\text{Variância populacional: } \sigma^2 = \frac{1}{N} \sum_{i=1}^N (x_i - \mu)^2 \quad (5)$$

Em que:

- N é o número de observações na população ou universo;

- x_i são os valores assumidos pela variável;
- μ é a média populacional.

O desvio padrão é a raiz quadrada da variância.

$$\text{Desvio padrão populacional: } \sigma = \sqrt{\sigma^2} \quad (6)$$

$$\text{Variância amostral: } S^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{X})^2 \quad (7)$$

Em que:

- n é o número de observações na amostra;
- x_i são os valores assumidos pela variável;
- $\bar{X}$ é a média amostral.

$$\text{Desvio padrão amostral: } S = \sqrt{S^2} \quad (8)$$

3.2.2 Coeficiente de variação

O coeficiente de variação é uma medida de dispersão relativa, definido como o quociente entre o desvio padrão e a média, multiplicado por 100, sendo assim expresso em porcentagem.

Em algumas situações, é necessário utilizar uma medida de dispersão relativa, por exemplo: quando se deseja comparar o grau de dispersão de dois conjuntos de dados com unidades de medidas diferentes ou quando as médias de dois conjuntos de dados são muito distintas.

$$\text{Coeficiente de variação populacional: } CV = \frac{\sigma}{\mu} \times 100 \quad (9)$$

$$\text{Coeficiente de variação amostral: } CV = \frac{S}{\bar{X}} \times 100 \quad (10)$$

TEMA 4 – DIAGRAMA DE CAIXA (BOXPLOT) E HISTOGRAMA DE FREQUÊNCIAS

Além das medidas de tendência central e de dispersão, já apresentadas, o diagrama de caixa e o histograma de frequências fazem parte da estatística descritiva.

4.1 Diagrama de caixa

É um gráfico que possibilita identificar valores atípicos ou *outliers*. Uma vez identificado um valor atípico, a decisão de excluir ou não é do pesquisador, pois os valores atípicos podem fornecer informações importantes sobre a variável em estudo.

A construção do diagrama de caixa requer o cálculo dos quartis, que são três medidas (Q_1 , Q_2 e Q_3) que dividem o conjunto de dados em quatro partes iguais, sendo que cada quartil corresponde a 25% dos dados.

A seguir estão dispostas as etapas para a obtenção dos quartis.


1. Ordenar os dados em ordem crescente (ou decrescente).
2. Calcular a posição que o quartil ocupa, por meio de:

$$PosQ_i = i \times \frac{(n - 1)}{4} + 1, \quad i = 1, 2, 3 \quad (11)$$

O valor de Q_i é o valor da variável que ocupa o lugar (ou posição) $PosQ_i$.

A Figura 1 mostra um exemplo de diagrama de caixa, com a identificação das medidas estatísticas.

Figura 1 – Diagrama de caixa



Fonte: a autora.

A linha dentro do retângulo ("caixa") representa a mediana da distribuição. As bordas superior e inferior do retângulo representam os quartis 1 e 3, respectivamente. A altura desse retângulo é chamada de *amplitude interquartílica*

($IQ = Q_3 - Q_1$). Os traços horizontais ao final das linhas verticais são traçados sobre o último ponto (de um lado ou de outro) que não é considerado um *outlier* inferior ou superior.

Em geral, a maior parte das definições considera que pontos acima do valor do 3.º quartil somado a 1,5 vezes a IQ ou os pontos abaixo do valor do 1.º quartil diminuído de 1,5 vezes a IQ são considerados *outliers*.

4.2 Distribuição de frequências e histograma de frequências

Segundo Morettin e Bussab (2017), a escolha dos intervalos de classes dependerá do conhecimento que o pesquisador tem sobre os dados. Assim, a definição do número de intervalos de classes é arbitrária. Porém, é importante observar que, quando se utiliza um pequeno número de intervalos, pode-se perder informações, e ao contrário, com um grande número de intervalos pode-se prejudicar o resumo dos dados.

Uma solução bastante utilizada é a fórmula de *Sturges* para o cálculo do número de classes (k):

$$k = 1 + 3,3 \times \log(n) \quad (12)$$

A amplitude de classes será obtida por meio de:

$$h = \frac{A_t}{k} = \frac{\text{maior valor} - \text{menor valor}}{k} \quad (13)$$

O histograma de frequências é um gráfico usado para apresentar dados organizados em intervalos de classes (distribuição de frequências), utilizado principalmente para representar a distribuição de variáveis contínuas.

Para elaboração do histograma de frequências, utilizam-se os intervalos de classes e as respectivas frequências. Um histograma é um gráfico de colunas justapostas, ou seja, sem espaços entre as colunas.

4.2.1 Polígono de frequências

É um gráfico de linhas em que as frequências são localizadas sobre perpendiculares levantadas dos pontos médios dos intervalos de classes de um histograma de frequências. À medida que o número de observações aumenta, os

segmentos de retas de um polígono de frequências se aproximam de uma curva, chamada de *curva de frequência*.

Os tipos de curva de frequência são: curvas de frequência simétrica e assimétrica ou desviada. Nesse último caso, pode ser assimétrica positiva, se a cauda for desviada para a direita, e assimétrica negativa, se a cauda for desviada para a esquerda.

Quando o tamanho da amostra for grande, o histograma de frequências é um indicador confiável para designar a forma da distribuição, isto é, da população de onde a amostra foi retirada (Montgomery; Ranger, 2009).

- Assimetria positiva: observações com valores menores são mais frequentes.
- Assimetria negativa: observações com valores maiores são mais frequentes.
- Simétrica: as observações estão igualmente distribuídas em torno de um valor mais frequente (metade abaixo e metade acima).

TEMA 5 – EXEMPLOS DE APLICAÇÃO

O objetivo deste tema é fazermos uma análise descritiva de dados, aplicando as técnicas estatísticas estudados nesta aula por meio do Sistema R.

5.1 Sistema R

O R é um *software* de domínio público, livre, que pode ser utilizado para análise de dados em geral. O ambiente R, ou simplesmente R, como é chamado normalmente, é uma importante ferramenta para realizar análise e manipulação de dados, com testes estatísticos paramétricos e não paramétricos, modelagem linear e não linear, análise de séries temporais, redes neurais, mineração de dados, entre outras ações, além de apresentar facilidade na elaboração de diversos tipos de gráficos.

Detalhes sobre a instalação do R podem ser encontrados em Itano e Santos (2020).

5.2 Exemplos de aplicação

Vamos fazer uma análise de salários (US\$/hora) de 40 pessoas, obtidos por meio do arquivo *Wages1*, disponível na biblioteca *Ecdat*, do Sistema R.

A análise consistirá no cálculo das medidas de tendência central, variabilidade, elaboração de tabela de distribuição de frequências, diagrama de caixa e histograma de frequências.

Tabela 1 – Salário de 40 pessoas

Obs.	Salário (US\$ /hora)	Obs.	Salário (US\$ /hora)	Obs.	Salário (US\$ /hora)	Obs.	Salário (US\$ /hora)
1	3,67	11	6,01	21	4,07	31	2,14
2	5,31	12	4,70	22	8,35	32	8,23
3	3,74	13	5,69	23	7,47	33	3,20
4	8,57	14	4,35	24	3,16	34	4,41
5	4,11	15	2,84	25	3,27	35	12,10
6	6,96	16	1,99	26	4,41	36	4,37
7	6,13	17	4,77	27	0,92	37	6,79
8	3,22	18	10,31	28	11,13	38	7,04
9	4,60	19	4,17	29	6,15	39	7,46
10	7,66	20	1,71	30	1,07	40	4,90

Fonte: elaborado com base em Sistema R, 2020.

Inicialmente, deve-se criar um objeto contendo os dados, como apresentado a seguir:

```
# para criar o objeto salario no R:
salario<-c(3.67,5.31,3.74,8.57,4.11,6.96,6.13,3.22,4.60,7.66,
           6.01,4.70,5.69,4.35,2.84,1.99,4.77,10.31,4.17,1.71,
           4.07,8.35,7.47,3.16,3.27,4.41,0.92,11.13,6.15,1.07,
           2.14,8.23,3.20,4.41,12.10,4.37,6.79,7.04,7.46,4.90)
```

Para visualizar o conteúdo do objeto criado, basta digitar:

```
salario
```

O R mostrará os dados, como segue:

```
> salario
[1] 3.67 5.31 3.74 8.57 4.11 6.96 6.13 3.22 4.60 7.66
6.01 4.70
[13] 5.69 4.35 2.84 1.99 4.77 10.31 4.17 1.71 4.07 8.35
7.47 3.16
[25] 3.27 4.41 0.92 11.13 6.15 1.07 2.14 8.23 3.20 4.41
12.10 4.37
[37] 6.79 7.04 7.46 4.90
```

Com base nesses dados, é possível calcular as medidas estatísticas e elaborar os gráficos.

5.2.1 Média

```
média<-mean(salario)
média
[1] 5.27875
```

O salário médio por hora é U\$ 5,28.

5.2.2 Mediana

```
mediana<-median(salario)
mediana
[1] 4.65
```

O salário mediano por hora é U\$ 4,65, indicando que 50% das pessoas têm salário por hora menor ou igual a U\$ 4,65 e 50%, maior do que este valor.

5.2.3 Moda

```
y <- table(salario)
moda<-names(y)[which(y==max(y)) ]
moda
[1] "4.41"
```

O salário por hora mais frequente é U\$ 4,41.

Para saber qual é a frequência observada basta digitar:

```
table(salario)
```

5.2.4 Variância

```
variância<-var(salario)
variância
[1] 6.852329
```

A variância é calculada elevando-se o desvio dos valores observados em relação à média ao quadrado, o que significa que a unidade dessa medida é

também elevada ao quadrado, portanto, não pode ser comparada com a média. Para que seja possível a comparação, deve-se usar o desvio padrão.

5.2.5 Desvio padrão

```
desvio_padrao<-sd(salario)
desvio_padrao
[1] 2.617695
```

O desvio padrão do salário por hora é U\$ 2,62.

5.2.6 Coeficiente de variação

```
coef_variacao<-(desvio_padrao/media)*100
coef_variacao
[1] 49.5893
```


A variação em torno do salário médio por hora é de 49,59%, indicando uma grande variabilidade dos salários.

5.2.7 Diagrama de caixa

```
boxplot(salario,main=" ", cex.main=0.9,col="lightgreen")
```

O Gráfico 1, apresentado a seguir, indica que não existe nenhum valor atípico ou *outlier*.

Gráfico 1 – Diagrama de caixa de salários



Fonte: elaborado com base em Sistema R, 2020.

Nota: Salários (em U\$/hora).

5.2.8 Distribuição de frequências e histograma de frequências

Para a elaboração da distribuição de frequências, deve-se inicialmente calcular o número de intervalos de classes (k). Nesse caso, o número de observações é igual a 40, ou seja, $n = 40$. Utilizando a fórmula de Sturges para obter o número de intervalos, tem-se:

$$k = 1 + 3,3 \times \log(n) = 1 + 3,3 \times \log(40) = 6,29 \cong 7$$

Serão utilizados sete intervalos de classes. Para definir os limites de classes:

$$A_t = \text{maior valor} - \text{menor valor}$$

$$A_t = 12,10 - 0,92 = 11,18$$

$$h = \frac{11,18}{7} = 1,5971 \cong 1,6$$

Recomenda-se arredondar o valor de h sempre para um valor maior, nesse caso, será arredondado para 1,6. O limite inferior do primeiro intervalo será o menor valor do conjunto de dados, nesse caso, 0,92. O limite superior é obtido somando o valor de h ; tem-se, então, 2,52, e assim por diante. A notação utilizada (|---) indica que inclui o limite inferior e não inclui o limite superior.

Para obter a distribuição de frequências e o histograma de frequências no R, proceder da seguinte forma:

```
# cálculo do número de intervalos de classe
k<-ceiling((1+3.3*log10(length(salario))))
k
# cálculo do intervalo de classe
h<-(diff(range(salario))/k)
h
h<-1.6 # definindo o intervalo
minimo<-min(salario);minimo
limites<-c(minimo,minimo+h,minimo+2*h,minimo+3*h,minimo+4*h,
            minimo+5*h,minimo+6*h,minimo+7*h)
limites # apresenta os limites dos intervalos de classes
> limites
[1] 0.92 2.52 4.12 5.72 7.32 8.92 10.52 12.12
```

Os limites de classes são: 0,92 |--- 2,52, 2,52 |--- 4,12, até 10,52 |--- 12,12.
Em seguida, calcula-se as frequências de cada intervalo de classe.

```
classes<-c("0.92|-- 2.52","2.52|-- 4.12","4.12|-- 5.72",
           "5.72|-- 7.32","7.32|-- 8.92","8.92|-- 10.52",
           "10.52|-- 12.12")
table(cut(salario,breaks=limites,right=FALSE,labels=classes))
0.92|-- 2.52    2.52|-- 4.12    4.12|-- 5.72    5.72|-- 7.32    7.32|-- 8.92
           5              9              11              6              6
8.92|-- 10.52 10.52|-- 12.12
           1              2
```

A Tabela 2, a seguir, apresenta a distribuição de frequências de salários.

Tabela 2 – Distribuição de frequências de salários

Classes de salário (U\$/hora)	Frequência
0,92 --- 2,52	5
2,52 --- 4,12	9
4,12 --- 5,72	11
5,72 --- 7,32	6
7,32 --- 8,92	6
8,92 --- 10,52	1
10,52 --- 12,12	2

Fonte: elaborado com base em Sistema R, 2020.

Para construir o histograma de frequências:

```
histo<-hist(salario,breaks =
c(minimo,minimo+h,minimo+2*h,minimo+3*h,minimo+4*h,
  minimo+5*h,minimo+6*h,minimo+7*h),
  include.lowest = TRUE,col="grey",freq=T,
  main=" ",ylab="Freq.",
  xlab="Intervalos de salário")
```


Em que:

- `hist`: função para construir o histograma;
- `breaks`: limites de classes;
- `include.lowest = TRUE`: inclui o limite inferior da classe;
- `col`: cor das colunas;

- `freq=T`: utiliza as frequências;
- `main=""`: título do gráfico em branco;
- `ylab="Freq."`: título do eixo Y;
- `xlab="Intervalos de ICEI"`: título do eixo X.

O histograma de frequências é apresentado no Gráfico 2.

Gráfico 2 – Histograma de frequências de salários



Fonte: elaborado com base em Sistema R, 2020.

Nota: Salários (em U\$/hora).

Para a construção do histograma de frequências e o polígono de frequências no R:

```
histo<-hist(salario,breaks =
c(minimo,minimo+h,minimo+2*h,minimo+3*h,minimo+4*h,
minimo+5*h,minimo+6*h,minimo+7*h),
include.lowest = TRUE,col="grey",freq=T,
main="",cex.main=0.8,
ylab="Freq.",xlab="Intervalos de salário",xlim=c(0,14))
lines(c(0.12, histo$mids, 12.92), c(0,histo$counts, 0),
type = "l",col="red",lwd=2)
```

Em que:

- `lines`: desenha os segmentos de reta;
- `histo$mids`: pontos médios das classes.


Os valores definidos na função `lines` são:

- 0,12: é limite inferior do primeiro intervalo de classe (0,92) menos a metade do valor de h ($h/2 = 0,80$);

- 12,92: é limite superior do último intervalo de classe (12,12) mais a metade do valor de h ($h/2 = 0,80$).

O Gráfico 3, a seguir, mostra o histograma de frequências e o polígono de frequências.

Gráfico 3 – Histograma e polígono de frequências de salários (Janeiro 2017 a Março 2020)



Fonte: com base em Sistema R; 2020.

Nota: Salários (em U\$/hora).

REFERÊNCIAS

CASTRO, L. N. de; FERRARI, D. G. **Introdução à mineração de dados**: conceitos básicos, algoritmos e aplicações. São Paulo: Saraiva, 2016.

ITANO, F.; SANTOS, S. M. dos. **Guia de Instalação R**. São Paulo: Instituto Matemática e Estatística, Universidade de São Paulo. Disponível em: <<https://cran.r-project.org/doc/contrib/Itano-installation.pdf>>. Acesso em: 21 jan. 2021.

MORETTIN, P. A.; BUSSAB, W. O. **Estatística básica**. 5. ed. São Paulo: Saraiva, 2017.

SISTEMA R. **Biblioteca Ecdat**. Disponível em: <<https://vincentarelbundock.github.io/Rdatasets/datasets.html>>. Acesso em: 21 jan. 2021.

SISTEMA R. Disponível em: <<http://cran.r-project.org>>. Acesso em: 21 jan. 2021.

SWANI, L; TYAGI, P. Predictive modelling anatytics through data mining. **International research journal of engineering and technology (IRJET)**, v. 4, n. 9, set. 2017.