

Aula 1

Análise Preditiva

Profª Sachiko A. Lira

1

Mineração de dados e análise preditiva

2

- Mineração de dados e análise preditiva
 - Mineração de dados
 - ✓ Descritiva: análise descritiva (ou sumarização), agrupamento e associação
 - ✓ Preditiva: classificação e estimação
 - Análise preditiva
 - Tendências estatísticas, modelagem preditiva, mineração de dados e aprendizado de máquina

3

Tipos de dados

4

- Dados não estruturados
 - Textos, imagens, vídeos e sons
 - Esse tipo de dado não fará parte do estudo
- Dados estruturados

5

Exemplo de dados estruturados

Id	Experiência	Gênero	Escola	Salário (U\$/hora)
1741	10	M	11	4,81
2982	5	M	12	8,36
2578	10	M	12	3,83
1356	8	F	11	3,15
908	6	F	13	7,88
3158	6	M	10	7,66
1034	8	F	12	4,06
133	10	F	12	7,35
2761	7	M	11	0,42
663	9	F	15	15,31
1120	6	F	9	3,54
3136	5	M	11	7,47

Fonte: Elaborado com base nos dados disponíveis na biblioteca Ecdf, Sistema R, 2020

6

- ▀ Valor de uma variável
 - Medida quantitativa ou qualitativa
- ▀ Medida quantitativa
 - Discreta ou contínua

7

Medidas de tendência central e dispersão

8

- ▀ População ou universo
- ▀ Amostra
- ▀ Parâmetro
- ▀ Estimativa do parâmetro ou medida amostral

9

- ▀ Medidas de tendência central
 - Média aritmética
 - ✓ Média aritmética populacional:

$$\mu = \frac{1}{N} \sum_{i=1}^N x_i \quad (1)$$
 - ✓ Média aritmética amostral:

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n x_i \quad (2)$$

10

- ▀ Medidas de tendência central
 - Mediana
 - ✓ Mediana populacional:

$$PosM_e = \frac{(N-1)}{2} + 1 \quad (3)$$
 - ✓ Mediana amostral:

$$PosM_e = \frac{(n-1)}{2} + 1 \quad (4)$$
 - ✓ O valor da mediana é o valor da variável que ocupa o lugar (ou posição) $PosM_e$
 - Moda

11

- ▀ Medidas de dispersão ou variabilidade
 - Variância e desvio padrão
 - ✓ Variância populacional:

$$\sigma^2 = \frac{1}{N} \sum_{i=1}^N (x_i - \mu)^2 \quad (5)$$
 - ✓ Desvio padrão populacional:

$$\sigma = \sqrt{\sigma^2} \quad (6)$$

12

✔ **Variância amostral:**

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{X})^2 \quad (7)$$

✔ **Desvio padrão amostral:**

$$S = \sqrt{S^2} \quad (8)$$

▀ **Medidas de dispersão ou variabilidade**

● **Coefficiente de variação**

✔ **Coefficiente de variação populacional:**

$$CV = \frac{\sigma}{\mu} \times 100 \quad (9)$$

✔ **Coefficiente de variação amostral:**

$$CV = \frac{S}{\bar{X}} \times 100 \quad (10)$$

Diagrama de caixa e histograma de frequências

▀ **Diagrama de caixa**

- **Quartil:** são três medidas (Q_1 , Q_2 e Q_3) que dividem o conjunto de dados em quatro partes iguais, sendo que cada quartil corresponde a 25% dos dados


● $PosQ_i = i \times \frac{(n-1)}{4} + 1, \quad i = 1, 2, 3 \quad (11)$

● $IQ = Q_3 - Q_1$

✔ **Li:** 1º quartil diminuído de 1,5 vezes a IQ

✔ **Ls:** 3º quartil somado a 1,5 vezes IQ

Diagrama de caixa



Fonte: Lima, 2021

■ Histograma de frequências

- Para a elaboração do histograma de frequências, são utilizados os intervalos de classes e as respectivas frequências. Um histograma é um gráfico de colunas justapostas
- Segundo Morettin e Bussab (2017), a escolha dos intervalos de classes dependerá do conhecimento que o pesquisador tem sobre os dados

19

- Uma solução bastante utilizada é a fórmula de Sturges, para o cálculo do número de classes (k):

$$k = 1 + 3,3 \times \log(n) \quad (12)$$

- A amplitude de classes será obtida a partir de:


$$h = \frac{A_t}{k} = \frac{\text{maior valor} - \text{menor valor}}{k} \quad (13)$$

- Sendo k o número de intervalos de classes

20

Histograma de frequência de salários

- Nota: salários (em U\$/hora)



Fonte: Elaborado com base nos dados disponíveis na biblioteca Ecdat, Sistema R, 2020

21

- Quando o tamanho da amostra for grande, o histograma de frequência é um indicador confiável da forma de distribuição, isto é, da população de onde a amostra foi retirada (Montgomery; Ranger, 2009)

22

- Assimetria positiva: observações com valores menores são mais frequentes
- Assimetria negativa: observações com valores maiores são mais frequentes
- Simetria: as observações estão igualmente distribuídas em torno de um valor mais frequente (metade abaixo e metade acima)

23

■ Polígono de frequências

Histograma e polígono de frequência de salários

- Nota: salários (em U\$/hora)



Fonte: Elaborado com base nos dados disponíveis na biblioteca Ecdat, Sistema R, 2020

24

Exemplos de aplicação

25

■ Sistema R

- O R está disponível em: <<http://cran.r-project.org>>
- Detalhes sobre a instalação do R podem ser encontrados em Itano e Santos (2020)

26

■ Exemplos de aplicação

- O objetivo é fazer uma análise de salários (U\$/hora) de 40 pessoas, obtidos a partir do arquivo Wages1, disponível na biblioteca Ecdat, do Sistema R

27

Salário de 40 pessoas

Obs.	Salário (U\$/hora)	Obs.	Salário (U\$/hora)	Obs.	Salário (U\$/hora)	Obs.	Salário (U\$/hora)
1	3,67	11	6,01	21	4,07	31	2,14
2	5,31	12	4,70	22	8,35	32	8,23
3	3,74	13	5,69	23	7,47	33	3,20
4	8,57	14	4,35	24	3,16	34	4,41
5	4,11	15	2,84	25	3,27	35	12,10
6	6,96	16	1,99	26	4,41	36	4,37
7	6,13	17	4,77	27	0,92	37	6,79
8	3,22	18	10,31	28	11,13	38	7,04
9	4,60	19	4,17	29	6,15	39	7,46
10	7,66	20	1,71	30	1,07	40	4,90

Fonte: Elaborado com base no arquivo Wages1 na biblioteca Ecdat, Sistema R, 2020

28

- A análise consistirá no cálculo das medidas de tendência central, variabilidade, construção do diagrama de caixa e histograma de frequências

29

■ Medidas de tendência central

● Média aritmética

✓ > média

✓ [1] 5.28

● Mediana

✓ > mediana

✓ [1] 4.65

30

- **Moda**
 - ✓ > moda
 - ✓ [1] "4.41"
- **Medida de dispersão ou variabilidade**
 - **Variância**
 - ✓ > variância
 - ✓ [1] 6.85


31

- **Desvio padrão**
 - ✓ > desvio_padrao
 - ✓ [1] 2.62
- **Coeficiente de variação**
 - ✓ > coef_variacao
 - ✓ [1] 49.59(%)

32

Diagrama de caixa de salários

- **Nota: salários (em U\$/hora)**



Fonte: Elaborado com base nos dados disponíveis na biblioteca Ecdfat, Sistema R, 2020

33

Distribuição de frequências de salários


Classes de salário (U\$/hora)	Frequência
0,92 --- 2,52	5
2,52 --- 4,12	9
4,12 --- 5,72	11
5,72 --- 7,32	6
7,32 --- 8,92	6
8,92 --- 10,52	1
10,52 --- 12,12	2

Fonte: Elaborado com base nos dados disponíveis na biblioteca Ecdfat, Sistema R, 2020

34

Histograma de frequências de salários

- **Nota: salários (em U\$/hora)**




Fonte: Elaborado com base nos dados disponíveis na biblioteca Ecdfat, Sistema R, 2020

35


Histograma e polígono de frequências de salários

- **Nota: salários (em U\$/hora)**



Fonte: Elaborado com base nos dados disponíveis na biblioteca Ecdfat, Sistema R, 2020

36



37