

| ANÁLISE PREDITIVA

TEMA 1 – DISTRIBUIÇÃO NORMAL

A inferência estatística compreende um conjunto de técnicas que, por meio de dados amostrais, possibilita tirar conclusões sobre os parâmetros populacionais. As técnicas estatísticas paramétricas presumem que a distribuição de probabilidade dos dados seja conhecida.

1.1 Distribuição normal

A distribuição normal, conhecida também como *distribuição Gaussiana*, é uma das mais importantes distribuições de probabilidades para variáveis aleatórias contínuas, sendo aplicada em probabilidades e frequentemente utilizada para o desenvolvimento teórico da inferência estatística, por exemplo, estimação e testes de hipóteses.

A função densidade de probabilidade de uma varável aleatória continua X , que segue distribuição normal e é dada por:

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2} \quad (1)$$

Em que:

- $x \in R$;
- $\mu \in R$;
- $\sigma \in R^+$.

Os parâmetros da distribuição normal são:

$$\text{Média: } E(X) = \mu \quad (2)$$

$$\text{Variância: } V(X) = \sigma^2 \quad (3)$$

A notação $X \sim N(\mu, \sigma^2)$ é muito usada para denotar que a distribuição da variável aleatória X é normal com parâmetros μ e σ^2 .


Algumas características da distribuição normal são:

- o gráfico da distribuição normal ter aspecto típico, que é a curva em forma de sino;
- a curva ser simétrica em torno da média μ e os valores da média, mediana e moda serem iguais;

- a área total sob a curva se igual a 1, ou seja, $\int_{-\infty}^{\infty} f(x)dx = 1$.

O Gráfico 1 apresenta as probabilidades associadas a uma distribuição normal.

Gráfico 1 – Distribuição normal



Fonte: elaborado com base em Gupta; Guttman, 2017.

A área compreendida entre $\mu \pm \sigma$ é igual a 68,27%; entre $\mu \pm 2\sigma$ é igual a 95,45% e entre $\mu \pm 3\sigma$ é igual a 99,73%.

TEMA 2 – TESTES DE HIPÓTESES

Os testes de hipóteses são procedimentos para a tomada de decisão quanto a uma afirmação sobre um parâmetro populacional. A afirmação sobre os parâmetros é chamada de hipótese estatística.

Em geral, uma hipótese estatística constitui-se de um par de afirmativas sobre o parâmetro desconhecido, a hipótese nula, representada por H_0 , que representa uma convicção ou algo conhecido, e a hipótese alternativa, representada por H_1 , que é uma afirmativa baseada em alguma nova informação. Com base nos dados amostrais, rejeita-se a hipótese nula H_0 ou não se rejeita a hipótese nula H_0 . A hipótese alternativa H_1 pode assumir diferentes situações, tendo como base alguma nova informação. Genericamente, tem-se:


- teste unilateral à esquerda: $H_0: T = T_0$, $H_1: T < T_0$;
- teste unilateral à direita: $H_0: T = T_0$, $H_1: T > T_0$;
- teste bilateral: $H_0: T = T_0$, $H_1: T \neq T_0$.

Para a definição da região de rejeição de H_0 , é necessário considerar a hipótese H_1 , uma vez que é ela que define o tipo do teste, se é unilateral à

esquerda, unilateral à direita ou bilateral. Por meio do tipo do teste identifica-se a área de rejeição de H_0 , conforme é possível visualizar na Figura 1.

Os pontos c_1 , c_2 , c_3 , e c_4 são os pontos críticos, obtidos nas tabelas das distribuições das estatísticas do teste para o nível de significância adotado.

Figura 1 – Região de rejeição (RR) da hipótese



Fonte: elaborado com base em Gupta; Guttman, 2017.

2.1 Erro estatístico

Na realização de testes estatísticos, é possível cometer dois tipos de erros.

- Erro tipo I: probabilidade de rejeitar a hipótese nula quando ela for verdadeira, também denominado *erro alfa* (α).

$$\alpha = P(\text{rejeitar } H_0 / H_0 \text{ verdadeira})$$

- Erro tipo II: probabilidade de não rejeitar a hipótese nula quando ela for falsa, também denominado *erro beta* (β).

$$\beta = P(\text{não rejeitar } H_0 / H_0 \text{ falsa})$$

2.2 Nível de significância (α) e valor-p

O nível de significância α é a probabilidade máxima com a qual se sujeitaria correr o risco de um erro tipo I. Está relacionado ao valor-p (ou *p-value*), obtido com a aplicação do teste estatístico. O valor-p é a probabilidade de se obter uma estatística de teste igual ou maior do que a obtida por meio de dado amostral.

Se o valor-p for menor ou igual ao valor de α estabelecido *a priori*, a hipótese nula H_0 é rejeitada.

O nível de significância é definido pelo pesquisador, sendo os valores mais utilizados iguais a 1% e 5%.

TEMA 3 – TESTES DE HIPÓTESES PARA UMA POPULAÇÃO

Ao realizar o teste de hipóteses quando a variância populacional é desconhecida e se trata de amostras pequenas ($n < 30$), a população de onde a amostra foi retirada deve ser normalmente distribuída. Para amostras grandes ($n \geq 30$), não é necessário observar tal condição, o que é justificado pelo teorema central do limite.

De acordo com o teorema central do limite, à medida que o tamanho da amostra aumenta, independentemente da forma de distribuição da população, a distribuição amostral de médias ($\bar{X}$) aproxima-se da distribuição normal. Para maiores detalhes, consultar Morettin e Bussab (2017).

Existem diferentes testes estatísticos para verificar a normalidade dos dados, entre eles, o teste de *Lilliefors*. Esse teste é utilizado para verificar a aderência dos dados a uma distribuição normal, sem a especificação de seus parâmetros, ou seja, a média e o desvio padrão são calculados com base na amostra. Detalhes sobre o teste podem ser obtidos em Razali e Wah (2011).

3.1 Teste para média populacional

Se a variância populacional σ^2 for desconhecida, a estatística do teste deverá ser calculada por:

$$t = \frac{\bar{X} - \mu_0}{S/\sqrt{n}} \quad (4)$$

Na equação, a distribuição *t* de Student é com $n - 1$ graus de liberdade.

Ainda:

- $\bar{X}$ é a média amostral;
- μ_0 é o valor a ser testado;
- S é o desvio padrão amostral;
- n é o tamanho da amostra.

As hipóteses estatísticas a serem testadas são:

$$H_0: \mu = \mu_0$$

A hipótese H_1 pode assumir diferentes situações:

- $H_1: \mu < \mu_0$ (*Teste unilateral à esquerda*);
- $H_1: \mu > \mu_0$ (*Teste unilateral à direita*);
- $H_1: \mu \neq \mu_0$ (*Teste bilateral*).

A conclusão do teste é feita analisando o valor-p ou *p-value*, conforme apresentado na seção 2.2.

3.2 Teste para proporção populacional

Utiliza-se o teste para a proporção populacional (p) quando se deseja testar a hipótese de que p é supostamente igual a um determinado valor (H_0), e a hipótese H_1 , que vai definir o tipo de teste, assume diferentes situações (unilateral à direita, unilateral à esquerda ou bilateral).

As hipóteses estatísticas a serem testadas são:

$$H_0: p = p_0$$

A hipótese H_1 pode assumir diferentes situações:

- $H_1: p < p_0$ (*Teste unilateral à esquerda*);
- $H_1: p > p_0$ (*Teste unilateral à direita*);
- $H_1: p \neq p_0$ (*Teste bilateral*).

Os critérios a serem obedecidos é que $np \geq 5$ e $n(1 - p) \geq 5$, exigindo assim que a amostra seja grande. Para amostras grandes, a estatística do teste é dada por:

$$Z = \frac{\hat{p} - p_0}{\sqrt{\frac{p_0 \times (1 - p_0)}{n}}} \quad (5)$$

Em que:

- $\hat{p}$ é a proporção amostral;
- p_0 é o valor a ser testado;
- n é o tamanho da amostra.

A conclusão do teste é feita analisando o valor-p ou *p-value*, conforme apresentado na seção 2.2.

TEMA 4 – TESTES DE HIPÓTESES PARA DUAS POPULAÇÕES

Em algumas situações, por exemplo, o consumidor pode desejar testar as hipóteses sobre a diferença entre os tempos médios de vida útil de um produto, considerando duas marcas diferentes, A e B. Ele poderá escolher a marca que apresentar tempo médio de vida útil maior, com base no resultado do teste de hipóteses para a diferença entre duas médias populacionais.

4.1 Teste para a diferença entre duas médias populacionais

Normalmente as variâncias populacionais σ_1^2 e σ_2^2 são desconhecidas e, portanto, devem ser estimadas por meio de amostras. Nesse caso, a aplicação do teste requer que as populações de onde as amostras foram retiradas sejam normalmente distribuídas para amostras pequenas ($n < 30$).

As hipóteses estatísticas a serem testadas são:

$$H_0: \mu_1 - \mu_2 = d_0$$

A hipótese H_1 pode assumir diferentes situações:

- $H_1: \mu_1 - \mu_2 < d_0$ (Teste unilateral à esquerda);
- $H_1: \mu_1 - \mu_2 > d_0$ (Teste unilateral à direita);
- $H_1: \mu_1 - \mu_2 \neq d_0$ (Teste bilateral).

4.1.1 Quando as variâncias populacionais são desconhecidas e supostamente iguais

Para aplicar esse teste, é necessário que as variâncias populacionais desconhecidas sejam iguais. Portanto, deve-se realizar inicialmente o teste de igualdade de duas variâncias, que será tratado mais adiante.

A estatística do teste é dada por:

$$t = \frac{(\bar{X}_1 - \bar{X}_2) - d_0}{\sqrt{S_p^2 \left(\frac{1}{n_1} + \frac{1}{n_2} \right)}} \quad (6)$$

sendo:

$$S_p^2 = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2} \quad (7)$$

Em que:

- $\bar{X}_1$ é a média da amostra 1;
- $\bar{X}_2$ é a média da amostra 2;
- S_1^2 é a variância da amostra 1;
- S_2^2 é a variância da amostra 2;
- n_1 é o tamanho da amostra 1;
- n_2 é o tamanho da amostra 2.

A conclusão do teste é feita analisando o valor-p ou *p-value*, conforme apresentado na seção 2.2.

4.1.2 Quando as variâncias populacionais são desconhecidas e supostamente diferentes

Uma vez realizado o teste de igualdade de duas variâncias e rejeitada a hipótese H_0 , isto é, de que variâncias são iguais, utiliza-se esse teste para testar a diferença entre duas médias populacionais.

A estatística do teste é dada por:

$$t = \frac{(\bar{X}_1 - \bar{X}_2) - d_0}{\sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}}} \quad (8)$$

A determinação da região crítica será com base no valor de **t** da tabela da distribuição **t** de Student, com nível de significância α e graus de liberdade dados pela expressão a seguir:

$$v = \frac{(w_1 + w_2)^2}{\frac{w_1^2}{n_1 - 1} + \frac{w_2^2}{n_2 - 1}} \quad (9)$$

Na equação:

$$w_1 = \frac{S_1^2}{n_1} \quad (10)$$

$$w_2 = \frac{S_2^2}{n_2} \quad (11)$$

Em que:

- $\bar{X}_1$ é a média da amostra 1;
- $\bar{X}_2$ é a média da amostra 2;
- S_1^2 é a variância da amostra 1;
- S_2^2 é a variância da amostra 2;
- n_1 é o tamanho da amostra 1;
- n_2 é o tamanho da amostra 2.

A conclusão do teste é feita analisando o valor-p ou *p-value*, conforme apresentado na seção 2.2.

4.2 Teste para igualdade de duas variâncias populacionais

Para aplicar o teste para a variância é necessário que as populações de onde foram extraídas as amostras sejam normalmente distribuídas.

As hipóteses estatísticas são:

$$H_0: \sigma_1^2 = \sigma_2^2$$

$$H_1: \sigma_1^2 \neq \sigma_2^2$$

A estatística do teste é calculada por:

$$F = \frac{S_1^2}{S_2^2} \quad (12)$$

Em que:

- S_1^2 é a variância da amostra 1;
- S_2^2 é a variância da amostra 2;
- n_1 é o tamanho da amostra 1;
- n_2 é o tamanho da amostra 2.

A conclusão do teste é feita analisando o valor-p ou *p-value*, conforme apresentado na seção 2.2.

TEMA 5 – EXEMPLOS DE APLICAÇÃO

Aplicaremos os diferentes tipos de testes de hipóteses abordados nesta aula. Para a aplicação, será utilizado o conjunto de dados do arquivo *Wages1*, disponível na biblioteca *Ecdat*, no Sistema R.

O arquivo *Wages1* contém 3.294 observações (registros) e as seguintes variáveis:

- *exper*: tempo de experiência (em anos);
- *sex*: gênero (masculino de feminino);
- *school*: anos de estudo;
- *wage*: salário por hora (U\$).

5.1 Teste de hipóteses para média populacional

Inicialmente é necessário instalar a biblioteca *Ecdat*, como segue:

```
install.packages("Ecdat") # instala a biblioteca ECDat
```

Uma vez instalada:

```
library(Ecdat) # ativa a biblioteca Ecdat
data(Wages1)
dados<-Wages1 # cria objeto dados
str(dados)    # mostra o conteúdo do objeto dados
```

O R vai apresentar as variáveis e o tipo de dados da seguinte forma:

```
> str(dados)
'data.frame':  3294 obs. of  4 variables:
 $ exper : int  9 12 11 9 8 9 8 10 12 7 ...
 $ sex   : Factor w/ 2 levels "female","male": 1 1 1 1 1 1 1 1 1 1
 $ school: int  13 12 11 14 14 14 12 12 10 12 ...
 $ wage  : num  6.32 5.48 3.64 4.59 2.42 ...
```

Retira-se uma amostra de salários (em U\$/hora) de 30 pessoas.

```
set.seed(51)
amostra<-sample(dados$wage, 30, replace=F)
amostra<-round(amostra, 2)
```

Em que:

- `set.seed`: pseudonúmero aleatório, possibilitando reproduzir os resultados;
- `sample`: função para selecionar amostra;
- `dados$wage`: variável para retirar amostra;
- 30: tamanho da amostra;
- `replace=F`: sem reposição;
- `round`: função para arredondamento de números;
- 2: número de casas decimais.

```
amostra<-c(3.67,5.31,3.74,8.57,4.11,6.96,6.13,3.22,4.60,7.66,
           6.01,4.70,5.69,4.35,2.84,1.99,4.77,10.31,4.17,1.71,
           4.07,8.35,7.47,3.16,3.27,4.41,0.92,11.13,6.15,1.07)
```

A amostra de salários (em U\$/hora) está apresentada na Tabela 1.

Tabela 1 – Salários de uma amostra de 30 pessoas

Obs.	Salário (U\$/hora)	Obs.	Salário (U\$/hora)	Obs.	Salário (U\$/hora)
1	3,67	11	6,01	21	4,07
2	5,31	12	4,70	22	8,35
3	3,74	13	5,69	23	7,47
4	8,57	14	4,35	24	3,16
5	4,11	15	2,84	25	3,27
6	6,96	16	1,99	26	4,41
7	6,13	17	4,77	27	0,92
8	3,22	18	10,31	28	11,13
9	4,60	19	4,17	29	6,15
10	7,66	20	1,71	30	1,07

Fonte: Sistema R, 2020.

O salário médio por hora e o desvio padrão são respectivamente iguais a U\$ 5,0170 e U\$ 2,5182.

Deseja-se testar as hipóteses a seguir, adotando nível de significância de 5%:

$H_0: \mu = 6,0$ (U\$/hora) Salário médio igual a 6,0 U\$/hora

$H_1: \mu < 6,0$ (U\$/hora) Salário médio menor que 6,0 U\$/hora

Para realizar o teste de hipóteses para a média populacional, deve-se instalar a biblioteca *nortest*.

```
install.packages("nortest") # instala a biblioteca nortest
library(nortest)           # carrega a biblioteca nortest
t.test(amostra, alternative = "less", mu=6)
```

Em que:

- `t.test`: teste *t* de Student;
- `amostra`: variável que contém os dados;
- `alternative=less`: define a hipótese H_1 (neste caso, $\mu < 6,0$);
- `mu=6`: valor a ser testado (hipótese H_0).

Resultado apresentado no R:

```
One Sample t-test
data:  amostra
t = -2.138, df = 29, p-value = 0.02053
alternative hypothesis: true mean is less than 6
```

Analisando, o $p - value = 0,02053$ (valor-p) é menor do que o nível de significância de 5%, logo, rejeita-se a hipótese de que o salário médio populacional é igual a U\$ 6,00/hora, portanto, é possível afirmar que é menor do que U\$ 6,00/hora.

Para verificar a normalidade dos dados por meio do teste de Lilliefors utilizando o Sistema R:

```
library(nortest)           # carrega a biblioteca nortest
lillie.test(amostra)
```

Em que:

- `lillie.test`: teste de *lilliefors*;
- `amostra`: variável que contém os dados.

Tem-se o seguinte resultado:

```
Lilliefors (Kolmogorov-Smirnov) normality test
data:  amostra
D = 0.13907, p-value = 0.146
```

O valor-p ou $p-value$ obtido é igual a 0,1460, maior do que o nível de significância adotado de 5%, portanto, conclui-se que os dados provêm de uma população normal.

5.2 Teste de hipóteses para a proporção populacional

Retira-se uma amostra de 200 pessoas do arquivo “Wages1” para analisar a proporção de pessoas segundo gênero.

```
set.seed(51)          # pseudo número aleatório
amostra_genero<-matrix(sample(dados$sex,200,replace=F) )
amostra_genero[amostra_genero=="male"]<-"M"
amostra_genero[amostra_genero=="female"]<-"F"
```

Em que:

- set.seed: pseudo número aleatório, possibilitando reproduzir os resultados;
- matrix: gera uma matriz com dados amostrados.

As frequências segundo gênero:

```
tabela<- table(amostra_genero)
```

Para visualizar a tabela de frequências, basta digitar:

```
tabela
```

O resultado será:

```
> tabela
  F   M
115  85
```

Tem-se, na amostra, 57,5% de pessoas do gênero feminino e 42,5% do gênero masculino.

Deseja-se testar as hipóteses a seguir, adotando-se nível de significância de 5% com relação à proporção de pessoas do gênero feminino.

- $H_0: p = 0,50$ (proporção de pessoas do gênero feminino é igual a 0,50);
- $H_1: p > 0,50$ (proporção de pessoas do gênero feminino é maior do que 0,50).

A estimativa da proporção amostral será obtida fazendo-se:

$$\hat{p} = \frac{\text{no. de pessoas do gênero feminino}}{\text{total de pessoas na amostra}} = \frac{115}{200} = 0,575$$

A estatística do teste é calculada por meio de:

$$Z = \frac{\hat{p} - p_0}{\sqrt{\frac{p_0 \times (1 - p_0)}{n}}}$$

Utilizando o Sistema R para realizar o teste:

```

Z<-(0.575-0.50)/(sqrt((0.50*(1-0.50))/200))
Z
> Z
[1] 2.12132
valor_p<-(pnorm(Z,lower.tail=F))
valor_p
> valor_p
[1] 0.01694743

```

O valor-p é igual a 0,017, menor do que o nível de significância adotado de 5%, portanto, rejeita-se a hipótese H_0 e conclui-se que a proporção de pessoas do gênero feminino na população é maior do que 0,50 (50%).

5.3 Teste para diferença entre duas médias populacionais

Serão obtidas duas amostras com 30 observações e as variáveis *wage* (salário por hora) e *sex* (gênero), com base no arquivo “*Wages1*”. A primeira amostra será composta por pessoas do gênero feminino, e a segunda, por pessoas do gênero masculino.

```
install.packages("Ecdat") # instala a biblioteca Ecdat
```

Uma vez instalada, deve-se ativar a biblioteca:

```

library(Ecdat) # carrega a biblioteca Ecdat
data(Wages1)
dados<-Wages1 # cria objeto dados

```

Separando as pessoas do gênero masculino e feminino:

```

install.packages("dplyr") # instala a biblioteca DPLYR
library(dplyr) # ativa a biblioteca dplyr
dadosF<-filter(dados, dados$sex=="female") # arquivo com pessoas
                                             # do gênero feminino
dadosM<-filter(dados, dados$sex=="male")   # arquivo com pessoas

```

do gênero masculino

Retirando amostra de salários das pessoas do gênero feminino:

```
set.seed(51)
amostraF<-sample(dadosF$wage,30,replace=F)
amostraF<-round(amostraF,2)
amostraF
> amostraF
[1] 3.77 5.14 8.10 2.24 3.71 8.64 3.83 5.51 6.12 6.91
5.05 4.27
[13] 7.96 5.19 3.27 3.28 3.51 11.45 5.67 1.98 5.86 8.70
8.77 5.82
[25] 3.95 6.85 3.69 5.34 0.93 4.64
```

Calculando o salário médio das pessoas do gênero feminino:

```
média_sal_F<-mean(amostraF)
média_sal_F
> média_sal_F
[1] 5.338333
```

Retirando amostra de salários das pessoas do gênero masculino:

```
set.seed(40)
amostraM<-sample(dadosM$wage,30,replace=F)
amostraM<-round(amostraM,2)
amostraM
[1] 5.51 3.70 10.43 5.71 5.39 6.60 1.85 0.82 8.52 5.70
5.94 5.51
[13] 7.26 10.11 3.34 7.40 2.76 3.63 7.96 6.68 8.71 5.24
7.04 7.04
[25] 5.86 6.65 5.21 5.55 9.97 3.94
```

Calculando o salário médio das pessoas do gênero masculino:

```
média_sal_M<-mean(amostraM)
média_sal_M
> média_sal_M
[1] 6.001
```

A Tabela 2 apresenta os salários (US\$/hora) de 60 pessoas segundo gênero.

Tabela 2 – Salários de 60 pessoas segundo gênero

Feminino				Masculino			
Obs.	Salário (US\$/hora)	Obs.	Salário (US\$/hora)	Obs.	Salário (US\$/hora)	Obs.	Salário (US\$/hora)
1	3,77	16	3,28	1	5,51	16	7,40
2	5,14	17	3,51	2	3,70	17	2,76
3	8,10	18	11,45	3	10,43	18	3,63
4	2,24	19	5,67	4	5,71	19	7,96
5	3,71	20	1,98	5	5,39	20	6,68
6	8,64	21	5,86	6	6,60	21	8,71
7	3,83	22	8,70	7	1,85	22	5,24
8	5,51	23	8,77	8	0,82	23	7,04
9	6,12	24	5,82	9	8,52	24	7,04
10	6,91	25	3,95	10	5,70	25	5,86
11	5,05	26	6,85	11	5,94	26	6,65
12	4,27	27	3,69	12	5,51	27	5,21
13	7,96	28	5,34	13	7,26	28	5,55
14	5,19	29	0,93	14	10,11	29	9,97
15	3,27	30	4,64	15	3,34	30	3,94

Fonte: Sistema R, 2020.

Define-se os salários médios da seguinte forma:

- μ_A : salário médio das pessoas do gênero masculino;
- μ_B : salário médio das pessoas do gênero feminino.

Considerando nível de significância de 5%, deseja-se testar as hipóteses a seguir:

- $H_0: \mu_A = \mu_B$ (os salários médios são iguais);
- $H_1: \mu_A > \mu_B$ (o salário médio das pessoas do gênero masculino é maior do que o salário das pessoas do gênero feminino).

É necessário verificar inicialmente se as populações de onde as amostras foram retiradas são normalmente distribuídas, entretanto, para esse caso, pelo fato de o tamanho das amostras ser igual a 30, consideradas grandes amostras, não é necessário. Deve-se verificar se as variâncias populacionais desconhecidas são iguais ou diferentes. Para isso, realiza-se o teste de igualdade de duas variâncias, com as seguintes hipóteses:

$$H_0: \sigma_1^2 = \sigma_2^2$$

$$H_0: \sigma_1^2 \neq \sigma_2^2$$

Utilizando o *software* R:

```
var.test(amostraF, amostraM, alternative = "two.sided")
```

Em que:

- `var.test`: teste para variâncias;
- `amostraF` e `amostraM`: variáveis a serem testadas;
- `alternative = "two.sided"`: teste bilateral.

Tem-se o seguinte resultado:

```
F = 1.0116, num df = 29, denom df = 29, p-value = 0.9754  
alternative hypothesis: true ratio of variances is not equal to 1
```

O *p-value* é igual a 0,9754, superior ao nível de significância de 5%, portanto, conclui-se que as variâncias populacionais são iguais.

Aplicando o teste de hipóteses para a diferença entre duas médias populacionais, com variâncias populacionais desconhecidas e supostamente iguais:

```
t.test(amostraM, amostraF, var.equal=TRUE, alternative="greater")
```

Em que:

- `amostraM`: variável de interesse para o teste;
- `amostraF`: variável de interesse para o teste;
- `var.equal`: igualdade das variâncias. Ao escolher a opção *TRUE*, assume que as variâncias populacionais são iguais;
- *alternative*: hipótese alternativa (H_1). A opção *greater* é para teste unilateral à direita.

Resultado apresentado no R:

```
Two Sample t-test  
data: amostraM and amostraF  
t = 1.1034, df = 58, p-value = 0.1372
```

O *p-value* é igual a 0,1372, superior ao nível de significância de 5%, portanto, conclui-se que os salários médios (U\$/horas) dos gêneros masculino e feminino são iguais.

REFERÊNCIAS

GUPTA, B. C; GUTTMAN, I. **Estatística e probabilidade com aplicações para engenheiros e cientistas**. Rio de Janeiro: LTC, 2017.

MORETTIN, P. A.; BUSSAB, W. O. **Estatística básica**. 5. ed. São Paulo: Saraiva, 2017.

SISTEMA R. **Biblioteca Ecdat**. Disponível em: <<https://vincentarelbundock.github.io/Rdatasets/datasets.html>>. Acesso em: 21 jan. 2021.

SISTEMA R. Disponível em: <<http://cran.r-project.org>>. Acesso em: 21 jan. 2021.

SWANI, L; TYAGI, P. Predictive modelling anatytics through data mining. **International research journal of engineering and technology (IRJET)**, v. 4, n.9, set. 2017.

RAZALI, N. M.; WAH, Y. B. Power comparisons of Shapiro-Wilk, Kolmogorov-Smirnov, Lilliefors and Anderson-Darling tests. **Journal of Statistical Modeling and Analytics**, v. 2. n. 1, p. 21-33, 2011.