

Aula 2

Análise Preditiva

Profª Sachiko A. Lira

Distribuição normal

- A função densidade de probabilidade de uma variável aleatória contínua X , que segue distribuição normal é dada por:

- $f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}$ (1)

- Em que: $x \in R$, $\mu \in R$, $\sigma \in R^+$

- Os parâmetros da distribuição são:


- Média: $E(X) = \mu$ (2)

- Variância: $V(X) = \sigma^2$ (3)

- A notação $X \sim N(\mu, \sigma^2)$ é muito usada para denotar que a distribuição da variável aleatória X é normal com parâmetros μ e σ^2

- O gráfico da distribuição normal tem aspecto típico, que é a curva em forma de sino
- A curva é simétrica em torno da média μ , e tem-se que os valores da média, da mediana e da moda são iguais
- A área total sob a curva é igual a 1, ou seja, $\int_{-\infty}^{\infty} f(x)dx = 1$

Distribuição normal




Fonte: Elaborado com base em Gupta e Guttman, 2017

Testes de hipóteses

- Os testes de hipóteses são procedimentos para a tomada de decisão, em relação a uma afirmação sobre um parâmetro populacional. A afirmação sobre os parâmetros é chamada de *hipótese estatística*
- Hipóteses estatísticas:
 - Hipótese nula: H_0
 - Hipótese alternativa: H_1

- Genericamente, há:
 - Teste unilateral à esquerda:**
 - $H_0: T = T_0$, $H_1: T < T_0$
 - Teste unilateral à direita:**
 - $H_0: T = T_0$, $H_1: T > T_0$
 - Teste bilateral:**
 - $H_0: T = T_0$, $H_1: T \neq T_0$

Região de rejeição (RR) da hipótese H_0



Fonte: Elaborado com base em Gupta e Guttman, 2017

- Erro estatístico**
 - Na realização de testes estatísticos é possível cometer dois tipos de erros
 - Erro tipo I: erro alfa (α)**
 - $\alpha = P(\text{rejeitar } H_0 / H_0 \text{ verdadeira})$
 - Erro tipo II: erro beta (β)**
 - $\beta = P(\text{não rejeitar } H_0 / H_0 \text{ falsa})$

- Nível de significância (α) e valor-p**
 - O nível de significância α é a probabilidade máxima com a qual se sujeitaria a correr o risco de um erro tipo I. Está relacionado ao valor-p (ou *p-value*), obtido com a aplicação do teste estatístico
 - O nível de significância é definido pelo pesquisador, sendo os valores mais utilizados iguais a 1% e 5%

Testes de hipóteses para uma população

Teste para a média populacional

- Se a variância populacional σ^2 for desconhecida, a estatística do teste deverá ser calculada por:

$$t = \frac{\bar{X} - \mu_0}{S/\sqrt{n}} \quad (4)$$

- Sendo a distribuição t de Student com n-1 graus de liberdade

Hipóteses estatísticas a serem testadas:

- $H_0: \mu = \mu_0$
- $H_1: \mu < \mu_0$ (Teste unilateral à esquerda)
- $H_1: \mu > \mu_0$ (Teste unilateral à direita)
- $H_1: \mu \neq \mu_0$ (Teste bilateral)

Teste para a proporção populacional

- Utiliza-se o teste para a proporção populacional (p) quando se deseja testar a hipótese de que p é supostamente igual a determinado valor (H_0) e a hipótese H_1 poderá assumir diferentes situações
- A estatística do teste é dada por:

$$Z = \frac{\hat{p} - p_0}{\sqrt{\frac{p_0 \times (1 - p_0)}{n}}} \quad (5)$$

- $H_0: p = p_0$
- $H_1: p < p_0$ (Teste unilateral à esquerda)
- $H_1: p > p_0$ (Teste unilateral à direita)
- $H_1: p \neq p_0$ (Teste bilateral)

Testes de hipóteses para duas populações

Teste para a diferença entre duas médias populacionais

■ Hipóteses estatísticas a serem testadas:

- $H_0: \mu_1 - \mu_2 = d_0$
- ✓ $H_1: \mu_1 - \mu_2 < d_0$ (Teste unilateral à esquerda)
- ✓ $H_1: \mu_1 - \mu_2 > d_0$ (Teste unilateral à direita)
- ✓ $H_1: \mu_1 - \mu_2 \neq d_0$ (Teste bilateral)

■ Quando as variâncias populacionais são desconhecidas e supostamente iguais

• A estatística do teste é dada por:

$$t = \frac{(\bar{X}_1 - \bar{X}_2) - d_0}{\sqrt{S_p^2 \left(\frac{1}{n_1} + \frac{1}{n_2} \right)}} \quad (6)$$

$$\text{Sendo: } S_p^2 = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2} \quad (7)$$

■ Quando as variâncias populacionais são desconhecidas e supostamente diferentes

• A estatística do teste é dada por:

$$t = \frac{(\bar{X}_1 - \bar{X}_2) - d_0}{\sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}}} \quad (8)$$

■ O número de graus de liberdade é dado por:

$$v = \frac{(w_1 + w_2)^2}{\frac{w_1^2}{n_1 - 1} + \frac{w_2^2}{n_2 - 1}} \quad (9)$$

■ Sendo:

$$w_1 = \frac{S_1^2}{n_1} \quad (10)$$

$$w_2 = \frac{S_2^2}{n_2} \quad (11)$$

Teste para igualdade de duas variâncias populacionais

■ As hipóteses estatísticas são:

- $H_0: \sigma_1^2 = \sigma_2^2$
- $H_1: \sigma_1^2 \neq \sigma_2^2$

■ A estatística do teste é calculada por:

$$F = \frac{S_1^2}{S_2^2} \quad (12)$$

Exemplos de aplicação

- Para os exemplos de aplicação, será utilizado o conjunto de dados do arquivo Wages1, disponível na biblioteca Ecdat, no Sistema R

- O arquivo Wages1 contém 3.294 observações (registros) e as seguintes variáveis:
 - exper: tempo de experiência (em anos)
 - sex: gênero (masculino e feminino)
 - school: anos de estudo
 - wage: salário por hora (U\$)

Salários de uma amostra de 30 pessoas

Obs.	Salário (U\$/hora)	Obs.	Salário (U\$/hora)	Obs.	Salário (U\$/hora)
1	3,67	11	6,01	21	4,07
2	5,31	12	4,7	22	8,35
3	3,74	13	5,69	23	7,47
4	8,57	14	4,35	24	3,16
5	4,11	15	2,84	25	3,27
6	6,96	16	1,99	26	4,41
7	6,13	17	4,77	27	0,92
8	3,22	18	10,31	28	11,13
9	4,6	19	4,17	29	6,15
10	7,66	20	1,71	30	1,07

Fonte: Elaborada com base nos dados disponíveis na biblioteca Ecdat, Sistema R, 2020

- 1. Teste para a média populacional
 - Tem-se: $\bar{X} = U\$ 5,0170$; $S = U\$ 2,5182$
 - Adotar nível de significância de 5%
 - $H_0: \mu = 6,0$ (U\$/hora)
 - $H_1: \mu < 6,0$ (U\$/hora)
 - Resultado apresentado no R:
 - One Sample t-test
 - data: amostra
 - $t = -2.138$, $df = 29$, $p\text{-value} = 0.02053$

- 2. Teste para proporção populacional
 - Retira-se uma amostra de 200 pessoas do arquivo Wages1, para analisar a proporção de pessoas segundo gênero
 - Tem-se os seguintes resultados:
 - amostra_genero
 - F M
 - 115 85
 - $\hat{p} = 0,575$ (proporção de pessoas do gênero feminino)

- Adotar nível de significância de 5%
 - $H_0: p = 0,50$
 - $H_1: p > 0,50$
- Resultado do R:
 - >Z # estatística do teste
 - [1] 2,1213
 - > valor_p
 - [1] 0,0169

- 3. Teste para diferença entre duas médias populacionais
 - Serão obtidas duas amostras com trinta observações e as variáveis *wage* (salário por hora) e *sex* (gênero), com base no arquivo *Wages1*. A primeira amostra será composta por pessoas do gênero feminino e a segunda, por pessoas do gênero masculino

Salários de 60 pessoas segundo gênero

Feminino				Masculino			
Obs.	Salário (U\$/hora)	Obs.	Salário (U\$/hora)	Obs.	Salário (U\$/hora)	Obs.	Salário (U\$/hora)
1	3,77	16	3,28	1	5,51	16	7,40
2	5,14	17	3,51	2	3,70	17	2,76
3	8,10	18	11,45	3	10,43	18	3,63
4	2,24	19	5,67	4	5,71	19	7,96
5	3,71	20	1,98	5	5,39	20	6,68
6	8,64	21	5,86	6	6,60	21	8,71
7	3,83	22	8,70	7	1,85	22	5,24
8	5,51	23	8,77	8	0,82	23	7,04
9	6,12	24	5,82	9	8,52	24	7,04
10	6,91	25	3,95	10	5,70	25	5,86
11	5,05	26	6,85	11	5,94	26	6,65
12	4,27	27	3,69	12	5,51	27	5,21
13	7,96	28	5,34	13	7,26	28	5,55
14	5,19	29	0,93	14	10,11	29	9,97
15	3,27	30	4,64	15	3,34	30	3,94

Fonte: Elaborada com base nos dados disponíveis na biblioteca *Ecdat*, Sistema R, 2020

- Com base nas amostras, são obtidos os seguintes salários (U\$/hora) médios:
 - $\bar{X}_A = 6,001$ (salário médio das pessoas do gênero masculino)
 - $\bar{X}_B = 5,338$ (salário médio das pessoas do gênero feminino)

- Considerando nível de significância de 5%, deseja-se testar as hipóteses a seguir:
 - $H_0: \mu_A = \mu_B$ (os salários médios são iguais)
 - $H_1: \mu_A > \mu_B$ (o salário médio das pessoas do gênero masculino é maior do que o salário médio das pessoas do gênero feminino)

- Realiza-se inicialmente o teste para igualdade de variâncias:
 - $F = 1.0116$, num $df = 29$, denom $df = 29$, $p\text{-value} = 0.9754$
- Para o teste de médias, tem-se o seguinte resultado do R:
 - $t = 1.1034$, $df = 58$, $p\text{-value} = 0.1372$