

| ANÁLISE PREDITIVA

TEMA 1 – ANÁLISE DE CORRELAÇÃO LINEAR SIMPLES

A análise de regressão é uma das técnicas para conduzir a análise preditiva. Uma etapa anterior à aplicação das técnicas de análise de regressão é saber como as variáveis envolvidas estão associadas, o que é possível avaliar por meio da análise de correlação.

1.1 Análise de correlação linear simples

O coeficiente de correlação linear simples mostra o grau de associação entre as variáveis. Não há a necessidade de definir as relações de causa e efeito, ou seja, qual é a variável dependente e a independente.

Existem diferentes tipos de correlação, sendo que, quando para maiores valores da variável X existir uma tendência de obter maiores valores da variável Y, tem-se uma correlação linear positiva. E, quando ocorrer o inverso, ou seja, para maiores valores da variável X existir uma tendência de obter menores valores da variável Y, tem-se uma correlação linear negativa. Obviamente, existem casos em que as variáveis X e Y não são correlacionadas linearmente; nesse caso, a correlação linear é nula.

O coeficiente de correlação linear de Pearson amostral é obtido por meio da expressão:

$$r = \frac{\sum_{i=1}^n (x_i - \bar{X})(y_i - \bar{Y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{X})^2 (y_i - \bar{Y})^2}} \quad (1)$$

Em que:

- **n** é o número de observações das variáveis X e Y.

A correlação é linear perfeita positiva quando $r = 1$ e linear perfeita negativa quando $r = -1$. Quando se tem $r = 0$, não existe correlação linear entre as variáveis X e Y.

De acordo com Callegari-Jacques (2003), o coeficiente de correlação pode ser avaliado qualitativamente de acordo com os critérios a seguir:

- $0 < |r| < 0,30$ existe fraca correlação linear;
- $0,30 \leq |r| < 0,60$ existe moderada correlação linear;
- $0,60 \leq |r| < 0,90$ existe forte correlação linear;

- $0,90 \leq |r| < 1,00$ existe correlação linear muito forte.

TEMA 2 – ANÁLISE DE REGRESSÃO LINEAR SIMPLES

Análise de regressão linear simples é uma técnica para analisar a relação entre uma variável dependente Y e uma variável independente X .

O objetivo dessa técnica é identificar uma função que descreve, o mais próximo possível, a relação entre essas variáveis e assim poder predizer o valor que a variável dependente Y vai assumir para um determinado valor da variável independente X .

O modelo de regressão poderá ser expresso como:

$$Y = \beta_0 + \beta_1 X + \varepsilon \quad (2)$$

Em que:

- Y é a variável resposta (dependente);
- β_0 e β_1 são os parâmetros desconhecidos, chamados de *coeficientes de regressão*, sendo que β_0 é o intercepto (coeficiente linear) e β_1 é a inclinação da reta (coeficiente angular);
- X é a variável preditora (independente);
- ε é o erro aleatório.

Qualquer inferência sobre β_0 e β_1 , por exemplo, a construção de intervalos de confiança e/ou teste de hipóteses, supõe que os erros aleatórios (ε_i) sejam $N(0, \sigma^2)$.

2.1 Estimação dos parâmetros

Uma vez escolhido o modelo de regressão, deve-se estimar os seus parâmetros, nesse caso, os coeficientes β_0 e β_1 . Os estimadores de β_0 e β_1 podem ser obtidos pelo Método dos Mínimos Quadrados. Os detalhes para a obtenção dos estimadores de β_0 e β_1 se encontram em Gupta e Guttman (2017).

Os parâmetros β_0 e β_1 são estimados por intermédio dos estimadores b_0 e b_1 , respectivamente. Tem-se:

$$b_0 = \bar{Y} - b_1 \bar{X} \quad (3)$$

$$b_1 = \frac{\sum_{i=1}^n (x_i - \bar{X}) y_i}{\sum_{i=1}^n (x_i - \bar{X})^2}$$

Em que: (4)

- n é o número de observações das variáveis X e Y . (5)

Assim, o modelo ajustado será: $\hat{Y} = b_0 + b_1X$

2.2 Teste de hipóteses na regressão

Uma etapa importante da verificação da adequação do modelo de regressão linear é a realização de um teste estatístico de hipóteses em relação aos parâmetros do modelo. O método da análise da variância pode ser usado para testar a significância da regressão.

As hipóteses para testar a significância da regressão são:

$$H_0: \beta_1 = 0$$

$$H_1: \beta_1 \neq 0$$

A não rejeição da hipótese H_0 equivale a concluir que não há relação linear entre X e Y . No entanto, a rejeição da hipótese H_0 levará à conclusão de que X é importante para explicar as variações em Y .

A análise da variância, conhecida como ANOVA, é um teste que permite verificar a significância da regressão, ou seja, se existe relação entre a variável dependente e independente, por meio do comportamento das variações total, explicada e residual. Esse teste é resumido no quadro da ANOVA. Detalhes podem ser obtidos em Fonseca, Martins e Toledo (2010).

2.3 Coeficiente de determinação ou explicação

A medida que indica a qualidade do ajuste é o coeficiente de determinação ou explicação (R^2). Essa medida mostra o quanto das variações (em %) da variável Y é explicado pelo modelo ajustado. Quanto mais próximo de 100%, melhor é o ajuste do modelo.

$$R^2 = \frac{SQE}{SQT} \times 100 \quad (6)$$

Em que:

- $SQT = \sum_{i=1}^n (y_i - \bar{Y})^2$ (soma de quadrados total); (7)

- $SQE = (b_1)^2 \sum_{i=1}^n (x_i - \bar{X})^2$ (soma de quadrados devido à regressão). (8)

2.3.1 Coeficiente de determinação ajustado

Muitos *softwares* estatísticos e planilhas eletrônicas calculam também o coeficiente de determinação ajustado ($R^2_{ajustado}$), que considera o número de observações e o número de parâmetros estimados.

$$R^2_{ajustado} = 1 - \frac{(n-1)}{(n-k)} \times (1 - R^2) \quad (9)$$

Em que:

- n é o número de observações;
- k é o número de parâmetros estimados.

2.4 Análise dos resíduos

A suposição do modelo é de que os erros ε_i sejam normais, isto é, $\varepsilon_i \sim N(0, \sigma^2)$. A verificação da suposição pode ser por meio da análise gráfica, consistindo nas seguintes etapas (Gupta; Guttman, 2017).

- a. Identificação de valores atípicos (*outliers*): a identificação de valores atípicos faz parte da análise descritiva e exploratória dos dados. Procedimentos usuais que auxiliam na análise descritiva e exploratória são o diagrama de caixa ou *Boxplot*.
- b. Verificação da independência (erros não correlacionados): a independência dos resíduos (erros) é normalmente avaliada por meio de um gráfico dos resíduos de acordo com a ordem de coleta dos dados. Na hipótese de ser satisfeita a suposição de independência, não deverá existir nenhum padrão nesse gráfico, ou seja, nenhum comportamento não aleatório dos resíduos.
- c. Verificação da normalidade dos erros: a suposição de normalidade dos resíduos (erros) pode ser verificada utilizando-se de gráfico de probabilidade normal.
- d. Verificação da homogeneidade das variâncias dos erros: a verificação dessa suposição pode ser feita por meio de análise gráfica dos valores preditos (ajustados) *versus* os resíduos (erros).

2.5 Intervalo de previsão para um valor individual de Y

Um dos objetivos do ajuste do modelo de regressão é fazer as projeções ou predições. Por meio do modelo ajustado é possível obter a projeção pontual, porém, é interessante conhecer o intervalo de previsão para um valor individual de Y (y_0), dado (x_0), com nível de confiança $(1 - \alpha)\%$, que pode ser obtido por intermédio de:

$$P[\hat{y}_0 - A \leq y_0 \leq \hat{y}_0 + A] = 1 - \alpha \quad (10)$$

sendo:

$$A = t_{\alpha/2; (n-2)} \times S \sqrt{1 + \frac{1}{n} + \frac{(x_0 - \bar{X})^2}{\sum_{i=1}^n (x_i - \bar{X})^2}} \quad (11)$$

Em que:

- $\hat{y}_0$ é a estimativa pontual, obtida por meio do modelo ajustado;
- $t_{\alpha/2; (n-2)}$ é o valor da distribuição **t** de Student, para nível de significância α e $v = n - 2$ graus de liberdade;
- S é o erro padrão do resíduo;
- x_0 é o valor assumido pela variável independente X, para o qual se deseja fazer a projeção.

Detalhes sobre análise de regressão linear simples podem ser obtidos em Fonseca, Martins e Toledo (2010).

TEMA 3 – FUNÇÃO EXPONENCIAL


O relacionamento entre duas variáveis X e Y nem sempre é linear. Existem funções que não são lineares, porém, é possível torná-la uma função linear por meio de uma transformação logarítmica.

A função exponencial é da forma:

$$Y = \alpha \beta^X \quad (12)$$

Tem-se um exemplo da função exponencial, apresentada no Gráfico 1.

Gráfico 1 – Função exponencial $\beta > 1$



Fazendo a transformação logarítmica, tem-se:

$$\ln Y = \ln \alpha + (\ln \beta)X \quad (13)$$

ou

$$Z = A + BX \quad (14)$$

Em que:

- $\ln Y = Z$;
- $\ln \alpha = A$;
- $\ln \beta = B$.

Assim, reduz-se o problema de ajuste de uma reta às variáveis X e Z , sendo $Z = \ln Y$. Os parâmetros A e B são estimados por meio dos dados amostrais.

Os valores de $\hat{A}$ e $\hat{B}$ serão obtidos por meio das seguintes equações:

$$\hat{A} = \bar{Z} - \hat{B}\bar{X} \quad (15)$$

$$\hat{B} = \frac{\sum_{i=1}^n (x_i - \bar{X})z_i}{\sum_{i=1}^n (x_i - \bar{X})^2} \quad (16)$$

Assim, a reta estimada é:

$$\hat{Z} = \hat{A} + \hat{B}X \quad (17)$$

Para obter a estimativa do modelo na sua forma original, faz-se a transformação inversa dos coeficientes $\hat{A}$ e $\hat{B}$. Tem-se, então:

$$\begin{aligned}\hat{A} &= \ln \hat{\alpha}, \text{ logo, } \hat{\alpha} = e^{\hat{A}} \\ \hat{B} &= \ln \hat{\beta}, \text{ logo, } \hat{\beta} = e^{\hat{B}}\end{aligned}\tag{18}$$

O modelo ajustado na forma exponencial é: $\hat{Y} = \hat{\alpha}\hat{\beta}^X$.

Os procedimentos para a realização análise da variância, bem como do cálculo do coeficiente de determinação, são os mesmos dos adotados para regressão linear simples.

TEMA 4 – FUNÇÃO POTÊNCIA


A função potência ou curva geométrica não é uma função linear, porém, por meio de uma transformação logarítmica é possível torná-la uma função linear.

A função potência é dada pela expressão:

$$Y = \alpha X^\beta\tag{19}$$

O Gráfico 2, a seguir, apresenta um exemplo da função potência.

Gráfico 2 – Função potência $0 < \beta < 1$



Fonte: a autora.

Fazendo a transformação logarítmica, tem-se:

$$\ln Y = \ln \alpha + \beta \ln X\tag{20}$$

ou

$$Z = A + \beta T\tag{21}$$

Em que:

- $\ln Y = Z$;
- $\ln \alpha = A$;
- $\ln X = T$.

Assim, reduz-se o problema de ajuste de uma reta às variáveis T e Z, sendo $Z = \ln Y$ e $T = \ln X$. Os parâmetros A e β são estimados por meio dos dados amostrais; a reta estimada será da forma:

$$\hat{Z} = \hat{A} + \hat{\beta}T \quad (22)$$

Os valores de $\hat{A}$ e $\hat{\beta}$ serão obtidos por meio das equações apresentadas a seguir:

$$\hat{A} = \bar{Z} - \hat{\beta}\bar{T} \quad (23)$$

$$\hat{\beta} = \frac{\sum_{i=1}^n (t_i - \bar{T})z_i}{\sum_{i=1}^n (t_i - \bar{T})^2} \quad (24)$$

Para obter a estimativa do modelo na forma da função potência, faz-se a transformação inversa do coeficiente $\hat{A}$. Tem-se, então, $\hat{A} = \ln \hat{\alpha}$, logo: $\hat{\alpha} = e^{\hat{A}}$.

O modelo ajustado na forma da função potência é:

$$\hat{Y} = \hat{\alpha}X^{\hat{\beta}} \quad (25)$$

Outros modelos de regressão, tais como regressão logística, linear múltipla e ajustamento polinomial, podem ser obtidos em Fonseca, Martins e Toledo (2010) e Montgomery e Runger (2009).

TEMA 5 – EXEMPLOS DE APLICAÇÃO

Será utilizado o banco de dados “*Credit*”, disponível na biblioteca *ISLR*, do Sistema R. É um conjunto de dados simulados, contendo o saldo do cartão de crédito de clientes. O banco de dados contém 400 observações e as seguintes variáveis:

- ID: identificação (1 a 400);
- income: renda em U\$ 10.000;
- limit: limite de crédito em U\$;
- rating: classificação de crédito;
- cards: número de cartões de crédito;

- age: idade em anos;
- education: número de anos de estudo;
- gender: gênero (Masculino e Feminino);
- student: indica se o indivíduo era aluno (Não e Sim);
- married: indica se o indivíduo era casado (Não e Sim);
- ethnicity: indica a etnia do indivíduo (afro-americanos, asiáticos e caucasianos);
- balance: saldo médio do cartão de crédito em U\$.

Deve-se inicialmente instalar e ativar a biblioteca *ISLR* para ter acesso ao arquivo de dados “*Credit*”:

```
install.packages("ISLR")
library(ISLR)
data(Credit)
dados<-Credit
```

Foi retirada uma amostra de 30 clientes considerando as variáveis *income* (renda em US \$ 10.000) e *limit* (limite de crédito).

```
set.seed(1)
amostra<-dados[sample(nrow(dados), 30), ]
amostra
```

Em que:

- `set.seed`: pseudonúmero aleatório, possibilitando reproduzir os resultados;
- `sample`: função para selecionar amostra.

Criando as variáveis X e Y:

```
X<-amostra$Income
Y<-amostra$Limit
```

A Tabela 1 apresenta a renda e o limite de crédito de uma amostra de 30 clientes.


Tabela 1 – Renda e limite de crédito de uma amostra de 30 clientes

Obs.	X (Renda U\$ 10.000)	Y (Limite de crédito U\$)	Obs.	X (Renda U\$ 10.000)	Y (Limite de crédito U\$)
1	16,819	1.337	16	124,290	9.560
2	15,184	2.420	17	163,329	8.732
3	66,989	5.614	18	53,308	2.860
4	53,566	5.891	19	19,529	4.673
5	15,354	2.101	20	65,896	5.140
6	12,068	3.873	21	180,682	11.966
7	19,782	3.782	22	83,948	7.100
8	33,657	6.196	23	73,327	6.555
9	19,588	3.211	24	44,646	4.431
10	10,742	1.757	25	21,153	3.736
11	27,369	3.449	26	17,392	2.748
12	27,847	5.619	27	80,180	8.047
13	88,830	4.952	28	103,893	7.416
14	37,728	2.525	29	182,728	13.913
15	55,054	4.381	30	26,427	5.533

Fonte: Sistema R, 2020.

O diagrama de dispersão (Gráfico 3) indica que há uma correlação positiva, isto é, um aumento na renda implica um aumento no limite de crédito.

Gráfico 3 – Diagrama de dispersão



Fonte: com base em Sistema R, 2020.

```
plot(X,Y,ylab="Limite de crédito (U$)",xlab="Renda (U$ 10.000)",
pch=16,
ylim=c(0,15000), main="DIAGRAMA DE DISPERSÃO",cex.main=0.9)
```

A análise do diagrama de dispersão mostra que há uma correlação linear positiva. Sendo assim, será ajustado inicialmente um modelo de regressão linear.

Ajustando o modelo de regressão linear simples:

```
modelo<-lm(Y ~ X)
summary(modelo)
```

A estimativa dos coeficientes do modelo ajustado são:

```
> summary(modelo)
lm(formula = Y ~ X)
Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) 2226.733    365.537   6.092 1.43e-06 ***
X           53.245      4.814  11.060 9.95e-12 ***
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1


Residual standard error: 1291 on 28 degrees of freedom
Multiple R-squared:  0.8137,    Adjusted R-squared:  0.8071
F-statistic: 122.3 on 1 and 28 DF,  p-value: 9.948e-12
```

Ou seja, o modelo ajustado é:

$$\hat{Y} = 2.226,733 + 53,245X$$

A estatística $F = 122,30$, cujo valor-p ou *p-value* é igual a $9,948 \cdot 10^{-12}$, é muito inferior ao nível de significância normalmente adotado de 5%, portanto, rejeita-se a hipótese H_0 e conclui-se que a regressão linear de Y sobre X é significativa. O Gráfico 4 apresenta os valores observados e ajustados do limite de crédito.

Gráfico 4 – Valores observados e ajustados



Fonte: com base em Sistema R, 2020.

O coeficiente de explicação ajustado do modelo é $R^2 = 0,8071 \cdot 100 = 80,71\%$. Isso quer dizer que o modelo ajustado explica 80,71% das variações ocorridas na variável dependente Y.

Para a construção do gráfico no R, tem-se:

```
plot(X,Y,
main="GRÁFICO DE VALORES OBSERVADOS E AJUSTADOS",cex.main=0.8,
type = "p",pch=16,xlab="Renda (U$ 10.000)",
ylab="Limite de crédito (U$)",xlim=c(0,200),ylim=c(500,15000))
abline(modelo, col=2, lty=2, lwd=2)
legend("top", legend=c("valores observados", "valores ajustados"),
lty=c(NA,2), col=c(1,2), lwd=1:2, bty="n", pch=c(16,NA))
```

Caso se deseje usar o modelo ajustado para fazer projeção para um valor de Y, por exemplo, quando o valor de X é igual a U\$ 200, tem-se o valor pontual e o intervalo de previsão, adotando nível de confiança de $(1 - 0,05)\%$, ou seja, nível de confiança de 95%.

```
fit      lwr      upr
12875.76 9845.341 15906.18
```

A projeção pontual é $\hat{y} = U\$ 12.875,76$, sendo o limite inferior de confiança igual a $\hat{y}_{inferior} = U\$ 9.945,341$ e superior igual a $\hat{y}_{superior} = U\$ 15.906,180$.

Para calcular no R:

```
x0<-data.frame(X=200)
predict(modelo,x0,interval="prediction",conf.level=0.95)
```

A verificação das suposições do modelo ajustado pode ser feita por meio da análise dos gráficos apresentados na Figura 1 a seguir.


```
par(mfrow=c(2,2))
## gráfico de boxplot
boxplot(residuals(modelo),main="GRAFICO DE BOXPLOT DOS RESÍDUOS",
cex.main=0.8,col="green")
## gráfico do resíduo na ordem de coleta dos dados- independência
ordem<-seq_along(residuals(modelo))
ordem
plot(ordem,residuals(modelo),type="b",pch=19,
main="RESÍDUOS versus ORDEM DE COLETA",cex.main=0.8,
```

```

      xlab=" Ordem de coleta ",ylab="Resíduos",col="black")
abline(h=0,col=8)
## gráfico probabilístico normal
qqnorm(residuals(modelo), ylab="Resíduos",xlab="Quantis
teóricos",
      main="GRÁFICO DE PROBABILIDADE NORMAL",cex.main=0.8,
      pch=19,col="black")
qqline(residuals(modelo))
## gráfico de valores ajustados versus resíduos
plot(fitted(modelo),residuals(modelo),xlab="Valores Ajustados",
      ylab="Resíduos",main="GRÁFICO DE VALORES AJUSTADOS VERSUS
RESÍDUOS", cex.main=0.8,col="black",pch=19)
abline(h=0)

```

Figura 1 – Gráficos dos resíduos



Fonte: Elaborados com base nos dados da biblioteca ISLR, Sistema R, 2020.

Por meio da análise dos gráficos é possível concluir que não existem resíduos *outliers* e que estes são independentes dos gráficos (a) e (b). Os gráficos (c) e (d) indicam que os resíduos se comportam segundo uma distribuição normal e são homogêneos. Com isso, é possível concluir que todas as suposições são verificadas.

Será ajustada a função exponencial aos mesmos dados. Para isso, é necessário fazer a transformação na variável resposta Y.

```
exponencial<-lm(log(Y)~X)
summary(exponencial)
lm(formula = log(Y) ~ X)

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  7.914913    0.093999   84.202  < 2e-16 ***
X              0.008978    0.001238    7.252 6.79e-08 ***
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.3319 on 28 degrees of freedom
Multiple R-squared:  0.6526,    Adjusted R-squared:  0.6402
F-statistic: 52.59 on 1 and 28 DF, p-value: 6.79e-08
```

O modelo linearizado ajustado é:

$$\hat{Z} = 7,914913 + 0,008978X$$

É necessário transformá-lo para a forma exponencial; assim, tem-se o modelo estimado ou ajustado.

```
alfaestimado<-exp(exponencial$coef[1]);alfaestimado
(Intercept)
  2737.809
betaestimado<-exp(exponencial$coef[2]); betaestimado
      X
1.009018
```


Tem-se, então, o modelo exponencial ajustado:

$$\hat{Y} = 2.737,809 \times 1,009018^X$$

A função exponencial ajustada explica 64,02% ($R^2_{ajustado} = 0,6402 \cdot 100$) das variações ocorridas na variável resposta Y.

Os valores observados e ajustados são mostrados no Gráfico 5.

Gráfico 5 – Valores observados e ajustados



Fonte: com base em Sistema R, 2020.

Para obter os valores estimados e a construção do gráfico no R:

```
y_estimado<-alfaestimado*(betaestimado^X)
y_estimado

plot(X,Y,
main="GRÁFICO DE VALORES OBSERVADOS E AJUSTADOS",cex.main=0.8,
type = "p",pch=16,xlab="Renda (US$ 10.000)",
ylab="Limite de crédito (US$)",xlim=c(0,200),ylim=c(500,15000))
points(X,y_estimado,type="p", col="red",
pch=16,ylim=c(500,15000),lty=2, lwd=2)
legend("top", legend=c("valores observados", "valores
ajustados"),col=c("black","red"),bty="n",pch=c(16,16))
```

5.1 Ajuste da função potência

Para o mesmo exemplo anterior – de uma amostra de 30 clientes e as variáveis *Income* (renda em US \$ 10.000) e *Limit* (limite de crédito em US\$) – deseja-se ajustar a função potência aos dados.

```
potencia<-lm(log(Y)~log(X))
summary(potencia)

lm(formula = log(Y) ~ log(X))
Coefficients:
      Estimate Std. Error t value Pr(>|t|)
```



```
(Intercept)  6.39860    0.26558  24.093  < 2e-16 ***
log(X)       0.54693    0.06961   7.858 1.47e-08 ***
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Residual standard error: 0.3145 on 28 degrees of freedom
Multiple R-squared:  0.688,    Adjusted R-squared:  0.6768
F-statistic: 61.74 on 1 and 28 DF,  p-value: 1.471e-08
```

O modelo linearizado ajustado é:

$$\hat{Z} = 6,39860 + 0,54693T$$

```
alfaestimado<-exp(potencia$coef[1]);alfaestimado
```

```
(Intercept)
601.0052
```


Tem-se, então, a função potência ajustada:

$$\hat{Y} = 601,0052 \cdot X^{0,54693}$$

O valor-p ou *p-value* do teste de significância do modelo é $1,471 \cdot 10^{-08}$, indicando que o modelo de regressão da variável Y sobre X é significativa.

A função potência ajustada explica 67,68% ($R^2_{ajustado} = 0,6768 \cdot 100$) das variações ocorridas na variável resposta Y. Os valores observados e ajustados são mostrados no Gráfico 6.

Gráfico 6 – Valores observados e ajustados



Fonte: com base em Sistema R, 2020.

Para obter os valores estimados:

```
y_estimado<-exp(potencia$coef[1])*(X^(potencia$coef[2]))
```

y_estimado

Para a construção do gráfico no R:

```
plot(X,Y,  
main="GRÁFICO DE VALORES OBSERVADOS E AJUSTADOS",cex.main=0.8,  
type = "p",pch=16,xlab="Renda (U$ 10.000)",  
ylab="Limite de crédito (U$)",xlim=c(0,200),ylim=c(500,15000))  
points(X,y_estimado,type="p",col="red",  
pch=16,ylim=c(500,15000),lty=2, lwd=2)  
legend("top",legend=c("valores observados","valores  
ajustados"),col=c("black","red"),bty="n",pch=c(16,16))
```

REFERÊNCIAS

CALLEGARI-JACQUES, S. M. **Bioestatística**: princípios e aplicações. Porto Alegre: Artemed, 2003.

FONSECA, J. S. da; MARTINS, G. A.; TOLEDO, G. L. **Estatística aplicada**. 2. ed. São Paulo: Atlas, 2010.

GUPTA, B. C; GUTTMAN, I. **Estatística e probabilidade com aplicações para engenheiros e cientistas**. Rio de Janeiro: LTC, 2017.

MONTGOMERY, D. C.; RUNGER, G. C. **Estatística aplicada e probabilidade para engenheiros**. Rio de Janeiro: LTC, 2009.

SISTEMA R. **Biblioteca Ecdat**. Disponível em: <<https://vincentarelbundock.github.io/Rdatasets/datasets.html>>. Acesso em: 21 jan. 2021.

SISTEMA R. Disponível em: <<http://cran.r-project.org>>. Acesso em: 21 jan. 2021.