

Aula 3

Análise Preditiva

Prof.^a Sachiko A. Lira

Análise de correlação linear simples

- A análise de correlação mede o grau de associação entre variáveis. O caso mais conhecido é a correlação linear simples, envolvendo duas variáveis
- O coeficiente de correlação linear de Pearson amostral é obtido através da expressão:

$$r = \frac{\sum_{i=1}^n (x_i - \bar{X})(y_i - \bar{Y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{X})^2 (y_i - \bar{Y})^2}} \quad (1)$$

- Coeficiente linear de Pearson: $-1 \leq r \leq 1$
- De acordo com Callegari-Jacques (2003), o coeficiente de correlação pode ser avaliado qualitativamente, de acordo com os critérios a seguir:
 - (...)

- (...)
 - $0 < |r| < 0,30$ (existe fraca correlação linear)
 - $0,30 \leq |r| < 0,60$ (existe moderada correlação linear)
 - $0,60 \leq |r| < 0,90$ (existe forte correlação linear)
 - $0,90 \leq |r| < 1,00$ (existe correlação linear muito forte)

Análise de regressão linear simples

- A análise de regressão é uma técnica para analisar a relação entre uma variável dependente Y e uma variável independente X
- O modelo de regressão pode ser expresso como:
 - $Y = \beta_0 + \beta_1 X + \varepsilon$
 - $\varepsilon_i \sim N(0, \sigma^2)$

(2)

- Os estimadores de β_0 e β_1 podem ser obtidos pelo método dos mínimos quadrados. Os detalhes para a obtenção dos estimadores de β_0 e β_1 , se encontram em Gupta de Guttman (2017)

- Os estimadores de β_0 e β_1 são b_0 e b_1 , obtidos por:
 - $b_0 = \bar{Y} - b_1 \bar{X}$
 - $b_1 = \frac{\sum_{i=1}^n (x_i - \bar{X}) y_i}{\sum_{i=1}^n (x_i - \bar{X})^2}$
 - O modelo ajustado é: $\hat{Y} = b_0 + b_1 X$

(3)

(4)

(5)

- As hipóteses para testar a significância da regressão são:
 - $H_0: \beta_1 = 0$
 - $H_1: \beta_1 \neq 0$
- A não rejeição da hipótese H_0 equivale a concluir que não há relação linear entre X e Y
- Por outro lado, a rejeição da hipótese H_0 levará à conclusão de que X é importante para explicar as variações em Y

- A medida que indica a qualidade do ajuste é o coeficiente de determinação ou explicação (R^2)
 - $R^2 = \frac{SQE}{SQT} \times 100$
 - Onde:
 - $SQE = (b_1)^2 \sum_{i=1}^n (x_i - \bar{X})^2$

(6)

(7)

$$SQT = \sum_{i=1}^n (y_i - \bar{Y})^2 \quad (8)$$


$$R^2_{ajustado} = 1 - \frac{(n-1)}{(n-k)} \times (1 - R^2) \quad (9)$$

- A suposição do modelo é de que os erros ε_i sejam normais, isto é, são $\varepsilon_i \sim N(0, \sigma^2)$
- Verificar os seguintes itens:
 - a. Valores atípicos (outliers)
 - ✓ Diagrama de caixa ou boxplot

- b. Independência (erros não correlacionados)
 - ✓ Gráfico dos resíduos *versus* ordem de coleta dos dados
- c. Normalidade dos erros
 - ✓ Gráfico de probabilidade normal
- d. Homogeneidade das variâncias dos erros
 - ✓ Gráfico dos valores preditos (ajustados) *versus* resíduos

Função exponencial

Gráfico 1 – Função exponencial




- A função exponencial é da forma:
 - $Y = \alpha\beta^X$ (10)
- Fazendo a transformação logarítmica:
 - $\ln Y = \ln \alpha + (\ln \beta)X$ (11)
- Ou:
 - $Z = A + BX$ (12)

- A reta estimada é: $\hat{Z} = \hat{A} + \hat{B}X$ (13)
- Sendo:
 - $\hat{A} = \bar{Z} - \hat{B}\bar{X}$ (14)
 - $\hat{B} = \frac{\sum_{i=1}^n (x_i - \bar{X})z_i}{\sum_{i=1}^n (x_i - \bar{X})^2}$ (15)
 - $\hat{A} = \ln \hat{\alpha}$, logo, $\hat{\alpha} = e^{\hat{A}}$
 - $\hat{B} = \ln \hat{\beta}$, logo, $\hat{\beta} = e^{\hat{B}}$
- Modelo estimado: $\hat{Y} = \hat{\alpha}\hat{\beta}^X$ (16)

Função potência

Gráfico 2 – Função potência



- A função potência é da forma:
 - $Y = \alpha X^\beta$ (17)
- Fazendo a transformação logarítmica:
 - $\ln Y = \ln \alpha + \beta \ln X$ (18)
- Ou:
 - $Z = A + \beta T$ (19)

- A reta estimada é: $\hat{Z} = \hat{A} + \hat{\beta}T$ (20)
- Sendo:
 - $\hat{A} = \bar{Z} - \hat{\beta}\bar{T}$ (21)
 - $\hat{\beta} = \frac{\sum_{i=1}^n (t_i - \bar{T})z_i}{\sum_{i=1}^n (t_i - \bar{T})^2}$ (22)
 - $\hat{A} = \ln \hat{\alpha}$, logo, $\hat{\alpha} = e^{\hat{A}}$
- Modelo estimado: $\hat{Y} = \hat{\alpha}X^{\hat{\beta}}$ (23)

Exemplos de aplicação


- Será utilizado o banco de dados *credit*, disponível na biblioteca ISLR, do Sistema R. É um conjunto de dados simulados, contendo o saldo do cartão de crédito de clientes. O banco de dados contém 400 observações e diversas variáveis
- Será obtida uma amostra de 30 clientes e as variáveis *income* (renda em U\$ 10.000) e *limit* (limite de crédito em U\$)

Tabela 1 – Renda e limite de crédito de uma amostra de 30 clientes

Obs.	X (Renda US 10.000)	Y (Limite de crédito US)	Obs.	X (Renda US 10.000)	Y (Limite de crédito US)
1	16,819	1.337	16	124,290	9.560
2	15,184	2.420	17	163,329	8.732
3	66,989	5.614	18	53,308	2.860
4	53,566	5.891	19	19,529	4.673
5	15,354	2.101	20	65,896	5.140
6	12,068	3.873	21	180,682	11.966
7	19,782	2.762	22	83,948	7.100
8	33,657	4.196	23	73,327	6.555
9	19,588	3.213	24	44,646	4.431
10	10,742	1.757	25	21,153	3.736
11	27,369	3.449	26	17,392	2.748
12	27,847	5.619	27	80,180	8.047
13	88,830	4.952	28	103,893	7.416
14	37,728	2.525	29	182,728	13.916
15	55,054	4.381	30	26,427	5.533

Fonte: Elaborado com base em dados da biblioteca JSLR, Sistema R (2020)

Gráfico 3 – Diagrama de dispersão




Fonte: Elaborado com base em dados da biblioteca JSLR, Sistema R, 2020.

Análise de regressão linear simples


- Modelo ajustado: $\hat{Y} = 2.226,733 + 53,245X$
- A estatística $F = 122,30$, cujo valor-p ou p-value é igual a $9,948 \times 10^{-12}$. Conclui-se que a regressão linear de Y sobre X é significativa
- $R^2_{ajustado} = 0,8071 \times 100 = 80,71\%$. Isso quer dizer que o modelo ajustado explica 80,71% das variações ocorridas na variável dependente Y

Gráfico 4 – Valores observados e ajustados



Fonte: Elaborado com base em dados da biblioteca JSLR, Sistema R, 2020.

Figura 1 – Gráficos dos resíduos



Fonte: Elaborado com base em dados da biblioteca JSLR, Sistema R, 2020.


Ajuste da função exponencial

- Modelo linearizado ajustado:
 - $\hat{Z} = 7,914913 + 0,008978X$
- Modelo ajustado na forma exponencial:
 - $\hat{Y} = 2.737,809 \times 1,009018^X$
- O valor-p ou p-value do teste de significância do modelo é $6,79 \times 10^{-08}$, indicando que o modelo de regressão da variável Y sobre X é significativa

- $R^2_{ajustado} = 0,6402 \times 100 = 64,02\%$

- Isso quer dizer que o modelo ajustado explica 64,02% das variações ocorridas na variável dependente Y

Gráfico 5 – Valores observados e ajustados



Ajuste da função potência

- Modelo linearizado ajustado:**
 - $\hat{Z} = 6,39860 + 0,54693T$
- Modelo ajustado na forma exponencial:**
 - $\hat{Y} = 601,0052 \times X^{0,54693}$
- O valor-p ou p-value do teste de significância do modelo é $1,471 \times 10^{-08}$, indicando que o modelo de regressão da variável Y sobre X é significativa**

- A função potência ajustada explica 67,68%**
 $(R^2_{ajustado} = 0,6768 \times 100 = 67,68\%)$ **das variações ocorridas na variável resposta Y**

Gráfico 6 – Valores observados e ajustados

