

| ANÁLISE PREDITIVA

TEMA 1 – SÉRIES TEMPORAIS UNIVARIADAS

Uma série temporal é um conjunto de dados observados ao longo do tempo. Ela pode ser representada por $\{Z_t, t = 1, 2, \dots, n\}$. Alguns exemplos de séries temporais:


- a) estimativas trimestrais do produto interno bruto (PIB);
- b) taxa mensal de desemprego;
- c) índice mensal de preços ao consumidor;
- d) número de automóveis vendidos mensalmente no país;
- e) temperaturas mensais registradas numa determinada cidade;
- f) índices diários da bolsa de valores.

Para os dados observados ao longo do tempo, nem sempre é possível utilizar as técnicas de análise de regressão, devido às características próprias de séries temporais, como veremos nesta aula.

1.1 Componentes de séries temporais

Os movimentos característicos de uma série temporal $\{Z_t, t = 1, 2, \dots, n\}$, podem ser classificados em três componentes: tendência, sazonal e aleatória, conforme Figura 1.

Figura 1 – Componentes sazonal, tendência e aleatória



Fonte: elaborada a partir dos dados do IBGE, 2020.

Tendência: é a componente que expressa um movimento regular, através de um período longo.

Sazonal: é a componente que representa padrões semelhantes, que uma série temporal pode apresentar numa determinada época do ano, quando os dados observados são semanais, mensais, bimestrais etc. Esse movimento refere-se aos ciclos de curto prazo em torno da tendência.

Aleatória: são os deslocamentos aleatórios das séries temporais, provocados por eventos casuais.

TEMA 2 – ANÁLISE DE SÉRIES TEMPORAIS: MÉTODOS DE SUAVIZAÇÃO

Os métodos de suavização são muito populares devido à simplicidade, à eficiência e à razoável precisão (Morettin; Toloi, 2006).

Serão abordados os modelos de suavização exponencial simples e de Holt. O método de suavização exponencial para série temporal sazonal não será tratado aqui. Para obter detalhes sobre esse último método, sugerimos consultar Barros et al. (2020).

2.1 Suavização Exponencial Simples (SES)

O método de suavização exponencial simples é indicado para séries temporais que não apresentam tendência e nem sazonalidade. A principal vantagem deste método é a simplicidade de implementação e não necessitar de uma série com grande quantidade de informações.

De acordo com Morettin e Toloi (2006), pode ser escrito matematicamente por:

$$\bar{Z}_t = \alpha Z_t + (1 - \alpha) \bar{Z}_{t-1}, \quad \bar{Z}_0 = Z_1, \quad t = 1, 2, \dots, n \quad (1)$$

em que $\bar{Z}_t$ é denominado de valor exponencialmente suavizado e α é a constante de suavização, com $0 \leq \alpha \leq 1$.

Quanto menor for o valor do parâmetro α , mais estáveis serão as previsões, ou seja, observações passadas terão pesos maiores. Entretanto, se α for próximo de 1, o amortecimento será pequeno e $\bar{Z}_t$ será aproximadamente igual a Z_t .

A previsão de todos os valores futuros é dada pelo último valor exponencialmente suavizado, isto é,

$$\hat{Z}_t(h) = \bar{Z}_t, \quad \forall h > 0 \quad (2)$$

O intervalo de previsão é obtido através de: $\hat{Z}_t(h) \pm \hat{\sigma}_h \times Z_{\alpha/2}$. (3)

2.2 Suavização exponencial de Holt (SEH)

Considere o caso de uma série temporal não sazonal, que é composta da soma de nível, tendência e resíduo aleatório com média zero e variância constante, isto é,

$$Z_t = \mu_t + T_t + a_t \quad , \quad t = 1, 2, \dots, n \quad (4)$$

Para as séries não estacionárias, ou seja, com dados que apresentam tendências ao longo do tempo, um dos métodos aplicáveis é o método de suavização exponencial de Holt.

Esse método é similar ao SES, a diferença é que a suavização é no nível e uma nova constante de suavização para “modelar” a tendência da série.

De acordo com Morettin e Toloi (2006), os valores do nível e da tendência da série, no instante t , serão estimados por:

$$\bar{Z}_t = A Z_t + (1 - A)(\bar{Z}_{t-1} + \hat{T}_{t-1}) \quad , \quad 0 < A < 1 \quad e \quad t = 2, \dots, n \quad (5)$$

$$\hat{T}_t = C(\bar{Z}_t - \bar{Z}_{t-1}) + (1 - C)\hat{T}_{t-1} \quad , \quad 0 < C < 1 \quad e \quad t = 2, \dots, n \quad (6)$$

respectivamente. A e C são denominadas constantes de suavização.

Para a determinação das constantes de suavização, escolhe-se o valor do vetor (A, C) que torna mínima a soma dos erros quadráticos de previsão.

A previsão para o valor Z_{t+h} , com origem em t , é dado por:

$$\hat{Z}_t(h) = \bar{Z}_t + h\hat{T}_t \quad , \quad \forall h > 0 \quad (7)$$

ou seja, a previsão é feita adicionando-se ao valor básico ($\bar{Z}_t$) a tendência multiplicada pelo número de passos à frente que se deseja prever (h).

O intervalo de previsão é obtido através de: $\hat{Z}_t(h) \pm \hat{\sigma}_h \times Z_{\alpha/2}$. (8)

TEMA 3 – INDICADORES DE ACURÁCIA

É usual ajustar diferentes modelos e adotar aquele que mais se aproxima dos dados observados. Existem diferentes indicadores para avaliar o modelo ajustado, tais como:

- Erro médio (*mean error*): soma dos erros de previsão de uma série de períodos e dividindo essa soma pelo número de erros usados para calcular a soma.

$$ME = \frac{1}{n} \sum_{t=1}^n (Z_t - \hat{Z}_t) \quad (9)$$

- Raiz do erro quadrático médio (*root mean square error*): raiz quadrada da média das diferenças individuais quadráticas entre a série temporal observada e ajustada.

$$RMSE = \sqrt{\frac{1}{n} \sum_{t=1}^n (Z_t - \hat{Z}_t)^2} \quad (10)$$

- Erro médio absoluto (*mean absolute error*): média da diferença absoluta entre os valores observados e ajustados.

$$MAE = \frac{1}{n} \sum_{t=1}^n |Z_t - \hat{Z}_t| \quad (11)$$

- Erro médio percentual absoluto (*mean absolute percentage error*): média da diferença absoluta entre os valores observados e ajustados, expressa em percentagem.

$$MAPE = 100 \times \frac{1}{n} \sum_{t=1}^n \left| \frac{Z_t - \hat{Z}_t}{Z_t} \right| \quad (12)$$

Em que:

- Z_t são os valores observados da série temporal;
- $\hat{Z}_t$ são os valores ajustados.

TEMA 4 – MÉTODOS DE PREVISÃO AVERAGE (MEAN), NAÏVE E DRIFT

Segundo Hyndman (2014), os métodos de previsão Average (*Mean*), *Naïve* e *Drift* são extremamente simples e surpreendentemente eficazes.

É sempre importante construir um intervalo em torno do valor previsto, chamado de intervalo de previsão.

4.1 Método de previsão average (*mean*)

Neste método, a previsão de todos os valores futuros é igual à média da série de dados. Seja $Y_1, Y_2, \dots, Y_t$, e a previsão será:

$$\hat{Y}_{t+h/t} = \bar{Y} = \frac{Y_1 + Y_2 + \dots + Y_t}{t} \quad (13)$$

A notação $\hat{Y}_{t+h/t}$ é uma abreviação para a estimativa $\hat{Y}_{t+h}$ com base nos dados $Y_1, Y_2, \dots, Y_t$ (Hyndman; Athanasopoulos, 2018).

$$\text{O intervalo de previsão é obtido através de: } \hat{Y}_{t+h/t} \pm c \times \hat{\sigma}_h \quad (14)$$

Em que: c é o valor de $t_{\alpha/2; t-1 \text{ g.l.}}$;

$$\hat{\sigma}_h = \hat{\sigma} \sqrt{1 + 1/t}. \quad (15)$$

4.2 Método de previsão *naïve*

As previsões utilizando esse método são definidos como o valor da última observação, que pode ser *naïve* simples ou sazonal.

4.2.1 *Naïve* simples

As previsões para o número de passos à frente que se deseja prever (h) são iguais ao último valor da série observado.

$$\hat{Y}_{t+h/t} = Y_t \quad (16)$$

Segundo Hyndman e Athanasopoulos (2018), esse método funciona muito bem para muitas séries de tempo econômicas e financeiras.

$$\text{O intervalo de previsão é obtido através de: } \hat{Y}_{t+h/t} \pm c \times \hat{\sigma}_h \quad (17)$$

em que: c é o valor de $Z_{\alpha/2}$;

$$\hat{\sigma}_h = \hat{\sigma} \sqrt{h}. \quad (18)$$

4.2.2 *Naïve* sazonal

É útil para dados que apresentam sazonalidade. Nesse caso, define-se cada previsão igual ao último valor observado na mesma estação do ano (por exemplo, o mesmo mês do ano anterior). Formalmente, a previsão para o tempo $t + h$ é escrito como sendo:

(19)

$$\hat{Y}_{t+h/t} = Y_{(t+h)-m(k+1)}$$

em que: k é a parte inteira de $(h - 1)/m$;

m é o período sazonal.

O intervalo de previsão é obtido através de: $\hat{Y}_{t+h/t} \pm c \times \hat{\sigma}_h$ (20)

em que: c é o valor de $Z_{\alpha/2}$;

$$\hat{\sigma}_h = \hat{\sigma} \sqrt{k + 1} \quad (21)$$

sendo k a parte inteira de $(h - 1)/m$.

4.3 Método de previsão *drift*

Permite que as previsões aumentem ou diminuam ao longo do tempo, em que a quantidade de mudança ao longo do tempo é definida pela mudança média observada nos dados históricos.

A previsão para o tempo $t + h$ é dado por:

$$\hat{Y}_{t+h/t} = Y_t + h \left(\frac{Y_t - Y_1}{t - 1} \right) \quad (22)$$

O que é equivalente a traçar uma linha entre a primeira e a última observação e extrapolar para o futuro.

O intervalo de previsão é obtido através de: $\hat{Y}_{t+h/t} \pm c \times \hat{\sigma}_h$ (23)

em que: c é o valor de $Z_{\alpha/2}$;

$$\hat{\sigma}_h = \hat{\sigma} \sqrt{h(1 + h/t)}. \quad (24)$$

TEMA 5 – EXEMPLOS DE APLICAÇÃO

Consideremos a série temporal do índice de produção da indústria de transformação, no Brasil, no período de janeiro de 2014 a dezembro de 2019 (base: média de 2012 = 100). O objetivo é realizar um estudo da série aplicando diferentes métodos para análise de séries temporais, apresentados nesta aula.

Tabela 1 – Índice de produção da indústria de transformação, no Brasil – 2014 – 2019

Meses	Índice da produção da indústria de transformação
-------	--

	2014	2015	2016	2017	2018	2019
Janeiro	92,2	85,7	74,6	74,9	79,8	77,8
Fevereiro	93,0	81,9	74,4	73,7	75,9	79,0
Março	97,3	92,7	82,8	83,7	85,0	80,7
Abril	96,0	86,5	82,1	77,2	85,4	84,6
Maio	101,6	90,9	84,8	88,4	81,9	91,5
Junho	94,1	90,3	86,6	86,7	89,6	85,6
Julho	104,1	93,5	88,2	90,6	94,6	93,1
Agosto	105,8	95,4	91,9	95,7	97,5	95,4
Setembro	105,3	92,3	89,4	91,8	89,5	91,0
Outubro	108,9	95,5	88,7	94,0	94,4	96,8
Novembro	99,1	86,6	84,8	89,4	87,9	87,4
Dezembro	84,8	74,6	73,7	78,4	74,3	74,9

Fonte: IBGE, 2020.

Nota: base (média de 2012 = 100).

É possível criar o objeto no R, porém, neste caso, é recomendado criar o arquivo de dados em uma planilha, por exemplo, no excel, no formato a seguir:

T	t	Y
jan/14	1	92,2
fev/14	2	93,0
mar/14	3	97,3
abr/14	4	96,0
mai/14	5	101,6
jun/14	6	94,1
jul/14	7	104,1
ago/14	8	105,8
...	...	...
...	...	...
set/19	69	91,0
out/19	70	96,8
nov/19	71	87,4
dez/19	72	74,9

Inicialmente, faz-se a leitura do arquivo de dados em Excel e transforma-o em objeto do tipo “*times series*” no R:

```
install.packages("readxl") # instala a biblioteca readxl
library(readxl) # ativa a biblioteca readxl
# Identificação do diretório e arquivo #
path<-"D:/DADOS/producao_ind_transf.xlsx"
# Lê o arquivo XLS e cria um objeto chamado "dados" #
dados<-read_excel(path)
str(dados)
```



Tem-se a seguir, o objeto dados no R.

```
variables:
$ T: POSIXct [1:72], format: "2014-01-01" "2014-02-01" ...
$ t: num  1 2 3 4 5 6 7 8 9 10 ...
$ Y: num  92.2 93 97.3 96 101.6 ...
attach(dados)
install.packages("forecast") # instala a biblioteca forecast
library(forecast)
# Cria o objeto serie no formato de série temporal
serie<-ts(Y,start=c(2014,1),end=c(2019,12),frequency=12)
```

A construção do gráfico da série temporal no R.

```
plot(serie,
     main="ÍNDICE DA PRODUÇÃO DA INDÚSTRIA DE
TRANSFORMAÇÃO, BRASIL - 2014 - 2019",cex.main=0.8,
     xlab="Meses/Ano",ylab="Indice")
```

Gráfico 1 – Índice da produção da indústria de transformação, Brasil – 2014 – 2019



Fonte: elaborado a partir dos dados do IBGE, 2020.

Nota: base (média de 2012 = 100).

5.1 Decomposição da série

Uma série temporal pode ser decomposta em três componentes: sazonal, tendência e aleatória.


```
#tipo de decomposição: aditivo
```

```

componentes<-decompose(serie,type="additive")
# Gráfico das componentes da série:
par(mfrow=c(3,1))
plot(componentes$seasonal,main="componente sazonal",xlab="Meses",
      ylab="Componente sazonal")
plot(componentes$trend,main="componente tendência",xlab="Meses",
      ylab="Componente tendência")
plot(componentes$random,main="componente aleatório",xlab="Meses",
      ylab="Componente aleatório")

```

Figura 2 – Componentes sazonal, tendência e aleatória, do índice da produção da indústria de transformação, Brasil – 2014 – 2019



5.2 Método de suavização exponencial simples

Uma vez criado o objeto do tipo *times series*, aplica-se o método de suavização exponencial simples utilizando a função `ses`.

```

ses<-ses(serie,initial="simple",h=6) ## previsão para 6 valores
                                   ## a frente
summary(ses)

```

Os resultados calculados e apresentados no R.

```

alpha = 0.904    (Constante de suavização  $\alpha = 0,904$ )
Initial states:

```

1 = 92.2 (Valor inicial $\bar{Z}_0 = 92,20$)

sigma: 6.0757

Tem-se assim que $\bar{Z}_t = 0,904Z_t + (1 - 0,904)\bar{Z}_{t-1}$, que é o valor exponencialmente suavizado.

A Tabela 2, a seguir, mostra os valores observados, suavizados e estimados (ajustados) para alguns meses.

Tabela 2 – Valores observados, suavizados e estimados

t	Mês/ano	Z_t	$\bar{Z}_t$	$\hat{Z}_t$
0			92,2000	
1	Jan/14	92,2	92,2000	92,2000
...	...	...	...	...
67	jul/19	93,1	92,4280	86,0991
68	ago/19	95,4	95,1147	92,4280
69	set/19	91,0	91,3950	95,1147
70	out/19	96,8	96,2812	91,3950
71	nov/19	87,4	88,2525	96,2812
72	dez/19	74,9	76,1816	88,2525

Fonte: elaborada a partir dos dados do IBGE, 2020.

Nota: base (média de 2012 =100).

Indicadores de acurácia:

ME	RMSE	MAE	MPE	MAPE	MASE
-0.246099	6.0757	4.76454	-0.568842	5.511366	0.9981578

Previsão pontual e intervalo de previsão para nível de 80% e 95% de confiança, apresentados para os três primeiros meses.

	Point Forecast	Lo 80	Hi 80	Lo 95	Hi 95
Jan 2020	76.18161	68.39529	83.96793	64.27346	88.08976
Feb 2020	76.18161	65.68524	86.67799	60.12880	92.23443
Mar 2020	76.18161	63.54354	88.81968	56.85335	95.50988

O Gráfico 2 apresenta o valores observados, ajustados e previstos.

Gráfico 2 – Valores observados, ajustados e previstos – suavização exponencial simples



Fonte: elaborado a partir dos dados do IBGE, 2020.

Nota: base (média de 2012 = 100).

Construção do gráfico no R.

```
previsao<-forecast(ses, h=6) ## previsão 6 valores a frente
plot(previsao,main="INDICE DA PRODUÇÃO INDUSTRIAL NO BRASIL",
      sub="Método de suavização exponencial simples",
      cex.main=0.8,xlab="Meses", ylab="Índice")
lines(ses$fit,col="red",type="l",lty=2)
legend("topright",
      legend=c("Série original","Série ajustada","projeção"),
      lty=c(1,2),col=c(1,2,4), lwd=1.0, bty="n")
```

5.3 Método de suavização exponencial de Holt

Para o método de suavização exponencial de Holt, utiliza-se a função *holt*.

```
holt <- holt(serie,initial = "simple",h=6)      ## previsão para 6
                                              ## valores a frente
summary(holt)
```

A seguir, os resultados calculados e apresentados no R.

```
Smoothing parameters:
  alpha = 0.9179  Constante de suavização do nível (A = 0,9179)
  beta  = 0.011   Constante de suavização da tendência (C = 0,011)
Initial states:
  l = 92.2        Valor inicial  $\bar{Z}_0 = 92,20$ 
```

b = 0.8 Valor inicial $\hat{T}_0 = 0,80$
sigma: 6.1542

Os valores de nível e tendência da série podem ser estimados através de:

$$\bar{Z}_t = 0,9179Z_t + (1 - 0,9179)(\bar{Z}_{t-1} + \hat{T}_{t-1})$$

$$\hat{T}_t = 0,011(\bar{Z}_t - \bar{Z}_{t-1}) + (1 - 0,011)\hat{T}_{t-1}$$

Indicadores de acurácia:

ME	RMSE	MAE	MPE	MAPE	MASE
-0.8141161	6.154244	4.792544	-1.203499	5.565242	1.004025

A Tabela 3, a seguir, mostra os valores observados, nível, tendência e série estimada para alguns meses.

Tabela 3 – Valores observados, nível, tendência e série estimada

t	Mês/ano	Z_t	$\bar{Z}_t$	$\hat{T}_t$	$\hat{Z}_t$
0			92,2000	0,8000	
1	jan/14	92,2	92,2657	0,7919	93,000
...	...	...	...	...	...
67	jul/19	93,1	92,5514	0,4130	86,4168
68	ago/19	95,4	95,2001	0,4376	92,9644
69	set/19	91,0	91,3807	0,3908	95,6377
70	out/19	96,8	96,3872	0,4415	91,7715
71	nov/19	87,4	88,1739	0,3465	96,8288
72	dez/19	74,9	76,0180	0,2092	88,5204

Fonte: elaborada a partir dos dados do IBGE, 2020.

Nota: base (média de 2012 =100).

Construção do gráfico no R.

```
fit<-(holt$fitted)
previsao<-forecast(holt)
plot(previsao,main="ÍNDICE DA PRODUÇÃO INDUSTRIAL NO BRASIL",
      sub="Método de Holt",
      cex.main=0.8,
      xlab="Meses",
      ylab="Índice")
lines(fit,col="red",type="l",lty=2)
legend("topright",
legend=c("Série original","Série ajustada","projeção"),
```

```
lty=c(1,2),col=c(1,2,4),lwd=1.0,bty="n")
```

Previsão pontual e intervalo de previsão para nível de 80% e 95% de confiança, apresentados para os três primeiros meses.

	Point Forecast	Lo 80	Hi 80	Lo 95	Hi 95
Jan 2020	76.22718	68.34020	84.11416	64.16508	88.28928
Feb 2020	76.43637	65.67172	87.20103	59.97326	92.89949
Mar 2020	76.64557	63.57547	89.71566	56.65657	96.63456

O Gráfico 3 apresenta os valores observados, ajustados e previstos.

Gráfico 3 – Valores observados, ajustados e previstos – suavização exponencial de Holt



Fonte: elaborado a partir dos dados do IBGE, 2020.

Nota: base (média de 2012 =100).

5.4 Métodos de previsão *mean*, *naïve* e *drift*

Inicialmente será aplicado o método de previsão average (*mean*).

```
modelo <- meanf(serie,h=6)
summary(modelo)
```

Resultados mostrados no R.

```
$mu
[1] 88.16944
```

Indicadores de acurácia:

ME	RMSE	MAE	MPE	MAPE	MASE
-6.710681e-15	8.2633	6.640586	-0.8903472	7.657544	1.391184

A Tabela 4, a seguir, mostra os valores observados e estimados (ajustados) para alguns meses.

Tabela 4 – Valores observados e estimados

t	Mês/ano	Z_t	$\hat{Z}_t$
1	jan/14	92,2	88,1694
...	...	...	...
67	jul/19	93,1	88,1694
68	ago/19	95,4	88,1694
69	set/19	91,0	88,1694
70	out/19	96,8	88,1694
71	nov/19	87,4	88,1694
72	dez/19	74,9	88,1694

Fonte: elaborada a partir dos dados do IBGE, 2020.


Nota: base (média de 2012 =100).

Previsão pontual e intervalo de previsão para nível de 80% e 95% de confiança, apresentados para os três primeiros meses.

	Point Forecast	Lo 80	Hi 80	Lo 95	Hi 95
Jan 2020	88.16944	77.33062	99.00827	71.46244	104.8764
Feb 2020	88.16944	77.33062	99.00827	71.46244	104.8764
Mar 2020	88.16944	77.33062	99.00827	71.46244	104.8764

O Gráfico 4 apresenta os valores observados, estimados e previstos.

Gráfico 4 – Valores observados, ajustados e previstos – método *Average (Mean)*



Fonte: elaborado a partir dos dados do IBGE, 2020.

Nota: base (média de 2012 =100).

Construção do gráfico com valores observados, estimados e previstos no R.

```
plot(modelo,main="PREVISÃO - MEAN", cex.main=0.8,ylim=c(60,120),
      xlab="Meses/Ano",
      ylab="Índice")
lines(modelo$fit,col="red",type="l",lty=2 )
legend("topright", legend=c("Série original","Série ajustada",
                             "projeção"), lty=c(1,2), col=c(1,2,4),lwd=1.0, bty="n")
```

Aplicando o método de previsão *naïve* simples.

```
modelo<-naive(serie, h=6)
summary(modelo)
```

Resultados calculados e apresentados no R.

Residual sd: 6.1502

A Tabela 5 mostra os valores observados e estimados (ajustados) para alguns meses.

Tabela 5 – Valores observados e estimados

t	Mês/ano	Z_t	$\hat{Z}_t$
1	Jan/14	92,2	-
...	...	...	

67 jul/19	93,1	85,6
68 ago/19	95,4	93,1
69 set/19	91,0	95,4
70 out/19	96,8	91,0
71 nov/19	87,4	96,8
72 dez/19	74,9	87,4

Fonte: elaborada a partir dos dados do IBGE, 2020.


Nota: base (média de 2012 =100).

Indicadores de acurácia:

ME	RMSE	MAE	MPE	MAPE	MASE
-0.243662	6.150243	4.930986	-0.5493315	5.697604	1.033028

O Gráfico 5 mostra os valores observados, estimados e previstos.

Gráfico 5 – Valores observados, ajustados e previstos – método *naïve simples*



Fonte: elaborado a partir dos dados do IBGE, 2020.

Nota: base (média de 2012 =100).

Previsão pontual e intervalo de previsão para nível de 80% e 95% de confiança, apresentados para os três primeiros meses.

	Point Forecast	Lo 80	Hi 80	Lo 95	Hi 95
Jan 2020	74.9	67.01815	82.78185	62.84574	86.95426
Feb 2020	74.9	63.75338	86.04662	57.85271	91.94729
Mar 2020	74.9	61.24823	88.55177	54.02142	95.77858

Construção do gráfico com valores observados, estimados e previstos.

```
plot(modelo, main="PREVISÃO - NAIVE SIMPLES", cex.main=0.8,
      ylim=c(60,120), xlab="Meses/Ano", ylab="Indice")
lines(modelo$fit, col="red", type="l", lty=2 )
```

```
legend("topright", legend=c("Série original","Série ajustada",
"projeção"),lty=c(1,2), col=c(1,2,4), lwd=1.0, bty="n")
```

Adotando o método de previsão *naïve* sazonal tem-se:

```
modelo<-snaive(serie, h=6)
summary(modelo)
```

Resultados calculados e apresentados no R.

Residual sd: 6.0083

Indicadores de acurácia:

ME	RMSE	MAE	MPE	MAPE	MASE
-2.406667	6.0083	4.773333	-2.85568	5.55321	1

A Tabela 6 mostra os valores observados e estimados (ajustados) para alguns meses.

Tabela 6 – Valores observados e estimados

t	Mês/ano	Z_t	$\hat{Z}_t$
1	jan/14	92,2	-
...	...	...	
55	jul/18	94,6	-
56	ago/18	97,5	-
57	set/18	89,5	-
58	out/18	94,4	-
59	nov/18	87,9	-
60	dez/18	74,3	-
...	...	...	
67	jul/19	93,1	94,6
68	ago/19	95,4	97,5
69	set/19	91,0	89,5
70	out/19	96,8	94,4
71	nov/19	87,4	87,9
72	dez/19	74,9	74,3

Fonte: elaborada a partir dos dados do IBGE, 2020.

Nota: base (média de 2012 =100).


Previsão pontual e intervalo de previsão para nível de 80% e 95% de confiança, apresentados para os três primeiros meses.

Point Forecast	Lo 80	Hi 80	Lo 95	Hi 95
Jan 2020	77.8	70.10005	85.49995	66.02395
				89.57605

Feb 2020	79.0	71.30005	86.69995	67.22395	90.77605
Mar 2020	80.7	73.00005	88.39995	68.92395	92.47605

O Gráfico 6 apresenta os valores observados, estimados e previstos.

Gráfico 6 – Valores observados, ajustados e previstos – método *naïve sazonal*



Fonte: elaborado a partir dos dados do IBGE, 2020.

Nota: base (média de 2012 =100).

Construção do gráfico no R.

```
plot(modelo,main="PREVISÃO - NAIVE SAZONAL", cex.main=0.8,
      ylim=c(60,120),xlab="Meses/Ano",ylab="Indice")
lines(modelo$fit,col="red",type="l",lty=2 )
legend("topright", legend=c("Série original","Série ajustada",
                             "projeção"), lty=c(1,2),col=c(1,2,4), lwd=1.0, bty="n")
```

E, finalmente, o método de previsão *drift*:

```
modelo<-rwf(serie, h=6,drift=T)
summary(modelo)
```

Resultados mostrados no R.

```
Model Information:
Drift: -0.2437 (se 0.7345)
Residual sd: 6.1892
```

Indicadores de acurácia:

ME	RMSE	MAE	MPE	MAPE	MASE
----	------	-----	-----	------	------

2.60189e-15 6.145415 4.956239 -0.2703097 5.718662 1.038318

Construção do gráfico dos valores observados, estimados e previstos no R.

```
plot(modelo,main="PREVISÃO - NAIVE DRIFT",cex.main=0.8,
      ylim=c(60,120),xlab="Meses/Ano",ylab="Indice")
lines(modelo$fit,col="red",type="l",lty=2 )
legend("topright", legend=c("Série original","Série ajustada",
                             "projeção"),lty=c(1,2),col=c(1,2,4), lwd=1.0, bty="n")
```

A Tabela 7 mostra os valores observados e estimados (ajustados) para alguns meses.

Tabela 7 – Valores observados e estimados

t	Mês/ano	Z_t	$\hat{Z}_t$
1	jan/14	92,2	
2	fev/14	93,0	91,9563
...	...	...	...
67	jul/19	93,1	85,3563
68	ago/19	95,4	92,8563
69	set/19	91,0	95,1563
70	out/19	96,8	90,7563
71	nov/19	87,4	96,5563
72	dez/19	74,9	87,1563

Fonte: elaborada a partir dos dados do IBGE, 2020.


Nota: base (média de 2012 =100).

Previsão pontual e intervalo de previsão para nível de 80% e 95% de confiança, apresentados para os três primeiros meses.

	Point Forecast	Lo 80	Hi 80	Lo 95	Hi 95
Jan 2020	74.65634	66.72462	82.58806	62.52582	86.78686
Feb 2020	74.41268	63.11681	85.70854	57.13714	91.68821
Mar 2020	74.16901	60.23872	88.09931	52.86447	95.47356

O Gráfico 7 mostra os valores observados, estimados e previstos.

Gráfico 7 – Valores observados, ajustados e previstos – método *Drift*



Fonte: elaborado a partir dos dados do IBGE, 2020.

Nota: base (média de 2012 =100).

REFERÊNCIAS

BARROS, A. C. et al. **Análise de séries temporais em R**: curso introdutório. São Paulo: Atlas, 2020.

FONSECA, J. S. da; MARTINS, G. A.; TOLEDO, G. L. **Estatística aplicada**. 2. ed. São Paulo: Atlas, 2010.

GUJARATI, D. N. **Basic Econometrics**. 3. ed. New York: McGraw-Hill International Editions, 1995.

HYNDMAN, R. J. **Forecasting**: principles & practice. Australia: University of Western, 2014.

HYNDAMN, R. J.; ATHANASOPOULOS, G. 2018. **Forecasting**: principles and practice. 2. Disponível em: <OTexts.com/fpp2>. Acesso em: 13 abr. 2021.

IBGE. Instituto Brasileiro de Geografia e Estatística. **Pesquisa Industrial mensal**. Disponível em: <http://ipeadata.gov.br/beta3/#/dados-serie?anomapa=&ascOrder=&base=macro&busca=&columnOrdering=&end=2020&fonte=&serid=PIMPFN12_QIITN12&skip=0&start=2002&tema=Produ%C3%A7%C3%A3o&territoriality=>>. Acesso em: 13 abr. 2021.

MORETTIN, P. A.; TOLOI, C. M. C. **Análise de séries temporais**. São Paulo: Egard Blucher, 2006.

SISTEMA R. Disponível em: <<http://cran.r-project.org>>. Acesso em: 13 abr. 2021.