

Aula 5


Análise Preditiva

Prof.^a Sachiko A. Lira

Redes neurais para séries temporais

- Uma rede neural artificial pode ser dividida em três partes, como mostra a Figura 1

Figura 1 – Rede neural artificial




Fonte: Adaptado de Ciaburro e Venkateswaran, 2017

- As três camadas de uma rede artificial são:
 - a) Camada de entrada
 - b) Camadas escondidas, intermediárias ou ocultas
 - c) Camada de saída

- Processos de aprendizagem:
 - a) Supervisionada
 - b) Não supervisionada

Figura 2 – Rede *perceptron* de camadas múltiplas



Fonte: SILVA; SPATTI; FLAUZINO (2010).

Redes neurais para modelos de regressão

- **Modelo de rede neural: muito semelhante a um modelo de regressão não linear**
- **Pode lidar com uma quantidade muito grande de parâmetros do modelo, por isso se diz que os modelos de redes neurais têm a capacidade de aproximar qualquer função contínua**
- (...)

- (...)
- **A rede neural é muito boa para aprender a função não linear, e também para aprender várias saídas ao mesmo tempo**

- **A função *neuralnet()* da biblioteca *neuralnet* possibilita trabalhar com *multilayer perceptron* na visão da análise de regressão, isto é, para aproximar as relações funcionais entre variáveis independentes e variáveis resposta**


Método de classificação k-NN

- **O algoritmo k-vizinhos mais próximos ou k-NN classifica um elemento cujo grupo é desconhecido, a partir da comparação desse elemento com aqueles que possuem um grupo já conhecido**

- O princípio desse algoritmo é armazenar o conjunto de treinamento e realizar comparações entre o elemento de teste e os elementos armazenados, a cada vez que um elemento de teste é apresentado

Figura 3 – Exemplo ilustrativo para classificação k-NN

- Nota: número de vizinho $k = 1$




Árvore de decisão

- A árvore de decisão (*decision tree*) é uma das técnicas mais populares de mineração de dados
- É normalmente utilizada para resolver tarefas de classificação de dados
- Consiste em um conjunto de nós internos e nós folhas, organizados em um modelo hierárquico

- Cada nó interno corresponde ao teste de um atributo (variável); cada ramo representa um resultado do teste; e os nós folhas representam classes (grupos) ou distribuições de classes (grupos)

Figura 4 – Árvore de decisão



Fonte: com base em Quillici-gonzalez; Zampirolli, 2014


Exemplos de aplicação

Redes neurais para séries temporais

- Tem-se a série do índice da produção da indústria de transformação (média 2012 = 100), no Brasil, no período de janeiro de 2002 a fevereiro de 2020
- (...)

- (...)
- Para criar a rede neural, utiliza-se a função mlp, da biblioteca nnfor. O total de observações é 218; as 196 observações iniciais (janeiro/2002 a abril/2018) foram utilizadas para treinamento e as outras 22 (maio/2018 a fevereiro/2020) para avaliação da rede (teste)

Gráfico 1 – Índice da produção da indústria de transformação, no Brasil (jan./2002 a fev./2020)



Fonte dos dados: IBGE (PIM-PF)

- Nota: média 2012 = 100

Tabela 1 – IPI observado e estimado e erro quadrático


Mês/ano	Z_t	$\hat{Z}_t$	Erro	Erro ²
Jan./02	81,9	84,27	-2,37	5,59
Jun./08	89,6	92,13	-2,53	6,43
Jul./18	94,6	96,97	-2,37	5,59
Ago./18	97,5	101,25	-3,75	14,06
Set./18	99,5	97,65	1,85	3,42
Out./18	94,4	99,0	-4,60	21,15
...	...	...	...	...
Jan./19	85,6	96,54	-10,94	119,87
Jul./19	92,1	99,78	-7,68	58,98
Ago./19	95,1	106,25	-11,15	124,32
Set./19	91,0	101,00	-10,00	100,00
Out./19	96,8	102,52	-5,72	32,74
Nov./19	87,4	99,15	-11,75	138,06
Dez./19	74,9	97,28	-22,38	500,87
Jan./20	79,0	88,95	-9,95	99,00
Fev./20	78,6	85,97	-7,37	54,32
Soma				2.589,15

$$MSE = 63,14$$

$$RMSE = 7,95$$

Fonte: Elaborada a partir dos dados do IBGE (PIM-PF)

Gráfico 2 – Valores observados e previstos do índice de produção da indústria de transformação, no Brasil



Fonte: IBGE (PIM-PF)

Redes neurais para modelos de regressão

- Consumo de combustível (milhas por galão) e deslocamento do motor (em *cubic inches*)
- Consumo de combustível função deslocamento do motor
 - 32 observações
 - 20 observações: treinamento
 - 12 observações: teste

Tabela 2 – Consumo de combustível e deslocamento do motor

Obs.	Deslocamento	Consumo	Obs.	Deslocamento	Consumo
1	185,0	21,0	17	445,0	14,7
2	185,0	21,0	18	76,7	25,4
3	158,0	22,0	19	75,7	20,4
4	158,0	21,4	20	71,7	33,9
5	360,0	18,7	21	120,1	21,5
6	237,0	18,1	22	18,0	15,9
7	360,0	14,3	23	304,0	15,2
8	146,7	24,4	24	350,0	13,3
9	146,8	22,8	25	400,0	19,2
10	187,8	19,2	26	79,0	27,3
11	187,8	17,8	27	120,3	28,0
12	273,8	16,4	28	95,1	30,4
13	273,8	17,3	29	301,0	15,8
14	273,8	15,2	30	145,0	19,7
15	472,0	10,4	31	301,0	15,8
16	400,0	10,4	32	121,0	21,4

Fonte: Biblioteca datasets do R

Tabela 3 – Consumo de combustível observado e estimado e erro quadrático

Obs.	Y	F	Erro	Erro ²
21	21,5	25,74	-4,24	17,96
22	15,5	15,27	0,23	0,05
23	15,2	15,40	-0,20	0,04
24	15,3	15,07	0,23	0,15
25	19,2	14,98	4,22	18,54
26	27,3	29,72	-2,42	5,84
27	26,0	25,71	0,29	0,08
28	20,4	28,43	-7,99	6,39
29	15,8	15,08	0,74	0,34
30	19,7	22,77	-3,07	9,45
31	15,0	15,43	-0,43	0,18
32	21,4	20,63	0,77	1,79
Soma				77,77

$$MSE = 6,48$$

$$RMSE = 2,55$$

Fonte: Elaborado a partir dos dados obtidos na Biblioteca datasets do R


Método de classificação k-NN

- Será utilizado o arquivo *computers* disponível na biblioteca Ecdat, do software R. Esse arquivo contém diversas variáveis (características sobre os computadores) e 6.259 observações

- Variável resposta: se premium ou não (yes e no)
- price: preço do computador em U\$ dólar
- speed: velocidade do relógio (MHZ)
- hd: tamanho do disco rígido em MB
- ram: tamanho da ram em MB
- screen: tamanho da tela em polegadas

- a) Padronizar as variáveis (escala de 0 a 1)
- b) Dividir o arquivo em subarquivos: treinamento = 4.694 (75%) e teste = 1.565 (25%)
- c) Variável para classificação: premium (yes, no)
- d) Definir o número de vizinhos mais próximos (k). Possível obter o melhor valor de K através de simulação, utilizando o subarquivo teste

Gráfico 3 – Percentual de erro em função do número de vizinhos mais próximos



Premium previsto

1	yes	yes
2	yes	yes
3	yes	yes
4	yes	yes
5	yes	yes
6	yes	yes
7	yes	yes
8	yes	yes
9	yes	no
10	yes	yes

	no	yes
no	135	18
yes	28	1384

- $Taxa\ de\ acerto = \frac{1.519}{1.565} = 0,9706$
- Para classificar uma nova observação:
 - $x = (1795, 33, 85, 2, 15)$
- Variáveis: price, speed, hd, ram e screen
 - [1] yes

Árvore de decisão

- Será utilizado o arquivo *computers* disponível na biblioteca Ecdat, do software R. Esse arquivo contém diversas variáveis (características sobre os computadores) e 6.259 observações
- (...)

- (...)
- Para a construção da árvore de decisão serão utilizadas as variáveis: price, speed, hd, ram e premium
- Treinamento: 80% das observações (5.007)
- Teste: 20% das observações (1.252)

- Variável resposta (se o fabricante do computador era IBM ou COMPAQ: premium): yes ou no
 - price: preço do computador em U\$ (dólar)
 - speed: velocidade do relógio (MHZ)
 - hd: tamanho do disco rígido em MB
 - ram: tamanho da ram em MB
 - screen: tamanho da tela em polegadas

▪ **Avaliação do modelo:**

ajuste	no	yes
no	364	65
yes	120	4458

▪ $Taxa\ de\ acerto = \frac{4.822}{5.007} = 0,9631$

▪ **Classificação de algumas observações do subarquivo teste**

	price	speed	hd	ram	premium	predicao
94	2505	50	210	8	yes	yes
114	2895	50	340	16	yes	yes
119	2499	33	170	4	yes	yes
124	3220	66	340	8	yes	no
132	1799	25	170	4	yes	yes
136	2195	25	245	8	yes	yes
137	2255	50	250	8	yes	yes
141	2225	33	250	8	yes	yes

▪ **Avaliação da predição**

predicao	no	yes
no	85	17
yes	43	1107

• $Taxa\ de\ acerto = \frac{1.192}{1.252} = 0,9521$

▪ **Para classificar novas observações:**

	price	speed	hd	ram
1	2200	50	170	8
2	2800	33	240	4
3	2000	25	200	2

▪ **As novas observações receberão as seguintes classificações:**

1	2	3
yes	no	yes