

| ANÁLISE PREDITIVA

TEMA 1 – MÉTODOS DE AGRUPAMENTO

A análise de agrupamento (*cluster analysis*) é uma técnica que permite encontrar nos dados uma estrutura de agrupamento natural e é uma importante técnica exploratória. Procura descobrir agrupamentos naturais de observações (ou variáveis) com base nos dados observados, agrupando elementos em função da similaridade ou distância (dissimilaridade).

O objetivo da técnica é maximizar a homogeneidade de elementos dentro de grupos e maximizar a heterogeneidade de elementos entre os grupos.

A maioria dos algoritmos de análise de agrupamento opera com o conceito de distância (dissimilaridade). As medidas de distâncias para variáveis quantitativas mais utilizadas são as seguintes:

- Distância euclidiana: é certamente a mais conhecida e utilizada para calcular a distância entre dois objetos no espaço p -dimensional. Considerando dois objetos x e y , a distância euclidiana entre eles é definida por:

$$d(x, y) = \sqrt{\sum_{j=1}^p (x_j - y_j)^2} \quad (1)$$

em que x_j e y_j são o j -ésimo atributo dos objetos x e y .

- Distância de Manhattan (*city block*)

$$d(x, y) = \sum_{j=1}^p |x_j - y_j| \quad (2)$$

- Distância de Minkowsky

$$d(x, y) = \left(\sum_{j=1}^p |x_j - y_j|^r \right)^{1/r} \quad (3)$$

Quando $r = 1$, a distância de Minkowski é a mesma de Manhattan e para $r = 2$, da distância euclidiana.


Para calcular as distâncias, consideremos o exemplo contendo 12 observações (funcionários) e duas variáveis (atributos), que são o tempo de experiência e anos de estudo, conforme mostra a Tabela 1 e para facilitar a visualização dos dados, eles são apresentados no gráfico da Figura 1.

Tabela 1 – Variáveis tempo de experiência e anos de estudo

ID	Tempo de experiência	Anos de estudo
1	10	11
2	5	12
3	10	12
4	8	11
5	6	13
6	6	10
7	8	12
8	9	12
9	7	11
10	9	15
11	6	9
12	5	11

Fonte: Biblioteca *Ecdat*, Sistema R, 2020.

Figura 1 – Variáveis tempo de experiência e anos de estudo



Fonte: Biblioteca *Ecdat*, Sistema R, 2020.

É fácil perceber que os elementos 1 e 3 estão próximos, entretanto 1 e 2 estão distantes. A distância euclidiana entre 1 e 2 é igual a 5,1 e entre 1 e 3, igual a 1. As distâncias indicam que os elementos 1 e 2 apresentam características distintas, ao passo que 1 e 3, similares.


TEMA 2 – MÉTODOS DE AGRUPAMENTO HIERÁRQUICO

Os algoritmos de agrupamento hierárquico podem ser divididos em duas subcategorias, que são: agrupamento *aglomerativo* e *divisivo*.

No agrupamento *aglomerativo* (*agglomerative clustering*), cada item de dados é considerado como um grupo individual, e grupos são recursivamente fundidos até produzir um bom agrupamento final. Já, no agrupamento *divisivo* (*divisive clustering*), inicialmente, o conjunto de todos os dados é considerado como sendo um único grupo e, em seguida, ele é recursivamente dividido para produzir um bom agrupamento final.

Na Figura 2, estão apresentados os passos dos agrupamentos aglomerativo e divisivo.

Figura 2 – Agrupamento aglomerativo e divisivo



Fonte: Silva; Peres; Boscarioli, 2016.

Para a aplicação da medida de distância a pares de exemplares é útil criar uma matriz de similaridade que relaciona todas as observações do conjunto de dados.

É importante observar que, antes de calcular a matriz de distâncias, devem-se padronizar os dados, devido às diferentes variabilidades apresentadas pelas variáveis. A padronização pode ser feita por meio da seguinte transformação:

$$z_p = \frac{x_{pj} - \bar{X}_p}{S_p} \quad (4)$$

em que: p é a variável


j é o número da observação.

O que caracteriza os algoritmos de produzir agrupamentos é o critério usado para definir a distância entre grupos, apresentados a seguir:

- Menor distância (*single linkage*): a distância entre 2 grupos é dada pela menor distância entre dois objetos;
- Maior distância (*complete linkage*): a distância entre 2 grupos é dada pela maior distância entre dois objetos;
- Distância média (*average linkage*): a distância entre 2 grupos é dada pela média das distâncias entre cada dois objetos;
- Método de Ward: a medida de distância entre dois clusters é a soma das distâncias dos pontos aos centroides ao quadrado.

O agrupamento hierárquico é obtido da criação de uma estrutura em forma de árvore, conhecida por dendrograma (ou dendograma). No eixo horizontal são representados os elementos (objetos), e a escala vertical à esquerda indica o nível de similaridade, conforme a Figura 3.

Figura 3 – Exemplo de dendrograma



TEMA 3 – MÉTODO DE AGRUPAMENTO DE K-MÉDIAS

O agrupamento não hierárquico é uma técnica usada quando se deseja formar k grupos de observações ou objetos. O algoritmo mais usado é o das k -médias, que classifica observações num determinado número predefinido de grupos (*clusters*).

Esse método de agrupamento é normalmente utilizado, quando há muitos objetos para agrupar. O critério mais utilizado de homogeneidade dentro do grupo e heterogeneidade entre os grupos é o da soma dos quadrados das distâncias euclidianas entre os objetos e seus centroides, e quanto menor for esse valor, mais homogêneos são os elementos dentro de cada grupo e melhor será a partição. Os centroides (médias de cada grupo) são dispostos aleatoriamente para

inicialização, cuja posição é recalculada a cada iteração (recálculo da distância entre cada objeto e centroide).

Uma vez que esse método requer um número inicial de *clusters* (grupos), é possível executar o algoritmo para vários números diferentes de *clusters* e dizer qual deles é o número ótimo. O ideal é que a distância das observações até o centro do agrupamento a que ela pertence tenda a zero, ou seja, a soma dos quadrados *intraclusters* (*within clusters sum of squares – wcss*) deve ser a menor possível. Esse procedimento é chamado de *método do cotovelo*, devido à forma do gráfico gerado, considerando a soma dos quadrados *intraclusters* versus número de *clusters*.

Consideremos o exemplo com 12 observações e duas variáveis (atributos), já apresentado no tema 1.

Tabela 2 – Variáveis tempo de experiência e anos de estudo

ID	Tempo de experiência	Anos de estudo
1	10	11
2	5	12
3	10	12
4	8	11
5	6	13
6	6	10
7	8	12
8	9	12
9	7	11
10	9	15
11	6	9
12	5	11

Fonte: Biblioteca *Ecdat*, Sistema R, 2020.

A média e o desvio padrão das variáveis tempo de experiência e anos de estudo estão apresentados na Tabela 3.

Tabela 3 – Estatísticas das variáveis *tempo de experiência* e *anos de estudo*

Estatísticas	Tempo de experiência	Anos de estudo
$\bar{X}$	7,4167	11,5833
S	1,8320	1,5050

Fonte: Biblioteca *Ecdat*, Sistema R, 2020.

Quando há grandes quantidades de variáveis com variabilidades distintas, recomenda-se fazer a sua padronização, isto é, colocar as diferentes variáveis numa mesma escala. Assim, as novas variáveis terão médias iguais a zero e desvios padrão iguais a 1.

A Tabela 4 mostra as variáveis tempo de experiência e anos de estudo padronizadas.

Tabela 4 – Variáveis tempo de experiência e anos de estudo padronizadas

ID	Tempo de experiência	Anos de estudo
1	1,4102	-0,3876
2	-1,3192	0,2768
3	1,4102	0,2768
4	0,3184	-0,3876
5	-0,7733	0,9413
6	-0,7733	-1,0520
7	0,3184	0,2768
8	0,8643	0,2768
9	-0,2274	-0,3876
10	0,8643	2,2701
11	-0,7733	-1,7165
12	-1,3192	-0,3876
Média	0,0000	0,0000

Fonte: Biblioteca *Ecdat*, Sistema R, 2020.

Para obter os agrupamentos para diferentes valores de k , utilizando o método de k -médias, devem-se calcular as somas de quadrados.

Considerando inicialmente que todas as observações pertencem a um mesmo grupo, tem-se que $k = 1$. Dividindo as observações em dois grupos, por meio da análise das características semelhantes observadas na Tabela 1 e com o auxílio do gráfico da Figura 4, tem-se que $k = 2$, como mostra a Tabela 5.

Tabela 5 – Variáveis tempo de experiência e

Anos de estudo padronizados os grupos ID	Tempo de experiência	Anos de estudo	Grupos
1	1,4102	-0,3876	1
2	-1,3192	0,2768	2
3	1,4102	0,2768	1

4	0,3184	-0,3876	1
5	-0,7733	0,9413	2
6	-0,7733	-1,0520	2
7	0,3184	0,2768	1
8	0,8643	0,2768	1
9	-0,2274	-0,3876	2
10	0,8643	2,2701	1
11	-0,7733	-1,7165	2
12	-1,3192	-0,3876	2

Fonte: Biblioteca *Ecdat*, Sistema R, 2020.

Calculando as somas de quadrados dos grupos tem-se:

Para $k = 1$: As médias das variáveis padronizadas tempo de experiência e anos de estudo são iguais a zero. Então, que a soma de quadrados dentro do grupo é:

$$SQ = (1,4102 - 0)^2 + (-1,3192 - 0)^2 + \dots + (-0,3876 - 0)^2 = 22,0000$$

Para $k = 2$: As médias das variáveis tempo de experiência e anos de estudo segundo os grupos são apresentadas na Tabela 6.

Tabela 6 – Média do tempo de experiência e anos de estudo padronizada segundo os grupos

Grupos	Tempo de experiência	Anos de estudo
1	0,8643	0,3876
2	-0,8643	-0,3876

Fonte: Biblioteca *Ecdat*, Sistema R, 2020.

As somas de quadrados dentro dos grupos são:


$$SQ \text{ do grupo } 1 = (1,4102 - 0,8643)^2 + \dots + (0,8643 - 0,8643)^2 + (-0,3876 - 0,3876)^2 + \dots + (2,2701 - 0,3876)^2 = 5,9745$$

$$SQ \text{ do grupo } 2 = (-1,3192 - (-0,8643))^2 + \dots + (-1,3192 - (-0,8643))^2 + (0,2768 - (-0,3876))^2 + \dots + (-0,3876 - (-0,3876))^2 = 5,2590$$

$$SQ = 5,9745 + 5,2590 = 11,2335 \quad (SQ \text{ grupo } 1 + SQ \text{ grupo } 2)$$

Observem que, quando se considera apenas um grupo, a soma de quadrados é igual a 22,0000 e, ao considerar dois grupos, esse valor diminui para 11,2335. É possível construir um gráfico mostrando as somas de quadrados *intra-clusters* (dentro dos grupos), *versus* o número de grupos (k), como mostra o gráfico da Figura 4.

Figura 4 – Soma de quadrados dentro dos grupos para diferentes números de grupos



Fonte: Biblioteca *Ecdat*, Sistema R, 2020.

Por meio do gráfico da Figura 4, é possível observar que, à medida que aumenta o número de grupos, a soma de quadrados dentro dos grupos diminui. Dessa forma, é possível definir o número de grupos para a análise de agrupamento.

TEMA 4 – AVALIAÇÃO DE MODELOS PARA ANÁLISE DE AGRUPAMENTO

A avaliação do resultado obtido na análise de agrupamento é normalmente chamada de *validação* (Silva; Peres; Boscarioli, 2016).

A análise de *Silhouette* é um método de interpretação e validação de consistência dentro dos agrupamentos (*clusters*) de dados. O índice *Silhouette* é uma medida de quão semelhante um objeto é ao seu próprio *cluster* (coesão) em comparação com outros *clusters* (separação). Pode ser usado para estudar a distância de separação entre os *clusters* resultantes.

Se o valor do índice *Silhouette* for alto, o objeto corresponderá bem ao seu próprio *cluster* e corresponderá mal aos *clusters* vizinhos.

O coeficiente de *Silhouette* é definido por meio de:

$$S(i) = \frac{b(i) - a(i)}{\max\{(a(i) - b(i))\}} \quad (5)$$

em que:

$a(i)$ é a distância média do objeto i a todos os demais objetos de seu grupo;

$b(i)$ é a distância média do objeto i a todos os demais objetos do grupo mais próximo.

Se o índice *Silhouette* for próximo de 1, os objetos estão bem agrupados e se o índice *Silhouette* estiver próximo de -1, os objetos estão classificados incorretamente.

TEMA 5 – EXEMPLOS DE APLICAÇÃO

Vamos considerar o arquivo *mtcars*, disponível no sistema R, contendo 32 observações e as seguintes variáveis selecionadas para proceder a análise de agrupamento (Battisti; Smolski, 2019):

mpg: milhas / galão (EUA)
cyl: número de cilindros
disp: deslocamento (cu.in)
hp: cavalos-força brutos
drat: relação do eixo traseiro
wt: peso (1.000 libras)
qsec: tempo de 1/4 de milha

Para acessar o arquivo de dados e apresentar as primeiras 7 observações do novo arquivo dados:

```
data(mtcars)
dados<-mtcars
dados1<-mtcars[,1:7] # seleciona as 7 variáveis
head(dados1,n=5)
```

	mpg	cyl	disp	hp	drat	wt	qsec
Mazda RX4	21.0	6	160	110	3.90	2.620	16.46
Mazda RX4 Wag	21.0	6	160	110	3.90	2.875	17.02
Datsun 710	22.8	4	108	93	3.85	2.320	18.61
Hornet 4 Drive	21.4	6	258	110	3.08	3.215	19.44
Hornet Sportabout	18.7	8	360	175	3.15	3.440	17.02

5.1 Método de agrupamento hierárquico aglomerativo

Em primeiro lugar, é necessário padronizar os dados, usando a função *scale* do R:

```
dadosp<-scale(dados1)
head(dadosp, n=3)
> head(dadosp, n=3)
```

	mpg	cyl	disp	hp	drat	wt	qsec
Mazda RX4	0.1509	-0.105	-0.5706	-0.5351	0.5675	-0.6104	-0.7772

```
Mazda RX4 Wag 0.1509 -0.105 -0.5706 -0.5351 0.5675 -0.3498 -0.4638
Datsun 710      0.4495 -1.225 -0.9902 -0.7830 0.4740 -0.9170  0.4260
```

Cálculo da matriz de distância euclidiana entre variáveis:

```
md<-dist(dadosp,method="euclidean")
```

Para escolher o tipo de distância entre grupos para produzir os agrupamentos será utilizada a seguinte função:

```
install.packages("cluster") # instala a biblioteca cluster
install.packages("purrr")   # instala a biblioteca purrr
library(cluster)           # ativa a biblioteca cluster
library(purrr)             # ativa a biblioteca purr
m <- c("average", "single", "complete", "ward")
names(m) <- c("average", "single", "complete", "ward")
# função para calcular o coeficiente aglomerativo
ca <- function(x) {
  agnes(md, method = x)$ac}
map_dbl(m, ca)
```

O coeficiente aglomerativo (ca) permite-nos encontrar o tipo de distância que pode identificar estrutura melhor.

```
> map_dbl(m, ca)

average  single complete    ward
0.7864   0.5807   0.8765   0.9396
```


O maior coeficiente aglomerativo é do método de Ward, será, portanto, o método adotado.

```
agrupamento <- agnes(md, method = "ward")
pltree(agrupamento, cex = 0.6, hang = -1,
       main = "DENDROGRAMA - MÉTODO DE WARD",
       cex.main=0.9,
       ylab="Altura",
       xlab="Marcas")
rect.hclust(agrupamento,k=2,border="red")
```

O gráfico da Figura 5 mostra o resultado do agrupamento. Os retângulos em vermelho indicam os 2 grupos de marcas de carros, definidos com base na análise dos índices *Silhouette*, apresentado no gráfico da Figura 6. Observem que para k=2, o índice *Silhouette* apresenta maior valor, e quanto mais próximo de 1,


mais bem agrupados estão os dados. Dessa forma, as observações foram divididas em 2 grupos.

Figura 5 – Dendrograma segundo o método aglomerativo



Fonte: Biblioteca *Ecdat*, Sistema R, 2020.

Figura 6 – Índice *Silhouette* segundo número de grupos



Fonte: Biblioteca *Ecdat*, Sistema R, 2020.

Os procedimentos para obtenção dos índices *Silhouette* no R.

```
install.packages("fpc") # instala a biblioteca fpc
library(fpc) # ativa a biblioteca fpc
sil<-function(k) {
  grupo<-cutree(agrupamento,k)
  val<-cluster.stats(md,grupo)
  val$avg.silwidth }
k<-2:5
media_sil<-map_dbl(k, sil)
```

```
plot(k, media_sil,
     main="ÍNDICE SILHOUETTE SEGUNDO NÚMERO DE GRUPOS k",
     cex.main=0.9,
     type = "b", pch = 19, frame = FALSE,
     xlab = "Número de grupos k",
     ylab = "Índice Silhouette",
     ylim=c(0.1,0.6))
```


5.2 Método de agrupamento hierárquico divisivo

Considerando o mesmo exemplo, foi utilizado o método de agrupamento divisivo.

```
data(mtcars)
dados<-mtcars
dados1<-mtcars[,1:7] # seleciona as 7 variáveis
dadosp<-scale(dados1)
md<-dist(dadosp,method="euclidean")
library(cluster)
agrupa<-diana(dadosp, metric = "euclidean")
pltree(agrupa, cex = 0.6, hang = -1,
       main = "DENDROGRAMA - MÉTODO DIVISIVO",
       cex.main=0.9,
       ylab="Altura",
       xlab="Marcas",
       sub="Método Diana")
rect.hclust(agrupa,k=2,border="red")
```

O gráfico da Figura 7 mostra o resultado do agrupamento pelo método divisivo.


Figura 7 – Dendrograma segundo método divisivo



Fonte: Biblioteca *Ecdat*, Sistema R, 2020.

Os retângulos em vermelho indicam os 2 grupos de marcas de carros, definidos com base na análise dos índices *Silhouette*, apresentado no gráfico da Figura 8. Observem que para $k=2$, o índice *Silhouette* apresenta maior valor, e quanto mais próximo de 1, mais bem agrupados estão os dados. Dessa forma, as observações foram divididas em 2 grupos.

Figura 8 – Índice *Silhouette* segundo número de grupos



Fonte: Biblioteca *Ecdat*, Sistema R, 2020.

Os procedimentos para obtenção dos índices *Silhouette* no R.

```
library(fpc)
library(purrr)
sil<-function(k) {
  grupo<-cutree(agrupa, k)
  val<-cluster.stats(md, grupo)
  val$avg.silwidth }
```

```

k<-2:5
media_sil<-map_dbl(k, sil)
plot(k, media_sil,
     main="ÍNDICE SILHOUETTE SEGUNDO NÚMERO DE GRUPOS k",
     cex.main=0.9,
     type = "b", pch = 19, frame = FALSE,
     xlab = "Número de grupos k",
     ylab = "Índice Silhouette",
     ylim=c(0.1,0.6))

```

5.3 Método de agrupamento de k-médias

Considerando o mesmo exemplo para aplicar o método de agrupamento k-médias, deve-se proceder conforme segue para definir o número ótimo de grupos.


```

data(mtcars)
dados<-mtcars
dados1<-mtcars[,1:7]
dadosp<-scale(dados1)
set.seed(123)
SQ <- function(k) {
  kmeans(dadosp, k, nstart = 10 )$tot.withinss
}
k <- 1:5
install.packages("tidyverse") # instala a biblioteca tidyverse
library(tidyverse)
SQval <- map_dbl(k, SQ)
plot(k, SQval,
     type="b", pch = 19, frame = FALSE,
     main="SOMA DE QUADRADOS DENTRO DOS GRUPOS EM FUNÇÃO DE k",
     cex.main=0.8,
     xlab="Número de grupos k",
     ylab="SQ dentro dos grupos",
     ylim=c(0,250))

```

O gráfico da Figura 9 mostra a soma de quadrados dentro dos grupos, para diferentes números de grupos.

Figura 9 – Soma de quadrados dentro dos grupos segundo diferentes números de grupos



Fonte: Biblioteca *Ecdat*, Sistema R, 2020.

É possível observar que, com base em k igual a 2, a soma de quadrados dentro dos grupos não se reduz significativamente. Adota-se, assim, o número de grupos igual a 2.

```
set.seed(123)
kmedias=kmeans(dadosp, 2, nstart=25)
```

Desejando obter a média das variáveis de cada grupo, basta executar o seguinte comando:

```
aggregate(dados1, by=list(cluster=kmedias$cluster), mean)
```

É possível visualizar as observações e o grupo a que pertence cada uma delas.

```
mtcars.grupo=cbind(mtcars, cluster=kmedias$cluster);
mtcars.grupo
```

As marcas de carros pertencentes a cada grupo:

- **Grupo 1:** Mazda RX4, Mazda RX4 Wag, Datsun 710, Hornet 4 Drive, Valiant, Merc 240D, Merc 230, Merc 280, Merc 280C, Fiat 128, Honda Civic, Toyota Corolla, Toyota Corona, Fiat X1-9, Pors 914-2, Lotus Europa, Ferrari Dino e Volvo142E;
- **Grupo 2:** Hornet Sportabout, Duster 360, Merc 50SE, Merc 450L, Merc 450SLC, Cadillac Fleetwood, Lincoln Continental, Chrysler Imperial, Dodge Challenger, AMC Javelin, Camaro Z28, Pontiac Firebird, Ford Pantera L e Maserati Bora.


5.4 Avaliação de modelos para análise de agrupamento

Considerando o exemplo do agrupamento pelo método de k-médias, a avaliação dos agrupamentos será feita por meio do índice *Silhouette*.

```
library(cluster)
set.seed(123)
media_sil <- function(k) {
  km.res <- kmeans(dadosp, centers = k, nstart = 25)
  ss <- silhouette(km.res$cluster, dist(dadosp))
  mean(ss[, 3])}
k <- 2:5
# extraindo a média de silhouette para 2 - 5 grupos
media_sil_val <- map_dbl(k, media_sil)
plot(k, media_sil_val,
     main="ÍNDICE SILHOUETTE SEGUNDO NÚMERO DE GRUPOS k",
     cex.main=0.9,
     type = "b", pch = 19, frame = FALSE,
     xlab = "Número de grupos k",
     ylab = "Índice Silhouette",
     ylim=c(0.1,0.6))
```

O gráfico da Figura 10 a seguir, mostra que o índice *Silhouette* apresenta maior valor para k=2 grupos, validando o número de grupos definidos no agrupamento pelo método de k-médias.

Figura 10 – Índice *Silhouette* segundo número de grupos



Fonte: Biblioteca *Ecdat*, Sistema R, 2020.

REFERÊNCIAS

BATTISTI, I. D. E.; SMOLSKI, F. M. S. **Software R**: curso avançado. Cerro Largo, RS: UFFS, 2019. Disponível em: <<https://smolski.github.io/livroavancado/>>. Acesso em: 11 mar. 2021.

BUSSAB, W. O.; MIAZAKI, E. S.; ANDRADE, D. F. Introdução à análise de agrupamentos. In: 9º SIMPÓSIO NACIONAL DE PROBABILIDADE E ESTATÍSTICA. São Paulo, jul. 1990.

CASTRO, L. N. de; FERRARI, D. G. **Introdução à mineração de dados**: conceitos básicos, algoritmos e aplicações. São Paulo: Saraiva, 2016.

HAIR JR, J. F. et al. **Multivariate data analysis**. 7. ed. London: Prentice Hall, 2010.

JOHNSON, R. A.; WICHERN, D. W. **Applied multivariate statistical analysis**. 4 ed. London: Prentice Hall, 1998.

RENCER, A. C. **Methods of multivariate analysis**. 2. ed. New York: John Wiley & Sons, 2002.

SILVA, L. A. da; PERES, S. M.; BOSCARIOLI, C. **Introdução à mineração de dados: com aplicações em R**. Rio de Janeiro: Elsevier, 2016.