

Aula 6

Análise Preditiva

Profª Sachiko A. Lira

Métodos de agrupamento

A análise de agrupamento (*cluster analysis*) é uma técnica que permite encontrar nos dados uma estrutura de agrupamento natural


Variáveis tempo de experiência e anos de estudo

Tabela 1

ID	Tempo de experiência	Anos de estudo
1	10	11
2	5	12
3	10	12
4	8	11
5	6	13
6	6	10
7	8	12
8	9	12
9	7	11
10	9	15
11	6	9
12	5	11

Fonte: dados obtidos a partir da biblioteca Ecdat, Sistema R, 2020.

Variáveis tempo de experiência e anos de estudo




- As medidas de distâncias para variáveis quantitativas mais utilizadas são:
- Distância euclidiana: $d(\underline{x}, \underline{y}) = \sqrt{\sum_{j=1}^p (x_j - y_j)^2}$ (1)
- Distância de Minkowsky: $d(\underline{x}, \underline{y}) = \left(\sum_{j=1}^p |x_j - y_j|^r\right)^{1/r}$ (2)
- Distância de Manhattan (city block): $d(\underline{x}, \underline{y}) = \sum_{j=1}^p |x_j - y_j|$ (3)

- As distâncias euclidiana e de Manhattan entre 1 e 2 são respectivamente iguais a 5,1 e 6, e entre 1 e 3, são iguais a 1
- As distâncias indicam que os elementos 1 e 2 apresentam características distintas, entretanto, 1 e 3, similares

Métodos de agrupamento hierárquico

- Agrupamento aglomerativo (*agglomerative clustering*):** cada item de dados é considerado como um grupo individual, e grupos são recursivamente fundidos até produzir um bom agrupamento final
- Agrupamento divisivo (*divisive clustering*):** inicialmente, o conjunto de todos os dados é considerado como sendo um único grupo e, em seguida, ele é recursivamente dividido para produzir um bom agrupamento final


Agrupamento aglomerativo e divisivo



- A padronização pode ser feita por meio da seguinte transformação:
$$z_p = \frac{x_{pj} - \bar{x}_p}{s_j} \quad (4)$$
- Existem diferentes algoritmos de produzir agrupamentos:

- Menor distância (*single linkage*)
- Maior distância (*complete linkage*)
- Distância média (*average linkage*)
- Método de Ward


Exemplo de dendrograma



Método de agrupamento de k-médias

- O k-médias é um algoritmo de agrupamento iterativo que classifica objetos em determinado número predefinido de grupos (*clusters*)
- Este método de agrupamento é normalmente utilizado quando se têm muitos objetos para agrupar, com pequenas variações, por ser mais preciso

Soma de quadrados dentro dos grupos para diferentes números de grupos



Avaliação de modelos para análise de agrupamento

- A avaliação do resultado obtido na análise de agrupamento é normalmente chamada de validação (Silva; Peres; Boscarioli, 2016)
- O índice Silhouette é uma medida de quão semelhante um objeto é ao seu próprio cluster (coesão) em comparação com outros clusters (separação)

- O coeficiente de Silhouette é definido por meio de:

$$S(i) = \frac{b(i) - a(i)}{\max\{a(i) - b(i)\}}$$

(5)

- onde:

- $a(i)$ é a distância média do objeto i a todos os demais objetos de seu grupo
- $b(i)$ é a distância média do objeto i a todos os demais objetos do grupo mais próximo

- Índice Silhouette

- Próximo de 1: os objetos estão bem agrupados
- Próximo de -1: os objetos estão classificados incorretamente

Exemplos de aplicação

Método de agrupamento hierárquico aglomerativo


- Vamos considerar o arquivo *mtcars*, disponível no sistema R, contendo 32 observações e as seguintes variáveis selecionadas para proceder à análise de agrupamento (elaborado com base em Smolski, 2020):

- *mpg*: Milhas/galão (EUA)
- *cyl*: Número de cilindros
- *disp*: Deslocamento (cu.in)
- *hp*: Cavalos-força brutos
- *drat*: Relação do eixo traseiro
- *wt*: Peso (1000 libras)
- *qsec*: tempo de ¼ de milha

- Coeficiente aglomerativo (ca): permite-nos encontrar o tipo de distância que pode identificar estrutura melhor
- average single complete ward
- 0.7864 0.5807 0.8765 0.9396
- O maior coeficiente aglomerativo é do método de Ward, será portanto o método adotado

Dendrograma segundo método aglomerativo


Gráfico 3



Fonte: elaborado com base nos dados da biblioteca *Ecdat*, Sistema R, 2020

Índice *Silhouette* segundo número de grupos

Gráfico 4



Fonte: elaborado com base nos dados da biblioteca *Ecdat*, Sistema R, 2020


Método de agrupamento hierárquico divisivo

- Vamos considerar o mesmo exemplo, os dados disponíveis no arquivo *mtcars* e as mesmas variáveis

- mpg*: Milhas/galão (EUA)
- cyl*: Número de cilindros
- disp*: Deslocamento (cu.in)
- hp*: Cavalos-força brutos
- drat*: Relação do eixo traseiro
- wt*: Peso (1000 libras)
- qsec*: tempo de ¼ de milha

Dendrograma segundo método divisivo


Gráfico 5



Fonte: elaborado com base nos dados da biblioteca *Ecdat*, Sistema R, 2020

Índice *Silhouette* segundo número de grupos

Gráfico 6




Fonte: Elaborado com base nos dados da biblioteca *Ecdat*, Sistema R, 2020

Método de agrupamento de k-médias

- Vamos considerar o mesmo exemplo, os dados disponíveis no arquivo *mtcars* e as mesmas variáveis

- *mpg*: Milhas/galão (EUA)
- *cyl*: Número de cilindros
- *disp*: Deslocamento (cu.in)
- *hp*: Cavalos-força brutos
- *drat*: Relação do eixo traseiro
- *wt*: Peso (1000 libras)
- *qsec*: tempo de ¼ de milha

Soma de quadrados dentro dos grupos segundo número de grupos



- É possível observar que a partir de k igual a 2, a soma de quadrados total dentro dos grupos não se reduz significativamente. Adota-se assim o número de grupos igual a 2
- Grupo 1: Mazda RX4, Mazda RX4 Wag, Datsun 710, Hornet 4 Drive, Valiant, Merc 240D, Merc 230, Merc 280, Merc 280C, Fiat 128, Honda Civic, Toyota Corolla, Toyota Corona, Fiat X1-9, Pors 914-2, Lotus Europa, Ferrari Dino e Volvo142E


- Grupo 2: Hornet Sportabout, Duster 360, Merc 50SE, Merc 450L, Merc 450SLC, Cadillac Fleetwood, Lincoln Continental, Chrysler Imperial, Dodge Challenger, AMC Javelin, Camaro Z28, Pontiac Firebird, Ford Pantera L e Maserati Bora

Avaliação de modelos para análise de agrupamento

- Considerando o exemplo do agrupamento pelo método de k-médias, a avaliação dos agrupamentos será feita por meio do índice *Silhouette*
- O gráfico a seguir indica que o índice *Silhouette* é maior para k=2 grupos, validando o número de grupos definidos no agrupamento pelo método de k-médias

Índice *Silhouette* segundo número de grupos

Gráfico 8



Fonte: elaborado com base nos dados da biblioteca Ecdat, Sistema R, 2020