

Aula 1

Big Data

Prof. Douglas Eduardo Basso

1

Introdução

2

Mundo digital

- Hoje, estamos conectados digitalmente desde que acordamos até a hora de dormir, absorvendo um volume muito grande de conteúdo – e também gerando muito conteúdo. Esse fenômeno acontece no nosso dia a dia, seja em casa ou no trabalho. Aliás, esta é outra transformação. A computação está se tornando tão ubíqua que fica praticamente impossível separar o mundo físico do digital

3



4

Pirâmide do conhecimento

- Formada por
 - Dados: são as medições e observações
 - Informação: são os dados estruturados
 - Conhecimento: são as interpretações dessas informações
 - Sabedoria: é a justificativa na utilização desses conhecimentos

5

Ciência de dados

- Trata de obter o conhecimento e a informação, de forma sistemática, bem como normalizar e organizar esse conhecimento
- Faz o estudo de todo o ciclo de vida dos dados, desde a sua criação até o seu descarte

6

As novas ondas tecnológicas

- Sim, estamos falando de
 - Computação em nuvem
 - Mobilidade
 - Mídias sociais
 - *Big data*

- 7

- Olhar para as ondas tecnológicas de forma isolada é enganoso
- A magnitude e a velocidade das mudanças são muito maiores do que já vivenciamos em qualquer outra época da história da computação

Internet das coisas

- Em um futuro próximo, bilhões de dispositivos estarão interligados com a rede mundial de computadores (internet)
- Veículos, sistemas de compras, automação residencial e industrial, eletrodomésticos, controles logísticos e de tráfego
- Estes dispositivos serão capazes de trocar dados sem que seja preciso ligar cabos e criar conexões de rede

9

- # Produção de Dados

10

- O volume de informações geradas pela sociedade é assustador, o Facebook tem mais dados fotográficos que todos os pixels processados pela Kodak em toda a sua história
- De acordo com um estudo da EMC, o mundo usou mais de 2,8 zetabytes de dados (o equivalente a 2,8 trilhões de gigabytes, um volume inconcebível) em 2012



Meios de entrada de dados

- Devemos lembrar dos dispositivos que estão interligados ao computador: teclados, *mouses*, escâner, telas sensíveis ao toque, leitores de códigos de barra, identificadores de radiofrequência, mesas digitalizadoras, entre outros
- Além de dispositivos que não estão conectados ao computador, como: câmeras de vídeo, máquinas fotográficas e dispositivos portáteis

13

Produção por processamento e análise

- O processamento de dados para análise ou para a execução de procedimentos operacionais, fechamento de folha de pagamento, por exemplo, também produzem volumes significativos de dados
- A criação de modelos estatísticos ou de aprendizado de máquina são outras formas de produção por análise

14

Produção por transformação

- Transformar dados é alterar sua estrutura e torná-los adequados a um processo específico
- A transformação de dados não é uma mera cópia com pequenas adequações
- Embora possa manter a essência dos dados de origem em alguns casos, normalmente ocorrem transformações estruturais significativas neles, inclusive aumentando o seu volume

15

Sensores

- São uma seção à parte
- Os telefones celulares têm uma série de sensores
 - Os *smartphones* podem executar atividades de vários dispositivos em um único equipamento
 - O telefone celular pode ter: bússola, GPS, rádio, TV, câmera fotográfica, filmadora, *videogame*, entre outros

16

- Tipos de sensores encontrados em um *smartphone*
 - Câmeras: produz maior volume de dados
 - Touch screen*: lê os toques da tela
 - Acelerômetro: mede a aceleração do objeto em três eixos

17

- GPS: detecta a localização do celular. Pode utilizar a triangulação com as antenas de celular ou conexão com três ou quatro satélites
- Giroscópio: detecta a orientação do celular em três eixos
- Magnetômetro: mede o campo magnético da terra. Tem aplicação para um aplicativo de bússola, por exemplo

18

Big Data

19

- ***Big data*** significa coisas diferentes para pessoas diferentes. A extensa cobertura da mídia, não apenas de tecnologia, mas também de negócios, contribui para gerar mais confusão, pois as reportagens e os textos abordam o ***big data*** sobre diversas óticas

20



TIERNEYJO/SHUTTERSTOCK

21

Conceitos de *big data*

- O termo ***big data***, em tradução básica para a língua portuguesa, significa “grandes dados” (***big***: importante, enorme, imenso, volumoso) e foi definido originalmente no início dos anos 2000 por um analista do Gartner Group

22

- ***Big data***, em geral, é definido como ativos de altos volume, velocidade e variedade de informação que exigem custo benefício, de formas inovadoras de processamento de informações para maior visibilidade e tomada de decisão

23

- ***Big data*** é o termo utilizado para descrever grandes volumes de dados e que ganha cada vez mais relevância à medida que a sociedade se depara com um aumento sem precedentes no número de informações geradas a cada dia
- ***Big data*** = volume + variedade + velocidade
- O ***big data*** torna-se cada dia mais importante para que se invista nessa nova arquitetura, bem como em tecnologias, metodologias de análise e ferramentas de ***software*** adequadas

24

Dados digitais

- Até o ano 2000, podíamos dizer que a informação digital no mundo girava em torno de 25%, muitos dados ainda eram preservados em papel, livros e outros tipos de documento. Já de meados de 2012 a 2014, o percentual de toda a informação gerada que estava presente em meio digital subiu para algo em torno de 98%

25

Muitos dados gerados

- Estamos presenciando um *boom* de informações, seja por aplicações corporativas, seja pela internet e suas redes sociais, assim como por *smartphones* e celulares, equipamentos leitores de RFID e câmeras de controle de vídeo para segurança e tráfego, que geram uma grande massa de dados complexos, estruturados e não estruturados

26

Por que *big data*?

- Big data* é o fenômeno em que dados são produzidos em vários formatos e armazenados por uma grande quantidade de dispositivos e equipamentos. Os insumos de tecnologia, como processadores, memórias e unidades de armazenamento, vêm se tornando cada vez mais acessíveis

27

- O barateamento, a miniaturização e o aumento da capacidade de processamento levam à disseminação de equipamentos, dispositivos e processos capazes de produzir e armazenar dados. A virtualização, a computação em nuvem e a internet impulsionaram o chamado *big data*

28

Impactos do *big data*

- O *big data* é um recurso tão amplo que é difícil vislumbrar todas as maneiras pelas quais ele pode afetar uma organização. Ele pode mudar a natureza de trabalho em muitas áreas específicas, conforme o cenário que a organização esteja inserida. Os maiores desafios envolvem a natureza dos sistemas de integração, como desenvolver padrões de dados e reunir os dados necessários. As mudanças devem ser feitas nos negócios, e não puramente nas questões tecnológicas

29

Os Vs do *Big Data*

30

- Embora, normalmente, o termo *big data* esteja associado a grandes volumes de dados, sua definição formal é dada por um conjunto de três a cinco Vs
- Inicialmente, a definição para Vs é de dados produzidos com volume, velocidade e variedade
- Para dois Vs a mais, aparecem outras definições: veracidade e valor
- Estes conceitos não fazem menção às causas e às consequências

31

Os 3Vs

- Doug Laney, analista do Gartner Group, estruturou uma definição de *big data* como sendo composta por três Vs:
- Volume: hoje as organizações conseguem coletar dados em uma grande variedade de fontes, que incluem transações comerciais, redes sociais, informações dos mais diversos sensores ou de dados transmitidos de máquina a máquina

32

- Velocidade: os dados são criados e fluem em uma velocidade sem precedentes e devem ser tratados em tempo hábil. Dados de sensores RFID, celulares e contadores inteligentes estão impulsionando a necessidade de capacitação para lidar com estas imensas quantidades de dados em tempo real, ou quase real

33

- Variedade: os dados são gerados no mais diversos tipos de formatos – dados estruturados, dados numéricos em bancos de dados tradicionais, até documentos de texto não estruturados, dados de um e-mail, vídeos, áudios e dados de cotações da bolsa e transações financeiras

34


Os cinco Vs

- Segundo Machado, para o *big data*, temos que considerar como base cinco grandes pilares, que são os cinco Vs: velocidade, volume, variedade, veracidade e valor. Acrescenta-se, aqui, dois Vs importantíssimos: a veracidade dos dados e o valor destes para a empresa

35

- Veracidade: necessidade que temos de garantir que os dados coletados sejam autênticos (com relação à fonte da informação) e que são verdadeiros naquele momento. Devemos lembrar que nem tudo que postado em rede social é verdadeiro e confiável, assim como todos os sistemas podem possuir dados com erros
- Valor: ponto mais destacado em relação a aplicações de *big data*

36



37




38

BI e big data

- O *business intelligence* (BI) é o sustentáculo de *big data*. Não temos *big data* sem antes termos um BI organizado estruturado e com seus indicadores-chave de desempenho (KPIs) claramente definidos. Apenas dessa forma é possível buscar, explorar e analisar as informações capturadas para *big data*. Os dois podem e devem coexistir simultaneamente

39



40

- Ambas as tecnologias e arquiteturas trabalham com extração ou captura de dados, modelam a arquitetura desses dados e têm por fim sua interpretação
- O *big data* não seria um grande *data warehouse*? Ou um BI feito em cima de *terabytes* e *petabytes* de dados? Essas são questões comuns

41

- *Big data* não é um novo BI
- É importante entender que, em *big data*, os recursos de análise preditiva devem ser intrínsecos a este conjunto de tecnologias, específicos em sua aplicação para melhorar a interpretação dos dados e ser possível antecipar possíveis comportamentos. Mais do que um BI aprimorado, o *big data* apresenta a inclusão de ferramentas e processos matemáticos de inteligência na soluções com base na análise de grandes volumes de dados, diversos em origem e formato e em constante criação e movimento

42


Big data e BI tradicional

- As implementações de uma solução de big data exigem que já se tenha anteriormente uma boa maturidade na utilização de BI
- **Orientação temporal:** de forma geral, o BI tradicional consiste em olhar para janelas de tempo de datas já ocorridas, ou seja, o passado dos dados. Essas janelas de tempo podem se tratar de anos, meses ou dias. Na maioria dos casos, o tempo é um dia anterior

43

- **Orientação analítica:** em projetos de BI, é muito comum tendências serem descobertas por meio de conceitos conhecidos e preestabelecidos, muitas vezes utilizando indicadores padrão de mercado, acompanhando as estas evoluções com o passar do tempo. Decisões são tomadas com base em análises e regras predefinidas

44



45