

| BIG DATA

TEMA 1 – ARMAZENAMENTO

O armazenamento de dados está relacionado com a utilização de mídias de gravação para a retenção desses dados, por meio de servidores, computadores, entre outros dispositivos. O armazenamento de dados pode ser feito por meio de arquivos, blocos e objetos, cada qual ideal para o cenário em que será utilizado. Esse armazenamento garante a recuperação desses dados no futuro. Cópias de segurança e replicações são utilizadas para produzir informações e transformá-las em conhecimento. Um bom armazenamento apresenta: segurança, integridade, disponibilidade, redundância reduzida, controle de concorrência, otimização de recursos, entre outras premissas.

O armazenamento pode ser realizado em dispositivos voláteis ou não voláteis. Dispositivos voláteis são aqueles que mantêm o estado dos dados enquanto o dispositivo estiver ligado à energia elétrica; sem a energia, os dados são perdidos. Como exemplo de armazenamento volátil, podemos citar a memória RAM de um computador. Já os dispositivos não voláteis têm a capacidade de manter os dados mesmo sem a presença de energia elétrica. Exemplos de dispositivos não voláteis são os discos rígidos, os discos ópticos, a memória *flash* e as unidades de disco sólido (discos SSD).

Durante a utilização dos dados são feitas diversas replicações entre vários tipos de dispositivos para diferentes finalidades. Essas replicações podem transferir os dados sem nenhum tipo de alteração em seu valor ou sua estrutura, até mesmo para um processo de cópia de segurança, em que os dados apenas mudam de mídia de gravação.

Já durante a criação e a construção de um *data warehouse*, os dados e as suas estruturas acabam sendo alterados com o intuito de acrescentar e qualificar melhor esses mesmos dados, tornando suas estruturas mais adequadas, preservando métricas de tempo e seus históricos. Os dados podem ser armazenados de maneira flexível ou rígida, utilizando uma estrutura de dados. Durante a sua utilização, podem ser transferidos por diferentes tipos de estruturas de armazenamento.

Com o início do uso massivo de computadores nos anos 1950 para manter sistemas de operações, folhas de pagamento e contabilidade, surgiu a necessidade de criar sistemas capazes de gerenciar dados com maiores volumes e estruturas mais complexas. Gerência essa de inclusão, alteração e exclusão de

dados, integridade e segurança de dados, bem como sua indexação. Existem quatro grandes fases desses modelos (Amaral, 2016): os pré-relacionais (com modelo hierárquico e rede), iniciados em 1960; os relacionais, dos anos 1970; os orientados a objetos, nos anos 1980; e, finalmente, o NoSQL, dos anos 2000, que será visto com mais detalhes nas próximas aulas.

1.1 Modelos pré-relacionais

Na era pré-relacional, na década de 1960, foram criados alguns modelos com estruturas de navegação. Os dados eram gravados em registros com vínculos. Os modelos pré-relacionais não representavam de maneira adequada as relações do mundo real, havia muitos problemas de desempenho e não havia linguagens de consulta declarativas. A manipulação de registros era feita de maneira lenta e as consultas exigiam programações feitas em aplicações. Surgiram dois modelos de bancos que tinham como base a navegação: o modelo hierárquico e o modelo em rede.

1.2 Modelos relacionais

O modelo relacional foi criado em 1970 por Edgar Frank Codd. O objetivo era criar um modelo sucessor do hierárquico e do modelo em rede, mantendo a integridade entre as transações e minimizando a redundância de dados. O modelo se mostrou eficiente em aplicações de negócio, em operações de inclusão, alteração e exclusão, mantendo a integridade durante as operações. O modelo relacional é baseado na álgebra relacional (Amaral, 2016, p. 25).

Hoje, a maioria das aplicações tem suporte para múltiplos usuários e o banco de dados deve garantir e assegurar a confiabilidade de transações, devendo também ter um controle de concorrência eficiente. Uma transação nada mais é que um sequenciamento de operações executadas com uma única unidade lógica de trabalho.

Dentro desse contexto, foi criado um conceito chamado *ACID*, que apresenta quatro propriedades de transações de banco de dados: **a**tomicidade, **c**onsistência, **i**solamento e **d**urabilidade.

- **Atomicidade:** quando uma transação envolve duas ou mais partes de informações, ou quando a transação está sendo executada totalmente ou

não. Mesmo não executada é uma forma de garantir que transações sejam atômicas.

- **Consistência:** nessa propriedade, a transação forma um novo estado válido dos dados e, em caso de falha, a consciência retorna todos os dados para o seu estado anterior ao início da transação, o que os administradores de dados chamam de *rollback*. Isso mostra consistência.
- **Isolamento:** durante o processamento de uma transação ainda não completada, deve-se permanecer isolado de qualquer outra operação, garantindo que a transação não sofra interferência de outra transação concorrente.
- **Durabilidade:** os dados devem ser validados e devidamente registrados pelo sistema, de tal maneira que, em caso de falha e/ou reinício do sistema, os dados estejam disponíveis e permaneçam em seu estado correto.

O modelo relacional obteve sucesso. Ocorreram muitas evoluções desse modelo com o incremento de algumas características, como capacidade de cópia de segurança incremental, replicação de dados, operação com sistemas distribuídos, distribuição de carga, tolerância a falhas, entre outras.

No modelo relacional, Codd propôs a criação de tabelas, com estrutura fixa e rígida. Um processo de normalização divide os dados entre várias tabelas, dependendo da estrutura que está sendo armazenada. Uma tabela deve ter um identificador único, a chamada *chave primária*, que pode ter valor semântico ou incremental produzido pelo próprio gerenciador de banco de dados. A relação entre as tabelas se dá entre a chave primária na tabela de origem e chave estrangeira na tabela relacionada (Amaral, 2016, p. 25).

O modelo relacional se mostrou eficiente e eficaz nos cenários em que foi aplicado e em projetos, porém, as regras de normalização não se mostraram muito boas para a análise de dados. Quando o objetivo é integrar e consolidar informações, a atividade se torna complexa, e é necessário realizar uma série de cálculos com várias junções e concatenações para cada informação. Essas operações acabam tendo um custo computacional muito maior para o gerenciador do banco de dados, e isso reflete negativamente no funcionamento do banco de dados.

Na década 1990, houve uma disseminação do modelo multidimensional e do *data warehouse*. Com o advento da internet e a chegada do Big Data, surgiram outros requisitos para o armazenamento de dados, como redundância,

escalabilidade e segurança, e capacidade de processamento de dados não estruturados, cenário este em que o modelo relacional não apresentou bom desempenho. Dessa forma, começou a ser criada uma nova geração de sistemas de gerenciamento de banco de dados, os chamados *NoSQL*, elaborados para suportar e atender aos novos tipos de aplicações. Trata-se de uma tecnologia diferente para enfrentar novas problemáticas. Os bancos de dados relacionais mais populares são: Microsoft SQL Server, IBM DB2, Oracle, MySQL e PostgreSQL.

1.3 Banco de dados orientado a objetos

Nos meados de 1980 as linguagens de programação orientadas a objeto, como Delphi e C++ começaram a se tornar dominantes. O modelo buscava abstrair entidades reais do mundo em objetos descritos por atributos e procedimentos executados como métodos. Surgiram então sistemas gerenciadores de banco de dados orientados a objetos que tinham como objetivo suportar de forma natural o modelo orientado a objetos das linguagens de programação. Porém, naquela época, os bancos de dados relacionais já eram extremamente populares e maduros. (Amaral, 2016, p. 30)

Uma nova linha de gerenciadores de banco de dados implementou, então, um modelo conhecido como *banco de dados objeto-relacional*. Esse modelo orientado de objetos é suportado, mas com suporte a elementos de sistemas relacionais, como linguagens de consulta como por exemplo o SQL.

TEMA 2 – BANCO DE DADOS NÃO RELACIONAIS

Uma grande mudança tem ocorrido em função das estruturas não rígidas e de dados não estruturados, coletados e armazenados, em Big Data sem estarem no formato de listas ou tabelas, dos quais surge a linguagem NoSQL, que não exige uma estrutura predefinida para funcionar e aceita dados de vários tipos e tamanhos para explorar.

Bancos de dados não relacionais (NoSQL) apresentam como diferença, quando comparados aos bancos de dados relacionais, a ausência de um esquema de tabelas em linhas e colunas normalizadas. Em geral, uma chave de partição é utilizada para recuperar valores, conjuntos de colunas ou documentos semiestruturados que contenham atributos de itens relacionados. Os bancos de dados NoSQL normalmente trocam algumas propriedades *ACID* de sistemas de gerenciamento de bancos de dados relacionais por um modelo de dados com mais flexibilidade e com escala horizontal (Machado, 2018, p. 56).

2.1 NoSQL

Os bancos de dados não relacionais ficaram conhecidos como *NoSQL* e, com a popularização das mídias sociais, a geração cada vez maior de conteúdo por smartphones e o número cada vez maior de pessoas e dispositivos conectados à internet criaram um cenário muito maior de atividades relacionadas com armazenamento de dados com foco na utilização em ferramentas analíticas. Isso gerou uma nova classe de banco de dados com maior escalabilidade e desempenho. É possível utilizar uma linguagem declarativa para consultar dados do banco de dados NoSQL, entretanto, são bancos de dados que simplesmente não têm sua essência baseada em modelos relacionais.

O modelo relacional foi desenvolvido sob as premissas de normalização, integridade e não redundância de dados. Essas novas aplicações precisavam de maior processamento, volume e muita escalabilidade. O desenvolvimento dessa nova forma de gerência de dados provocou a concepção de uma série produtos sem as principais características do modelo relacional: os dados não normalizados, poucas regras de integridade e mínimo controle de transações. Como resultado, essas soluções se mostraram mais escaláveis, flexíveis e com valores mais acessíveis.

Em geral, desempenho é uma função do tamanho do *cluster* do hardware subjacente, da latência de rede e da aplicação que faz a chamada de acesso ao banco de dados. Um banco de dados NoSQL é projetado para aumentar a sua escala em sentido horizontal por meio de sistemas distribuídos em hardware de baixo custo para aumentar as taxas de transferência de dados sem aumentar a latência (Machado, 2018, p. 57).

2.2 Tipos de banco de dados NoSQL

Para Amaral (2016, p. 31), existem várias famílias de produtos NoSQL, e cada família compartilha de um mesmo modelo de armazenamento. O modelo mais tradicional, em vez de possuir uma tabela com um número fixo de colunas, trabalha com o conceito chave-valor, ou KVS, acrônimo para *Key-Value Store*. É o tipo de banco de dados mais simples, cujo conceito se baseia em uma chave e um valor para ela. No entanto, é ele que aguenta a maior carga de dados e possui a maior escalabilidade.

Isso significa que, em vez de incluir um conjunto de atributos, a operação insere apenas uma chave e um valor, nada mais. Algumas implementações do tipo KVS são *Couchbase*, *Kyoto Cabinet*, *Redis* e *DynamoDB*, da Amazon.

Já na especificação de colunas ordenadas (*wide columns store*), baseada no modelo *Bigtable* do Google, em vez de o dado ser orientado por linha, ele é orientado por coluna. São implementações desse modelo HBase, mantido pela fundação Apache, HyperTable da Cloudata e o Cassandra (Apache), que veremos com mais detalhes nas próximas aulas.

O terceiro grupo é orientado a documentos (*document store*), também armazenando um KVS, porém, os documentos são organizados em conjunto, permitindo o armazenamento de estruturas como um arquivo XML ou JSON. São exemplos de implementações desse modelo: MongoDB, Riak, RavenDB e CouchDB – este último também apresenta a função Apache (Amaral, 2016, p. 32).

Uma última categoria que deve ser destacada é a dos bancos de dados de grafos. Grafos são estruturas compostas por vértices ligados por arestas. Têm aplicações diversas em medicina, genética, economia e matemática. Bancos de dados como Neo4j e FlockDB têm estrutura otimizada para armazenar e operar sobre grafos. Grafos serão estudados posteriormente (Amaral, 2016, p. 32).

Os bancos NoSQL são indicados para grandes cargas de dados, aplicações com exigência de velocidade na consulta e de registro (escrita) em grandes volumes de dados (Machado, 2018).

2.3 Dados não estruturados, semiestruturados e estruturados

Os dados podem ser classificados em três tipos, levando em conta a sua estrutura:

- não estruturados: opostos aos de estrutura rígida. Os dados são armazenados de forma flexível e dinâmica ou sem estrutura. Exemplos comuns de dados não estruturados são documentos, fotos e vídeos, podendo misturar textos, áudios, gráficos, imagens, entre outros.
- dados semiestruturados: se apresentam de forma heterogênea. Possuem uma estrutura, mas ela é flexível, agregando um pouco os dados e mostrando alguns benefícios. Facilitam os controles por ter pouca estrutura e permitem maior flexibilidade. Os arquivos no formato XML são exemplos desse tipo de dados, como um endereço postal.

- dados estruturados: são aqueles que estão organizados e representados por uma rígida estrutura, como foi previamente planejado no armazenamento. O exemplo típico de dados estruturados são os bancos de dados relacionais.

Dentro desse contexto, podemos apontar que os modelos tradicionais de análise de dados são voltados para o tratamento de dados estruturados, que são aqueles que possuem uma estrutura rígida, normalmente organizados em colunas e linhas. Segundo algumas pesquisas, entre 80 e 90% dos dados existentes no mundo não são estruturados. Essa é, também, a estrutura de dados que mais cresce.

2.4 Transformação

A transformação de dados é um processo necessário para que os dados sejam produzidos em uma estrutura organizada e ajustada para o armazenamento e o processamento. Essas estruturas não se mostram adaptadas para outras operações, como uma análise desses dados. Apesar de existirem diversos motivos e métodos que exigem a transformação de dados, existem muitas estruturas que historicamente foram criadas e elaboradas para processos de análise. Uma delas, apresentada nos anos 1990, é a dos modelos dimensionais. A outra, mais recente, é a da construção de depósitos de dados em sistemas de arquivos distribuídos (HDFS, de *hadoop distributed file system*), que utiliza o modelo MapReduce.

2.5 ETL

O termo *ETL* é o acrônimo de *Extract, Transform and Load*, ou *extrair, transformar e carregar* (carga). Uma breve descrição a seguir:

- extração: nessa etapa, os dados são extraídos dos sistemas corporativos e enviados para uma área de transição temporária, onde são convertidos em um único formato.
- transformação: nessa fase são realizados alguns ajustes nos dados, o que pode melhorar a sua qualidade, levando à consolidação, à concatenação e ao cruzamento de dados de duas ou mais fontes.

- carga: a última fase consiste em estruturar fisicamente e carregar os dados para dentro de uma camada de apresentação, seguindo o modelo dimensional.

Esses processos envolvem todas as atividades relacionadas com a extração de dados de fontes externas. Essa transformação visa suportar todas as necessidades de negócios e de carga dos dados dentro de um *data warehouse* ou de um *data mart*, ou para outras demandas que envolvam importação e exportação de dados. Os processos de extração podem atuar desde a integração de dados à construção de modelos analíticos.

O ETL possui conexões com várias fontes de dados que podem ser heterogêneas e dispersas geograficamente; processos de extração, por meio da conexão, podem copiar dados dessas fontes; um processo de arquivamento que manterá os dados em disco temporariamente para a etapa posterior; e, por fim, os procedimentos de transformação e arquivamento que carregam os dados em sua fonte de dados definitiva.

O processo de transformação pode apresentar uma série de objetivos, como transformar modelos relacionais em modelos multidimensionais que devem incluir operações de junção, sumarização e cálculos diversos.

TEMA 3 – ARMAZENAMENTO ANALÍTICO

As estruturas de armazenamento de dados foram naturalmente evoluindo ou se adequando às novas necessidades. Veremos agora um pouco dos modelos analíticos, ou seja, dados estruturados, de forma a facilitar a sua análise. Embora os sistemas relacionais tenham se mostrado eficientes para suportar operações e manter dados de negócios operacionais e íntegros, o modelo não se mostrou eficiente no processo de geração de informação e conhecimento (Amaral, 2016, p. 39).

3.1 Data warehouse

O *data warehouse* (DW) teve sua origem no meio acadêmico na década de 1980. Trata-se do conceito de um banco de dados com capacidades de armazenamento e organização de um grande volume de dados, traduzido para o português como um armazém de dados. São verdadeiros depósitos, estruturados a partir de bancos de dados de operacionais, com estruturas relacionais. Sua

estrutura se altera, os dados são armazenados com o objetivo de facilitar a análise, com informações pré-calculadas e dados não normalizados (Amaral, 2016).

Dentre suas características, podemos citar a consistência, a organização, a variedade no tempo, a estrutura relacional, a utilização de modelos de cliente e servidor. Os dados podem ser extraídos de planilhas, sistemas de gestão integrada (ERP), sistema de relacionamento com o cliente (CRM), entre outros.

As vantagens de utilizar o DW são a qualidade de dados, a facilidade uso, o custo de operação, o acesso rápido, a simplicidade, as vantagens competitivas e auxiliar nas operações de decisão. Algumas desvantagens são os altos custos de desenvolvimento, a administração, o treinamento e a complexidade de desenvolvimento.

3.2 Data marts

Os *data marts* são subconjuntos de um *data warehouse*, que é um grande armazém de dados corporativo. Esse grande armazém de dados deve estar dividido e agrupado em partes menores, e geralmente são dados referentes a um assunto em especial, como vendas, controladoria, estoque, entre outros; além disso, destacam uma ou mais áreas: estes são os chamados *data marts*. Normalmente, os departamentos corporativos estão agrupados em diferentes *datas marts*, como: informática, recursos humanos, vendas etc.

3.3 Granularidade

Os *data warehouses* armazenam muitas informações gerenciais que geralmente não estão bem detalhadas. Para a tomada de decisão, quanto maior o detalhamento das informações, maior a flexibilidade para se conseguir respostas. O detalhamento é fornecido, geralmente, por meio de relatórios com o objetivo de fazer uma conferência, extraindo do sistema transacional para as áreas operacionais. O nível de detalhamento em que a informação gerencial é armazenada é conhecido como *grão*. Quanto menor o grão, maior o nível de detalhe, e mais performance e armazenamento são exigidos do *data warehouse*.

3.4 OLAP

OLAP, acrônimo de *Online Analytical Processing*, ou *processamento analítico em tempo real*, é uma ferramenta de *Business Intelligence* (BI) muito utilizada para apoiar as empresas na análise de informações, um tipo de gerenciador de banco de dados multidimensional que está associado à construção de cubos. Um *data warehouse* é construído em um OLAP server, que é um tipo de aplicação otimizada para gerência de dados em formato multidimensional. São ferramentas pelas quais os usuários têm acesso à extração de dados de suas bases para construir os relatórios capazes de responder às suas questões gerenciais.

TEMA 4 – CONSTRUÇÃO DE DATA WAREHOUSE

Segundo Amaral (2016, p. 48), a construção de armazéns analíticos envolve extrair, normalizar, transformar e carregar dados entre ambientes distintos. Esse processo é chamado de *ETL*, explicado anteriormente, e é executado por ferramentas de software, com função de extração de dados de diversos sistemas, transformando esses dados conforme regras de negócio e, por fim, a carga de dados. Construir um *data warehouse* é um processo complexo; é necessário ter a ajuda de profissionais especializados, o entendimento do negócio, compreender as estruturas de dados em sua origem e desenvolver processos.

4.1 OLAP (*Online Analytical Processing*) e OLTP (*Online Transaction Processing*)

OLTP, acrônimo de *Online Transaction Processing*, ou *processamento de transações em tempo real*, é o termo usado para se referir aos sistemas transacionais, ou seja, os sistemas operacionais das empresas.

São empregados no processamento dos dados de rotina que são criados diariamente por meio dos sistemas informacionais da organização e suportam as funções de execução do negócio organizacional. Diferenciando os termos, OLAP está no contexto de multidimensional/analítico, e OLTP está vinculado ao relacional/transacional.

O OLTP tem por finalidade manter a operação de departamentos por meio de inclusão, alteração, consulta, deleção e cálculos, reduzir a redundância de informações e manter a integridade dos dados. Já o OLAP busca facilitar a análise e, por isso, não há problema se houver dados repetidos.

4.2 Business Intelligence

A inteligência de mercado, ou simplesmente BI – acrônimo de *Business Intelligence* –, também chamado de *inteligência empresarial*, é um grande conjunto de metodologias, processos, teorias, estruturas, ferramentas, técnicas e tecnologias que transforma grandes volumes de dados em informações, gerando conhecimento, com o objetivo de dar apoio à tomada de decisões.

Geralmente, uma solução de BI está estruturada com base em um *data warehouse*; todavia, pode estar ainda relacionada diretamente a um sistema operacional, planilhas ou até arquivos textos.

4.3 Relatórios

Relatórios são conjuntos de informações detalhadas que têm a função de reportar de forma estática e sem interatividade resultados parciais ou totais de uma atividade ou processo, projeto, ação ou pesquisa. Normalmente, um relatório possui um caráter operacional, para atividades de conferência. Pode conter elementos gráficos para resumir dados. A informação pode aparecer agrupada ou resumida em níveis. As fontes de dados podem ser provenientes de um sistema transacional ou multidimensional, ou até mesmo planilhas ou arquivos textos.

4.4 Cubos

Cubos são representações multidimensionais de dados, que normalmente representam um único fato, em que, por meio de operações de *drill down* e *drill up*, o usuário pode aumentar ou diminuir o nível de detalhamento da informação. Nas linhas e colunas, um cubo representa dimensões; ao centro, medidas. Sua representação principal é textual, porém, algumas ferramentas podem facilmente produzir gráficos. Outras, mais sofisticadas, permitem ainda a inclusão de indicadores de performance dentro de células de medidas (Amaral, 2016, p. 50).

4.5 Dashboards e infográficos

Dashboards são painéis visuais que mostram métricas e indicadores importantes para alcançar algumas metas e objetivos de maneira visual, facilitando a compreensão das informações. Existem vários tipos de informações resumidas, normalmente com enfoque estratégico ou gerencial, mas também há aplicações de diversas áreas operacionais. Com o aumento exponencial do uso de dispositivos móveis, os *dashboards* também oferecem opções adaptadas para celulares ou *tablets*, normalmente com uma riqueza de conteúdo reduzida para a resolução desses dispositivos. O formato visual das informações ajuda muito essa compreensão. Possibilitam o monitoramento dos resultados em tempo real.

Já os infográficos são elementos e conteúdos visuais, mas que não estão conectados a uma fonte de dados; podem apresentar imagens, ilustrações, gráficos e pictogramas. A informação é tratada como um retrato estático em um ponto no tempo; é uma mistura perfeita entre textos e recursos visuais.

4.6 Balanced scorecard

Balanced scorecard, ou BSC, pode ser traduzido como *indicadores balanceados de desempenho*. Foi um sistema criado por Kaplan e Norton que tem um conjunto de objetivos com a finalidade de mensurar o desempenho de uma empresa sob quatro perspectivas: financeira; clientes; processos internos e aprendizado; e crescimento. Dentro dessas quatro perspectivas, são desenvolvidos uma série de indicadores que medirão a performance da organização. Um BSC consegue organizar e materializar a estratégia da organização, e provê um mapeamento para que os objetivos estratégicos sejam medidos. Além disso é também uma excelente ferramenta de gestão e tem muita aplicação prática como ferramenta de comunicação do planejamento organizacional.

TEMA 5 – ANÁLISE DE DADOS

A análise de dados é a aplicação de alguma forma de transformação nos dados em busca de conhecimento. É um processo de transformação de um conjunto de dados com o intuito de identificação e verificação desses dados. Dados podem ser criados para análise, como podem ser criados para manter operações de um departamento de uma organização e, posteriormente,

analisado. Veja, a seguir, de que forma podemos analisar os dados e quais são as técnicas mais comuns.

5.1 Análise explícita

Dentro das análises explícitas, a informação e o conhecimento estão disponíveis de forma explícita nos dados. Dessa forma, é normal que seja necessária apenas alguma operação ou um complemento, possui baixa complexidade e precisa apenas que alguns dados sejam ressaltados para produzir a informação. A informação está lá, explicitamente, é preciso apenas um destaque na multidão de dados.

5.2 Análise implícita

Na análise implícita, a informação nem sempre está disponível claramente dentro do conjunto de dados: mesmo que sejam observados os dados de várias maneiras, com filtros, classificações, seleções, ou que se faça algum tipo de cálculo, a informação só será encontrada com a utilização de alguma função mais complexa e sofisticada. Alguns dos exemplos de funções para esse tipo de análise são a utilização de tarefas de aprendizado de máquina e algumas leis estatísticas.

5.3 Análise exploratória

O objetivo é analisar conjuntos de dados e tentar resumir suas principais características. Emprega uma grande variedade de técnicas explícitas ou implícitas, gráficas e quantitativas para tirar algumas conclusões, visando sempre à máxima obtenção de informações ocultas em sua estrutura, além de encontrar variáveis importantes em suas tendências, observar comportamentos anômalos do fenômeno, verificar se são válidas as hipóteses assumidas, determinar modelos e apresentar os números ótimos de variáveis.

5.4 Técnica quantitativa

Dentre as técnicas quantitativas, podemos elencar as medidas de dispersão e posição como média, mediana, amplitude e desvio padrão. A maioria das ferramentas de análise de dados possibilitam a geração de medidas de dispersão de uma variável, como desvio padrão e variância. Essas técnicas são vistas como métodos mais complexos para a obtenção de conhecimento.

5.5 Histograma

Um histograma é um tipo de gráfico de apresenta frequências, que tem como finalidade apresentar uma determinada amostragem ou população de dados em certos intervalos de distribuição. Ele traz quantas vezes temos um determinado valor dentro de uma distribuição de dados. O histograma mostra uma informação quantitativa por vez, diferentemente de gráficos de barras, em que cada barra representa uma instância dos dados. O histograma é uma ferramenta de qualidade, que auxilia no controle de processos, tanto na indústria quanto no setor de serviços.

5.6 Nuvem de palavras

As nuvens de palavras são representações visuais de frequências e de valores das palavras. Ela é amplamente utilizada para dar um destaque na frequência que um termo apresenta ou em uma categoria específica que aparece em uma determinada fonte de dados. Quanto mais vezes essa palavra-chave aparecer em um conjunto de dados, maior e mais forte ela aparecerá na nuvem.

Pode parecer apenas um gráfico decorativo, entretanto, é muito utilizada na mineração de texto, podendo exibir termos mais frequentes em uma rede social e ser utilizada em análise de sentidos. O gráfico é criado a partir de um grupo de palavras vinculadas com sua frequência. Alguns elementos complementares, como fontes, cores, proporção entre palavras horizontais e verticais são definidas durante a geração do gráfico.

REFERÊNCIAS

AMARAL, F. **Introdução à ciência de dados:** mineração de dados e Big Data. Rio de Janeiro: Alta Books, 2016.

DAVENPORT, T. H. **Big data no trabalho:** derrubando mitos e descobrindo oportunidades. Tradução Cristina Yamagami. 1. ed. Rio de Janeiro: Elsevier, 2014.

MACHADO, F. N. R. **Big data:** o futuro dos dados e aplicações. São Paulo: Érica, 2018.

TAURION, C. **Big Data.** Rio de Janeiro: Brasport, 2013.