

Aula 2

Big Data

Prof. Douglas Eduardo Basso

1

Armazenamento

2

- Dados produzidos, normalmente, devem ser armazenados
- Isso garante que, no futuro, possa ser recuperado ou copiado, para replicar um processo ocorrido ou produzir informação ou conhecimento
- O armazenamento apresenta uma série de premissas que devem ser atendidas, como segurança da informação, integridade, minimização de redundância, concorrência, otimização de espaço, entre outros

3

- O armazenamento é realizado em um dispositivo volátil ou não volátil
- Um dispositivo volátil é aquele que mantém o estado dos dados enquanto houver energia elétrica; na falta dela, a informação se perde
- Um exemplo de armazenamento volátil é a memória RAM em PC

4

- Um dispositivo não volátil é capaz de manter os dados mesmo que o dispositivo não esteja ligado a uma fonte de energia
- Pode ser magnético como um disco rígido, um disco óptico, memória flash ou disco sólido

5



YAFETO/SHUTTERSTOCK

6

Modelos pré-relacionais

- Na era pré-relacional, na década de 1960, foram desenvolvidos modelos com estruturas de navegação, em que dados eram armazenados em registros vinculados
- Para recuperar um registro, era preciso navegar entre os vínculos criados entre eles
- Dois modelos de bancos com base em navegação se popularizaram: o modelo hierárquico e o modelo em rede

7

Modelos relacionais

- Esse modelo mantém a integridade entre as transações e minimiza a redundância de dados
- O modelo se mostrou eficiente em aplicações de negócio, em operações de inclusão, alteração e exclusão, mantendo a integridade durante as operações
- O modelo relacional tem como base a álgebra relacional

8

Operações transacionais

- As operações em sistemas transacionais possuem um conjunto de características conhecidos pelo acrônimo *ACID* – Atomicidade, Consistência, Isolamento e Durabilidade
- Para recuperar dados divididos em várias tabelas em um modelo relacional, a linguagem de consulta estruturada (*Structured Query Language*) é chamada de SQL

9

Banco de dados orientado a objeto

- O modelo buscava abstrair entidades reais do mundo em objetos descritos por atributos e procedimentos executados como métodos
- Surgiram, então, sistemas gerenciadores de banco de dados orientados a objetos que tinham a finalidade de suportar de forma natural o modelo orientado a objetos das linguagens de programação

10

Bancos de Dados Não Relacionais

- Apresentam como diferenças, quando comparados aos bancos de dados relacionais, a ausência de um esquema de tabelas em linhas e colunas normalizadas
- Em geral, uma chave de partição é utilizada para recuperar valores, conjuntos de colunas ou documentos semiestruturados que contenham atributos de itens relacionados

11

12

NoSQL

- Não se pode usar uma linguagem declarativa para consultar dados em um gerenciador NoSQL, são bancos de dados que não estão apenas baseados no modelo relacional
- É projetado para aumentar a sua escala em sentido horizontal por meio de sistemas distribuídos em hardware de baixo custo para aumentar as taxas de transferência de dados sem aumentar latência



13

14

Tipos de bancos NoSQL

- Existem várias famílias de produtos NoSQL, cada família compartilha um modelo de armazenamento
- O modelo mais tradicional, em vez de possuir uma tabela com um número fixo de colunas, trabalha com o conceito *chave-valor*, ou KVS, acrônimo para *Key-Value Store*

- Já na especificação de colunas ordenadas (*Wide Columns Store*), com base no modelo *Bigtable* do Google, em vez de o dado ser orientado por linha, ele é orientado por coluna
- São implementações deste modelo HBase, mantido pela fundação Apache: HyperTable da Cloudata e o Cassandra (Apache)

15

16

- O terceiro grupo são os orientados a documentos (*Document Store*), que também armazenam um KVS, porém, são organizados em conjunto, permitindo o armazenamento de estruturas como um arquivo XML ou JSON
- São exemplos de implementações deste modelo MongoDB: Riak, RavenDB e CouchDB, este último também da função Apache

- Uma última categoria que deve ser destacada é composta pelos Bancos de Dados de Grafos
- Grafos são estruturas compostas por vértices ligados por arestas
- Têm aplicação diversa na medicina, genética, economia e matemática
- Bancos de dados como Neo4j e FlockDB têm estrutura otimizada para armazenar e operar sobre grafos

17

18

Dados não estruturados e semiestruturados

- Os modelos tradicionais de análise de dados são adequados para tratar dados estruturados que são aqueles que têm uma estrutura rígida, normalmente organizados em linhas e colunas
- São exemplos de dados estruturados planilhas eletrônicas e tabelas em banco de dados

19

- Dados não estruturados não possuem qualquer tipo de estrutura definida
- Muitas vezes, este tipo de dado não possui sequer qualquer tipo de metadado, mesmo quando possuem, estes metadados não são de muita ajuda para um processo de análise

20

- São exemplos de dados não estruturados
 - Documentos em geral, páginas de internet, e-mails e postagens em redes sociais
- Dados não estruturados também não significam apenas informação textual, mas são também compostos por imagens, vídeos, arquivos de áudios, plantas de engenharia, entre outros

21

Transformação

- A transformação de dados é necessária porque os dados são produzidos em uma estrutura otimizada para persistência e processamento
- Essas estruturas não são boas para outras operações, como a análise de dados
- Apesar de existirem vários motivos e métodos que requerem transformação de dados, existem estruturas que historicamente são otimizadas para a análise

22

ETL

- ETL é acrônimo para *Extract, Transform and Load* (*Extrair, Transformar e Carregar*)
- O uso clássico de processos de ETL é para cargas de dados em *data warehouse*, porém, existem diversos outros tipos de processos, desde integração de dados à construção de modelos analíticos, que podem ser elaborados através destes processos

23

Armazenamento Analítico

24

- As estruturas de armazenamento de dados foram naturalmente evoluindo ou se adequando às novas necessidades, agora vamos ver um pouco sobre os modelos analíticos, ou seja, dados estruturados de forma a facilitar sua análise

25

Data Warehouse

- Na década de 1990, popularizou-se a construção de *data warehouses*, verdadeiros depósitos de dados, estruturados a partir de bancos de dados de operação, normalmente relacionais
- Sua estrutura difere no sentido em que os dados são armazenados no intuito de facilitar a análise, com informações pré-calculadas e dados não normalizados. Um *data warehouse* guarda informações históricas por um período de 3 a 10 anos

26

Data marts

- O *data warehouse* é um grande banco de dados analítico corporativo
- Esse banco de dados deve estar dividido em partes menores e melhor gerenciáveis conhecidos como *data marts*
- Normalmente, os departamentos corporativos estão agrupados em diferentes *data marts*, como finanças, contabilidade, recursos humanos, CRM etc.

27

Granularidade

- Para tomar decisão, um gerente precisa de informações detalhadas
- Isso normalmente é fornecido por meio de relatórios, com a finalidade de conferência, extraídos do sistema transacional para a área operacional

28


- O nível de detalhamento em que a informação gerencial é armazenada é conhecido como *grão*
- Quanto menor o *grão*, maior o nível de detalhe, por isso o termo *granularidade* é utilizado

29

OLAP

- OLAP, acrônimo para *Online Analytical Processing* (Processamento Analítico em Tempo Real), é um gerenciador de banco de dados multidimensional, que normalmente está associado à construção de cubos
- Um *data warehouse* normalmente é construído em um OLAP Server, que é um tipo de aplicação otimizada para gerência de dados em formato multidimensional

30



31

Construção de *Data Warehouse*

32

- A construção de armazéns analíticos envolve extrair, normalizar, transformar e carregar dados entre ambientes distintos
- Esse processo citado como *ETL*, explicado anteriormente, é executado por ferramentas de software, com função de extração de dados de diversos sistemas, transformando esses dados conforme regras de negócio e, por fim, a carga de dados

33

OLAP e OLTP

- **OLTP**, acrônimo para *Online Transaction Processing* (Processamento de Transações em Tempo Real), é como são conhecidos os sistemas transacionais que implementam o modelo relacional
- Desta forma, **OLAP** é multidimensional/analítico e **OLTP** é relacional/transacional

34

- **OLTP** tem por objetivo manter a operação de departamentos por meio da inclusão, alteração, consulta e cálculos, reduzindo a redundância e mantendo os dados íntegros
- **OLAP** busca facilitar a análise, por isso não há problema se houver dados repetidos

35

Business intelligence

- **BI**, acrônimo para *Business Intelligence*, normalmente está associado a gráficos interativos e cubos, mas a expressão é muito mais abrangente
- **BI** se refere à metodologia, às ferramentas e às técnicas de produzir dados para apoio às decisões

36

- Seu objetivo final pode ser o da produção de gráficos e relatórios, mas também, análises preditivas, indicadores de performance, monitoramento contínuo, entre outros

37

Relatórios

- Relatórios produzem informação detalhada, de forma estática e sem interatividade, ou seja, não é possível aumentar ou reduzir o grão na própria interface do relatório
- Normalmente, um relatório tem caráter operacional, para atividades de conferência
 - Pode conter elementos gráficos para resumir dados
- A informação pode vir agrupada ou resumida em níveis

38

Cubos

- Cubos são representações multidimensionais de dados, que normalmente representam um único fato. Através de operações de *drill down* e *drill up*, o usuário pode aumentar ou diminuir o nível de detalhamento da informação
 - Nas linhas e colunas, um cubo representa dimensões, ao centro, medidas
- Sua representação principal é textual, porém, algumas ferramentas podem facilmente produzir gráficos

39

Dashboards e infográficos

- *Dashboards* são painéis visuais que mostram indicadores de um mesmo assunto
- Trazem informações resumidas, normalmente de cunho estratégico ou gerencial, mas também têm aplicações nas áreas operacionais
- Infográficos são elementos extremamente ricos visualmente, mas que não estão conectados a uma fonte de dados
 - A informação é um retrato estático em um ponto no tempo

40

Balanced scorecard

- *Balanced scorecard*, ou BSC, é um sistema criado por Kaplan e Norton que tem por objetivo medir o desempenho de uma empresa sob quatro perspectivas
 - Financeira, clientes, processos internos e aprendizado e crescimento

41

- Dentro dessas quatro perspectivas, são desenvolvidos indicadores que medirão a *performance* da organização
- Um BSC ajuda a organizar e materializar a estratégia da organização, prove mecanismos para que os objetivos estratégicos sejam medidos

42

Análise de Dados

- Analisar dados é aplicar algum tipo de transformação nos dados em busca de conhecimento
- Dados podem ser produzidos para análise ou para manter a operação de um departamento de uma empresa e, posteriormente, analisado
- De que forma podemos analisar os dados e quais são as técnicas mais comuns

43

44

Análises explícitas

- Nas análises explícitas, a informação e o conhecimento estão disponíveis explicitamente nos dados, e normalmente só é necessária alguma operação, de baixa complexidade, para ressaltar o dado e produzir a informação
- A informação está lá, explicitamente, é preciso apenas destacá-la na "multidão"

45

Análises implícitas

- Já na análise implícita, a informação não está disponível claramente no conjunto de dados
 - Mesmo que você olhe os dados de várias formas, filtre, selecione ou faça algum tipo de cálculo, a informação só será produzida com o uso de alguma função mais sofisticada
- Exemplos de funções para análises implícitas são usar uma tarefa de aprendizado de máquina ou uma lei estatística

46

Técnicas quantitativas

- Exemplos de técnicas quantitativas são as medidas de dispersão e posição como média, mediana, amplitude e desvio padrão
- A grande maioria das ferramentas de análise de dados pode gerar medidas de dispersão de uma variável como desvio padrão e variância

47

Histograma

- O histograma desenha uma informação quantitativa por vez
- Seu objetivo é contar a frequência de dados em certos intervalos

48

