

Aula 3

Big Data

Prof. Douglas Eduardo Basso

1

Utilizações de *Big Data*

2

- Devemos sempre lembrar que o ***Big Data*** está baseado nos princípios de volume, variedade, necessidade de velocidade de processamento, veracidade dos dados, para que seja possível obter o item final com a geração de algum valor para uma organização

3

O que é *Analytics*

- ***Analytics*** é a habilidade de utilizar dados, realizar análises e usar um raciocínio sistemático para conduzir a um processo de tomada de decisão mais eficiente
- A utilização de inteligência analítica significa melhorar o desempenho em relação aos domínios fundamentais do negócio usando dados e análises sobre estes


4

- Volume é algo óbvio pois são geradas milhares de informações todos os dias tanto dentro da empresa como nos ambientes de redes sociais, empresas de pesquisa de dados, entre outros produtores de conteúdo
- No aspecto da variedade temos diversos tipos a considerar
 - E-mails, sistemas estruturados, grande parte de sistemas não estruturados, como *Facebook*, *Twitter*, *YouTube*, *Instagram*, entre outros que surgem a cada dia

5

- A velocidade está assumindo maior importância, pois a cada dia se faz necessária a interação com o mundo externo e real
- Todos os dados a serem considerados para um projeto deste nível devem ter sua veracidade confirmada, pois não podemos nos arriscar a trabalhar e analisar dados que não sejam verdadeiros. Na veracidade, outro V entra em questão, o valor, ou seja, a validação se o dado tem valor para os negócios da empresa

6



Análise descritiva


- A análise descritiva para viabilizar decisões de negócio baseadas em fatos e dados, e não em sentimentos pessoais, tem um longo caminho a percorrer
- No entanto, a análise descritiva como é realizada hoje em dia já não é suficiente com seus dados, pelo fato da sociedade em que vivemos gerar uma imensidão de informações, fazendo com que se torne imprescindível que a tomada de decisões seja altamente precisa

Análise preditiva

- O uso da análise preditiva surgiu para trabalhar e focar para o futuro e, assim, definir decisões de negócio e processos com uma amplitude mais objetiva, e tirando a empresa de seu universo particular, colocando-se frente à sua comunidade consumidora e global

IoT

- IoT é a capacidade de capturar, analisar e transmitir dados para as coisas, aumentando sua utilidade
- A Internet das Coisas está provocando mudanças nas decisões de gerenciamentos das mais variadas empresas
- Bilhões de coisas que serão encadeadas algum dia, dispositivos conectados, juntamente com avanços na coleta de dados e análise




Análise de cliques

- A análise do fluxo de cliques em um site na web é um processo de coleta, análise e geração de relatórios de dados agregados sobre as páginas que alguém visita – e em que ordem ele entra e sai nas páginas desse site
- O caminho que o visitante de um site navega é chamado de fluxo de cliques ou *ClickStream*
- Existem dois níveis de análise de fluxo de cliques, análise de tráfego e análises de comércio eletrônico



13



14

- A modelagem preditiva é uma área da estatística que trata de extração das informações de dados e utilização deste para prever tendências e padrões de comportamento
- Muitas vezes, um evento desconhecido é de interesse no futuro, mas a análise preditiva pode ser aplicada a qualquer tipo de informação desconhecida, seja no passado, no presente ou no futuro

15

Modelos preditivos

- O objetivo do modelo é avaliar a probabilidade de que uma unidade similar em uma amostra diferente exiba o desempenho específico
- Esta categoria abrange modelos em muitas áreas, como o marketing, nas quais são procurados padrões sutis de dados para responder a perguntas sobre o desempenho do cliente ou modelos de detecção de fraude

16

Modelos descritivos

- Os modelos descritivos quantificam as relações nos dados de uma forma que é usado para classificar clientes ou clientes em grupos
- Os modelos descritivos são essenciais para que possamos vir a ter um conhecimento maior e amplo domínio sobre o que são os dados a que se referem, o que nos dizem e sobre o que estão baseados, assim como sua qualidade e aproveitamento

17

Modelos de decisão

- Os modelos de decisão descrevem a relação entre todos os elementos de uma decisão – os dados conhecidos (incluindo os resultados dos modelos preditivos), a decisão e o resultados previstos da decisão – para prever os resultados das decisões que envolvem muitas variáveis
- Esses modelos podem ser usados na otimização, maximizando determinados resultados e minimizando outros

18

Correlação de Dados

- Esta é a grande chave do *Big Data*, a descoberta de correlações entre dados que aparentemente nada têm a ver uns com os outros
- As correlações são fortes quando temos a modificação do valor de alguns dados, o que faz com que o outro dado completamente diferente sofra alterações

29

30

Aprendizado de máquina

- Aprendizado de máquina é um método de análise de dados que busca a automatização do desenvolvimento de modelos analíticos, usando algoritmos que aprendem interativamente a partir de dados, por meio de um processo repetitivo, o aprendizado de máquinas permite que os computadores, ao aplicar modelos preditivos, encontrem relacionamentos ocultos sem serem explicitamente programados para procurar uma informação oculta específica

Métodos de aprendizado de máquina

- Dois métodos de aprendizado de máquina mais adotados são o aprendizado supervisionado e o aprendizado não supervisionado
- A maior parte do desenvolvimento de aprendizado de máquina é 70% supervisionado, o aprendizado não supervisionado é responsável pelos restantes 10% a 20%

31

32

Preparação de dados

- Existe uma etapa de preparação de dados, antes de tudo começar, que consiste em executar um processo de coletar, limpar, normalizar, combinar, estruturar e organizar os dados para análise
- Embora alguns campos de dados possam ser usados no estado em que se encontram, a maioria requer algum tipo de tratamento, da mesma forma que isso é feito nas aplicações de BI, limpeza de dados e tratamento destes

Tarefas de Aprendizado de Máquina

33

34

- O aprendizado de máquina pode ser dividido em três grandes grupos de tarefas: classificação, agrupamento e associação
- Porém, antes de falarmos de técnicas e algoritmos, uma observação sobre classificação: este tipo de tarefa é aplicado apenas quando a classe, ou seja, aquilo que queremos prever ou descrever é um dado nominal, se a classe é numérica, temos uma tarefa de regressão

25

Classificação

- Diferente de um algoritmo tradicional, a classificação funciona como dados históricos
- Estes dados históricos, como são fatos ocorridos, obviamente já estão classificados
- Dados históricos de clientes que já solicitaram aprovação de crédito e que já estão classificados
 - Bom ou mau pagador são usados pelo algoritmo de classificação para construir um modelo

26

Agrupamento

- Agrupamentos são tarefas de mineração de dados não supervisionadas, pois não existe uma classe
 - Algo para prever ou descrever
- As tarefas de agrupamento buscam reunir instâncias com características comuns em grupos, que, posteriormente podem ser classificados

27


Associação

- Um algoritmo de aprendizado de máquina vai minerar as transações em busca de associações entre os itens
- Porém, qualquer compra vai gerar muitas associações

28

- Sistemas de recomendação estão em toda parte, quando entramos em um site de comércio eletrônico e colocamos item no carrinho de compras, o sistema imediatamente recomenda outros itens semelhantes
- Essas recomendações são geradas por algoritmos de regras de associação

29



30

Mineração de Texto

31

Mineração de dados

- Um processo de mineração inicialmente constrói um *corpus*, que é um conjunto de textos de um ou mais documentos
- Os documentos que são um conjunto de textos de um ou mais documentos

32

- Os documentos que formam o *corpus* podem ter origens diversas, por exemplo
 - Disco, internet, banco de dados ou sistema de gestão integrada
- Os documentos podem ter diferentes formatos (texto, páginas de internet, arquivos pdf, entre outros)


33

- Criado o *corpus*, normalmente diversas operações são realizadas sobre este
- Uma operação usual é a remoção das palavras sem valor semântico para o processo de mineração
- Cada idioma tem seu próprio de palavras sem valor semântico, palavras com o mesmo significado que sejam agrupadas juntas, remoção de pontuação, numeração, símbolos e linguagens de marcação

34

- Feitos os tratamentos, a mineração de dados pode produzir uma matriz de termos com suas respectivas frequências, que pode ser utilizado para classificar documentos, analisar sentimento, construir uma nuvem de palavras, entre outras aplicações

35



36

Distância Levenshtein

- A distância de Levenshtein é uma métrica usada para analisar a diferença entre dois textos
- Exemplo: a distância entre "rua" e "sua" é um
- Já entre "Elana" e "Elisa" são dois
- A distância é calculada pelo número de operações necessárias para um texto ficar igual ao outro

37

- **Suas aplicações na ciência de dados são muitas**
 - **Em qualidade de dados para buscar registros, como clientes duplicados**
 - **Corretores ortográficos**
 - **Reconhecimento ótico de caracteres (OCR)**
 - **Entre outros**

38

Teoria dos Grafos

- Um grafo é um elemento formado por pontos conectados
- Tecnicamente, um ponto é chamado de vértice e a conexão, de aresta
- As arestas podem ou não ter direção

39

- Na prática, a teoria dos grafos é utilizada para soluções de problemas em economia, matemática, redes de computadores, logística, medicina, ciências sociais, biologia, entre outros
- Uma aplicação prática e clássica é encontrar o menor caminho

40



pumpyvector/shutterstock

41

Lei de Benford

- É uma lei estatística bastante curiosa. Primeiramente, vamos entender o que é primeiro dígito
 - Trata-se do dígito mais à esquerda em um número, independente de quantos algarismos o número é formado
 - Entendido o primeiro dígito, qual será a frequência esperada de cada dígito à esquerda em uma população de dados numéricos?

42


- A princípio, como são 9 dígitos possíveis (de 1 até 9), imagina-se que a frequência esperada de um dígito qualquer seja de 11,11%
- Por exemplo, a frequência esperada do dígito 1, como primeiro dígito, seria de 11,11%
- Na prática, a Lei pode ser aplicada para analisar faturamento, variação de preços, bolsa de valores, contas a pagar, dados de eleições, entre muitos outros

43

Grafos para cartéis

- Cartel é um acordo secreto entre empresas de uma mesma atividade, buscando fixar o preço de seus produtos, desta forma, não há livre concorrência
- Além de mostrar as relações, o grafo facilmente exhibe peças faltantes para o fechamento de ciclos de relações, normalmente devido ao fato que estas relações não estão datificadas
 - Um filho adotivo, por exemplo, desta forma cria subsídios para investigações futuras

44



45