

BIG DATA

TEMA 1 – UTILIZAÇÕES DE BIG DATA

Devemos sempre lembrar que o Big Data está baseado nos princípios de volume, variedade, necessidade de velocidade de processamento, veracidade dos dados, para que seja possível obter o item final com a geração de algum valor para uma organização.

Volume é algo óbvio, pois são gerados milhares de informações todos os dias tanto dentro da empresa como nos ambientes de redes sociais, empresas de pesquisa de dados, entre outros produtores de conteúdo. No aspecto da variedade, temos diversos tipos a considerar: *e-mails*, sistemas estruturados, grande parte de sistemas não estruturados, como Facebook, Twitter, YouTube, Instagram, dentre outros que surgem a cada dia. Temos também documentos digitalizados, documentos eletrônicos, sensores de RFID como instrumentos de captura de dados para sistemas, etiquetas eletrônicas, apresentação etc.

A velocidade está assumindo maior importância, pois é e deverá ser cada dia mais necessário que as empresas tenham interação com o mundo externo e real, assim como a sua necessidade de tomada de decisão em tempo real. Para isso, grandes investimentos são necessários em infraestrutura de TI, como servidores, equipamentos de redes, armazenamento e processamento.

Outro ponto a ser considerado é a veracidade. Todos os dados a serem considerados para um projeto desse nível devem ter sua veracidade confirmada, pois não podemos nos arriscar a trabalhar e analisar dados que não sejam verdadeiros. Na veracidade, outro V entra em questão: o valor, ou seja, a validação se o dado tem valor para os negócios da empresa, para o que se deseja obter. É preciso que a empresa tenha planejamento estratégico, com definição de metas e objetivos, antes de ativar um projeto de Big Data sem saber o que vai buscar de informação (Machado, 2018).

1.1 O que é Analytics

Com um mundo de informações à disposição, é necessário determinar por quais dados a organização tem interesse, para poder, com esses dados e recursos tecnológicos, obter resultados que gerem valores ao negócio e agregar conhecimento à análise de negócios.

Se entendermos Big Data como o volume de dados, variedade e velocidade que excedem a capacidade de uma organização em administrar e analisar em

tempo hábil seus sistemas ou manualmente, existem fortes sinais para a utilização do Big Data Analytics em qualquer setor de negócios e para a tomada de decisões.

Analytics é a habilidade em utilizar dados, realizar análises e utilizar um raciocínio sistemático para conduzir a um processo de tomada de decisão mais eficiente. A utilização da inteligência analítica significa melhorar o desempenho com relação aos domínios fundamentais do negócio por meio de dados e análises sobre eles.

Existem diversos tipos de análise que podemos inserir em um conjunto para designarmos de *Analytics*. Dentre as análises possíveis, temos as técnicas de modelagem estatística, de modelo de previsão (*forecasting*), o próprio processo de *Data Mining*, ou *Text Mining*, a criação de modelos preditivos experimentais etc. Analytics nada mais é do que um conjunto de tipos de análises sobre dados realizadas com a finalidade de obter indicadores de desempenho ou novas visões sobre os dados tratados (Machado, 2018).

Sempre que tivermos a necessidade de entender e interpretar os fatos que já aconteceram (passado), chamamos isso de *inteligência de negócios* (BI).

1.2 Análises descritiva e preditiva

A análise descritiva para viabilizar decisões de negócio baseadas em fatos e dados, e não em sentimentos pessoais, tem um longo caminho a percorrer. No entanto, a análise descritiva simplesmente como é realizada hoje em dia já não é suficiente com seus dados, pelo fato de a sociedade em que vivemos gerar uma imensidão de informações, o que torna imprescindível que a tomada de decisões seja altamente precisa.

Surge o uso da análise preditiva para trabalhar e focar para o futuro e, assim, definir decisões de negócio e processos com uma amplitude mais objetiva, tirando a empresa de seu universo particular e colocando-se diante da sua comunidade consumidora e global (Machado, 2018).

A análise preditiva, a bem da verdade, já nos acompanha há muito tempo. Era um tema acadêmico há vários anos, entretanto agora tem relevância no segmento profissional de TI, o qual cresceu justamente com a quantidade de dados capturados pelas pessoas. Para citar alguns exemplos, temos as transações de negócios *online* e as redes sociais, bem como a utilização de equipamentos e sensores como dispositivos móveis (*smartphones*, GPS, coletores de dados, RFID, entre outros). Estamos vivenciando a disponibilidade

do aumento da capacidade e do poder de processamento de dados a um custo sensivelmente reduzido, com base em tecnologias de computação em nuvem.

1.2.1 IoT

IoT é a capacidade de capturar, analisar e transmitir dados para as coisas, aumentando a sua utilidade. Estamos falando de qualquer tipo de coisa, desde carros sem motoristas que se autodirigem a geladeiras que fazem lista de compras de supermercado. A Internet das Coisas está provocando mudanças nas decisões de gerenciamentos das mais variadas empresas. Bilhões de coisas que serão encadeadas algum dia, dispositivos conectados, juntamente com avanços na coleta de dados e análise (Machado, 2018).

Empresas de logística ou que têm na logística uma de suas atividades primordiais utilizam diversas análises para acompanhar e possibilitar a otimização de seu desempenho. Dados de sensores em seus caminhões e em produtos lhes permitem identificar e acompanhar a rota e os tempos de entrega, com aplicação de Analytics para identificar e determinar a rota ideal para entregas (inclusive levando em conta as previsões de tráfego e condições meteorológicas).

As principais forças policiais nos Estados Unidos estão testando tecnologias que contam com sensores e análises para detectar automaticamente o som de tiros, mapeando cidades em quadrados de cerca de 150 m². Com esse componente, seria possível responder a qualquer incidente com arma de fogo rapidamente. O uso desse sensor demonstrou de 80 a 90% dos tiros até então nunca relatados.

1.3 Análise de clique

A análise do fluxo de cliques em um *site* na *web* compreende um processo de coleta, análise e geração de relatórios de dados agregados sobre as páginas que alguém visita – e em que ordem ele entra e sai nas páginas desse *site*. O caminho que o visitante de um *site* navega é chamado de *fluxo de cliques* ou *ClickStream*. Existem dois níveis de análise de fluxo de cliques: análise de tráfego e análise de comércio eletrônico (Machado, 2018).

A análise de tráfego opera no nível do servidor e rastreia quantas páginas são acessadas por um usuário, quanto tempo ele fica em cada página a ser carregada e com que frequência usa o botão de retorno ou de parada do

navegador, assim como a quantidade de dados transmitidos antes de o usuário se mover.

A análise baseada em comércio eletrônico usa dados do clique para determinar a eficácia do *site* para o mercado. Preocupa-se com as páginas em que o comprador navega, o que ele olha, que detalhes examina, o que coloca ou tira de um carrinho de compras, principalmente quais itens compra, independentemente de o indivíduo pertencer a um programa de fidelidade, usar um código de cupom ou se valer de outro método de pagamento.

Como é extremamente grande o volume de dados que pode ser obtido por meio da análise do fluxo de cliques, muitas empresas dependem de grandes análises de dados e ferramentas direcionadas para isso. A análise de *ClickStream* é considerada mais eficaz quando usada em conjunto com outros recursos de avaliação de mercado mais tradicionais – nossos celulares rastreiam a nossa localização geográfica e como e para onde estamos nos movendo.

A Amazon usa o Big Data Analytics para detectar o que cada cliente adicionou ao seu carrinho de compras na loja virtual, fazendo a relação dos itens comprados ou visualizados em um passado recente ou mais distante. Essa técnica se chama *filtragem colaborativa item a item* e foi criada por Greg Linden, que utiliza fontes de dados estruturados e não estruturados para customizar a experiência de compra dos usuários em um *site* na *web*.

TEMA 2 – MODELAGEM

A modelagem preditiva é uma área da estatística que trata da extração das informações de dados e da utilização destes para prever tendências e padrões de comportamento. Muitas vezes, um evento desconhecido é de interesse no futuro, mas a análise preditiva pode ser aplicada a qualquer tipo de informação desconhecida, no passado, no presente ou no futuro. O cerne da análise preditiva se baseia na captura de relações entre as variáveis explicativas e as previstas das ocorrências passadas, explorando-as para prever um resultado desconhecido. No entanto, é importante notar que a precisão e a usabilidade dos resultados dependerão muito do nível de análise de dados e da qualidade dos deles.

A análise preditiva é a tecnologia que faz uso da experiência (dados) para prever o comportamento dos indivíduos, a fim de gerar melhores decisões. Nos sistemas industriais futuros, o valor das análises preditivas terá como principal objetivo prever e prevenir problemas potenciais em produtos para conseguir um

nível de retorno, manutenção e reclamações quase zero e estar integrado em análises prescritivas para a otimização de decisões.

2.1 Tipos

Geralmente, o termo *análise preditiva* é usado para significar modelagem preditiva, *pontuação* de dados com modelos preditivos e previsão. No entanto, as pessoas estão cada vez mais usando o termo para se referir a disciplinas analíticas relacionadas, como modelagem descritiva e modelagem de decisões ou otimização. Essas disciplinas também envolvem a análise rigorosa de dados e são amplamente utilizadas nos negócios para segmentação e tomada de decisão, mas têm propósitos diferentes, e as técnicas estatísticas subjacentes variam.

2.2 Modelos preditivos

O objetivo do modelo é avaliar a probabilidade de que uma unidade similar em uma amostra diferente exiba o desempenho específico. Essa categoria abrange modelos em muitas áreas, como o *marketing*, nas quais são procurados padrões sutis de dados para responder a perguntas sobre o desempenho do cliente ou modelos de detecção de fraude.

Os modelos preditivos geralmente realizam cálculos durante transações ao vivo – por exemplo, para avaliar o risco ou a oportunidade de determinado cliente ou transação, a fim de orientar uma decisão. Com os avanços na velocidade de computação, os sistemas de modelagem de agentes individuais tornaram-se capazes de simular comportamentos ou reações humanas a determinados estímulos ou cenários.

2.3 Modelos descritivos

Os modelos descritivos quantificam as relações nos dados de uma forma frequentemente usada para classificar clientes ou clientes em grupos. Esses modelos são essenciais para que possamos vir a ter um conhecimento maior e um amplo domínio sobre o que são os dados a que se referem, o que nos dizem e em que estão baseados, assim como sua qualidade e aproveitamento (Machado, 2018).

Ao contrário dos modelos preditivos que se concentram na previsão de um comportamento de cliente único (como o risco de crédito), os modelos descritivos

identificam muitas relações diferentes entre os clientes ou produtos. Os modelos descritivos não classificam os clientes de acordo com a probabilidade de tomar uma ação particular da maneira como os modelos preditivos. Em vez disso, os modelos descritivos podem ser usados, por exemplo, para categorizar os clientes pelas preferências de seus produtos e pelo estágio da vida.

As ferramentas de modelagem descritiva podem ser utilizadas para desenvolver modelos adicionais que possam simular grande número de agentes individualizados e fazer previsões.

2.4 Modelos de decisão

Os modelos de decisão descrevem a relação entre todos os elementos de uma decisão – os dados conhecidos (incluindo os resultados dos modelos preditivos), a decisão e os resultados previstos da decisão – para prever os resultados das decisões que envolvem muitas variáveis. Esses modelos podem ser usados na otimização, maximizando determinados resultados e minimizando outros (Machado, 2018).

Os modelos de decisão geralmente são usados para desenvolver uma lógica de decisão ou um conjunto de regras comerciais ou organizacionais que produzirão a ação desejada para cada cliente ou circunstância.

As oportunidades que os cinco Vs trazem para uma empresa que os aplicarem de forma crescente e correta não podem nem devem ser jogadas fora; a utilização de Big Data já começa a se tratar de uma questão estratégica de sobrevivência de uma empresa em seu mercado.

TEMA 3 – CORRELAÇÃO DE DADOS

A correlação de dados começou com o engenheiro de *software* Greg Linden, contratado da Amazon e administrador do *site* da empresa. Na época a Amazon possuía dezenas de críticos e editores literários que selecionavam os livros e títulos apresentados na página, assim como os indicavam para os clientes que a acessavam – com base na crítica literária, mas sem correlação, sem elementos que pudessem fazer o leitor gostar de livros tão adversos.

Greg Linden percebeu que o melhor era comparar os produtos e as associações entre eles, a chamada *correlação*. Esta é a grande chave do Big Data: a descoberta de correlações entre dados que aparentemente nada têm a

ver uns com os outros. As correlações são fortes quando temos a modificação do valor de alguns dados, o que faz com que o outro dado completamente diferente sofra alterações (Machado, 2018)

Esse princípio da correlação de dados, associado às técnicas de *ClickStream*, foi o que desencadeou a criação de algoritmos preditivos sobre a possibilidade de alguém vir a se interessar por outro produto. Hoje é comum entrarmos em um *site* e vemos, ao clicar em um produto, quais foram buscados, as sugestões que aparecem em suas redes sociais – trata-se da massificação do marketing digital. Essa utilização de correlação está enorme e bastante disseminada no *e-commerce* e em compras interativas.

Essas correlações de dados são muito úteis em universos de grandes dados, mas também podem ser úteis com poucos dados. Tudo é realizado por meio de correlações, descobertas com a ajuda de um *Data Mining* com algoritmos complexos que descobrem padrões inacessíveis ao olho ou à análise humana pura e simples.

3.1 Aprendizado de máquina

O aprendizado de máquina é um método de análise de dados que busca a automatização do desenvolvimento de modelos analíticos, usando algoritmos que aprendem iterativamente a partir de dados por meio de um processo repetitivo. O aprendizado de máquinas permite que os computadores, ao aplicarem modelos preditivos, encontrem relacionamentos ocultos sem serem explicitamente programados para procurar uma informação oculta específica (Machado, 2018).

Em razão das novas tecnologias de computação distribuída e da computação em nuvem, além dos novos algoritmos desenvolvidos, da capacidade de aplicar automaticamente cálculos matemáticos complexos, a Big Data – cada vez mais e com maior velocidade – é um desenvolvimento decorrente das tecnologias de processamento paralelo mais atuais e dinâmicas.

O interesse no aprendizado de máquina ressurgiu em virtude dos mesmos fatores que tornaram a mineração de dados mais popular do que nunca: a constante busca por resultados cada dia mais rápidos e confiáveis e que a mente humana é incapaz de identificar com rapidez e precisão.

3.2 Métodos do aprendizado de máquina

Os dois métodos de aprendizado de máquina mais adotados são o aprendizado supervisionado e o aprendizado não supervisionado. A maior parte do desenvolvimento de aprendizado de máquina é 70% supervisionado; o não supervisionado é responsável pelos restantes 10 a 20%.

Algoritmos de aprendizado de máquina supervisionado são realizados usando exemplos rotulados, como uma entrada em que a saída desejada é conhecida. O algoritmo de aprendizagem recebe um conjunto de entradas junto com as saídas corretas correspondentes e aprende comparando a saída real com as saídas corretas para encontrar erros. O aprendizado supervisionado é mais utilizado para aplicações nas quais os dados históricos podem prever prováveis acontecimentos futuros (Machado, 2018).

O aprendizado não supervisionado é usado com dados que não possuem rótulos históricos – o sistema não sabe a “resposta certa”. O algoritmo deve descobrir o que está sendo mostrado. O objetivo é explorar os dados e encontrar alguma estrutura neles. O aprendizado não supervisionado funciona bem em dados transacionais.

3.3 Preparação de dados

Existe uma etapa de preparação de dados, antes de tudo começar, que consiste em executar um processo de coletar, limpar, normalizar, combinar, estruturar e organizar os dados para análise. Embora alguns campos de dados possam ser usados no estado em que se encontram, a maioria requer algum tipo de tratamento, da mesma forma que isso é feito nas aplicações de BI, limpeza de dados e tratamento destes (Machado, 2018).

Dados históricos possuem vários formatos. Como ações inerentes a esse processo de preparação de dados, as mais comuns são a remoção de abreviações, a normalização de dados numéricos, a exclusão de campos repetidos, o preenchimento de campos vazios, a padronização de formatos de datas e de unidades, a hierarquização de entrada de dados, a detecção de anomalias, assim como a deduplicação e a desambiguação dessas mesmas entradas.

As informações são obtidas a partir do registro de conta do cliente e de transações passadas. Dados não estruturados podem ser representados como

um comentário sobre um serviço ou item comprado e ser coletados em mídias como Twitter, Facebook e demais redes sociais.

TEMA 4 – TAREFAS DE APRENDIZADO DE MÁQUINA

O aprendizado de máquina pode ser dividido em três grandes grupos de tarefas: classificação, agrupamento e associação. Porém, antes de falarmos de técnicas e algoritmos, uma observação sobre classificação: esse tipo de tarefa é aplicado apenas quando a classe, ou seja, aquilo que queremos prever ou descrever é um dado nominal. Se a classe é numérica, temos uma tarefa de regressão (Amaral, 2016).

Uma técnica é uma forma de resolver uma tarefa de aprendizado de máquina. Cada técnica utiliza abordagens diferentes e consequentemente tem vantagens e desvantagens. Já o algoritmo é como a técnica é implementada.

4.1 Classificação

Diferentemente de um algoritmo tradicional, a classificação funciona como dados históricos. Esses dados históricos, como são fatos ocorridos, obviamente já estão classificados. Dados históricos de clientes que já solicitaram aprovação de crédito e que já estão classificados como bons ou maus pagadores são usados pelo algoritmo de classificação para construir um modelo (Amaral, 2016).

Uma vez construído o modelo, os dados históricos não serão mais necessários, a cada nova instância com novos dados – ou seja, dados ainda não classificados são aplicados ao modelo que vai prever, com uma margem de erro, se aquele cliente é ou não bom pagador.

4.2 Agrupamentos

Agrupamentos são tarefas de mineração de dados não supervisionadas, pois não existe uma classe: algo para prever ou descrever. As tarefas de agrupamento buscam reunir instâncias com características comuns em grupos que posteriormente podem ser classificados. Exemplos de aplicações de tarefas de agrupamento são: identificar grupos de clientes para direcionar campanhas, uma seguradora poder agrupar clientes que são indenizados com mais frequência, identificar fraude ou até mesmo classificar instâncias, quando não existe uma classe conhecida.

4.3 Associação

Um algoritmo de aprendizado de máquina vai minerar as transações em busca de associações entre os itens. Porém, qualquer compra vai gerar muitas associações. Sistemas de recomendação estão em toda parte – quando entramos em um *site* de comércio eletrônico e colocamos ite(ns) no carrinho de compras, o sistema imediatamente recomenda outro(s) semelhante(s). Essas recomendações são geradas por algoritmos de regras de associação (Amaral, 2016).

TEMA 5 – MINERAÇÃO DE TEXTO

Um processo de mineração inicialmente constrói um *corpus*, que é um conjunto de textos de um ou mais documentos. Os documentos formam um conjunto de textos de um ou mais documentos. Os documentos que formam o *corpus* podem ter origens diversas, tais como disco, *internet*, banco de dados ou sistema de gestão integrada. Os documentos podem ter diferentes formatos (texto, páginas de internet, arquivos PDF, entre outros). A construção do *corpus* vai coletar esses dados de todas as suas fontes e armazená-los em um repositório volátil ou permanente.

Criado o *corpus*, normalmente diversas operações são realizadas sobre este. Uma operação usual é a remoção das palavras sem valor semântico para o processo de mineração. Cada idioma tem seu próprio grupo de palavras sem valor semântico, e palavras com o mesmo significado são agrupadas juntas, com remoção de pontuação, numeração, símbolos e linguagens de marcação.

Feitos os tratamentos, a mineração de dados pode produzir uma matriz de termos com suas respectivas frequências, o que pode ser utilizado para classificar documentos, analisar sentimentos, construir uma nuvem de palavras, entre outras aplicações.

5.1 Distância de Levenshtein

A distância de Levenshtein é uma métrica usada para analisar a diferença entre dois textos – por exemplo, a distância entre *rua* e *sua* é um, já entre *Elana* e *Elisa* é de dois. A distância é calculada pelo número de operações necessárias para um texto ficar igual ao outro. Suas aplicações na ciência de dados são muitas: em qualidade de dados para buscar registros, como clientes duplicados,

mas que foram digitados de forma semelhante; corretores ortográficos ou tradutores; reconhecimento ótico de caracteres (OCR) etc. (Amaral, 2016).

5.2 Teoria dos grafos

Um grafo é um elemento formado por pontos conectados. Tecnicamente, um ponto é chamado de *vértice* e a conexão, de *aresta*. As arestas podem ou não ter direção. A teoria de grafos, como quase tudo na matemática, não é algo novo – seus primeiros problemas datam do século XVIII. Porém, com o advento das redes sociais, eles ganharam destaque, e muitos estudos estão sendo realizados e várias ferramentas e algoritmos novos têm surgido (Amaral, 2016).

Na prática, a teoria dos grafos é utilizada para soluções de problemas em economia, matemática, redes de computadores, logística, medicina, ciências sociais, biologia, entre outros.

Uma aplicação prática e clássica é encontrar o menor caminho. Imagine uma empresa de entregas com uma rota por diversos pontos da cidade. O caminhão de entregas deve fazer o menor percurso possível, retornando para o mesmo ponto de onde saiu, economizando tempo e combustível.

5.3 Lei de Benford

Frank Benford, em 1883, e Simon Newcomb, em 1881, por meio de observações, propuseram o que é hoje conhecida como *lei de Benford*, uma lei estatística bastante curiosa. Primeiramente, vamos entender o que é primeiro dígito: trata-se do dígito mais à esquerda em um número, independentemente de de quantos algarismos o número é formado.

Entendido o primeiro dígito, qual será a frequência esperada de cada dígito à esquerda, em uma população de dados numéricos? A princípio, como são nove dígitos possíveis (de 1 até 9), imagina-se que a frequência esperada de um dígito qualquer seja de 11,11%. Por exemplo, a frequência esperada do dígito 1, como primeiro dígito, seria de 11,11%.

Porém, a lei de Benford nos diz algo bem diferente. Em uma população de dados numéricos, produzidos naturalmente, a frequência esperada do primeiro dígito ser 1 é algo em torno de 30,1%, para dígito 2 é 17,6% etc. A lei traz as distribuições esperadas para todos os nove primeiros dígitos. O cálculo da distribuição de cada dígito se dá pela fórmula $\log(1+1/\text{dígito})$.

Mas qual o significado da diferença entre o percentual encontrado e o percentual esperado pela lei? A diferença pode significar que os dados foram alterados ou inventados. Na prática, a lei pode ser aplicada para analisar faturamento, variação de preços, bolsa de valores, contas a pagar, dados de eleições, entre muitos outros. A lei de Benford vai além – ela nos dá a probabilidade da ocorrência do segundo, terceiro e quarto dígitos. Também, dígitos podem ser analisados em conjunto (Amaral, 2016).

5.4 Grafos para cartéis

Cartel é um acordo secreto entre empresas de uma mesma atividade, buscando fixar o preço de seus produtos – dessa forma, não há livre concorrência. A relação de parentesco, entre sócios de diferentes empresas de ramos de atividades semelhantes, não necessariamente indica a presença de um cartel: na prática, empresas de fachada são criadas para a formação de cartéis, cujos sócios, de diferentes empresas de um mesmo ramo, são suspeitos de participarem em conjunto de processos licitatórios com valores vultosos, principalmente pelo fato de essas relações poderem ser altamente complexas.

Além de mostrar as relações, o grafo facilmente exhibe peças faltantes para o fechamento de ciclos de relações, normalmente devido ao fato de que essas relações não estão datificadas: um filho adotivo, por exemplo, dessa forma cria subsídios para investigações futuras (Amaral, 2016).

REFERÊNCIAS

AMARAL, F. **Introdução à ciência de dados**: mineração de dados e Big Data. Rio de Janeiro: Alta Books, 2016.

DAVENPORT, T. H. **Big Data no trabalho**: derrubando mitos e descobrindo oportunidades. Tradução de Cristina Yamagami. 1. ed. Rio de Janeiro: Elsevier, 2014.

MACHADO, F. N. R. **Big data**: o futuro dos dados e aplicações. São Paulo: Érica, 2018.

TAURION, C. **Big Data**. Rio de Janeiro: Brasport, 2013.