

| BIG DATA

TEMA 1 – GOVERNANÇA DE DADOS

Ativo é o conjunto de bens de uma pessoa física ou jurídica. Os equipamentos de uma indústria são exemplos de ativos. Empresas de modo geral protegem seus ativos: fazem seguros contra roubos, instalam câmeras de segurança, contratam engenheiros de produção para aperfeiçoar o uso de equipamentos, entre outros.

O dado sempre foi também um ativo organizacional, por isso, o valor do dado vem se tornando ainda maior. Se existe uma preocupação com ativos materiais, naturalmente a empresa deve ter procedimentos de governança também sobre seus dados. Uma governança de dados vai reduzir riscos, proteger a reputação da empresa e de seus colaboradores, atender a questões regulatórias, melhorar a gestão e consequentemente melhorar o negócio (Amaral, 2016).

1.1 Qualidade de dados

O fato de haver mais dados e em maior volume disponíveis para as organizações não significa que estes sejam dados de qualidade. Uma das promessas do Big Data é que os requisitos de qualidade e estrutura de dados serão menores do que no *data warehouse* tradicional.

A qualidade dos dados, ou melhor, a falta de qualidade causa prejuízos em todas as áreas: medicina, aeronáutica, indústria, comércio, serviços, em virtude de decisões erradas, perda de oportunidades, prejuízos financeiros, perda de clientes e problemas de produção (Amaral, 2016).

1.2 Análise de dados para auditorias

As auditorias internas e externas sempre tiveram uma relação estreita com análise de dados. O processo clássico de auditoria envolve inspecionar documentos. Por questões de tempo e custos, a inspeção de todos os documentos é inviável, então, utiliza-se um processo de amostragem, que dá a todos os documentos a mesma chance de serem auditados.

Por outro lado, a análise de dados permite que 100% dos eventos sejam inspecionados, de forma mais rápida, segura e com menor custo. Um fato relevante para as auditorias é que se estima, em média, que 5% do faturamento das empresas sejam perdidos com fraudes. Os dados permitem que cada vez

mais eventos auditáveis estejam disponíveis na forma de dados digitais, aumentando cada vez mais o escopo de eventos auditáveis com o auxílio da tecnologia da informação (Amaral, 2016).

1.3 Segurança e privacidade

A era da informação traz consigo uma série de preocupações relacionadas à segurança e à privacidade. Vazamento de arquivos, fotos, vídeos, casos de espionagem internacional, crimes desvendados em redes sociais, aplicativos de encontros causando separações e divórcios.

Com um mundo cada vez mais digital, estamos deixando nossos rastros digitais. Isso nem sempre é opcional. Devemos ter muita preocupação com sigilo e segurança de nossos dados, para ficar menos vulnerável, entretanto, nossos rastros na internet sempre ficam registrados: *sites* de compra, como usamos nosso telefone celular, utilização de cartões de crédito, os sensores que temos no carro, no celular, entre outros.

Quando utilizamos redes sociais, *sites* e algumas aplicações que de alguma forma disponibilizam nossos dados, ocorrem os chamados vazamentos de informações pela ação de *hackers*, empresas que coletam dados para *marketing*, processos de mineração de dados.

O direito à privacidade está vinculado a políticas de privacidade e legislações ainda arcaicas. O fato é que as mudanças sociais e culturais causadas pela internet ocorrem de forma muito mais rápida do que a sociedade, as empresas e a própria legislação conseguem se adequar. A sociedade já sofreu mudanças nessa era, porém, é só o começo. Nós, usuários, ainda não sabemos até que ponto nossa privacidade está sendo invadida, se existem leis para nos proteger dessa provável invasão, ou ainda, aonde isso pode chegar. O fato é que a privacidade é, acima de tudo, um direito; não se trata apenas de ter o que esconder ou ser um criminoso (Amaral, 2016).

1.4 Projetos de dados

Os projetos de dados podem envolver uma série de tecnologias, recursos humanos formados por equipe multidisciplinares e requisitos de infraestrutura de TI. Um projeto de dados como qualquer outro requer uma boa gerência que inclua uma boa gestão dos envolvidos e partes interessadas, escopo do projeto, custo,

orçamento. Os projetos de dados englobam: banco de dados, *data warehouses*, desenvolvimento de modelos, extração, transformação e produção de informações, inteligência de negócios, integração de aplicativos e envolvimento de vários tipos de tecnologia.

Como qualquer outro projeto, uma das etapas mais importantes é a análise e gestão de riscos. Existem alguns riscos comuns como:

- Qualidade dos dados: fazer um processo de higienização dos dados, isso é feito através de algoritmos, *software* e ferramentas de mercado especializadas, porém em algumas situações é necessária intervenção humana.
- Tecnologia inadequada: algumas tecnologias ainda não estão devidamente testadas e consolidadas, falta de mão de obra qualificada, suporte técnico não disponível, recursos limitados, arquiteturas e sistemas operacionais com pouca portabilidade.
- Recursos humanos: a disponibilidade de especialistas de negócios ao longo dos projetos é muito importante, em algumas situações esses profissionais estão envolvidos com outras atividades dentro da organização e a indisponibilidade de profissionais qualificados pode ser um risco muito grande.
- Viabilidade técnica: fazer um estudo de viabilidade não é muito simples, existem vários fatores, acessibilidade de dados, uso de tecnologia obsoleta, dados com criptografia, volume de dados inadequado, problemas de infraestrutura, extração, transformação, análise e entrega de dados.

TEMA 2 – INFRAESTRUTURA DE TECNOLOGIA

O Big Data tem chamado muito a atenção pelo aumento dos volumes de dados. Há uma década não imaginávamos que teríamos discos rígidos com terabytes dentro de nossas residências.

As tecnologias que sustentam Big Data podem ser analisadas sob duas óticas: as envolvidas com Analytics, tecnologias como Hadoop e MapReduce como nomes principais da infraestrutura que armazenam e processam petabytes de dados. Nesse aspecto, temos também os bancos de dados NoSQL. O Big Data é a simples constatação prática de que o imenso volume de dados gerados a cada dia excede a capacidade das tecnologias atuais de os tratar adequadamente.

A TI deve planejar sua arquitetura tecnológica para suportar essa demanda, seja em equipamentos próprios, ou, cada vez mais provável, seja em ambiente de computação nuvem (Taurion, 2013).

Nesse contexto de infraestrutura, é importante entender os diversos formatos, padrões de dados, sistemas e arquitetura, ter disponível tecnologias que possam coletar dados de diversas fontes, mídias, câmeras, vídeos e sensores, com o uso cada vez maior de celulares, dispositivos móveis, mídias sociais e até mesmo a internet das coisas, o volume de dados gerados irá crescer de forma exponencial.

2.1 Tecnologias Big Data

O Big Data é mais que apenas um grande volume de dados não estruturados. Ele também inclui as tecnologias que possibilitam seu processamento e análise. As tecnologias específicas de Big Data têm a capacidade de analisar conteúdo de texto, vídeo e áudio. No contexto de Big Data de fluxo rápido, tecnologias como o aprendizado de máquina possibilitam a rápida criação de modelos estatísticos que se encaixam aos dados, os otimizam e os preveem (Davenport, 2014).

Davenport apresenta uma visão geral das tecnologias de Big Data:

- a) Hadoop: *software* de código aberto para o processamento de Big Data em uma série de *servidores* paralelos;
- b) Map Reduce: um *framework* (conjunto de ferramentas) arquitetônico no qual o Hadoop se baseia;
- c) Linguagens de Script: linguagens de programação adequadas à Big Data (por exemplo Python, Pig e Hive);
- d) Aprendizado de máquina: *software* para identificar rapidamente o modelo mais adequado ao conjunto de dados;
- e) Visual Analytics: apresentação dos resultados analíticos em formatos visuais ou gráficos;
- f) Processamento de linguagem natural (PLN): *software* para análise de texto – frequências, sentido, entre outros;
- g) In-memory Analytics: processamento de Big Data na memória do computador para obter maior velocidade.

O Big Data é uma nova tendência de negócio que apresenta um impacto potencial sobre os investimentos de TI, é uma ameaça as grandes empresas que utilizam tecnologia legadas, o modo de armazenamento, processamento e análise que os dados recebem hoje. A infraestrutura de *hardware* e *software* estão sofrendo fortes transformações com o desenvolvimento do Big Data, a aplicação dessas tecnologias está sendo feitas de várias maneiras diferentes.

2.2 Camadas Big Data

De acordo com Davenport, tendo em vista os acontecimentos e todas as tendências tecnológicas estratégicas, o Big Data traz consigo uma gama de funcionalidades bem especializadas que o difere dos sistemas legados. O Big Data é formado por diversos componentes que podem ser classificados em camadas empilhadas (*stack*) de tecnologia, cada camada do empilhamento trabalha em conjunto, tudo é ajustado para que desde do armazenamento, incluindo o processamento até a camada de aplicação trabalham em alto desempenho:

- **Armazenamento:** a capacidade de armazenar grandes e diversas quantidade de dados em discos rígidos está ficando cada vez mais barata, as tecnologias de disco têm evoluído muito e estão mais eficientes. O armazenamento é feito utilizando um grupo de discos e conectados a servidores num regime de *comodities*. Hoje as soluções de armazenamento estão mais acessíveis, são escaláveis e são alternativas para arquivamento e a recuperação rápida de grandes volumes de dados.
- **Infraestrutura de plataforma:** Big Data é um conjunto de funcionalidades, as plataformas geralmente oferecem uma base, que é um mecanismo-chave para a execução do Big Data, destaque para o Hadoop, um projeto de código aberto que vem sendo adotado como plataforma de processamento para o Big Data. Com os efeitos da adoção e ascensão dessas novas plataformas, houve uma mudança de paradigmas em relação as soluções de análise de dados, com o Hadoop é possível concatenar cargas de trabalho complexas e fazer transformações de grandes volumes de dados não estruturados em dados estruturados para possíveis análises.
- **Dados:** existe um leque muito grande de aplicações para utilizados de diversos tipos de dados, seja na medicina (genoma humano), na

engenharia (sensores em poços de petróleo), no comércio eletrônico (localização e pesquisa de produtos), nas mídias sociais, entre outros. A camada de dados mostra que esses dados são um grande ativo, sendo justificada a sua gestão, auditoria e governança. Existe uma preocupação muito grande com a qualidade dos dados, a integração, as atualizações, segurança e privacidade dos dados na adoção do Big Data, outro ponto de atenção se refere à propriedade dos dados e às responsabilidades pela gestão continuada, ou seja, são desafios referentes à governança do Big Data.

- Código de aplicação: a codificação utilizada na manipulação dos dados é bem variável, o Hadoop utiliza um *framework* (conjunto de ferramentas) de processamento, que chamamos de MapReduce, o Big Data não é só distribuir dados entre discos de armazenamento; é necessário elaborar e manipular uma série de instruções computacionais complexas a esses dados. As instruções do MapReduce podem ser processadas em paralelo aos vários nós componentes da plataforma de Big Data, disponibilizam novas estruturas de dados e vários conjuntos de respostas. O Apache Pig e o Hive são linguagens de código aberto que utilizam *scripts* (programa que automatiza a execução de tarefas) dentro da plataforma Hadoop. Outra linguagem que também aparece para manipulação de *scripts* é o Python.
- Visão de negócios: essa camada prepara o Big Data para possíveis análises posteriores. Em algumas aplicações de Big Data, é necessária uma estrutura de dados intermediária como modelos estatísticos, tabelas relacionais, cubos de dados, entre outras estruturas. Modelos SQL são muito utilizados por ser uma ferramenta tradicional de consulta. Essa visão de negócios tem o objetivo de adaptar o Big Data às necessidades e às ferramentas das empresas, aproveitando o conhecimento que já existe dentro das organizações.
- Aplicações: a última camada de aplicação apresenta os resultados do processamento do Big Data aos usuários do negócio ou para sistemas que utilizem os resultados do Big Data para a tomada de decisões automáticas. Nessa camada, a apresentação dos dados é muito importante. A preferência é sempre por ferramentas gráficas e intuitivas, planilhas pouco práticas usadas antigamente não são recomendadas.

TEMA 3 – BANCO DE DADOS CASSANDRA

Os bancos de dados NoSQL (não relacionais) trouxeram uma mudança de paradigmas na sua utilização. A maioria dos bancos de dados utilizados hoje é composta de banco de dados relacionais. É importante mostrar as características dos bancos de dados NoSQL, por mais que haja poucas comparações entre os modelos de banco de dados, os bancos de dados NoSQL foram criados para atender a outros cenários de gerencia de dados. O banco de dados Apache Cassandra é utilizado pela Amazon, mas foi criado originalmente pelo Facebook.

3.1 Banco de dados Apache Cassandra

Cassandra é uma das implementações NoSQL do que podemos chamar família de colunas, que suporta o modelo de dados Big Table e possui muito pontos da arquitetura introduzida pelo Amazon DynamoDB, um serviço de banco de dados em nuvem compatível com armazenamento de documentos e baseado em chave-valor (Machado, 2018).

Para Machado, algumas características do Cassandra são:

- a) Alta escalabilidade e alta disponibilidade, pois permite adicionar novos elementos ao cluster, de forma rápida e sem colocar em risco o desempenho do sistema, já que existem sistemas operando em produção com a utilização do Cassandra e outros elementos do sistema distribuído (cluster), sem um ponto único de falha;
- b) Implementa o conceito de família de colunas NoSQL;
- c) Seus modelos de dados são facilmente alterados, sendo muito flexível;
- d) Rendimento de gravação muito alto e bom rendimento de leitura;
- e) Linguagem de consulta semelhante a SQL e suporte para procura por índices secundários;
- f) Escalabilidade linear, podendo ser aumentada com a adição de novos nós;
- g) Consistência ajustável e suporte para replicação, podendo estar em vários data centers.

3.2 Cassandra e sua estrutura

Dentro de sua estrutura, o banco de dados Cassandra possui um modelo de dados formado por: linhas, colunas, família de colunas e *keyspace*. Vamos entender cada componente:


- a) Coluna: unidade básica do modelo de dados do Cassandra, contém um nome, um valor e um registro de data e hora, podemos ignorar esses registros e é possível representar uma coluna como um par de nome e valor (por exemplo, `author="Uninter"`);
- b) Linha: é uma coleção de colunas rotuladas por um nome.

O banco de dados Cassandra consiste em muitos nós de armazenamento, cada um deles é armazenado em cada linha. Em cada linha, Cassandra sempre armazena as colunas classificadas por seus nomes. Tendo em vista essa ordem de classificação, o banco de dados Cassandra tem suporte a consulta de fatias, das quais, dada uma linha, os utilizadores podem recuperar um subconjunto de suas colunas que estejam em determinado intervalo de nomes de coluna. Podemos considerar que uma família de colunas é como uma tabela no modelo relacional (Machado, 2018).

- c) *Keyspace*: é um grupo de várias famílias de colunas agrupadas, é uma espécie de agrupamento lógico de famílias de colunas que apresenta um escopo isolado para nomes.

A Figura 1 apresenta a estrutura de um banco de dados NoSQL:

Figura 1 – Estrutura de Banco de Dados NoSQL



Fonte: Machado, 2018.

3.3 Modelo de dados Cassandra

No modelo de dados do Cassandra, os dados são hospedados em um espaço bidirecional em cada família de colunas. Para a recuperação dos dados, os utilizadores necessitam de duas chaves: nome da linha e nome da coluna. Nesse contexto, os modelos do Cassandra e o modelo de banco de dados relacionais são parecidos, embora existam algumas diferenças.

No armazenamento de dados no Cassandra, as colunas são classificadas em concordância com seus nomes, isso favorece a procura de dados em uma coluna utilizando as consultas de fatias. A busca por dados em uma linha é mais difícil, as linhas do Cassandra podem possuir muitas colunas, essa variação do número de colunas ocorre, bem diferente do modelo de dados relacionais, que apresentam poucas colunas. Os esquemas de dados no Cassandra podem ser ajustados para as consultas específicas exigidas pelos aplicativos.

TEMA 4 – CONSULTAS E OPERAÇÕES DO BANCO DE DADOS CASSANDRA

Tendo em vista que o Cassandra faz o armazenamento das colunas classificadas por seus nomes, as consultas de fatia são notadamente rápidas.

Destacamos que a classificação de todos os detalhes de um item de dados em uma única linha e o uso de classificações de ordem são as ideias mais importantes por trás do *design* de dados do Cassandra. Os usuários podem usar as ordens de classificação do armazenamento de dados e criar índices, ao anexar registros de data e hora como chaves de coluna, os resultados das pesquisas teriam a mesma ordem e isso acaba gerando um ID de coluna exclusivo (Machado, 2018).

4.1 Chaves do Cassandra são imutáveis

No banco de dados Cassandra, não existem chaves estrangeiras, dessa forma, o Cassandra não faz a gerência e consistência de dados para os utilizadores, estes também não podem fazer a alteração de chaves, todavia a aplicação que for utilizar o banco de dados deve tratar e lidar com a consistência de dados. É recomendável a utilização das chaves geradas (*surrogate keys*), gerenciadas como uma de suas propriedades.

4.2 Chaves do Cassandra devem ser exclusivas

As chaves dentro do Cassandra devem ser exclusivas. Cada chave (seja de linha ou coluna) devem ser utilizadas de forma exclusiva no escopo de dados, se em existirem casos em que a mesma chave seja utilizada duas vezes, provavelmente os dados serão sobrescritos dentro do banco de dados. Para Machado, existem duas soluções para esse problema:

- a) Em primeiro lugar, uma solução é usar uma chave composta, em outras palavras, criar uma chave combinando vários campos. Essa solução é usada frequentemente com chaves de linha.
- b) Em segundo lugar, como solução, nos casos em que há o risco de uma mesma chave ocorrer duas vezes, podemos incluir na chave um valor aleatório qualquer ou um registro de data e hora.

Para evitar que duas entradas tenham o mesmo nome de coluna por apresentarem a mesma classificação, o registro de data e hora é incluído após o nome (Machado, 2018).

4.3 Operações com falhas

O Cassandra suporta operações idempotentes, a idempotência é uma propriedade em que as operações podem ser utilizadas várias vezes sem que os valores resultantes dessas operações se alterem após uma utilização inicial. Quando a operação atinge seu objetivo, tudo fica certo, quando a operação falha o utilizador pode tentar novamente, todavia se a operação falhar novamente é possível que isso cause algum dano ao banco de dados. Esse tipo de problema precisa ser ajustado pelos desenvolvedores dos aplicativos.

4.4 Seleções de dados

Uma característica do Cassandra é que ele não possui a seleção e procura de dados integrada, tem suporte a índices secundários, gerados automaticamente pelo sistema, entretanto com funcionalidades limitadas, falhas com os índices secundários fazem os utilizadores ter que aprender mais sobre o modelo de dados e desenvolver seus índices secundários com parâmetros de fatias e ordem de classificação.

Para Machado, existem três áreas com complexidade associada à criação de métodos de procura:

- a) Para a criação dos métodos de procura customizados, os desenvolvedores precisam entender de índices e detalhes sobre armazenamento em um grau maior, assim, o Cassandra requer desenvolvedores mais qualificados.
- b) As ordens de classificação são pontos complicados. Existem dois tipos de ordem de classificação: na primeira, as colunas são classificadas por nome; na segunda, as ordens de classificação de linha funcionam somente se um particionador que preserva a ordem de utilização.
- c) A inserção de novas consultas geralmente demanda mais alterações nos índices e na codificação. Diferente dos modelos relacionais, os desenvolvedores precisam analisar em detalhes as consultas antes de iniciar o armazenamento dos dados.

TEMA 5 – TEXT MINING

Hoje, o mundo está orientado a dados e informações, com a revolução digital por meio das mídias sociais, a mobilidade, a computação em nuvem e o Big Data, as chamadas *ondas tecnológicas* têm contribuído para que o volume de dados na internet cresça de uma maneira exponencial, entretanto, é necessário entender a quantidade de dados e à qualidade de informação.

A extração de informações da internet, bem como sua orientação e análises, é um grande desafio. Os processos de mineração de texto (*text mining*), por meio de dados estruturados ou não estruturados, de associações, padrões, alterações e anomalias que impulsionam a produção do conhecimento. O processo de mineração de dados vai ser indispensável.

5.1 Metas e objetivos da mineração de texto

A mineração de texto parece um processo simples, entretanto, possui algumas premissas para que seja um *text mining* que atinja êxito: as metas e objetivos devem ser bem definidos, a equipe profissional muito qualificada, *softwares*, algoritmos e metodologias devem ser implementadas ao longo de um projeto de mineração de texto.

Quando utilizamos uma mineração de texto, é importante ter em mente um problema a ser resolvido, seja uma regra de negócio, uma classificação, valores numéricos e estatísticos, primordial é traçar metas alcançáveis e apresentar um modelo que seja possível ser ajustado de forma constante, tudo isso deve estar bem definido no escopo do projeto de mineração de texto e principalmente dentro dos prazos e sabendo utilizar os recursos disponíveis.

5.2 Recursos humanos

Uma equipe necessária para projetos de mineração de dados deve ter conhecimento multidisciplinar, com conhecimentos em várias áreas. Para a elaboração de modelos eficientes e eficazes, é imprescindível que o conhecimento seja compartilhado por diversas áreas. Um bom analista de negócio é importante para orientar as metas e objetivos dos estudos, focando nas necessidades dos usuários (clientes), um cientista de dados que tenha bons conhecimentos técnicos e estatísticos que possa analisar, determinar, concatenar e processar os dados e transformar em informação gerando conhecimento, por

fim, o gerente do projeto é responsável por coordenar as atividades e garantir que os profissionais entreguem um bom resultado seguindo a metodologia proposta.

5.3 Técnicas, sistemas e algoritmos

Para a elaboração e criação de um modelo de dados é necessária ter uma boa base de dados, com muito histórico e principalmente que tenham os resultados, ou seja, as respostas que o projeto de mineração de texto procura encontrar, existem no cenário atual um grande leque de opções para a construção de modelos preditivos, sejam soluções proprietárias, sejam de código aberto, é desejável que apresentem facilidade na implementação e desenvolvimento.

Nesse contexto, destaca-se a linguagem R, que traz muita flexibilidade por se mostrar uma linguagem de programação estatística. Outra ferramenta de destaque é o Weka, que possui uma coleção de algoritmos prontos como: árvores de decisão, classificação probabilística bayesiana, aprendizagem de máquina e métodos de agrupamento, entre outras, são algoritmos que podem trazer bons resultados aos projetos. Outra solução que merece ser citada é o Orange, feito sob a linguagem Python, oferecendo interfaces gráficas e possui codificação aberta.

Dentro da lista de ferramentas proprietárias, que são pagas, temos o Google Prediction, essa solução acelera o processo de mineração, pois executam previamente técnicas de filtragem, remoção de caracteres especiais, acentuação, sintetiza palavras, faz a exclusão de palavras sem relevância, tudo isso incluso de forma oculta em seus algoritmos. Existem outras ferramentas que merecem destaque como o IBM Watson, Microsoft Azure ML e Amazon ML, todos com técnicas de validação para projetos de modelos preditivos.

5.4 Metodologias

Dentro dos projetos de mineração de texto, uma metodologia que se destaca é a CRISP-DM (Cross Industry Standard for Data Mining). É um guia que é referência de mercado em mineração de dados, foi elaborado na década de 1990 por vários profissionais da área de TI. A IBM é detentora dos direitos. O guia apresenta 6 fases que devem fazer parte de qualquer tipo de projeto de mineração de dados. Existe uma sequência lógica das fases, porém, é possível readequar

as etapas. As fases são: entendimento do negócio, entendimento dos dados, preparação de dados, modelagem, avaliação e entrega de resultados.

Os projetos de mineração textual apresentam algumas vantagens, pois é possível fazer agrupamentos do texto com facilidade e de forma rápida, bases estatísticas para análise e comprovação dos processos de mineração. Dessa forma, é possível utilizar essas informações com uma visualização de dados feita e fornecer conhecimento e sabedoria para a tomada de decisões.

REFERÊNCIAS

AMARAL, F. **Introdução a ciência de dados**: mineração de dados e Big Data. Rio de Janeiro: Alta Books, 2016.

DAVENPORT, T. H. **Big data no trabalho**: derrubando mitos e descobrindo oportunidades. Tradução de Cristina Yamagami. Rio de Janeiro: Elsevier, 2014.

MACHADO, F. N. R. **Big data**: o futuro dos dados e aplicações. São Paulo: Érica, 2018.

TAURION, C. **Big Data**. Rio de Janeiro: Brasport, 2013.