

Aula 4

Big Data

Prof. Douglas Eduardo Basso

Governança de Dados

- O dado sempre foi também um ativo organizacional, cujo valor vem se tornando ainda maior
- Se existe uma preocupação com ativos materiais, naturalmente a empresa deve ter procedimentos de governança também sobre seus dados
- Uma governança de dados vai reduzir riscos, proteger a reputação da empresa e de seus colaboradores, atender questões regulatórias, melhorar a gestão e, conseqüentemente, melhorar o negócio

Qualidade de dados

- O fato de haver mais dados e em maior volume, disponível para as organizações, não significa que sejam dados de qualidade
- A qualidade dos dados, ou melhor, a falta de qualidade causa prejuízos em todas as áreas
 - Medicina, aeronáutica, indústria, comércio, serviços, devido às decisões erradas, têm perda de oportunidades, prejuízos financeiros, perda de clientes e problemas de produção

Análise de dados para auditoria

- As auditorias internas e externas sempre tiveram uma relação estreita com a análise de dados
- O processo clássico de auditoria envolve inspecionar documentos
- Os dados permitem que cada vez mais eventos auditáveis estejam disponíveis na forma de dados digitais, aumentando cada vez mais o escopo de eventos auditáveis com o auxílio da tecnologia da informação

Segurança e privacidade de dados

- A era da informação traz consigo uma série de preocupações relacionados à segurança e privacidade
- Com um mundo cada vez mais digital, estamos deixando nossos rastros digitais e isso nem sempre é opcional; devemos ter muita preocupação com o sigilo e a segurança de nossos dados

Projetos de dados

- Os projetos de dados podem envolver uma série de tecnologias, recursos humanos formados por equipe multidisciplinares e requisitos de infraestrutura de TI
- Um projeto de dados – como qualquer outro – requer uma boa gerência que inclua uma boa gestão dos envolvidos e partes interessadas, escopo do projeto, custo, orçamento

Infraestrutura de Tecnologia

- O Big Data é a simples constatação prática de que o imenso volume de dados gerados a cada dia excede a capacidade das tecnologias atuais de os tratarem adequadamente
- A TI deve planejar sua arquitetura tecnológica para suportar essa demanda, seja em equipamentos próprios, ou cada vez mais provável, em ambiente de computação na nuvem

Tecnologias Big Data

- O Big Data é mais que apenas um grande volume de dados não estruturados
- Ele também inclui as tecnologias que possibilitam seu processamento e análise
- As tecnologias específicas de big data têm a capacidade de analisar conteúdo de texto, vídeo e áudio
- Davenport apresenta uma visão geral das tecnologias de big data

- Aprendizado de máquina
 - Software para identificar rapidamente o modelo mais adequado ao conjunto de dados
- Visual Analytics
 - Apresentação dos resultados analíticos em formatos visuais ou gráficos

- Processamento de linguagem natural (PLN)
 - Software para análise de texto – frequências, sentido, entre outros
- In-memory Analytics
 - Processamento de big data na memória do computador para obter maior velocidade

- **Hadoop**
 - Software de código aberto para o processamento de big data em uma série de servidores paralelos
- **Map Reduce**
 - Um *framework* (conjunto de ferramentas) arquitetônico no qual o Hadoop se baseia
- **Linguagens de Script**
 - Linguagens de programação adequadas ao big data (por exemplo, Python, Pig e Hive)

Camadas Big Data

- Tendo em vista os acontecimentos e todas as tendências tecnológicas estratégicas, o big data traz consigo uma gama de funcionalidades bem especializadas que o difere dos sistemas legados
- É formado por diversos componentes que podem ser classificados em camadas empilhadas (*stacks*) de tecnologia
- Cada camada do empilhamento trabalha em conjunto

- Tudo é ajustado para que, desde do armazenamento, incluindo o processamento até a camada de aplicação, trabalhem em alto desempenho
 - Armazenamento
 - Infraestrutura de Plataforma
 - Dados
 - Código de Aplicação
 - Visão de Negócios
 - Aplicações

Banco de Dados Cassandra

- Os bancos de dados NoSQL (não relacionais) trouxeram uma mudança de paradigmas na sua utilização
- Foram criados para atender outros cenários de gerência de dados
- O banco de dados Apache Cassandra é utilizado pela Amazon, mas foi criado originalmente pelo Facebook

Cassandra e sua estrutura

- Cassandra é uma das implementações NoSQL do que podemos chamar *família de colunas*, que suporta o modelo de dados Big Table e possui muitos pontos da arquitetura introduzida pelo Amazon DynamoDB, um serviço de banco de dados em nuvem compatível com armazenamento de documentos e baseado em chave-valor

- Para Machado, algumas características do Cassandra são
 - Alta escalabilidade e alta disponibilidade
 - ✓ Permite adicionar novos elementos ao *cluster*, de forma rápida e sem colocar em risco o desempenho do sistema, já que existem sistemas operando em produção com a utilização do Cassandra e outros elementos do sistema distribuído (*cluster*) sem um ponto único de falha

- Implementa o conceito de *família de colunas NoSQL*
- Seus modelos de dados são facilmente alterados, sendo muito flexível
- Rendimento de gravação muito alto e bom rendimento de leitura


- Linguagem de consulta semelhante à SQL e suporte para procura por índices secundários
- Escalabilidade linear, podendo ser aumentada com a adição de novos nós
- Consistência ajustável e suporte para replicação, podendo estar em vários data centers

Cassandra e sua estrutura

- Dentro de sua estrutura o banco de dados, Cassandra possui um modelo formado por
 - Linhas, colunas, família de colunas e *keyspace*

- Vamos entender cada componente
 - Coluna: unidade básica do modelo de dados do Cassandra contém um nome, um valor e um registro de data e hora. Podemos ignorar esses registros e é possível representar uma coluna como um par de nome e valor (por exemplo, `author="Uninter"`)

- Linha: é uma coleção de colunas rotuladas por um nome
- *Keyspace*: é um grupo de várias famílias de colunas agrupadas, é uma espécie de agrupamento lógico de famílias de colunas que apresenta um escopo isolado para nomes



Modelo de dados Cassandra

- No modelo de dados do Cassandra, os dados são hospedados em um espaço bidirecional em cada família de colunas
- Para a recuperação dos dados, os utilizadores necessitam de duas chaves
 - Nome da linha e nome da coluna
 - ✓ Dentro desse contexto os modelos do Cassandra e o modelo de banco de dados relacionais são parecidos, embora existam algumas diferenças

Consultas e Operações do Banco de Dados Cassandra

- A classificação de todos os detalhes de um item de dados em uma única linha e o uso de classificações de ordem são as ideias mais importantes por trás do design de dados do Cassandra
- Os usuários podem usar as ordens de classificação do armazenamento de dados e criar índices

- Ao anexar registros de data e hora, são incluídos como chaves de coluna
- Os resultados das pesquisas teriam a mesma ordem e isso acaba gerando um ID de coluna exclusivo

Chaves do Cassandra são imutáveis

- No banco de dados Cassandra não existem chaves estrangeiras, dessa forma, o Cassandra não faz a gerência e consistência de dados para os utilizadores, estes também não podem fazer a alteração de chaves, todavia, a aplicação que for utilizar o banco de dados deve tratar e lidar com a consistência de dados
- É recomendável a utilização das chaves geradas (*surrogate keys*), recomenda-se gerenciar essas chaves como uma de suas propriedades

Chaves do Cassandra devem ser exclusivas

- As chaves dentro do Cassandra devem ser exclusivas
- Cada chave (seja de linha ou coluna) deve ser utilizada de forma exclusiva no escopo de dados
- Se existirem casos em que a mesma chave seja utilizada duas vezes, provavelmente os dados serão sobrescritos dentro do banco de dados

- Para evitar que duas entradas tenham o mesmo nome de coluna por apresentarem a mesma classificação, o registro de data e hora é incluído após o nome

Operações com falhas

- O Cassandra suporta operações idempotentes
- A idempotência é uma propriedade em que as operações podem ser utilizadas várias vezes, sem que os valores resultantes dessas operações se alterem após uma utilização inicial

- Quando a operação atinge seu objetivo, tudo fica certo
- Quando a operação falha, o utilizador pode tentar novamente, todavia, se a operação falhar mais uma vez, é possível que isso cause algum dano ao banco de dados
 - Esse tipo de problema precisa ser ajustado pelos desenvolvedores dos aplicativos

Seleções de dados

- Uma característica do Cassandra é que ele não possui a seleção e procura de dados integrada, tem suporte a índices secundários, gerados automaticamente pelo sistema
- No entanto, com funcionalidades limitadas, falhas com os índices secundários fazem os utilizadores terem que aprender mais sobre o modelo de dados e desenvolverem seus índices secundários com parâmetros de fatias e ordem de classificação

Text Mining

- A extração de informações da internet, bem como sua orientação e análises é um grande desafio
- Os processos de mineração de texto (*text mining*), sejam por meio de dados estruturados ou não estruturados, de associações, padrões, alterações e anomalias que impulsionam a produção do conhecimento
- O processo de mineração de dados vai ser indispensável

Metas e objetivos da mineração de texto

- Quando utilizamos uma mineração de texto, é importante ter em mente um problema a ser resolvido, seja uma regra de negócio, uma classificação, valores numéricos e estatísticos
- É primordial traçar metas alcançáveis e apresentar um modelo que seja possível ser ajustado de forma constante

- Tudo isso deve estar bem definido no escopo do projeto de mineração de texto e principalmente dentro dos prazos e sabendo utilizar os recursos disponíveis

Recursos humanos

- Uma equipe necessária para projetos de mineração de dados deve ter conhecimento multidisciplinar em várias áreas
- Para a elaboração de modelos eficientes e eficazes, é imprescindível que o conhecimento seja compartilhado por diversos segmentos

- Um bom analista de negócios é importante para orientar as metas e os objetivos dos estudos, focando nas necessidades dos usuários (clientes)
- Um cientista de dados que tenha bons conhecimentos técnicos e estatísticos, que possa analisar, determinar, concatenar e processar os dados e transformar em informação gerando conhecimento

- O gerente do projeto é responsável por coordenar as atividades e garantir que os profissionais entreguem um bom resultado seguindo a metodologia proposta

Técnicas, sistemas e algoritmos

- Para a elaboração e criação de um modelo de dados, é necessário ter uma boa base de dados, com muito histórico e, principalmente, resultados, ou seja, as respostas que o projeto de mineração de texto procura encontrar
- Existe no cenário atual um grande leque de opções para a construção de modelos preditivos, sejam soluções proprietárias ou de código aberto
- É desejável que apresentem facilidade na implementação e no desenvolvimento

Metodologias

- Dentro dos projetos de mineração de texto, uma metodologia que se destaca é a **CRISP-DM** (*Cross Industry Standard for Data Mining*), um guia que é referência de mercado em mineração de dados e foi elaborado na década de 1990 por vários profissionais da área de TI
 - A IBM é detentora dos direitos

- O guia apresenta 6 fases que devem fazer parte de qualquer tipo de projeto de mineração de dados. Existe uma sequência lógica, porém, é possível readequar as etapas
- As fases são
 - Entendimento do negócio
 - Entendimento dos dados
 - Preparação de dados
 - Modelagem
 - Avaliação e entrega de resultados