

# | BIG DATA

---

## TEMA 1 – MAPREDUCE

Dentro do contexto das tecnologias que desenvolvem e impulsionam o tratamento de grandes volumes de dados e que atuam com o V da velocidade do Big Data, temos o conjunto de ferramentas (*framework*) de codificação e programação MapReduce.

Imagine que temos várias máquinas e queremos dar um pedaço do processamento para cada uma delas. O MapReduce é um modelo de programação, ou seja, um *framework* de programação que permite um processamento paralelo largamente distribuído de grandes conjuntos de dados, convertendo-os em um conjunto de listas ordenadas, reduzindo o tamanho desses conjuntos e gerando listas ordenadas ainda menores. Não necessariamente sua função é fazer classificação (Machado, 2018).

Explicando em poucas palavras, o MapReduce foi elaborado para atuar com computação paralela distribuída e transformar grandes volumes de dados em pedaços menores. Foi um desafio para a Google fazer o processamento sobre grandes volumes de dados não relacionais.


O MapReduce foi projetado para trabalhar com problemas que podem ser fracionados em, digamos, subproblemas, de forma que possamos trabalhar com a aplicação de duas funções separadamente: mapeamento – Map – e redução – Reduce (Machado, 2018).

Essas duas etapas são feitas da seguinte forma:

- a) Mapeamento de dados: na primeira etapa os dados de entrada são distribuídos em pares e divididos em fragmentos. A cada fragmento é atribuída uma tarefa de mapeamento, e ao fazer a criação de uma função Map o programador deve declarar quais dados contidos nas entradas serão utilizados como chaves e valores. Durante o processamento, esses dados são classificados e formam um novo conjunto de dados que serão utilizados posteriormente para a etapa de redução.
- b) Redução de dados: as operações de redução recebem um conjunto de dados atribuídos pela função Map, e o processamento do conjunto é feito de acordo com as regras e codificações do programador. Esse processamento é executado em um sistema distribuído, e o resultado é publicado e gravado em uma unidade de armazenamento global.

Em resumo, para tratar dados de alto volume, velocidade e variedade, é possível usar processos de mapeamento e redução para classificar os dados em pares chave-valor e reduzi-los em pares menores por meio de operações de agregação que combinam múltiplos valores de uma base de dados, em um único valor (Machado, 2018)

Figura 1 – Estrutura MapReduce



Fonte: Machado, 2018.

### 1.1 Execução paralela


A operação de Map é distribuída em múltiplas máquinas a partir do particionamento dos dados em pedaços que podem ser processados em paralelo por diferentes máquinas. A operação de Reduce é distribuída por meio do particionamento das chaves intermediárias. O tamanho e a função de particionamento são parâmetros fornecidos pelo programador (Machado, 2018).

### 1.2 Processos de execução

O processo inicial divide os dados de entrada em fatias (*split*), seguindo para a fase de execução de múltiplas cópias do programa dentro de um sistema distribuído. Dentro dos programas em execução existe o programa máster, e os demais programas são cópias do máster, as *workers*. O programa máster distribui tarefas de Map ou de Reduce, e os programas *workers* recebem em suas instruções os dados de entrada e utilizam as funções Map criadas pelo programador.

Muitas operações de ordenação são executadas ao longo do processo. Os programas trocam uma série de informações de localização, chaves e valores intermediários; quando todas as tarefas são executadas, o programa máster retorna os dados para o programa do usuário e o resultado é salvo, com vários arquivos de saída. A Figura 2 mostra os detalhes de execução do particionamento MapReduce:

Figura 2 – Detalhes de execução MapReduce



Fonte: Machado, 2018.

### 1.3 Tolerância a falhas

Em um sistema distribuído, como várias máquinas conectadas fazem da tolerância a falhas algo muito importante, o processo máster faz todo o controle de falhas testando periodicamente a comunicação com os processos *workers*. Quando um processo *worker* falha, todas as tarefas daquele processo são migradas para outro, e quando existe qualquer falha ao longo do processo existe um mecanismo de repetição da execução, de forma a garantir que as tarefas tenham sido todas completadas. Os arquivos de saída devem ser armazenados em discos locais com êxito; caso ocorra uma falha dentro desse processo, os dados podem ficar inacessíveis.

Em uma situação de falha do processo máster, são executados *checkpoints* de tempos em tempos de toda a estrutura de dados. Caso ocorram falhas, é criada

---

uma nova instância de dados, recuperando assim o último *checkpoint* salvo. Antes da ocorrência da falha, no MapReduce existe apenas um processo máster, dessa forma nele não são desejáveis falhas.

Lentidões em algumas máquinas pertencentes ao sistema distribuído podem ser um problema. Com isso, durante a execução de alguns programas cópias de tarefas são iniciadas; se uma tarefa até então primária falhar, uma tarefa de *backup* poderá ser invocada.

## 1.4 Localidade

A conectividade de rede é um componente muito importante em um sistema distribuído. A largura de banda é um recurso primordial, e muitas informações do MapReduce são armazenadas em discos locais das máquinas que fazem parte do sistema distribuído. Os arquivos são divididos em blocos de 64MB e armazenam cópia desses blocos em máquinas diferentes (tipicamente, três).

O processo máster do MapReduce leva em conta a localização dos dados na hora de escalonar as tarefas de Map em uma máquina que contém uma das réplicas dos dados de entrada (Machado, 2018).


## TEMA 2 – HADOOP

O Hadoop pode ser definido como um grupo de programas e procedimentos de codificação aberta para operações com grande volumetria de dados.

O projeto Apache Hadoop é um conjunto de ferramentas (*framework*) para o processamento de grandes quantidades de dados em *clusters* computacionais homogêneos. A ideia de promover soluções para os desafios dos sistemas distribuídos em um único *framework* é o ponto central do projeto (Machado, 2018).

Dentro desse conjunto de ferramentas, situações como recuperação de falhas, escalabilidade de aplicativos, disponibilidade de máquinas e integração de dados ficam totalmente transparentes para os utilizadores do *framework*. A programação e o armazenamento nessa plataforma são bem superiores aos das demais tecnologias. Além disso, o Hadoop está em constante crescimento, sendo muito bem aceito nos mundos empresarial e acadêmico. Seu nome teve inspiração em um elefante de pelúcia que pertencia ao filho do criado, Doug Cutting, como mostra a Figura 3.

Figura 3 – Hadoop



Fonte: is am are/Shutterstock.

O Hadoop é apresentado em módulos. Cada módulo possui tarefas essenciais e específicas. O sistema foi desenhado e elaborado para analisar grandes volumes de dados. O Hadoop MapReduce é uma parte importante, cuja responsabilidade é executar todo o processamento dos dados. O MapReduce é a melhor solução para processamento de dados em paralelo.

O Hadoop não é um banco de dados; é uma maneira de armazenar conjunto de dados enormes de servidores distribuídos e depois executar aplicativos de análise de maneira totalmente distribuída. Ele armazena dados que se podem extrair e se assemelha a um *data warehouse*; entretanto, por se tratar de grandes volumes de dados e muita variedade, é tratado em Big Data.

### 2.1 Distributed file system

Um dos pilares do Hadoop é o seu sistema de arquivos distribuídos, que deve possuir um formato de fácil acesso e confiável. Como esses arquivos são utilizados em aplicações muito robustas, devem possuir muita integridade, e, como o Hadoop usa codificação aberta, permite modificações e customizações, o que é visto mais frequentemente em distribuições e aplicações Linux.

Existem outros projetos proprietários de sistemas de arquivos distribuídos, como o GDFS (Google Distributed File System), da Google.

### 2.2 MapReduce e Hadoop

Com a fusão do Hadoop e do MapReduce, o crescimento do primeiro foi muito rápido. Ele surgiu em meados de 2006, quando incorporado pela Yahoo, o que permitiu o fornecimento de um grande time de profissionais. A Yahoo, como

---

grande empresa, dispôs dos recursos necessários e tornou o Hadoop um sistema que poderia ser utilizado em grande escala.

### 2.3 Hadoop Distributed File System

O HDFS é um sistema criado para armazenar arquivos muito grandes em volume de dados, em ambientes distribuídos, em vários servidores de armazenamento. O conceito sobre o qual o HDFS foi construído é o chamado *write once read many times*, ou seja, *escreva uma vez, leia muitas vezes*. Esse tipo de construção é essencial para o Hadoop, uma vez que os dados serão processados inúmeras vezes, dependendo da aplicação, embora, normalmente, sejam escritos apenas uma vez (Machado, 2018).

O HDFS possui um tamanho fixo de bloco de dados 64MB, e os arquivos possuem as operações básicas de leitura, escrita, execução e propriedade de arquivo (dono). O HDFS conta também com um arquivo diferenciado que salva todas as informações de edição de dados (arquivo de *log*), o que permite auditar e ter um controle mais específico sobre o sistema de arquivos.


Em termos de funcionamento, o HDFS necessita de dois tipos de elementos de armazenamento: um *namenode* (mestre) e um ou mais *datanodes* (trabalhadores). O *namenode* comanda todo o sistema de arquivos, mantendo os metadados de todos os arquivos, diretórios da árvore de diretórios e arquivos do sistema. Os *datanodes* guardam e recuperam blocos e, quando mandados pelo nó mestre, enviam relatórios periodicamente, com as listas de blocos que eles estão armazenando (Machado, 2018).

O Hadoop fornece mecanismos de *backup* do sistema de arquivos e utiliza *namenodes* secundários que possam assumir a função de mestre em caso de falhas.

## TEMA 3 – INTEGRAÇÃO DE TECNOLOGIAS BIG DATA

Com as novas ondas tecnológicas, as grandes organizações estão investindo e procurando benefícios com as tecnologias de Big Data, embora disponham de um grande ambiente de TI, redes, banco de dados e demais tecnologias para administrar um negócio. A Figura 4 mostra um cenário em que as tecnologias de Big Data se integram, utilizando o Hadoop centralizado no ambiente, além de promover o armazenamento de dados e o processamento:

Figura 4 – Integração Big Data



Fonte: is am are/Shutterstock.

É possível observar na figura que as fontes de dados são bastante heterogêneas. Esse tipo de ambiente integrado envolve conjuntos de dados não estruturados e semiestruturados bem diversificados, como *e-mails*, arquivos de auditoria de servidores, imagens, redes sociais. As fontes de dados hoje acabam sendo encontradas fora dos perímetros dos *firewalls* das empresas – são os chamados *dados externos*.

### 3.1 Ambientes Big Data

As empresas que adotam ambientes de Big Data no estágio de produção precisam de maneiras mais rápidas e econômicas de processar grandes volumes de dados atípicos. Pense no poder de processamento necessário para que as companhias de energia processem os dados que fluem de medidores inteligentes; para que varejistas monitorem trajetórias de localização de *smartphones* dentro de suas lojas; ou para que o LinkedIn concilie milhões de recomendações de colegas (Davenport, 2014).

Existe uma série de bons cenários para a utilização de um ecossistema de tecnologia de Big Data. Podemos destacar os *games*, que aumentaram a sua



escalabilidade e disponibilidade. Empresas de TI que aderiram ao Hadoop começaram a utilizar algoritmos de análise mais avançados para otimizar previsões, ofertas para clientes e guerras de preço.

Para Davenport, o Hadoop oferece a essas empresas uma maneira de não apenas ingerir rapidamente os dados, mas também processá-los e armazená-los para reutilização. Devido ao custo-benefício superior, algumas empresas chegam a apostar no Hadoop para substituir os *data warehouses*; em alguns casos, são utilizadas linguagens de consulta SQL, que tornam a Big Data mais acessível aos negócios.

### 3.2 Ambientes atuais das empresas

O ambiente atual das empresas apresenta seus servidores com sistemas operacionais e suas fontes de dados: um *data warehouse* com um conjunto de *data marts* integra várias fontes de dados e possui um conjunto de ferramentas de análise e inteligência de mercado (BI), entre outras que oferecem às empresas a possibilidade de uso para auxiliar na tomada de decisão. A Figura 5 mostra as estruturas antes do Big Data:

Figura 5 – *Data warehouse*



Fonte: Aa Amie/Shutterstock.

Com o Big Data, surge um cenário com muito mais oportunidades de expansão, uma visão mais abrangente, com novas funcionalidades que a integração dessas tecnologias pode oferecer às organizações.

---

### 3.3 Junção de ambientes

Com os grandes investimentos em *data warehouses*, BI e Big Data, a maioria das empresas faz a junção dessas tecnologias, em um ambiente estratégico de coexistência, combinando o que tem de melhor nos ambientes. O *data warehouse* contém todas as informações de produtos, clientes, dados históricos, inteligência de mercado e as ferramentas de análise, enquanto o Big Data tem o que é realmente necessário para a obtenção de armazenamento e processamento computacional mais avançado para a exploração de dados estruturados e não estruturados.

Com a junção desses ambientes, se feita de maneira bem canalizada, com divisões de cargas de trabalho entre as plataformas, certamente o resultado será muito melhor e mais rápido, o que acelera os processos de negócio, além de possibilitar a criação de novos negócios.

Algumas organizações já utilizam o Hadoop como o primeiro passo de pré-processamento para a transformação e a exploração de dados e para a descoberta de padrões de tendências (Davenport, 2014).

## TEMA 4 – COLETANDO DADOS EM REDES SOCIAIS

As novas ondas tecnológicas – Big Data, computação em nuvem, mobilidade e as mídias sociais – estão intimamente ligadas. Dessa forma surgem as ideias de coleta de dados em mídias sociais, bem como sua utilização para análises por meio de ferramentas avançadas de Big Data Analytics, buscando sempre padrões novos, informações, conhecimento e detalhes sobre produtos, empresas, serviços e usuários de maneira geral.

Nos Estados Unidos, ocorre o processo de utilização de análise de texto para explorar várias fontes de dados e obter opiniões. Na maior parte das vezes, a análise do sentimento sobre alguma coisa é feita em dados coletados na *internet* e várias plataformas de redes sociais. Gestores que acompanham a evolução da tecnologia já entendem o quanto as potencialidades que o uso desse tipo de estratégia permite saber o que as pessoas pensam sobre alguma coisa. Apesar disso, mesmo para quem está mais atualizado e é usuário de uma rede social, não é simples entender como funciona e como é possível realizar a coleta do grande volume de dados, o Big Data das redes sociais (Machado, 2018).

---

## 4.1 Estrutura de dados

Antes das buscas nas mídias sociais, é primordial conhecer a estrutura de dados e como funcionam as principais redes sociais. A maioria das mídias sociais possui três elementos básicos:

- a) Contatos e conexões: são vínculos e relacionamentos criados na rede social.
- b) Assuntos e conteúdo: são as informações disponibilizadas pelos usuários.
- c) Usuários, perfis, grupos, comunidades, páginas: são todos os dados e atributos dos usuários das redes sociais.

As principais mídias sociais, como Instagram, Twitter, Facebook, YouTube, entre outras, possuem algumas configurações de privacidade para seus utilizadores. As publicações podem ser classificadas como públicas ou privadas. As públicas, obviamente, estão disponíveis para todos visualizarem, e as privadas podem ser visualizadas por grupos, conexões e têm uma série de restrições. Dentro desse contexto essas publicações, bem como as conexões e os grupos, não conseguem apresentar algumas ideias e conceitos.

Nas mídias sociais, é muito comum encontrar alguns itens nas páginas, nos perfis, nos grupos, como imagens, vídeos, textos, fotos, animações etc. Ainda temos tipos de dados como *hashtags*, utilizadas para destacar e identificar um tópico específico. No Twitter existe uma limitação de texto em 280 caracteres.

## 4.2 Coleta de dados

As redes sociais são constantes objetos de pesquisas e estudos acadêmicos, entretanto ainda não existe uma metodologia madura e consolidada para a coleta e a análise dos dados dessas mídias sociais.

Apesar da grande quantidade de informação disponível nas redes, existe a necessidade de fazermos buscas com palavras-chave: nomes, marcas, temas, *hashtags* específicas. Podemos também fazer essa coleta de dados de canais específicos, ou grupos específicos, e escolher determinados usuários a serem acompanhados, assim como buscar a localização geográfica deles para o nosso processo de coleta e classificação, caso seja necessário e útil (Machado, 2018).

Existem muitas mídias sociais, todavia o Twitter é a que permite, com maior facilidade, a análise e grande parte das coletas de dados. Quando falamos de

---

ferramentas de coleta de dados, grandes empresas, gestores e profissionais de TI não contam com investimento para esse tipo de atividade.

Para Machado, o BuzzSumo é uma plataforma de *software* que serve para muitas funções e traz uma infinidade de filtros. Ele é usado para pesquisa de conteúdo e de influenciadores ou monitoramento de palavras-chave em toda a *web*. Existem ferramentas gratuitas, como o Analytics for Twitter, que funcionam como o *plugin* para o Excel da Microsoft, sendo ferramenta de uso pessoal.

A análise de dados em mídias sociais normalmente é usada como estratégia para analisar principalmente campanhas de *marketing* com o intuito de:

- Acompanhar e monitorar campanhas de lançamento de um produto;
- Criar e desenvolver um novo produto;
- Avaliar os comentários e sentimentos do público com relação à marca;
- Obter informações e alertas para alterações e crises;
- Avaliar a audiência dos concorrentes.

#### 4.3 Tipos de dados coletados

Segundo Machado, os principais tipos de dados coletados nas mídias sociais são:

- Cliques em anúncios;
- Navegador;
- Informações de dispositivo (móvel, *desktop*);
- Endereços de *e-mails* e IP;
- Servidores de acesso;
- Localização;
- Reconhecimento facial;
- Sistemas operacionais (Windows, Linux, MacOS);
- Números de telefone;
- Histórico de buscas realizadas;
- Métodos de monitoramento e *cookies*;
- Tecnologias para identificação de dispositivos;
- Perfis de usuário;
- Mecanismo de busca;
- Aplicativos de terceiros;
- Modo de utilização dos dados;

- Serviços baseados em geolocalização;
- Integração entre múltiplas contas;
- Notificações;
- Conteúdo personalizado;
- Publicidades segmentadas.

A maioria das coletas nas mídias sociais utiliza todos esses itens.

## TEMA 5 – TIPOS E CATEGORIAS DE MÍDIAS SOCIAIS

Existem um grande número de mídias sociais, com as mais diversas aplicações e objetivos. Algumas das categorias mais conhecidas na *internet* são entretenimento, multimídia, comunicação e colaboração.

### 5.1 Colaboração

As redes sociais de colaboração trabalham de forma interativa, na qual os usuários e utilizadores compartilham uma série de dados e informações, gerando um conhecimento colaborativo, atingindo um objetivo. Alguns exemplos são: Digg, Wikipedia, Yelp.

### 5.2 Comunicação

As mídias sociais de comunicação são as mais comuns. A conversação é feita entre pessoas, com formação de grupos, realização de comentários, conversas diretas e indiretas, produção de conteúdo, discussões, compartilhamento das mais diversas informações. Os *blogs* entram nessa categoria. Outros exemplos são Facebook, Twitter, LinkedIn, Google+.

### 5.3 Multimídia

São as mídias relacionadas com material e componentes audiovisuais, não limitadas a textos simples. Trabalham com fotos, vídeos, animações, músicas, *podcasts*. Exemplos são YouTube, Instagram, Flickr.

### 5.4 Entretenimento

Nessa categoria surge uma ideia de mundo virtual. São mídias criadas a partir do desenvolvimento de jogos virtuais, a chamada *gamificação*. São

---

ambientes criados de forma *online*, e é estimulada a competição. Os usuários compartilham informações sobre o jogo e seus objetivos. Exemplos: TvTag e Second Life.

## REFERÊNCIAS

AMARAL, F. **Introdução à ciência de dados**: mineração de dados e Big Data. Rio de Janeiro: Alta Books, 2016.

DAVENPORT, T. H. **Big Data no trabalho**: derrubando mitos e descobrindo oportunidades. Tradução de Cristina Yamagami. 1. ed. Rio de Janeiro: Elsevier, 2014.

MACHADO, F. N. R. **Big Data**: o futuro dos dados e aplicações. São Paulo: Érica, 2018.

TAURION, C. **Big Data**. Rio de Janeiro: Brasport, 2013.