

Aula 5

Big Data

Prof. Douglas Eduardo Basso

1

MapReduce

2

- MapReduce é um modelo de programação, ou seja, um *framework* de programação que permite processamento paralelo largamente distribuído de grandes conjuntos de dados, convertendo-os em um conjunto de listas ordenadas, reduzindo o tamanho desses conjuntos e gerando listas ordenadas ainda menores
- Sua função não é necessariamente fazer classificação

3

- Explicando em poucas palavras, o MapReduce foi elaborado para atuar com computação paralela distribuída, transformar grandes volumes de dados em pedaços menores
- Foi um desafio para o Google fazer o processamento sobre grandes volumes de dados não relacionais

4

- O MapReduce foi projetado para trabalhar com problemas que podem ser fracionados em, digamos, subproblemas, de forma que possamos trabalhar com a aplicação de duas funções separadamente
 - Mapeamento (Map)
 - Redução (Reduce)

5

- Essas duas etapas são feitas da seguinte forma
 - Mapeamento de dados
 - ✓ Na primeira etapa, os dados de entrada são distribuídos em pares e divididos em fragmentos, cada fragmento é atribuído a uma tarefa de mapeamento. (...)

6

(...) Ao fazer a criação de uma função Map, o programador deve declarar quais dados contidos nas entradas serão utilizados como chaves e valores. Durante o processamento, esses dados são classificados e formam um novo conjunto, que será utilizado posteriormente para a etapa de redução

7

- Redução de dados
 - ✓ As operações de redução recebem um conjunto de dados atribuídos pela função Map. O processamento do conjunto é feito de acordo com as regras e codificações do programador. Esse processamento é executado em um sistema distribuído e o resultado é publicado e gravado em uma unidade de armazenamento global

8

Execução paralela


- A operação de Map é distribuída em múltiplas máquinas a partir do particionamento dos dados em pedaços que podem ser processados em paralelo por diferentes máquinas
- A operação de Reduce é distribuída por meio do particionamento das chaves intermediárias
- O tamanho e a função de particionamento são parâmetros fornecidos pelo programador

9

Processos de execução

- O processo inicial divide os dados de entrada em fatias (*split*), seguindo para a fase de execução de múltiplas cópias do programa em um sistema distribuído. Dentro dos programas em execução, existe o programa *master*; os demais programas são cópias suas (*workers*)
- O programa *master* distribui tarefas de Map ou de Reduce. Os programas *workers* recebem em suas instruções os dados de entrada, e utilizam as funções Map criadas pelo programador

10



11

Tolerância a falhas

- Um sistema distribuído com várias máquinas conectadas faz da tolerância a falhas algo muito importante
- O processo master faz todo o controle de falhas testando periodicamente a comunicação com os processos *workers*

12

- Quando um processo *worker* falha, todas as tarefas daquele processo são migradas para outro
- Quando existe qualquer falha ao longo do processo, existe um mecanismo de repetição da execução de forma a garantir que as tarefas tenham sido todas completadas

13

Localidade

- A conectividade de rede é um componente muito importante em um sistema distribuído
- A largura de banda é um recurso primordial

14

- Muitas informações do MapReduce são armazenadas em discos locais das máquinas que fazem parte do sistema distribuído
- Os arquivos são divididos em blocos de 64MB e armazenam cópia desses blocos em máquinas diferentes (tipicamente, três)

15

- O processo *master* do MapReduce leva em conta a localização dos dados na hora de escalonar as tarefas de Map

16

Hadoop

17


Projeto Hadoop

- O projeto Apache Hadoop é um conjunto de ferramentas (*framework*) para o processamento de grandes quantidades de dados em clusters computacionais homogêneos
- A ideia de promover soluções para os desafios dos sistemas distribuídos em um único *framework* é o ponto central do projeto

18

- Dentro desse conjunto de ferramentas, situações como recuperação de falhas, escalabilidade de aplicativos, disponibilidade de máquinas e integração de dados ficam totalmente transparente para os utilizadores do *framework*
- A programação e o armazenamento, nessa plataforma, são bem superiores às demais tecnologias

19



20

MapReduce e Hadoop

- Com a fusão do Hadoop e o MapReduce, o crescimento do Hadoop foi muito rápido
- Surgiu em meados de 2006, incorporado pela Yahoo!, o que permitiu um fornecimento de um grande time de profissionais

21

- O Yahoo!, como grande empresa, dispôs dos recursos necessários e tornou o Hadoop um sistema que poderia ser utilizado em escala grande

22

Hadoop Distributed FileSystem

- O HDFS é um sistema de arquivos criado para armazenar arquivos muito grandes em volume de dados, em ambientes distribuídos, em vários servidores de armazenamento
- O conceito sobre o qual o HDFS foi construído é o chamado *write-once, read-many-times* (escreva uma vez, leia muitas vezes)

23


- O HDFS possui um tamanho fixo de bloco de dados 64MB
- Os arquivos possuem as operações básicas de leitura, escrita, execução e propriedade de arquivo (dono)
- O HDFS apresenta um arquivo diferenciado que salva todas as informações de edição de dados (arquivo de log)
 - Isso permite auditar e ter um controle mais específico sobre o sistema de arquivos

24

Ambientes atuais das empresas

- O ambiente atual das empresas apresenta seus servidores com sistemas operacionais e suas fontes de dados
- Um *data warehouse* com um conjunto de *data marts* integra várias fontes de dados, possuem um conjunto de ferramentas de análise, inteligência de mercado (BI), entre outras que possibilitam que as empresas possam utilizar para auxiliar a tomada de decisão

31



32

Junção de ambientes

- Se a junção desses ambientes for feita de maneira bem canalizada, com divisões de cargas de trabalho entre as plataformas, com certeza o resultado será muito melhor e muito mais rápido. Isso acelera os processos de negócio, além de possibilitar a criação de novos negócios
- Algumas organizações já utilizam o Hadoop como o primeiro passo de pré-processamento para a transformação e a exploração de dados e para a descoberta de padrões de tendências

33

Coletando Dados em Redes Sociais

34

- As novas ondas tecnológicas
 - Big data, computação em nuvem, mobilidade e as mídias sociais estão intimamente ligadas
 - Dessa forma, surgem as ideias de coleta de dados em mídias sociais, bem como sua utilização para análises por meio de ferramentas avançadas de Big Data Analytics, buscando sempre padrões novos, informações, conhecimento e detalhes sobre produtos, empresas, serviços e usuários de maneira geral

35

Estrutura de dados

- Conhecer a estrutura de dados e como funcionam as principais redes sociais
- A maioria das mídias sociais possui três elementos básicos
 - Contatos e conexões
 - ✓ São vínculos e relacionamentos criados na rede social

36

- **Assuntos e conteúdo**
 - ✓ São as informações disponibilizadas pelos usuários
- **Usuários, perfis, grupos, comunidades e páginas**
 - ✓ São todos os dados e atributos dos usuários das redes sociais

37

- **As principais mídias sociais, como Instagram, Twitter, Facebook, YouTube, entre outras, possuem algumas configurações de privacidade para seus utilizadores**
- **As publicações podem ser classificadas como públicas ou privadas**

38

- **Nas mídias sociais, é muito comum encontrarmos alguns itens nas páginas, nos perfis, nos grupos como**
 - **Imagens, vídeos, textos, fotos, animações, entre outros**
- **Ainda temos tipos de dados como**
 - **#hashtags: utilizada para destacar e identificar um tópico específico**
 - **Na mídia social Twitter existe uma limitação de texto em 280 caracteres**

39

Coleta de dados

- **Apesar da grande quantidade de informação disponível nas redes sociais, existe a necessidade de usarmos buscas com palavras-chave**
 - **Nomes, marcas, temas, *hashtags* específicas**

40

- **Também podemos fazer essa coleta de dados de canais específicos, ou grupos específicos, além de poder escolher determinados usuários para serem acompanhados e acompanhar e buscar a localização geográfica desses usuários para nosso processo de coleta e classificação, caso seja necessário e útil**

41

- **A análise de dados em mídias sociais normalmente é utilizada como estratégia para analisar principalmente campanhas de marketing com o intuito de**
 - **Acompanhar e monitorar campanhas de lançamento de um produto**
 - **Criar e desenvolver um novo produto**
 - **Avaliar os comentários e sentimentos do público em relação à marca**
 - **Informar e alertar para alterações e crises**
 - **Avaliar a audiência dos concorrentes**

42

- ▀ Os principais tipos de dados coletados nas mídias sociais são
 - Cliques em anúncios
 - Navegador
 - Informações de dispositivo (móvel, *desktop*)
 - Endereços de e-mails e IP
 - Servidores de acesso
 - Localização

43

- Reconhecimento facial
- Sistemas operacionais (Windows, Linux, MacOS)
- Números de telefone
- Histórico de buscas realizadas
- Métodos de monitoramento e *cookies*
- Tecnologias para identificação de dispositivos
- Perfis de usuário

44

- Mecanismo de busca
- Aplicativos de terceiros
- Modo de utilização dos dados
- Serviços com base em geolocalização
- Integração entre múltiplas contas
- Notificações
- Conteúdo personalizado
- Publicidades segmentadas

45

Tipos e Categorias de Mídias Sociais

46

- ▀ Existe um grande número de mídias sociais, com as mais diversas aplicações e objetivos, algumas das categorias mais conhecidas na internet são
 - Entretenimento, multimídia, comunicação e colaboração

47

Colaboração

- ▀ As redes sociais de colaboração estão relacionadas e trabalham de forma interativa
 - As usuários e utilizadores compartilham uma série de dados e informações gerando um conhecimento colaborativo, atingindo um objetivo
- ▀ Alguns exemplos são
 - Digg, Wikipedia, Yelp, entre outras

48

Comunicação

- ▀ As mídias sociais de comunicação são as mais comuns. A conversação é feita entre pessoas, a formação de grupos, a realização de comentários, conversas diretas e indiretas, produção de conteúdo, discussões, compartilhamento das mais diversas informações

49

- ▀ Os blogs entram nessa categoria, outros exemplos são
 - Facebook, Twitter, LinkedIn, Google+, entre outros

50

Multimídia

- ▀ São as mídias relacionadas com material e componentes audiovisuais, não ficam limitadas a textos simples, trabalham com fotos, vídeos, animações, músicas, *podcasts*
- ▀ Exemplos são
 - YouTube, Instagram, Flickr, entre outras

51

Entretenimento

- ▀ Nessa categoria, surge uma ideia de mundo virtual
- ▀ São mídias criadas a partir do desenvolvimento de jogos virtuais, a chamada *gamificação*
- ▀ São ambientes criados de forma on-line e estimulados à competição

52

- ▀ Os usuários compartilham informações sobre o jogo e seus objetivos
 - Exemplo: TvTag e Second Life

53