

| BIG DATA

TEMA 1 – FORMAS DE COLETA DE DADOS

Podemos descrever as mídias sociais como tecnologias e práticas na *internet* que os usuários utilizam para expor suas opiniões, experiências e perspectivas. O conteúdo publicado pode ter vários formatos, incluindo vídeos, fotos, animações, imagens e áudio. O crescimento dessas mídias possibilitou o compartilhamento de ideias, a construção de comunidades virtuais e a democratização do conteúdo.

Segundo Machado, estima-se que 80% de todo conteúdo mundial *online* sejam textos. Considerando que dados não estruturados englobam textos, imagens, vídeos e músicas, pode-se perceber que realmente grande parte da *web* é composta de dados não estruturados, o que implica um processo de coleta do meio de ferramentas que busquem a correlação entre textos de acordo com o objetivo desejado. A Figura 1 demonstra que devemos filtrar esses conteúdos:

Figura 1 – Coleta de dados



Fonte: Tetiana Yurchenko/Shutterstock.

Há duas formas de coleta de dados em mídias sociais. A primeira seria utilizar palavras-chave, ou termos para coletar citações e buscar um histórico de utilização dessas palavras-chave no passado. A segunda forma envolveria um conceito diferente, chamado de *streaming*, em que algumas aplicações trabalham e atuam como “ouvintes” nas redes, fazendo um processo de captura de dados na sequência em que são gerados.

1.1 Estrutura de coleta de dados

Concluída a fase de coleta e captura de dados das mídias sociais, surge a necessidade de estruturar e considerar alguns componentes dessa engrenagem, como:

- Armazenamento de dados: a estratégia de distribuição dos servidores, os sistemas, a rede, enfim, todos os aspectos de infraestrutura de tecnologia. A estrutura é um componente muito importante, e uma boa distribuição garante que as informações sejam armazenadas de forma adequada e segura, com políticas de *backup*. Na maioria dos casos é necessário um bom investimento em estruturas físicas dentro das organizações ou contratação de serviços em computação na nuvem;
- Organização: quando temos muitas informações, existe a necessidade de categorizar e nivelar os dados não estruturados, semiestruturados e estruturados. Tudo isso vem para auxiliar e facilitar nos processos de análise e na distribuição desses dados dentro das plataformas, como o Hadoop e o banco de dados NoSQL;
- Análise de dados: com todos os dados devidamente armazenados e organizados, a análise trata da extração das informações e faz toda a tradução dessas informações em conhecimento, tendo como base os conceitos e as regras de negócios. É bem comum o uso de estatística para auxiliar as organizações na tomada de decisão.

1.2 Utilização de dados

Com uma grande quantidade de dados capturados, a solução é utilizar bons filtros, buscar informações relevantes para o seu negócio. Transformar esses dados em valor e conhecimento é o grande desafio.

É importante saber determinar o que importa ou não para o seu negócio, o que você deseja buscar. A triagem de dados de redes sociais deve mostrar uma grande quantidade de dados, mas será preciso refiná-los para obter informações inerentes aos objetivos do negócio em questão (Machado, 2018).

1.3 Coleta de dados distribuída

Quando a coleta de dados é muito grande nas mídias sociais, isso deve ser feito por *softwares* e ferramentas que trabalhem de maneira distribuída, divididos

em várias máquinas. Todo esse procedimento acontece pela necessidade de processar as requisições de maneira distribuída e pelo fato de os servidores utilizados pelas mídias sociais não entenderem que essas requisições estão sendo feitas por um possível ataque de *hackers* a seus servidores.

TEMA 2 – PROJETOS DE BIG DATA

O nascimento de um projeto de Big Data não ocorre dentro da área de tecnologia das empresas; a amplitude de um projeto assim é grande, e existe uma série de requisitos. É muito importante que haja um diálogo com a alta administração da empresa, além da definição de metas e objetivos a serem atingidos.

Um projeto de Big Data nunca deve ser um objetivo de TI simplesmente, e sim um objetivo compartilhado entre o que a empresa em si tem como metas e objetivos a serem atingidos ao longo do tempo, indicadores de *performance* bem definidos e problemas existentes identificados, para então partirmos para um projeto em busca de resultados desejados e definidos (Machado, 2018).

2.1 Objetivos de negócio

O levantamento dos objetivos e das metas do negócio deve ser claro, as especificidades devem ser apontadas, e é primordial que as metas sejam possíveis de serem alcançadas. Criar uma lista com os pesos de cada meta e objetivo e medir o desempenho ao longo do projeto é muito importante. Dentro do escopo do projeto, deve constar:

- *Performance* da TI: acompanhar as atividades técnicas de captura de dados, preparação, filtragem, classificação, armazenamento, enfim, todas as atividades inerentes de tecnologia;
- Metas alcançadas: mensurar ao longo do projeto as metas alcançadas, se tiveram êxito ou não, e utilizar métricas para que seja possível computar os resultados;
- Definições de tempo: como em qualquer projeto o tempo é um fator-chave, verificar em tempo real o período utilizado para o alcance de cada meta.

2.2 Dados necessários

As organizações possuem muitos dados em seus sistemas internos: cadastro de cliente, registro de produtos, estoque, recursos humanos, compras. Dessa forma, estima-se que a maioria das empresas não usa efetivamente seus dados. Por outro lado, existem muitos dados externos à empresa.

Ao considerar os conjuntos de dados aos quais você não tem acesso, não se limite aos dados externos à sua organização. Primeiramente, olhe para dentro, pois encontrará muitos dados que você nunca imaginou existirem e aos quais não tinha acesso. Isso é bastante comum com o desenvolvimento de sistemas de forma massiva nas empresas (Machado, 2018).

2.3 Grande volume de dados

Quando falamos em volume de dados grande em um projeto Big Data, é preciso ter em mente que a velocidade e a variedade de dados podem tornar mais complicados os processos de extração de informação e, naturalmente, dificultar a criação de bons resultados para o negócio.

Uma boa prática, nesse caso, seria realizar um bom inventário de todos os dados existentes dentro da empresa, adotar parâmetros de capacidade de servidores, espaço utilizado, recursos de rede e processamento. Tudo isso pode resultar em uma atividade de expansão de infraestrutura com a compra de equipamentos para o tratamento de grandes volumes de dados com a qualidade esperada pelos gestores envolvidos no projeto.

TEMA 3 – OS VS DO PROJETO BIG DATA

Os projetos de Big Data envolvem uma série de variáveis, e alguns aspectos precisam ser observados, seja na etapa de preparação de dados, seja na análise deles. Dentre as características do Big Data que devem ser respeitadas ao longo do projeto, estão variedade, velocidade e veracidade, acompanhadas da conformidade. A Figura 2 relembra os Vs do Big Data:

Figura 2 – Os Vs do Big Data



Fonte: ogichobanov/Shutterstock.

3.1 Variedade de dados

A imensa variedade de dados, estruturas e formatos é uma dificuldade para os projetos de Big Data. A integração de várias fontes de dados, novos tipos de dados (animações, vídeos, redes sociais, sensores), concatenados com fontes de dados já tradicionais (banco de dados relacionais, planilhas, arquivos-textos), agregando tudo isso em um banco de dados NoSQL, requer profissionais bem capacitados, para um efetivo desenvolvimento de aplicações e ferramentas que possam utilizar esse banco de dados.

3.2 Velocidade de processamento

Existe um esforço muito grande no desenvolvimento de plataformas e estruturas que consigam processar os grandes volumes de dados de maneira mais rápida. Os dados e o conteúdo são gerados de maneira cada vez mais dinâmica, e os sistemas distribuídos precisam ser cada vez mais eficientes para que os prazos e as metas dos projetos de Big Data sejam mantidos.

A geração de dados em tempo real, com fluxos contínuos, como o *streaming* de dados, é um exemplo de velocidade de criação de conteúdo. Os dados fluem constantemente entre a *internet* e os sistemas externos e internos. O armazenamento desses dados, os diferentes formatos e as tecnologias analíticas requerem infraestruturas lógicas que permitam gerenciar todo esse ecossistema.

3.3 Veracidade de dados

A confiança nos dados que estão sendo analisados nos projetos Big Data é primordial. É preciso adequar corretamente os dados à sua finalidade, com a garantia de que os dados estão corretos e são confiáveis para serem utilizados ao longo do projeto. Essa etapa de preparação merece atenção principalmente em projetos que envolvam a parte financeira.

3.4 Conformidade

Dentre os requisitos citados ao conjunto de dados coletados e utilizados nos projetos, está a segurança. Esses dados em muitas situações acabam sendo divulgados para toda a organização, e é importante que tenham uma classificação de confidencialidade, utilização de criptografia e mecanismos de segurança para limitar e controlar os acessos. Também é preciso que haja ambientes onde os dados possam passar por testes e homologação antes de serem utilizados nas aplicações de produção da empresa.

TEMA 4 – ADMINISTRAÇÃO E GOVERNANÇA DE DADOS

A meta da governança de dados em um projeto de Big Data consiste em criar processos capazes de garantir que essa estrutura seja mais um ponto de ajuda a todos os envolvidos no projeto do que ser uma barreira que crie dificuldades às atividades. Não podemos deixar que essa governança venha a se transformar em uma sobrecarga burocrática, de forma que todos estejam empenhados em atingir os mesmos objetivos, com o compromisso dos mesmos prazos estabelecidos nas metas do projeto (Machado, 2018).

Para facilitar esse trabalho, a governança deve contar com ferramentas de colaboração, bons canais de comunicação, relatórios automatizados e buscar a agilidade. O alinhamento entre todas as áreas da organização é um fator crítico; equipes diferentes têm prioridades distintas em relação aos objetivos de negócio, e o grande objetivo da governança é manter o foco e ter agilidade na tomada de decisões.

4.1 Gerenciamento de dados

Com relação ao gerenciamento de dados, as políticas, práticas, processos e atividades necessárias devem atender a critérios de eficiência e eficácia, precisão, confiabilidade e disponibilidade. Algumas perguntas devem ser feitas em cada etapa, conforme segue:

- Qualidade: os dados estão confiáveis e sem erros?
- Segurança: a proteção está adequada, com as permissões de acesso corretas?
- Integração: as diversas estruturas e fontes de dados estão consolidadas?
- Estrutura: as necessidades de armazenamento e processamento estão bem dimensionadas?

4.2 Entrega de dados

A entrega de dados a todos os sistemas e aplicativos utiliza alguns mecanismos, como carga de lotes, fluxo de dados em tempo real, *hubs* integradores de dados, visualização de dados e processamento baseado em eventos. Esses mecanismos devem ser capazes de dimensionar com eficiência os dados de sistemas de origem, fluxos em tempo real para aplicativos de análise, ter integração entre os sistemas, entrega de dados sem sobrecarga e a capacidade de identificar, analisar e ter reação a mudanças, ameaças e oportunidades de eventos críticos aos negócios da empresa.

4.3 Análise de dados

Transformar os dados brutos coletados no começo do projeto em resultado, com padrões, cálculos e precisão sobre determinados domínios, é função da análise de dados, cuja visualização deve apresentar uma maneira fácil de compreender os resultados e promover o entendimento, aplicar avançados algoritmos e técnicas ao conjunto de dados e permitir o aprendizado de padrões, bem como fazer previsões a um nível para o qual o projeto foi concebido.

4.4 Processos Big Data

Ao longo do projeto de Big Data, muitos processos são executados, em consonância com metodologias ágeis de desenvolvimento. Elencamos alguns passos a serem seguidos para o sucesso do projeto:

- Acesso a dados: conseguir todos os dados para o projeto, captura, coleta etc. O armazenamento é a etapa inicial;
- Integração de dados: sem dúvida é o processo mais difícil, pois envolve várias estruturas e formatos, a normalização dos dados e a garantia da integração;
- Limpeza de dados: alguns chamam de *higienização dos dados*. É um processo que elimina erros, duplicações, redundâncias, incompletude, imprecisões, entre outros;
- Controlador de dados: organizar os dados por áreas, departamentos, domínios, a fim de estabelecer uma fonte de dados confiável. Organizar por produtos, clientes, setores para que esses dados possam ser utilizados por outros sistemas;
- Segurança de dados: aplicar regras de segurança, controle de acessos, classificar os dados confidenciais, usar criptografia e chaves de segurança caso necessário;
- Análise de dados: o processo mais crucial de todo o projeto, onde são feitas as descobertas. É muito importante o papel dos analistas para traduzir os dados brutos em informações confiáveis, gerando conhecimento ao negócio;
- Avaliar necessidades de negócio: ao longo do projeto, é possível perceber outras necessidades de negócios, e outras metas podem surgir durante a análise e a execução desse projeto;
- Compreensão do projeto: compreender o impacto que o projeto Big Data teve dentro da organização, fazer a documentação do projeto, o aprendizado, buscar melhorias contínuas e checar se a entrega do resultado chegou a todos os envolvidos no negócio e na TI.

4.5 Plano de projeto

O planejamento do projeto de Big Data deve abordar dois temas específicos: os dados e a estratégia.

Para Machado, na estratégia deve-se ter a definição clara das metas de negócios e de TI e a definição das métricas de sucesso do projeto. No tocante a dados, devem-se identificar os dados necessários, identificá-los, assim como as suas origens.

O planejamento do projeto de Big Data deve atingir três esferas: as pessoas, os processos, além das plataformas e ferramentas.

- a) Pessoas: fazer uma avaliação da equipe, suas habilidades atuais e as desejáveis e necessárias.
- b) Processos: acesso a dados, integração, higienização, controle, segurança, análise, necessidades de negócio e compreensão.
- c) Plataformas e ferramentas: sistemas distribuídos, qualidade e integração de dados, gerenciamento e visualização.

Por fim, o projeto deve apresentar painéis com os resultados, gráficos, fazer a entrega do conhecimento, dar um retorno do investimento à organização. A Figura 3 apresenta uma série de processos e atividades que são desenvolvidos em um projeto de Big Data:

Figura 3 – Processos de Big Dat



Fonte: Ozz Design/Shutterstock.

TEMA 5 – O SUCESSO DO BIG DATA

Grande parte das primeiras atividades em Big Data foi realizada por empresas de produtos e serviços na internet – Google, eBay, Yahoo!, Facebook, LinkedIn, entre outras – e em *startups* que atuam na internet e em setores afins. Essas organizações consolidaram a área da ciência de dados e outras disciplinas do Big Data (Davenport, 2014).

Ainda segundo Davenport, como a maioria dessas empresas era nova e atuou no negócio de dados desde o início, não precisaram se preocupar muito em como integrar o Big Data a tipos de dados menores e estruturados. O foco foi quase exclusivamente ao Big Data.

Alguns fatores que devem ser considerados para o sucesso do Big Data, para Davenport, são:

- Processo decisório baseado em fatos;
- Organização dos analistas e de outros recursos;

-
- Revisão contínua das premissas do negócio e modelos analíticos;
 - Reforço da cultura de decisões analíticas e de “teste e aprendizado”;
 - Incorporação (*embedding*) do Analytics aos principais processos de negócio.

5.1 Lições aprendidas

Dessa forma, muitas lições foram aprendidas no que se refere a Big Data nas empresas *online* e em *startups*. Dentre elas, podemos citar:

- Utilizar o Big Data para a inovação de produtos e serviços;
- Trabalhar no desenvolvimento de ferramentas, e não só no de aplicações;
- Dar poder e autonomia para os cientistas de dados;
- Garantir a produtividade do trabalho com o Big Data;
- Contribuir para o bem comum;
- Lembrar sempre que, mesmo sendo ágil, ainda somos lentos demais;
- Usar e ter benefícios de ferramentas grátis e baratas;
- Fazer experimentos em grande escala;
- Promover a colaboração e o conhecimento multidisciplinar.

Do outro lado, existem algumas lições que ainda não foram aprendidas. Dentre elas, destacamos:

- Não compartilhar dados e informações com os clientes;
- Coletar dados apenas para ter mais dados;
- Falar demasiadamente sobre a tecnologia;
- Focar excessivamente no projeto Big Data.

Dentre alguns casos de sucesso na adoção e no conceito de Big Data, algumas verticais de negócio se destacam, como varejo, mídia, logística, telecomunicações, finanças, automotiva etc.

5.2 Varejo

As empresas de varejo têm usado ferramentas avançadas de análise para conhecer e traçar o perfil de seus clientes. Dessa forma, é possível criar programas de fidelidade e garantir o retorno dos clientes, sendo utilizadas informações demográficas, dados de cadastro, histórico de compras, enfim, são

analisados muitos dados de clientes concatenados com produtos, o que aumentou a rentabilidade das empresas mesmo em momentos de crise.

5.3 Mídia

A mídia tem se valido dos dados para procurar atender da melhor forma seus consumidores. Esse gerenciamento de negócio é totalmente baseado em dados, sempre visando aprimorar a experiência de seus clientes, recomendações, customização, personalização etc. São utilizadas plataformas de análise para que gerem conhecimento sobre o público, e com isso é possível gerar anúncios bem direcionados, conhecer as preferências de conteúdo dos leitores, fazer crescer a relevância de sua comunicação e adequação de conteúdo, tudo isso para aumentar e manter o tráfego de usuários pelo maior tempo possível.

5.4 Logística

O ramo de logística tem muitas aplicações usando Big Data; uma das principais é a otimização de frotas, além do tráfego de caminhões, bem como suas rotas de entrega, o uso de algoritmos avançados na montagem do roteamento de veículos, a melhoria dos sistemas de distribuição, os serviços de geolocalização, a diminuição do tempo ocioso dos veículos, a manutenção preventiva, a economia gerada pela economia de combustíveis e os gastos com motoristas.

5.5 Telecomunicações

As empresas de telecomunicações estão sempre em busca de melhoria na qualidade de seus serviços e da satisfação de seus consumidores, o que envolve diversas atividades. Muitas delas se referem à disponibilidade dos serviços, à redução das taxas de erros e à análise da infraestrutura em tempo real, a fim de evitar o descontentamento de seus clientes.

5.6 Finanças

O setor financeiro, em especial as empresas de crédito, mudou seus modelos de avaliação com relação aos métodos mais tradicionais. Relatórios inteligentes e indicadores de desempenho apresentam uma nova maneira de prever a fidelidade de consumidores. O Big Data e seus modelos preditivos

fornece previsões mais sofisticadas, sendo possível fazer projeções, identificar potenciais fraudes e permitir um melhoramento contínuo das operações.

5.7 Automotiva

Existem diversas inovações no ramo automobilístico. Sensores nos veículos das montadoras coletando dados para análise em ambientes Big Data são utilizados para o aprimoramento dos veículos, a medição do desempenho, a melhora da manutenção e a garantia de maior satisfação de seus clientes.

Algumas montadoras têm usado o Big Data para avaliar a qualidade de seus carros, os gastos com segurança, logística e transporte, a padronização de direção, a coleta de dados econômicos dos clientes etc., com o intuito de melhorar as vendas e conhecer melhor seu público-alvo, também reduzindo os gastos e aumentando o número de clientes.

5.8 Outros negócios

Existem outros segmentos de sucesso com o Big Data. Há empresas que trabalham com aplicações de relacionamento, onde se utilizam grande variedade de dados e informações de geolocalização, criando uma espécie de revolução social. Corretoras de seguro procuram diferenciar seus serviços e aumentar suas vendas.

No setor público, as empresas têm utilizado o Big Data para melhorar a utilização de suas redes, monitorar em tempo real demandas existentes, melhorar processos com mais precisão e velocidade, buscar novas demandas e adotar novas tecnologias em suas soluções.

5.9 Tendências em Big Data

Com relação às tendências, a capacidade de análise descritiva e preditiva dessas tecnologias deve ser mais explorada. Com o advento da Internet das Coisas, a explosão de dados deve ser muito maior no futuro, bem como as simulações e o desenvolvimento de novas oportunidades. Sem contar a distância cada vez mais curta entre o mundo digital e o físico, a computação em nuvem, o transporte de cargas, os estudos de meteorologia, informações em tempo real, com um número cada vez maior de dispositivos e sensores conectados a sistemas ligados em nuvem, podendo mudar diversos paradigmas de processamento e

análise de dados. Podem-se citar também a produtividade das fábricas, a cadeia de suprimentos, a capacidade de trabalho, enfim, vários cenários onde o Big Data pode atuar, solucionando os mais variados problemas e auxiliando cada vez mais na tomada de decisões dentro das organizações.

REFERÊNCIAS

AMARAL, F. **Introdução à ciência de dados**: mineração de dados e Big Data. Rio de Janeiro: Alta Books, 2016.

DAVENPORT, T. H. **Big Data no trabalho**: derrubando mitos e descobrindo oportunidades. Tradução de Cristina Yamagami. 1. ed. Rio de Janeiro: Elsevier, 2014.

MACHADO, F. N. R. **Big Data**: o futuro dos dados e aplicações. São Paulo: Érica, 2018.

TAURION, C. **Big Data**. Rio de Janeiro: Brasport, 2013.