

## Aula 6

### Big Data

Prof. Douglas Eduardo Basso

1

### Formas de Coleta de Dados

2

- Podemos descrever as mídias sociais como tecnologias e práticas na internet, utilizadas pelos usuários para expor suas opiniões, experiências e perspectivas. O conteúdo publicado pode ter vários formatos incluindo
  - Vídeos, fotos, animações, imagens e áudio
- O crescimento dessas mídias possibilitou o compartilhamento de ideias, construção de comunidades virtuais, uma democratização do conteúdo

3

- Há duas formas de coleta de dados em mídias sociais
  - A primeira seria utilizar palavras-chave, ou termos para coletar citações, e buscar um histórico de utilização dessas palavras-chave no passado
  - A segunda forma utiliza um conceito diferente, chamado de *streaming*, em que algumas aplicações trabalham e atuam como "ouvinte" nas redes fazendo um processo de captura de dados na sequência em que são gerados

4



Tetiana Yurchenko/shutterstock

5

### Estrutura de coleta de dados

- Concluída a fase de coleta e captura de dados das mídias sociais, surge a necessidade de estruturar e considerar alguns componentes dessa engrenagem como

6

- **Armazenamento de dados:** a estratégia de distribuição dos servidores, os sistemas, a rede, enfim, todos os aspectos de infraestrutura de tecnologia. A estrutura é um componente muito importante. Uma boa distribuição garante que as informações serão armazenadas de forma adequada e segura

7

- **Organização**
  - Quando temos muitas informações, existe a necessidade de categorizar e nivelar os dados não estruturados, semiestruturados e estruturados. Tudo isso vem para auxiliar e facilitar os processos de análise e a distribuição desses dados dentro das plataformas como Hadoop e os banco de dados NoSQL

8

- **Análise de dados**
  - Com todos os dados devidamente armazenados e organizados, a análise trata da extração das informações e faz toda a tradução dessas informações em conhecimento. Tendo como base os conceitos e as regras de negócios, é bem comum o uso de estatística para auxiliar as organizações na tomada de decisão

9

### Utilização de dados

- Com grande quantidade de dados capturadas, a solução para a utilização é usar bons filtros e buscar informações relevantes para seu negócio. Fazer a transformação desses dados em valor e conhecimento é o grande desafio

10

- É importante saber determinar o que importa ou não para o seu negócio, o que você deseja buscar
  - A triagem de dados de redes sociais deverá mostrar uma grande quantidade de dados, mas é você que precisará refiná-los para obter informações inerentes aos objetivos do seu negócio

11

### Coleta de dados distribuída

- Quando a coleta de dados é muito grande nas mídias sociais, isso deve ser feito por softwares e ferramentas que trabalham de maneira distribuída dividida em várias máquinas. Todo esse procedimento acontece pela necessidade de processar as requisições de maneira distribuída e pelo fato de os servidores utilizados pelas mídias sociais não interpretarem que essas requisições estão sendo feitas por um possível ataque de hackers a seus servidores

12

## Projetos de Big Data

- Um projeto de big data nunca deve ser um objetivo de TI simplesmente, mas um objetivo compartilhado entre o que a empresa tem como metas e objetivos a serem atingidos ao longo do tempo, indicadores de performance bem definidos, e problemas existentes identificados, para então partirmos para um projeto em busca de resultados desejados e definidos

13

14

## Objetivos de negócio

- O levantamento dos objetivos e metas do negócio deve ser claro, as especificidades devem ser apontadas e é primordial que as metas sejam possíveis de serem alcançadas
- Criar uma lista com os pesos de cada meta e objetivo e medir o desempenho ao longo do projeto é muito importante

- Dentro do escopo do projeto deve constar
  - Performance da TI
    - ✓ Acompanhar as atividades técnicas de captura de dados, preparação, filtragem, classificação, armazenamento, enfim, todas as atividades inerentes de tecnologia

15

16

- Metas alcançadas
  - ✓ Mensurar ao longo do projeto as metas alcançadas, se tiveram êxito ou não
  - ✓ Utilizar métricas para que seja possível computar os resultados

- Definições de tempo
  - ✓ Como em qualquer projeto, o tempo é um fator-chave
  - ✓ Verificar em tempo real o período utilizado para o alcance de cada meta

17

18

### Dados necessários

- As organizações possuem muitos dados em seus sistemas internos, cadastro de cliente, registro de produtos, estoque, recursos humanos, compras. Dessa forma, estima-se que a maioria das empresas não usa efetivamente seus dados
- Por outro lado, existem muitos dados externos à empresa

19

### Grande volume de dados

- Uma boa prática nesse caso seria realizar um bom inventário de todos os dados existentes dentro da empresa, ter parâmetros de capacidade de servidores, espaço utilizado, recursos de rede e processamento
- Isso pode resultar em uma atividade de expansão de infraestrutura, com a compra de equipamentos para o tratamento de grandes volumes de dados e com a qualidade esperada pelos gestores e envolvidos ao projeto

20

### Os Vs dos Projetos Big Data

21

- Os projetos de big data envolvem uma série de variáveis
- Alguns aspectos precisam ser observados, tanto na etapa de preparação de dados quanto em sua análise
- Dentre as características do big data que devem ser respeitadas ao longo do projeto estão
  - Variedade, velocidade e veracidade (acompanhadas da conformidade)

22



23

### Variedade de dados

- A imensa variedade de dados, estruturas e formatos é uma dificuldade para os projetos de big data

24

- A integração de várias fontes e novos tipos de dados (animações, vídeos, rede sociais, sensores), concatenados com fontes já tradicionais (banco de dados relacionais, planilhas, arquivos de textos), agregados em um banco de dados NoSQL
- Toda essa integração requer profissionais bem capacitados, e também no desenvolvimento de aplicações e ferramentas que possam utilizar esse banco de dados

25

### Velocidade de processamento

- Existe um esforço muito grande no desenvolvimento de plataformas e estruturas que consigam processar os grandes volumes de dados de maneira mais rápida
- Os dados e conteúdos são gerados de maneira cada vez mais dinâmica e os sistemas distribuídos precisam ser cada vez mais eficientes para que os prazos e as metas dos projetos de big data sejam mantidos

26

- A geração de dados em tempo real, com fluxos contínuos, como o *streaming*, é um exemplo de velocidade de criação de conteúdo
- Os dados fluem constantemente entre a internet, sistemas externos e internos

27

### Veracidade dos dados

- A confiança nos dados que estão sendo analisados nos projetos big data é primordial
- Adequar corretamente os dados à sua finalidade, com a garantia de que estão corretos e são confiáveis para serem utilizados ao longo do projeto
- Essa etapa de preparação merece atenção, principalmente, em projetos que envolvam parte financeira

28

### Conformidade

- Dentre os requisitos citados no conjunto de dados coletados e utilizados nos projetos, está a segurança
- Esses dados, em muitas situações, acabam sendo divulgados para toda a organização

29

- Por isso, é importante que tenham uma classificação de confidencialidade
- Utilização de criptografia e mecanismos de segurança para limitar e controlar os acessos, ter disponível ambientes em que os dados possam passar por testes e homologação antes de serem utilizados nas aplicações de produção da empresa

30

## Administração e Governança de Dados

31

## Governança de dados

- A meta da governança de dados em um projeto de big data é criar processos capazes de garantir que essa estrutura seja mais um ponto de ajuda a todos os envolvidos no projeto do que uma barreira que crie dificuldade às atividades do projeto

32

- Não podemos deixar que essa governança venha a se transformar em uma sobrecarga burocrática, de forma que todos estejam empenhados em atingir os mesmos objetivos, e com o compromisso dos mesmos prazos estabelecidos nas metas do projeto

33

## Gerenciamento de dados

- Em relação ao gerenciamento de dados, as políticas, práticas, processos e atividades necessárias devem atender a critérios de eficácia, precisão, confiabilidade e disponibilidade

34

- Algumas perguntas devem ser feitas em cada etapa, conforme a seguir
  - Qualidade: os dados estão confiáveis e sem erros?
  - Segurança: a proteção está adequada, com as permissões de acesso corretas?
  - Integração: as diversas estruturas e fontes de dados estão consolidadas?
  - Estrutura: as necessidades de armazenamento e processamento estão bem dimensionadas?

35

## Entrega de dados

- A entrega de dados a todos os sistemas e aplicativos utilizando alguns mecanismos como
  - Carga de lotes, fluxo de dados em tempo real, *hubs* integradores de dados, visualização de dados e processamento com base em eventos

36

- Esses mecanismos devem ser capazes de dimensionar com eficiência os dados de sistemas de origem e fluxos em tempo real para aplicativos de análise, ter uma integração entre os sistemas, entrega de dados sem sobrecarga e a capacidade de identificar, analisar e ter reação a mudanças, ameaças e oportunidades de eventos críticos aos negócios da empresa

37

### Análise de dados

- Transformar os dados brutos coletados no começo do projeto em resultado, com padrões, cálculos e precisão sobre determinados domínios é a função da análise de dados

38

- A visualização dessa análise deve apresentar uma maneira fácil de compreender os resultados e promover o entendimento, aplicar avançados algoritmos e técnicas a conjuntos de dados e permitir o aprendizado de padrões, fazendo previsões a um nível para qual o projeto foi concebido

39

### Processos do big data

- Transformar os dados brutos coletados ao longo do projeto de big data
- Muitos processos são executados em consonância com metodologias ágeis de desenvolvimento

40

- Elencamos alguns passos a serem seguidos para o sucesso do projeto
  - Acesso a dados
    - ✓ Conseguir todos os dados para o projeto (a captura, a coleta e o armazenamento) é a etapa inicial
  - Integração de dados
    - ✓ Sem dúvida, é o processo mais difícil, pois envolve várias estruturas e formatos, fazer a normalização dos dados e garantir a integração

41

- Limpeza de dados
  - ✓ Alguns chamam de *higienização dos dados*
  - ✓ É um processo que elimina erros, duplicações, redundâncias, incompletude, imprecisões, entre outros

42

- **Controlador de dados**

- ✓ Organizar os dados por áreas, departamentos e domínios, a fim de estabelecer uma fonte confiável
- ✓ Organizar por produtos, clientes e setores para que esses dados possam ser utilizados por outros sistemas

43

- **Segurança de dados**

- ✓ Aplicar regras de segurança, controle de acessos, classificar os dados confidenciais, usar criptografia e chaves de segurança, caso necessário
- **Análise de dados**
  - ✓ O processo mais crucial de todo o projeto, no qual são feitas as descobertas
  - ✓ O papel dos analistas de traduzir os dados brutos em informações confiáveis, gerando o conhecimento ao negócio, é muito importante

44

- **Avaliar necessidades de negócio**

- ✓ Ao longo do projeto, é possível perceber outras necessidades de negócios
- ✓ Outras metas podem surgir durante as análises e a execução do projeto
- **A compreensão do projeto**
  - ✓ Compreender o impacto que o projeto big data teve dentro da organização, fazer a documentação do projeto, o aprendizado, buscar melhorias contínuas e checar se a entrega do resultado chegou a todos os envolvidos no negócio e na TI

45

### **Plano de projeto**

- **O planejamento do projeto big data deve abordar dois temas específicos**
  - Os dados
  - A estratégia

46

- Para Machado, na estratégia, deve-se ter a definição clara das metas de negócios e de TI e a definição das métricas de sucesso do projeto
- No tocante a dados, deve-se identificar os que forem necessários, assim como as suas origens

47

- **O planejamento do projeto big data deve atingir três esferas**
  - As pessoas
  - Os processos
  - Plataformas e ferramentas

48



- **Pessoas**
  - Fazer uma avaliação da equipe, suas habilidades atuais e as desejáveis e necessárias
- **Processos**
  - Acesso a dados, integração, higienização, controle, segurança, análise, necessidades de negócio e a compreensão
- **Plataformas e ferramentas**
  - Sistemas distribuídos, qualidade e integração de dados, gerenciamento e visualização



Ozz Design/shutterstock

## O Sucesso do Big Data

- Grande parte das primeiras atividades em big data foi realizada por empresas de produtos e serviços na internet – Google, eBay, Yahoo!, Facebook, LinkedIn, entre outras – e em *startups* que atuam na internet e em setores afins
- Essas organizações consolidaram a área da ciência de dados e outras disciplinas do big data. Como a maioria dessas empresas era nova e atuou no negócio de dados desde o início, não precisaram se preocupar muito em como integrar o big data a tipos de dados menores e estruturados

- Alguns fatores que devem ser considerados para o sucesso do big data para Davenport são
  - Processo decisório com base em fatos
  - Organização dos analistas e de outros recursos
  - Revisão contínua das premissas do negócio e modelos analíticos
  - Reforço da cultura de decisões analíticas e de “teste e aprendizado”
  - Incorporação (*embedding*) do Analytics aos principais processos de negócio

- Dessa forma, muitas lições foram aprendidas no que se refere ao big data, nas empresas on-line e em *startups*
- Dentre elas, podemos citar
  - Utilizar o big data para a inovação de produtos e serviços
  - Trabalhar no desenvolvimento de ferramentas e não só de aplicações
  - Dar poder e autonomia para os cientistas de dados

- Garantir a produtividade do trabalho com o big data
- Contribuir para o bem comum
- Lembrar sempre que, mesmo sendo ágil, ainda somos lentos demais
- Usar e ter benefícios de ferramentas grátis e baratas
- Fazer experimentos em grande escala
- Promover a colaboração e o conhecimento multidisciplinar

55

- Por outro lado, existem algumas lições que ainda não foram aprendidas
- Dentre elas, destacamos
  - Não compartilhar dados e informações com os clientes
  - Coletar dados apenas para ter mais dados
  - Falar demasiadamente sobre a tecnologia
  - Focar excessivamente no projeto big data

56

- Dentre alguns casos de sucesso na adoção e no conceito de big data, algumas verticais de negócio se destacam, como
  - Varejo, mídia, logística, telecomunicações, finanças, automotiva, entre outras

57

### Varejo

- As empresas de varejo têm usado ferramentas avançadas de análise para conhecer e traçar o perfil de seus clientes. Dessa forma, é possível criar programas de fidelidade e garantir seu retorno

58

- São utilizadas informações demográficas, dados de cadastro, histórico de compras, enfim, são analisados muitos dados de clientes concatenados com produtos, o que aumentou a rentabilidade das empresas mesmo em momentos de crise

59

### Mídia

- A mídia tem utilizado os dados para procurar atender de melhor forma seus consumidores
- Esse gerenciamento de negócio é totalmente baseado em dados, sempre visando aprimorar a experiência de seus clientes, recomendações, customização, personalização

60

- São utilizadas plataformas de análise que geram um conhecimento sobre o público.
- Dessa forma, é possível gerar anúncios bem direcionados, conhecer as preferências de conteúdo dos leitores, fazer crescer a relevância de sua comunicação e adequação de conteúdo. Tudo isso para aumentar e manter o tráfego de usuários pelo maior tempo possível

61

## Logística

- O ramo de logística tem muitas aplicações usando big data

62

- Uma das principais é a otimização de frotas, o tráfego de caminhões e suas rotas de entrega, o uso de algoritmos avançados na montagem do roteamento de veículos, a melhoria dos sistemas de distribuição, serviços de geolocalização, diminuição de tempos ociosos de veículos, manutenção preventiva, a economia gerada pela economia de combustíveis e gastos com motoristas

63

## Telecomunicações

- As empresas de telecomunicações estão sempre em busca de uma melhoria na qualidade de seus serviços e da satisfação de seus consumidores
- Isso envolve muitas atividades e algumas delas se referem à disponibilidade dos serviços, à redução das taxas de erros e à análise da infraestrutura em tempo real, a fim de evitar o descontentamento de seus clientes

64

## Finanças

- O setor financeiro, em especial as empresas de crédito, mudou seus modelos de avaliação em relação aos métodos mais tradicionais
- Relatórios inteligentes e indicadores de desempenho apresentam uma nova maneira de prever a fidelidade de consumidores

65

- O big data e seus modelos preditivos fornecem previsões mais sofisticadas, sendo possível fazer projeções, identificar potenciais fraudes e permitir um melhoramento contínuo em suas operações

66

### Automotiva


- Existem muitas inovações no ramo automobilístico
- A utilização de vários sensores em veículos pelas montadoras, coletando dados para análise em ambientes big data, por exemplo. Esses registros são utilizados para o aprimoramento dos veículos, para medir o desempenho, melhorar a manutenção e garantir uma maior satisfação de seus clientes

67

### Outros negócios

- Existem outros segmentos de sucesso com o big data: empresas que trabalham com aplicações de relacionamento, em que são utilizadas grande variedade de dados e informações de geolocalização, criando uma espécie de revolução social
- Corretoras de seguro procuram diferenciar seus serviços e aumentar suas vendas

68



69