

BUSINESS EM INTELIGÊNCIA ARTIFICIAL

TEMA 1 – TIPOS DE INTELIGÊNCIA ARTIFICIAL

Mecanismos operacionais para IA em *Business*

O objetivo da inteligência artificial (IA) está relacionado ao fornecimento de sistemas de computador ou *softwares* capazes de efetuar ações semelhantes ao raciocínio humano sobre um conjunto de dados, como uma entrada, e que operem sobre o que se assemelha ao pensamento humano, para um resultado considerado saída de dados ou informações tratadas. Os diferentes recursos disponibilizados pela IA podem se apresentar como o cerne para um plano de atendimento aos diversos tipos de demandas solicitadas aos negócios.

Nesse sentido, a inteligência artificial pode sofrer uma categorização em três níveis de diferenciação por conteúdo teórico, baseados em funcionalidades.

1.1 Inteligência emocional

A inteligência emocional está relacionada à possibilidade do reconhecimento das emoções humanas por parte da tecnologia aplicada. Origina-se com base na figura humana capturada no formato de imagem de rosto, possibilitando identificar emoções como a raiva, o desejo, a alegria, o amor, entre outras.

O aprendizado de padrão é utilizado em diversas aplicações e fins específicos de áreas como a de jogos digitais, educação médica e segurança.

1.2 Inteligência humanizada

A inteligência humanizada tem como características, além da adaptabilidade, a autoconsciência dentro de um contexto de inteligência social. Esse tipo de inteligência ainda é um objetivo a ser atingido, e estamos ainda distantes dele. Os aspectos cognitivos e emocionais humanos já foram possíveis de se copiar, contudo, transformar robôs em humanos ainda é somente teoria.

1.3 Inteligência cognitiva

A inteligência cognitiva pode ser entendida como uma evolução da inteligência artificial. Enquanto as técnicas utilizadas em IA têm seu aprendizado baseado em padrões que são seguidos até receberem novos treinamentos, a técnica utilizada na inteligência cognitiva, além do aprendizado baseado em um padrão, é capaz de efetuar ações baseadas em aprendizado e raciocínio. Isso

possibilita uma capacidade de deduzir e ampliar conhecimentos. Uma frota de veículos de uma empresa de logística, por exemplo, pode se beneficiar em uma programação de agenda de manutenção no formato preventivo, no qual a prevenção de problemas ocorre de forma automática, assim como a aquisição prévia de peças para reparos.

TEMA 2 – MÉTRICAS DE DESEMPENHO E INDICADORES

Para atender demandas de negócio, os recursos de inteligência artificial podem oferecer resultados que possibilitem maior efetividade. Seus resultados podem ser vistos em diversas aplicações implementadas em campos como gestão de armazenamento e estoque e atividades preditivas. A ampliação da competitividade empresarial e maior lucratividade também têm se tornando possíveis pela utilização de inteligência artificial.

As empresas estão lidando com grandes volumes de informação que circulam diariamente. Uma gestão pode ser comprometida caso uma etapa do processo de produção apresentar baixa eficiência sem ser observada preventivamente. Visando coletar e mensurar os dados relativos a uma questão como essa, existem o que chamamos de indicadores de desempenho, que são relacionados a métricas que avaliam o fluxo de trabalho, contribuindo para o atingimento de metas pré-estabelecidas dentro de um planejamento estratégico focado na gestão.

Para dar um direcionamento de gestão – como um GPS indicador de caminho –, a aquisição de informações no formato quantitativo possibilita uma visão ampla de conflitos, tanto internos como externos ao negócio.

2.1 Métricas de desempenho

As métricas de desempenho podem ser compreendidas como dados brutos de modo geral. Sua representação ocorre por meio de valores numéricos e de outras formas. Sua utilização é usada para mensurar o desempenho de estratégias ou processos. Usualmente, as métricas são usadas na identificação de tendências e na projeção de cenários. Dessa forma, orientam as tomadas de decisão na gestão empresarial.

Podemos exemplificar as métricas como o número de usuários de uma ferramenta de rede social que acessa a área de uma empresa, da mesma forma que um total de *leads* no pico de um funil, representando uma métrica comercial ou de venda. Contudo, não é em todos os casos que as métricas apresentam efetividade.

Uma empresa pode demonstrar altos valores quantitativos de acessos, porém nem todos se transformam em *leads*, o que não resultará em atingimento do funil de vendas. Desse modo, é importante efetuar o cruzamento de dados para atingir os objetivos de monitoramento por indicadores de resultado e desempenho.

2.2 Indicadores de desempenho

Os indicadores de resultado são medidores de desempenho, derivando das métricas na possibilidade de auxílio aos gestores a compreender os dados obtidos pelas métricas de maneira bruta. Podemos ainda considerar os indicadores de desempenho como um conjunto de medidas utilizadas pelas empresas de forma a medir sua performance em um determinado período com base em um histórico. Para efetuar uma medição com os indicadores, é necessário, inicialmente, ter métricas para tal medição.

Por derivarem das métricas, os indicadores de desempenho podem ser representados por KPIs. Estes permitem que seja realizada uma avaliação mais detalhada acerca do conteúdo mostrado pelas métricas. Nesse sentido, podemos considerar todos os KPIs como métricas, mas nem todas as métricas podem ser consideradas KPIs. O indicador KPI oferece dados e mensura alguns resultados. Ao contrário disso, a métrica não é considerada como indicador, pois simplesmente oferece dados brutos.

Figura 1 – Indicador KPI



Crédito: buffaloboy/Shutterstock.

Efetuar um alinhamento entre as diferentes métricas requer um trabalho entre a direção e os setores da empresa. Entre as diferentes metodologias de gestão utilizadas para essa finalidade está o OKR (*objective and key result*), ou “objetivos e resultados-chave”. Ele é um sistema simplificado, que visa a um alinhamento e um comprometimento, tendo como centro as metas mensuráveis.

Figura 2 – Objective Key Result (OKR)



Crédito: Dari-designPie/Shutterstock.

O método OKR normalmente tem medição e reavaliação trimestral. Sua existência baseia-se na criação e alinhamento que definem andamento rápido, envolvendo os objetivos esperados e a capacidade criativa das áreas, definindo, de maneira geral, o andamento da organização como um todo. Seu foco está na garantia do andamento e direcionamento, com priorização de ações em constante andamento.

TEMA 3 – SISTEMAS DE MEDIÇÃO DE DESEMPENHO

O que é medido, é feito: este é um velho clichê, mas há muita verdade nele. Você se preocupa com sua nota neste curso? Você estuda para os exames quando eles estão mais próximos? Nesse caso, o que está sendo medido, está de fato sendo feito. Mas não seja religioso sobre a medição: este é um grande erro. Por quê? Porque muitas coisas que não são medidas, também são feitas, e porque o que é medido, muitas vezes não é o que deve ser feito.

Por exemplo, eu realmente não me importo com suas notas, mas com o que você aprende, e se você desenvolve um interesse, ou até mesmo uma paixão pelo tema. Infelizmente, não posso medir isso totalmente e, mesmo que sua nota possa ser um *proxy* para isso, não é realmente uma medida perfeita.

Gerenciar o desempenho é uma parte importante da gestão de qualquer negócio profissional. No mínimo, as empresas são muito cuidadosas ao monitorar seu desempenho financeiro: receita menos custos.

Para os gerentes, a medição ajuda a comunicar objetivos estratégicos e a alinhar a organização para alcançá-los. Ajuda-os também a obter informações sobre o desempenho atual e, portanto, a facilitar ações corretivas, melhorias e mudanças

organizacionais. Além disso, pode auxiliar na criação de um esquema de distribuição justo de recompensas.

Para os funcionários, ter medidas de desempenho ajuda a esclarecer os critérios de seu sucesso em seus cargos. Quando o desempenho é bom, pode aumentar a motivação a autoestima, e também fornece uma referência para melhorias. Em suma, o uso de medição é parte integrante da gestão de empresas.

Os negócios modernos são impensáveis sem gerenciamento de desempenho, mas é muito difícil acertar. Na década de 1990, Robert Kaplan e David Norton perceberam que as empresas tinham uma perspectiva muito desequilibrada de medidas. Todas as empresas se concentravam em medições financeiras, mas muito menos em outras capacidades. Como resposta, eles propuseram o *Balanced Scorecard*. O *Balanced Scorecard* usa quatro perspectivas para encorajar uma medição de desempenho mais equilibrada.

Uma perspectiva é a clássica *perspectiva financeira*. As medidas típicas aqui são ganhos, receitas, retorno sobre o investimento, custo de fabricação, custo de baixa qualidade etc.

Outra perspectiva é a *perspectiva do cliente*. As medidas típicas são a satisfação do cliente, taxas de reclamação e participação de mercado.

A terceira é a *perspectiva interna de negócios*. É com ela que medimos o desempenho direto de nossas operações. Podemos rastrear a qualidade do processo, a qualidade do produto, as taxas de refugo, a velocidade e a eficiência, além de uma série de outras métricas.

A quarta perspectiva diz respeito à *inovação e aprendizagem*. Medidas que estão apenas indiretamente relacionadas às operações de hoje, mas que terão impacto sobre o quão bem o faremos no futuro.

Por exemplo, métricas para melhoria contínua e desenvolvimento de habilidades pertencem a esta categoria. O *Balanced Scorecard* ajuda as empresas a lembrarem de que as medidas financeiras são apenas parte da imagem, mas ainda hoje muitas empresas precisariam, vez ou outra, desse lembrete.

Os resultados financeiros são uma variável de resultado dependente de como usamos nossos ativos para atender a uma demanda. E como usamos nossos ativos?

Considere um jogador de futebol que vai cobrar o pênalti decisivo em uma final de campeonato. O melhor é ele não se concentrar excessivamente em marcar o gol, mas em como fazê-lo. O comprimento do salto e a pontuação do gol são, obviamente, o que importa no final, e será medido e relatado. Mas para entregar um

bom resultado, é necessária uma abordagem equilibrada de medição. O jogador de futebol de classe internacional também mede as métricas operacionais durante os treinos.

A ideia de medição de desempenho era tão atraente para tantas pessoas, que Peter Drucker, um dos pensadores de gestão mais influentes da última década, propôs uma forma de gestão quase inteiramente baseada nela. Ele a chamou de *gerenciamento por objetivos*. Hoje, essa estratégia é amplamente desmascarada – pelo menos como uma filosofia de gestão superior.

Existem muitas armadilhas na medição: primeiro, se “o que é medido, é feito” você corre o risco de obter exatamente o que mede, não o que deseja saber. Em segundo lugar, o que é fácil de medir, geralmente não é o que é certo medir. Terceiro, embora a medição possa criar motivação extrínseca, pode prejudicar a motivação intrínseca mais eficaz. Quarto, o uso da medição de desempenho cria uma cultura organizacional orientada para KPI não necessariamente focado em atender às necessidades do cliente. Quinto, o foco no desempenho cria competição interna, que quase sempre será travada, e cria menos cooperação e compartilhamento entre equipes e departamentos. Isso é particularmente um problema quando as métricas de desempenho são usadas para compensação e recompensas. Sexto, quando as medidas não são cumpridas, os colaboradores podem ficar com baixa autoestima, esgotamento e insatisfação com o trabalho e, quando as medidas são sempre cumpridas, as pessoas podem ficar complacentes. Sétimo, os sistemas de medição de desempenho podem criar burocracias caras que drenam recursos da entrega de desempenho para medir e relatar o desempenho.

Então, o que fazer?

Por um lado, a medição de desempenho é claramente necessária e pode aumentá-lo. Por outro, é impossível criar o sistema de medição perfeito. A chave é estar ciente das limitações e usar medidas de desempenho para suporte à decisão.

Muitas empresas criaram sistemas de medição de desempenho altamente eficazes, que as ajudam a desenvolver e a manter uma cultura de desempenho positiva.

Uma dessas empresas é (novamente) a Toyota. O chamado *Hoshin Kanri* é um processo anual de implantação de políticas, que começa com estratégias de nível superior e as divide em objetivos tangíveis para diferentes departamentos e equipes. Isso acontece em um processo *catchball*, no qual cada nível comunica metas e medidas para os níveis acima e abaixo, quase como se estivessem jogando uma bola para cima e para baixo na organização. A chave aqui é que cada nível

está criando seus próprios objetivos para atender aos desafios de desempenho definidos pelos níveis acima.

Esta maneira de quebrar as medidas financeiras gerais e métricas operacionais no chão de fábrica alinha toda a organização na realização das estratégias definidas.

TEMA 4 – ARMAZENAMENTO DE GRANDES VOLUMES DE DADOS (*BIG DATA*)

Entre as diversas tendências emergentes no mercado atual, o *Big Data* é algo diferenciado. Esse termo é utilizado muitas vezes de forma inadequada, mas apresenta consigo a promessa de algo verdadeiramente revolucionário para inúmeros setores, como indústria e serviços.

O termo *Big Data* descreve o grande volume de dados tanto estruturados, como não estruturados. Contudo, o importante não é a quantidade de dados disponíveis, mas sim o que é feito com eles. Com o uso de *Big Data*, é possível fazer uma análise para obtenção de *insights* que resultem em melhores decisões e ações estratégicas de negócio.

4.1 Caracterização de *Big Data*

Ainda que o termo *Big Data* seja novo, a atividade de coleta e armazenamento de volumosas quantidades de informações para análises eventuais surgiu há muito mais tempo. O conceito teve destaque no começo dos anos 2000, e se caracteriza por três aspectos.

O primeiro é referente ao volume. As organizações coletam dados de diversas fontes, abrangendo transações financeiras, mídias sociais e informações oriundas de sensores ou de dados transmitidos de máquina para máquina. Antigamente, armazenar esses dados gerava um problema, contudo, com o desenvolvimento de novas tecnologias como a *Hadoop*, eliminam em grande parte essa dificuldade.

O segundo aspecto se refere à velocidade. Mesmo com a velocidade acelerada com que os dados são transmitidos, eles precisam ser igualmente tratados. As tecnologias atuais de RFID, sensores e medições inteligentes, têm proporcionado um avanço relativo à necessidade de lidar com torrentes de dados praticamente em tempo real.

Por fim, o terceiro aspecto faz referência à variedade. São inúmeros os formatos em que os dados são gerados. Dessa forma, podemos encontrar dados estruturados – que podem ser numéricos, em *databases* tradicionais –, e não

estruturados, como dados encontrados em documentos de texto, e-mails, áudio, vídeo, transações financeiras e cotações na bolsa.

4.2 Caracterização informal de *Big Data*

Além dos aspectos relativos a volume, velocidade e variedade, dois outros aspectos têm sido considerados no processo de caracterização dos dados em *Big Data*, pois se referem a dimensões que incorporam as características anteriormente citadas.

O primeiro aspecto é a complexidade. Atualmente, as fontes de dados são diversificadas e ampliadas em sua abrangência, tornando penoso o processo de relacioná-los, agrupá-los, filtrá-los e convertê-los entre sistemas. Contudo, é necessário efetuar uma conexão e correlacionar relações, hierarquias e ligações múltiplas. Caso isto não seja feito, possivelmente, perderemos o controle sobre esses dados em pouco tempo.

O segundo aspecto é a variabilidade. Os aspectos de velocidade e variedade dos dados são características ainda insuficientes para defini-los. Os fluxos de dados podem ser altamente inconsistentes, com picos periódicos. Informações relativas às tendências nas redes sociais, por exemplo, geram essas flutuações nas situações dos dados. Diariamente, picos de dados ocorrem de maneira sazonal, ou são gerados por eventos particulares que podem ser complexos de se gerenciar, ainda mais quando se trata de dados não estruturados.

4.3 Fases do processo *Big Data*

A primeira fase do processo de *Big Data* consiste na coleta de dados, ou aquisição e agravação. Nessa fase, ocorre a análise de volume e variedade dos dados a serem coletados, que devem ser submetidos a limpeza, formatação e validação. Isto ocorre para que sejam eliminados erros e dados incompletos e incoerentes, para evitar a contaminação das análises.

A fase seguinte trata da integração, agregação e representação dos dados obtidos, uma vez que existem diferentes tipos e formatos de dados. Por isso, precisam de tratamentos específicos. É necessária a sua categorização, a definição de critérios de validação e aceitação, além de critérios de segurança que variam conforme a fonte dos dados.

Outra fase é a análise e modelagem dos dados. Os usuários devem possuir alto conhecimento, pois os dados tratados são originados de diversas fontes. Nessa

fase, atua o cientista de dados (*data scientist*), profissional com habilidades em ciência da computação, matemática, estatística, além de conhecimento de negócio.

TEMA 5 – MINERAÇÃO DE DADOS (*DATA MINING*)

Devido ao aumento crescente do volume de dados produzido e armazenado, podemos observar também a ampliação da possibilidade (e capacidade) de obtenção de maior volume de informações valiosas para os gestores. Porém, em muitos casos, o enorme volume gerado inviabiliza tanto a percepção quanto a avaliação ao ultrapassar os limites da capacidade humana de efetuar essas ações.

A mineração de dados (do inglês *data mining*) pode ser entendida como um grupo de técnicas que possibilita a estratificação de conhecimento baseado em grandes volumes de dados. Essa “mineração” consiste na extração de dados baseada em padrões que simbolizam o conhecimento armazenado de maneira implícita em diferentes bancos de dados, *data warehouses* e, até mesmo, repositórios informacionais com grandes volumes de dados.

5.1 Entendendo *data mining*

A capacidade que possuímos atualmente para gerar dados e coletá-los constantemente aumenta sua velocidade. O volume gerado está se tornando impossível de ser analisado por um ser humano, sendo necessário ter recursos de tecnologia para seu processamento. As áreas de estatística, inteligência artificial e banco de dados destacam-se em proporcionar soluções necessárias para essa análise de dados. O somatório dessas áreas originou a tecnologia de *mineração de dados*.

A tecnologia de mineração de dados – ou *data mining* –, somada à área de gestão e descoberta do conhecimento em bases de dados, destaca-se na formação de um novo campo que se apresenta como um dos mais importantes e promissores. A junção dessas áreas está na relação existente entre elas e a quantidade elevada de dados na atualidade, e também na carência das organizações na transformação desse volume de dados em informação útil.

5.2 Tipologia dos dados a minerar

São inúmeros os tipos de dados disponíveis atualmente, tanto pela sua aplicação compartilhada em áreas diversas áreas, como os específicos de algumas

dessas áreas. Diferentes dados científicos, como dados médicos, financeiros, demográficos ou gerados por sensores da internet das coisas (IoT), são gerados constantemente.

Por essa razão, o volume de dados disponível tem aumentado enormemente, e há grande dificuldade de analisar todos esses dados com a utilização de ferramentas de uso tradicional para seu gerenciamento. Ao gerarmos um modelo ou uma estrutura de mineração de dados, precisamos definir os tipos de dados para cada uma das colunas nessa estrutura.

Os tipos de dados comunicam ao instrumento de análise quando um dado é do tipo numérico ou textual, por exemplo. Nesse exemplo, podemos averiguar diretamente na fonte a forma como os dados numéricos serão tratados: se inteiros, ou com casas decimais.

Outra classificação que define o tipo de dado está em sua estruturação. Nessa linha, podemos encontrar dois tipos de dados: os estruturados e os não estruturados.

5.2.1 Dados estruturados

Podemos dizer que os dados estruturados são dados formatados, com a devida organização em diferentes tabelas que contém linhas e colunas. Esses dados possuem maior facilidade em seu processamento pela ordem em que se apresentam. Normalmente são utilizados sistemas de gerenciamento de banco de dados (SGBD) para armazenar esse tipo de dado. Aplicações empresariais como os *Enterprise Resource Planning* (ERP), ou “sistema integrado de gestão empresarial”, fazem uso desse tipo de dado.

5.2.2 Dados não estruturados

Os dados não estruturados se caracterizam por não possuírem uma formatação específica, o que dificulta sua capacidade de processamento. Da mesma forma que os dados estruturados, esse tipo de dado requer processamento e análise para ser apresentado como informação. Encontramos dados não estruturados em imagens, mensagens de *e-mail*, documentos de textos, planilhas e, até mesmo, em mensagens postadas em redes sociais.

5.2.3 Dados armazenados pelo formato

Os dados armazenados requerem diferentes tipos de técnicas de extração de acordo com seu formato, que pode ser caracterizado como textual (ou literal), numérico, booleano (ou de lógica booleana – verdadeiro ou falso), ou por data (período).

5.2.3.1 Textual ou literal

Os dados classificados como textuais ou literais são constituídos de uma sequência de caracteres com letras, dígitos e símbolos especiais. São também conhecidos como dados alfanuméricos ou cadeia de caracteres; em inglês, recebem o nome de *string*. O tamanho desse tipo de dado é determinado pela quantidade de caracteres que possui. Este tipo de dado costuma ser encontrado em uma chamada de algoritmo por uma coleção de caracteres delimitada tanto no início como em seu final pelo caractere aspas (“”).

5.2.3.2 Numérico

Os dados do tipo numérico são subdivididos basicamente em inteiros e reais. Os dados numéricos inteiros não apresentam nenhum componente decimal ou fracionário, e são positivos ou negativos. Os dados numéricos reais, por sua vez, têm capacidade de armazenar tanto números decimais como fracionários, além de poderem ser negativos ou positivos.

5.2.3.3 Booleanos

Os dados do tipo booleano (ou lógico) são utilizados para representar apenas dois valores possíveis: 0 ou 1, ou seja, sim ou não; ou 0 ou 1 para verdadeiro ou falso.

5.2.3.4 Data

Este tipo de dado pode proporcionar uma série de cálculos e operações de ordem cronológica. Com dados dessa modalidade, é possível fazer o cálculo de uma quantidade de dias entre duas datas, ou somar ou subtrair períodos contendo dias, meses ou anos.

5.3 Métodos de *data mining*

Existem vários métodos de *data mining* para descobrir respostas ou extrair conhecimento em diferentes e numerosos repositórios de dados. Entre eles estão o KDD, de classificação; modelos de relacionamento entre variáveis, *cluster* (ou agrupamento), sumarização, dependência e associação.

5.3.1 Classificação

A classificação utiliza uma técnica estatística denominada *análise discriminante*, a qual busca o envolvimento de uma descrição gráfica ou algébrica das características de diferenciação das diversas populações. Dessa forma, classifica as observações em diferentes classes pré-definidas.

5.3.2 Relacionamento entre variáveis

Esse modelo efetua uma associação entre um ou mais itens a variáveis de predição de valores reais. As variáveis utilizadas podem ser tanto independentes, quanto exploratórias. As técnicas utilizadas para esse fim são de regressão linear simples, múltipla e modelos lineares atuantes por transformação.

5.3.3 Cluster ou agrupamento

Esse modelo opera por associação de um item a uma ou mais classes categorizadas, denominada(s) *cluster*. Essas classes são classificadas pelos tipos de dados contidos, independentemente de pré-classificação.

A definição dos *clusters* se estabelece mediante a formação de grupos de dados fundamentados em medidas de similaridade ou em modelos probabilísticos. O objetivo está na detecção da existência de diferenciados grupos inseridos em um conjunto de dados.

5.3.4 Sumarização

A utilização de modelo de sumarização está essencialmente nas medidas de posição e variabilidade. Por meio de sumarização é estabelecida uma descrição com uma dispersão reduzida em um determinado subconjunto de dados.

5.3.5 Dependência

Como o próprio nome sugere, neste modelo é descrita a dependência entre as variáveis. Esse modelo é basicamente classificado em dois tipos: quantitativo e estruturado. O primeiro define o grau de interdependência utilizando uma escala numérica; o segundo apresenta, em forma de gráfico, as variáveis que são localmente dependentes.

5.3.6 Regras de associação

Esse modelo opera pela forma com que ocorrem as relações entre diferentes campos de um banco de dados. Dessa forma, associa valores correlatos que venham a se tornar significantes.

REFERÊNCIAS

AKERKAR, R. **Artificial intelligence for business**. New York: Springer, 2019.

ARAUJO, R. C. A. de. **Modelo de inteligência pública baseado em agente inteligente no contexto de serviços da cidade digital estratégica**. 165 p. Tese (Doutorado em Gestão Urbana) – Pontifícia Universidade Católica do Paraná. Curitiba, 2020.

BRAGA, A. de P.; FERREIRA, A. C. P. de L.; LUDERMIR, T. B.. **Redes neurais artificiais: teoria e aplicações**. Rio de Janeiro: LTC, 2007.

CÔRTEZ, S. da C.; PORCARO, R. M.; LIFSCHITZ, S. **Mineração de dados: funcionalidades, técnicas e abordagens**. PUC, 2002.

COSTA, E. et al. Mineração de dados educacionais: conceitos, técnicas, ferramentas e aplicações. **Jornada de Atualização em Informática na Educação**, v. 1, n. 1, p. 1-29, 2013.

DI VAIO, A. et al. Artificial intelligence and business models in the sustainable development goals perspective: A systematic literature review. **Journal of Business Research**, v. 121, p. 283-314, 2020.

FAYYAD, U.; PIATETSKY-SHAPIRO, G.; SMYTH, P. The KDD process for extracting useful knowledge from volumes of data. **Communications of the ACM**, v. 39, n. 11, p. 27-34, 1996.

FERNANDES; G. L; MARQUES, M. L. Competitividade na era do Big Data: uma perspectiva a partir da disciplina de arquitetura da informação. In: TARAPANOFF, K. (Org.). **Análise da Informação para a tomada de decisão**. Curitiba: InterSaberes, 2015.

JAIN, A. K.; DUBES, R. C. **Algorithms for clustering data**. Upper Saddle River, NJ: Prentice-Hall, 1988.

LEE, J. et al. Emerging technology and business model innovation: the case of artificial intelligence. **Journal of Open Innovation: Technology, Market, and Complexity**, v. 5, n. 3, p. 44, 2019.

WAMBA-TAGUIMDJE, S.-L. et al. Influence of artificial intelligence (AI) on firm performance: the business value of AI-based transformation projects. **Business Process Management Journal**, 2020.