

| COMPUTAÇÃO EM NUVEM

Prof. Armando Kolbe Junior

INTRODUÇÃO

Começaremos discutindo o armazenamento e processamento de Big Data, abordando conceitos como *Data Lakes*, *Data Warehouses*, e ferramentas como *Hadoop* e *Spark* para processamento em lote e em tempo real. Em seguida, veremos como a análise de dados e *Business Intelligence* (BI) transforma dados brutos em insights. Discutiremos ferramentas como Power BI e Tableau, além de processos de ETL e visualização de dados.

No tema de IA e Machine Learning, exploraremos plataformas como AWS *SageMaker*, Azure ML e Google AI, e como construir pipelines de ML, com modelos pré-treinados e customizados. Também vamos falar sobre Governança e Qualidade de Dados, cobrindo políticas de governança e ferramentas como Collibra e Alation para garantir a integridade dos dados. Finalizaremos com Tendências Futuras em Big Data e IA, discutindo ética em IA, regulamentação e tecnologias emergentes como computação quântica.



Crédito: PopTika/Shutterstock.

TEMA 1 – ARMAZENAMENTO E PROCESSAMENTO DE BIG DATA

No contexto da computação em nuvem, o armazenamento e processamento de Big Data são fundamentais para aproveitar ao máximo o valor dos dados em larga escala que as organizações coletam. Este tema abrange as estratégias e tecnologias utilizadas para organizar, armazenar e processar vastas quantidades de dados, permitindo que empresas transformem informações brutas em insights valiosos. *Data Lakes* e *Data Warehouses* são duas abordagens que oferecem soluções distintas para o armazenamento, enquanto ferramentas como *Hadoop* e *Spark* capacitam o processamento eficiente desses dados, seja em grandes lotes ou em tempo real. Entender essas tecnologias é essencial para

quem deseja navegar no vasto mundo do Big Data e tirar proveito das suas capacidades na era digital.



Créditos: GamePixel/Shutterstock.

1.1 Data lakes, data warehouses e data lakehouse

Um *data lake* é um repositório centralizado que armazena grandes volumes de dados em seu formato original, permitindo que esses dados sejam processados e utilizados para diversas necessidades analíticas. Graças à sua arquitetura aberta e escalável, um *data lake* pode acomodar todos os tipos de dados de qualquer fonte, desde dados estruturados (tabelas de banco de dados, planilhas Excel) a semiestruturados (arquivos XML, páginas da web) e não estruturados (imagens, arquivos de áudio, tweets). Os dados são armazenados em zonas diferenciadas – bruta, limpa e curada – permitindo que diferentes usuários acessem e utilizem os dados conforme suas necessidades (AWS, n.d.; *Componentes de Data Warehouse Paralelos - Parallel Data Warehouse*, 2023; Microsoft, 2024).

Em um mundo altamente conectado e orientado por insights, as soluções de data lake são essenciais para manter os dados integrados, seguros e acessíveis. Ferramentas escaláveis como o *Azure Data Lake Storage* permitem centralizar e proteger dados, eliminando silos a um custo otimizado. Isso

possibilita uma ampla variedade de trabalhos, como processamento de big data, consultas SQL, mineração de texto, análises de streaming e machine learning. Uma plataforma de dados moderna e completa, como o *Azure Synapse Analytics*, atende às necessidades de uma arquitetura de big data centrada no data lake.

Empresas de streaming usam *data lakes* para melhorar algoritmos de recomendação; firmas de investimento gerenciam riscos de portfólio com dados de mercado em tempo real; hospitais melhoram a qualidade do atendimento analisando dados históricos; varejistas consolidam dados de múltiplos pontos de contato; e sensores IoT geram grandes quantidades de dados para análise futura.

Enquanto um *data lake* e um *data Warehouse* armazenam e processam dados, um *data lake* captura dados de diversas fontes sem a necessidade de definir a estrutura dos dados até serem lidos, o que permite armazenar dados brutos em qualquer escala. Já um *data warehouse* armazena dados tratados e transformados, otimizados para operações de consulta SQL, ideal para BI padrão e casos de uso definidos.

Um *data lakehouse* combina os benefícios de um *data lake* com a estrutura de um *data warehouse*, oferecendo uma solução flexível que lida com transações ACID, integrações de *streaming* e recursos avançados como versionamento de dados e *enforcement* de esquemas (Ait Errami et al., 2023; Park et al., 2023).

Esta visão geral destaca a importância dos *data lakes* na gestão moderna, mostrando como eles facilitam a inovação e a eficiência operacional em diversas indústrias e organizações.

1.2 Ferramentas de processamento de dados (Hadoop, Spark)

Tanto o *Hadoop* quanto o *Spark* são como grandes computadores virtuais, capazes de analisar quantidades imensas de dados de forma eficiente. O *Hadoop* divide o trabalho em partes menores e distribui essas partes por vários computadores, funcionando como uma equipe que resolve um grande quebra-cabeça juntos. Já o *Spark* é mais rápido e inteligente, usando técnicas avançadas como inteligência artificial para encontrar padrões nos dados. Muitas empresas usam as duas ferramentas em conjunto para obter insights mais profundos e tomar decisões de negócios mais acertadas (AWS, 2023b).

Diferenças entre Apache Hadoop e Apache Spark no Contexto de Gestão		
	Hadoop	Spark
Processamento de Dados	Projetado para processamento de grandes volumes de dados em lotes, adequado para tarefas que não exigem resultados em tempo real. Utiliza o HDFS (Hadoop Distributed File System) para armazenamento distribuído de dados, e o MapReduce para processar dados em paralelo, gravando os resultados em disco, o que pode ser mais lento.	Projetado para processamento em tempo real, com capacidade de manter os dados na memória (RAM) durante o processamento, o que acelera significativamente a análise de dados. É ideal para tarefas que exigem rapidez, como análises em tempo real ou machine learning.
Arquitetura e Integração	Possui seu próprio sistema de arquivos (HDFS) e é altamente escalável, permitindo que as organizações aumentem a capacidade de processamento adicionando mais nós ao cluster. É mais econômico em termos de custo de armazenamento, pois utiliza discos rígidos.	Embora possa ser integrado ao HDFS do Hadoop para armazenamento, ele não possui um sistema de arquivos nativo e depende da RAM para processamento rápido, o que pode tornar o escalonamento mais caro.
Segurança e Tolerância a Falhas	Proporciona segurança robusta com criptografia e controle de acesso, e possui alta tolerância a falhas, com a capacidade de recuperar dados de outros nós em caso de falhas.	Oferece segurança limitada por padrão, sendo necessário configurar medidas adicionais. Utiliza Resilient Distributed Datasets (RDDs) para recuperar dados e garantir tolerância a falhas.
Custos e Escalabilidade	Geralmente mais econômico para configuração e operação, sendo uma escolha melhor para organizações que precisam escalar o processamento de dados de forma acessível.	Exige maior investimento em RAM, aumentando os custos, mas oferece melhor performance para análises complexas e em tempo real.
Machine Learning	Não possui bibliotecas integradas de machine learning, sendo necessário integrá-lo a outras ferramentas como o Apache Mahout.	Inclui a biblioteca MLlib, facilitando a implementação de machine learning em grandes conjuntos de dados sem a necessidade de integrações adicionais.
Quando Usar Cada um	Melhor para processamento de dados em lote, escalabilidade econômica e segurança.	Ideal para análises em tempo real, machine learning e situações que exigem performance superior. Combinar ambos pode ser uma estratégia eficiente para maximizar os benefícios de cada ferramenta, especialmente em ambientes que exigem tanto segurança quanto velocidade (AWS, 2023b).

1.3 Processamento em lote e em tempo real

O processamento em lote é uma técnica de computação que agrupa um grande volume de tarefas e as executa de forma sequencial e programada. Essa abordagem é ideal para tarefas repetitivas e intensivas em computação, como processamento de folha de pagamento, geração de relatórios e backups de dados (AWS, 2023a).

O processamento em lote é uma técnica que agrupa um conjunto de tarefas e as executa de forma sequencial e programada. Essa abordagem apresenta diversas vantagens: otimiza o uso de recursos computacionais, evitando sobrecargas em horários de pico; reduz a necessidade de intervenção humana, minimizando erros e aumentando a produtividade; e permite o processamento eficiente de grandes volumes de dados. O funcionamento envolve três etapas principais: agendamento das tarefas para um determinado momento ou intervalo, execução sequencial das tarefas em lote e monitoramento do processo com geração de relatórios detalhados (AWS, 2023a).

Alguns exemplos de uso

- Serviços financeiros: Processamento de transações, cálculo de riscos.
- *E-commerce*: Processamento de pedidos, geração de relatórios de vendas.
- Saúde: Análise de dados genômicos, estudos clínicos.
- Indústria: Controle de qualidade, otimização de processos (AWS, 2023a).

Diferença entre processamento em lote e processamento em fluxo

- Processamento em lote: Processa dados em blocos, de forma programada. Ideal para tarefas que não requerem processamento imediato.
- Processamento em fluxo: Processa dados continuamente, à medida que eles chegam. Ideal para aplicações em tempo real, como análise de dados de sensores Z.

O processamento em lote é uma ferramenta poderosa para automatizar tarefas repetitivas e otimizar o uso de recursos computacionais. Ao entender seus princípios básicos e aplicações, você pode aproveitar seus benefícios para melhorar a eficiência e a produtividade em sua organização.

TEMA 2 – ANÁLISE DE DADOS E *BUSINESS INTELLIGENCE*

No ambiente de computação em nuvem, a análise de dados e o *Business Intelligence* (BI) são cruciais para transformar grandes volumes de dados em insights acionáveis que orientam a tomada de decisões estratégicas. Ferramentas de BI, como *Power BI* e *Tableau*, desempenham um papel vital ao permitir que empresas visualizem dados complexos de forma clara e compreensível, facilitando a interpretação e a comunicação de tendências e padrões. Processos de **ETL** (extração, transformação e carregamento) e integração de dados garantem que informações provenientes de diversas fontes sejam unificadas e preparadas para análise. A combinação dessas técnicas permite que as organizações contem suas histórias de dados com precisão, aprimorando a estratégia e a eficiência operacional.



Crédito: Nuttapong punna/Shutterstock.

2.1 Ferramentas de BI (Power BI, Tableau)

Power BI e Tableau são duas ferramentas de *Business Intelligence* (BI) líderes de mercado, cada uma com suas próprias fortalezas e direcionamentos (Hashtag, 2022).

Power BI

- **Integração:** Se integra perfeitamente com o ecossistema Microsoft, oferecendo facilidade de uso para quem já utiliza outras ferramentas da marca.
- **Preço:** Geralmente mais acessível, com opções gratuitas para uso básico.
- **Simplicidade:** Ideal para quem busca criar dashboards e relatórios mais simples e rápidos, com foco em análise básica.
- **Self-service:** Permite que usuários não técnicos criem visualizações de forma intuitiva.

Tableau

- **Visualização:** Oferece recursos mais avançados para criação de visualizações complexas e interativas, ideal para exploração profunda dos dados.
- **Flexibilidade:** Maior flexibilidade na configuração e personalização dos dashboards.
- **Comunidade:** Possui uma comunidade de usuários mais extensa e experiente.
- **Análise:** Perfeito para análises aprofundadas e exploratórias, com foco em descobrir insights mais complexos (Hashtag, 2022).

A escolha entre *Power BI* e *Tableau* depende das necessidades específicas de cada empresa. Se vai ser priorizada a integração com o ecossistema Microsoft e a simplicidade de uso, o Power BI é a melhor opção. Caso a necessidade é a visualizações mais complexas e análises profundas: Tableau é a escolha ideal. Na situação de orçamento limitado, Power BI oferece opções mais acessíveis e na comunidade e suporte, o Tableau possui uma comunidade maior e mais experiente (Hashtag, 2022).

Uma comparação geral:

- **Power BI:** Ideal para empresas que buscam uma solução completa e integrada ao ecossistema Microsoft, com foco em dashboards simples e intuitivos.
- **Tableau:** Perfeito para empresas que precisam de uma ferramenta poderosa para análise de dados complexos e criação de visualizações avançadas (Hashtag, 2022).

É altamente recomendável realizar um teste gratuito de ambas as ferramentas para avaliar qual delas melhor atende às suas necessidades específicas e ao perfil da sua equipe. Tanto o Power BI quanto o Tableau são excelentes ferramentas de BI, cada uma com suas próprias vantagens. A escolha da ferramenta certa depende das necessidades específicas de cada empresa e do perfil dos usuários.

2.2 ETL e integração de dados

ETL é um processo de três etapas (Extração, Transformação e Carga) usado para coletar dados de diversas fontes, transformá-los em um formato utilizável e carregá-los em um *data warehouse* ou *data mart* para análise (FiveActs, 2023).

Por que usar ETL?	
Qualidade dos dados	Garante a limpeza e a consistência dos dados antes da análise.
Integração de dados	Combina dados de diferentes fontes em um único repositório.
Preparação para análise	Transforma os dados em um formato adequado para análise e geração de relatórios.
Suporte à tomada de decisão	Fornece dados confiáveis e relevantes para a tomada de decisões estratégicas (FiveActs, 2023).

Como funciona o processo ETL?	
Extração	Coleta dados de diversas fontes (bancos de dados, arquivos etc.).
Transformação	Limpa, transforma e padroniza os dados para garantir a qualidade.
Carga	Carrega os dados transformados em um data warehouse ou data mart (FiveActs, 2023).

Ferramentas ETL populares	
SAP Business Objects Data Services	Conhecido por sua capacidade de tratar grandes volumes de dados e criar visões completas.
IBM InfoSphere DataStage	Combina integração de dados com DataOps e IA para acelerar tarefas administrativas.
Microsoft SQL Server Integration Services (SSIS)	Integrado ao SQL Server, é ideal para tarefas de migração e ETL.
Pentaho Data Integration	Oferece uma interface amigável e é amplamente utilizado para projetos de ETL.
Informatica PowerCenter	Conhecido por sua flexibilidade e capacidade de integrar dados de diversas fontes.
Oracle Data Integrator (ODI)	Uma solução modular e escalável para projetos de ETL (FiveActs, 2023).

Importância do ETL para o *Business Intelligence*

O ETL é fundamental para o sucesso de qualquer iniciativa de BI, pois garante que os dados utilizados para análise sejam precisos, confiáveis e

relevantes. Ao preparar os dados adequadamente, as empresas podem obter insights valiosos sobre seus negócios e tomar decisões mais informadas (FiveActs, 2023). É um processo essencial para qualquer organização que busca transformar dados em informações úteis para a tomada de decisão. Ao entender os fundamentos do ETL e as ferramentas disponíveis, as empresas podem otimizar seus processos de análise de dados e obter um melhor retorno sobre seus investimentos.

2.3 Visualização de dados e *storytelling*

Data storytelling é a arte de transformar dados complexos em narrativas envolventes e fáceis de entender. Por meio de técnicas de *storytelling*, é possível comunicar insights valiosos de forma mais eficaz, seja para a equipe interna ou para clientes externos (Menezes, 2024).

Algumas razões para se usar *Data Storytelling*

- **Aumenta o engajamento:** Histórias são mais fáceis de lembrar e geram mais interesse do que números isolados.
- **Facilita a compreensão:** Transforma dados complexos em informações acessíveis para todos.
- **Apoia a tomada de decisão:** Permite visualizar tendências e padrões, facilitando a identificação de oportunidades e riscos.
- **Melhora a comunicação:** Torna a comunicação mais eficaz e persuasiva (Menezes, 2024).

Qual o funcionamento do *Data Storytelling*?

- **Coleta e preparação dos dados:** Os dados são coletados de diversas fontes e preparados para a análise.
- **Criação da narrativa:** Uma história é construída em torno dos dados, com uma introdução, desenvolvimento, clímax e resolução.
- **Visualização dos dados:** Gráficos, tabelas e outros elementos visuais são utilizados para ilustrar a história.
- **Comunicação:** A história é compartilhada com o público-alvo de forma clara e concisa.

Ferramentas para Data Storytelling

O *Power BI* é uma ferramenta poderosa para visualizar e contar histórias com dados, oferecendo uma ampla gama de recursos e integrações.

Entre os benefícios do *Data Storytelling*, temos

- **Tomada de decisões mais assertivas:** Ao transformar dados em histórias, é mais fácil identificar padrões e tendências, permitindo tomar decisões mais informadas.
- **Melhora da comunicação:** Facilita a comunicação de informações complexas para diferentes públicos.
- **Aumento da colaboração:** Estimula a colaboração entre diferentes áreas da empresa.
- **Fortalecimento da marca:** Demonstra a capacidade da empresa de analisar dados e gerar insights valiosos.

O *Data Storytelling* é uma habilidade fundamental para qualquer profissional que trabalha com dados. Ao transformar dados em histórias, é possível comunicar insights de forma mais eficaz, engajar o público e impulsionar o sucesso da empresa.

TEMA 3 – INTELIGÊNCIA ARTIFICIAL E MACHINE LEARNING

A Inteligência Artificial (IA) e o *Machine Learning* (ML) estão no centro das inovações tecnológicas na computação em nuvem, impulsionando a automação e a capacidade de análise avançada. Serviços como *AWS SageMaker*, *Azure ML* e *Google AI* facilitam a implementação de modelos de IA e ML, permitindo tanto o uso de modelos pré-treinados quanto o desenvolvimento de soluções customizadas. A criação de pipelines de ML, desde a coleta e preparação dos dados até o treinamento e a implementação dos modelos, é essencial para integrar essas tecnologias ao ambiente de negócios. Essas ferramentas e processos estão transformando a maneira como as empresas abordam problemas complexos, tornando a IA e o ML mais acessíveis e poderosos para diversas aplicações (Nogare, 2024).



Crédito: Gumbariya/Shutterstock.

3.1 Serviços de IA e ML (AWS SageMaker, Azure ML, Google AI)

IA e ML estão revolucionando o mundo da tecnologia e novas ferramentas e plataformas estão surgindo para facilitar o desenvolvimento de projetos nessas áreas. A escolha da ferramenta certa pode fazer toda a diferença no seu projeto, por isso é importante considerar alguns fatores como o tipo de projeto, o nível de habilidade do desenvolvedor e o orçamento disponível (Nogare, 2024).

Ferramentas populares de IA e ML para Python

Ferramenta	Descrição
TensorFlow	Biblioteca de código aberto criada pelo Google. Pode ser usada em várias linguagens de programação
PyTorch	Framework de código aberto usado para construir e treinar modelos de Deep Learning
Keras	API projetada para ser fácil de usar e reduzir a carga cognitiva dos desenvolvedores (Nogare, 2024)

Plataformas de desenvolvimento de IA e ML

Plataforma	Descrição
Google Cloud AI	Plataforma de IA que oferece serviços como análise de vídeo e imagem, reconhecimento de fala e processamento multilíngue
AWS SageMaker	Serviço totalmente gerenciado na nuvem para construir, treinar e implantar modelos de ML
Microsoft Azure Machine Learning	Serviço de IA corporativo que suporta o ciclo de vida completo de Machine Learning (Nogare, 2024)

Escolha a ferramenta e plataforma certa considerando

- Facilidade de uso
- Flexibilidade
- Escalabilidade
- Suporte da comunidade
- Custo
- Compatibilidade com tecnologias existentes
- Necessidades futuras do seu negócio
- Evite lock-in de fornecedor (Nogare, 2024)

Ao escolher as ferramentas e plataformas certas, os desenvolvedores podem focar em resolver problemas complexos e inovar, em vez de se preocupar com questões técnicas.

3.2 Modelos pré-treinados e treinamento customizado

Modelos pré-treinados são como atalhos no aprendizado de máquina. São modelos já treinados em grandes conjuntos de dados para realizar tarefas específicas, como reconhecimento de imagens ou processamento de linguagem natural. Esses modelos "aprendem" padrões e características dos dados durante o treinamento inicial. Ao serem adaptados para novas tarefas, eles já possuem um conhecimento base, acelerando o processo e melhorando o desempenho (Barbon; Akabane, 2022; Ramos, 2024).

Vantagens

- **Aceleração do desenvolvimento:** Não é necessário treinar um modelo do zero.
- **Melhor desempenho:** Modelos pré-treinados geralmente têm um desempenho superior, especialmente com dados limitados.
- **Conhecimento prévio:** Os modelos já possuem um conhecimento prévio sobre o tipo de dados, facilitando a adaptação a novas tarefas (Nogare, 2024; Ramos, 2024).

Tipos de modelos pré-treinados

- **Reconhecimento de imagens:** Usados para classificar ou segmentar imagens.

- **Processamento de linguagem natural:** Utilizados para tarefas como tradução, análise de sentimentos e geração de texto.
- **Análise de dados:** Empregados para prever, detectar fraudes e analisar dados estruturados (Ramos, 2024).

Como usar um modelo pré-treinado?

- **Carregar o modelo:** Carregar o modelo pré-treinado e seus pesos.
- **Fine-tuning:** Adaptar o modelo aos dados específicos da sua tarefa.
- **Previsões:** Usar o modelo ajustado para fazer previsões ou tomar decisões (Ramos, 2024).

Desafios

- **Dados rotulados:** Requerem grandes quantidades de dados rotulados para o treinamento inicial.
- **Adaptação:** Nem sempre se encaixam perfeitamente em todas as tarefas (Barbon & Akabane, 2022; Nogare, 2024; Ramos, 2024).

Aplicações

Medicina: Diagnóstico de doenças por meio de imagens.

Finanças: Previsão de mercado, detecção de fraudes.

Marketing: Segmentação de clientes, personalização de campanhas.

Modelos pré-treinados são ferramentas poderosas que aceleram o desenvolvimento de projetos de aprendizado de máquina. Ao aproveitar o conhecimento prévio desses modelos, é possível obter resultados mais precisos e em menos tempo. No entanto, é importante entender suas limitações e adaptá-los adequadamente às suas necessidades específicas.

3.3 Implementação de pipelines de MLOps

MLOps é uma abordagem que visa otimizar o processo de desenvolvimento e implantação de modelos de Machine Learning, integrando as práticas de DevOps ao mundo da ciência de dados. Em resumo, o MLOps busca automatizar e agilizar o ciclo de vida completo de um modelo de ML, desde a coleta de dados até o monitoramento em produção (Eng, 2024).

Algumas razões para implementar o MLOps

- **Acelera o desenvolvimento:** Agiliza o processo de criação e implantação de modelos.
- **Melhora o desempenho:** Permite monitorar e otimizar continuamente os modelos.
- **Aumenta a confiabilidade:** Garante a qualidade e a robustez dos modelos em produção.
- **Reduz custos:** Automatiza processos e otimiza o uso de recursos.
- **Facilita a colaboração:** Promove a colaboração entre equipes de ciência de dados, engenharia e operações (Eng, 2024; Kreuzberger et al., 2023; Testi et al., 2022).

Desafios da implementação

- **Gerenciamento de pipelines:** Dificuldade em gerenciar um grande número de pipelines de ML.
- **Monitoramento de modelos:** Falta de ferramentas e processos para monitorar continuamente o desempenho dos modelos.
- **Governança de dados:** Dificuldade em garantir a qualidade e a segurança dos dados utilizados nos modelos (Eng, 2024; Kreuzberger et al., 2023; Testi et al., 2022).

Práticas recomendadas

- **Definir metas claras:** Estabelecer objetivos específicos para os projetos de ML.
- **Padronizar processos:** Criar processos e diretrizes para garantir a qualidade e a consistência.
- **Automatizar tarefas:** Utilizar ferramentas para automatizar tarefas repetitivas.
- **Monitorar continuamente os modelos:** Acompanhar o desempenho dos modelos em produção.
- **Colaborar entre equipes:** Promover a colaboração entre as equipes envolvidas (Eng, 2024; Kreuzberger et al., 2023).

A ferramenta indicada para implementação do MLOps é a DHuO Data, que facilita a gestão do ciclo de vida dos modelos de ML, automatiza processos e permite o compartilhamento de insights (Eng, 2024)..

O MLOps é fundamental para as empresas que desejam tirar o máximo proveito da inteligência artificial. Ao implementar o MLOps, as empresas podem acelerar o desenvolvimento de modelos de ML, melhorar sua performance e garantir que eles sejam utilizados de forma eficaz para gerar valor de negócio (Eng, 2024; Kreuzberger et al., 2023; Testi et al., 2022)..

Benefícios de implementar MLOps

- **Agilidade:** Entrega mais rápida de modelos e soluções de IA.
- **Eficiência:** Otimização de recursos e redução de custos.
- **Qualidade:** Modelos mais precisos e confiáveis.
- **Inovação:** Facilita a experimentação e a criação de novas soluções (Eng, 2024; Kreuzberger et al., 2023; Testi et al., 2022).

O MLOps é um investimento estratégico para qualquer empresa que busca se destacar no mercado por meio da inteligência artificial. Ao adotar as práticas e ferramentas corretas, as empresas podem transformar seus dados em insights valiosos e impulsionar o crescimento do negócio (Eng, 2024).

TEMA 4 – DATA GOVERNANCE E QUALIDADE DE DADOS

Data Governance e Qualidade de Dados são pilares fundamentais para o gerenciamento eficaz de informações na era do Big Data. A governança de dados envolve o estabelecimento de políticas, processos e responsabilidades que garantem a segurança, privacidade e conformidade dos dados, enquanto a qualidade de dados se concentra em assegurar a precisão, integridade e consistência das informações. Ferramentas como Collibra e Alation ajudam a implementar essas práticas, fornecendo suporte para o monitoramento, catalogação e auditoria de dados. Sem uma governança sólida e um compromisso com a qualidade, as iniciativas de análise e inteligência artificial podem ser comprometidas, levando a decisões baseadas em dados incorretos ou incompletos (Brasil, 2023; EDUCAUSE, 2023).



Crédito: Aree_S/Shutterstock.

4.1 Políticas de governança de dados

De acordo com Brasil (2023), as Políticas de Governança de Dados são um conjunto estruturado de regras, diretrizes e práticas que uma organização implementa para gerenciar, proteger, e maximizar o valor dos dados que possui. Essas políticas são essenciais para garantir que os dados sejam utilizados de maneira eficiente e segura, permitindo que a organização tome decisões baseadas em informações precisas e confiáveis (Brasil, 2023).

Objetivos Principais das Políticas de Governança de Dados

1. **Garantir a Qualidade dos Dados:** Assegurar que os dados sejam precisos, completos, consistentes e confiáveis.
2. **Proteger a Segurança dos Dados:** Implementar medidas para proteger os dados contra acessos não autorizados, violações, e uso indevido.
3. **Garantir a Conformidade Legal:** Assegurar que os dados sejam gerenciados de acordo com as leis e regulamentos aplicáveis, como a LGPD (Lei Geral de Proteção de Dados) no Brasil.
4. **Definir Responsabilidades:** Clarificar quem dentro da organização é responsável por diferentes aspectos da gestão de dados.
5. **Maximizar o Valor dos Dados:** Usar os dados de maneira estratégica para gerar insights valiosos e apoiar as decisões de negócios (Brasil, 2023).

4.2 Qualidade e integridade de dados

Dentro das políticas de governança de dados, a Qualidade e Integridade de Dados são componentes críticos que garantem que os dados utilizados pela organização sejam confiáveis e úteis para as suas operações e decisões (Brasil, 2023; EDUCAUSE, 2023).

Qualidade dos Dados

A qualidade dos dados refere-se à precisão, completude, consistência e atualidade dos dados. Dados de alta qualidade são essenciais para garantir que as análises e as decisões baseadas em dados sejam corretas e eficazes. Para manter a qualidade dos dados, as políticas de governança de dados geralmente incluem:

- **Padrões de Dados:** Definição de padrões para a entrada e armazenamento de dados, assegurando que todos os dados sigam um formato consistente e sejam coletados com precisão.
- **Validação de Dados:** Implementação de processos para verificar a precisão e a completude dos dados, corrigindo erros e omissões quando identificados.
- **Atualização de Dados:** Garantir que os dados sejam mantidos atualizados e relevantes, com processos para revisão e atualização regular (Brasil, 2023; EDUCAUSE, 2023).

Integridade dos Dados

A integridade dos dados refere-se à confiabilidade e à consistência dos dados ao longo de seu ciclo de vida. Isso inclui garantir que os dados não sejam alterados ou corrompidos de maneira não autorizada e que sejam armazenados e transmitidos de forma segura. Aspectos importantes incluem:

- **Integridade Referencial:** Garantir que os dados armazenados em diferentes partes de um sistema (ou em sistemas diferentes) permaneçam consistentes e corretamente relacionados entre si.
- **Proteção Contra Manipulação Indevida:** Implementar controles de acesso e monitoramento para evitar que dados sejam alterados por pessoas não autorizadas.
- **Criptografia e Backup:** Uso de criptografia para proteger os dados durante a transmissão e armazenamento, além de políticas robustas de backup

para assegurar que os dados possam ser recuperados em caso de falhas (Brasil, 2023; EDUCAUSE, 2023).

Implementação de Políticas de Governança de Dados

Para implementar essas políticas, é necessário que a organização:

1. **Defina Claramente os Papéis e Responsabilidades:** Estabeleça quem é responsável por diferentes aspectos da gestão dos dados, como o Data Steward (responsável pela gestão diária dos dados) e o Data Owner (responsável pela governança e qualidade dos dados).
2. **Estabeleça Processos e Ferramentas:** Adote processos bem definidos e ferramentas tecnológicas que suportem a gestão e monitoramento contínuo da qualidade e integridade dos dados.
3. **Eduque e Treine a Equipe:** Garanta que todos na organização entendam a importância das políticas de governança de dados e estejam treinados para seguir as diretrizes estabelecidas.
4. **Monitore e Audite Regularmente:** Implemente mecanismos de monitoramento e auditoria para garantir que as políticas sejam seguidas e que os dados permaneçam de alta qualidade e íntegros ao longo do tempo (Brasil, 2023; EDUCAUSE, 2023).

4.3 Ferramentas de governança de dados (Collibra, Alation)

Gartner (2024) faz uma análise comparativa entre duas plataformas de governança de dados: Alation e Collibra, com base em avaliações de usuários.

Segue um resumo contextualizado:

1. **Avaliação Geral:** Ambas as plataformas são bem avaliadas por seus usuários, com Alation recebendo uma nota média de 4,5/5 e Collibra 4,4/5.
2. **Pontos Positivos:**
 - **Alation:** É elogiado pela sua transparência, capacidade de conectar fontes de dados e pelo suporte dedicado ao cliente.
 - **Collibra:** Destaca-se pela gestão de catálogos de dados, linhagem técnica e glossário de negócios, sendo muito usada em governança de dados em diferentes departamentos.
3. **Pontos Negativos:**
 - **Alation:** Críticas incluem a necessidade de melhorias no roadmap do produto e no modelo de suporte.

- **Collibra**: Recebeu críticas por ter um sistema de busca pouco intuitivo e uma gestão de relacionamento com clientes que poderia ser melhorada.

4. Preferência dos Usuários:

- 85% dos usuários da Alation estão dispostos a recomendar a plataforma, enquanto 81% dos usuários da Collibra fariam o mesmo.


5. Mercado e Funcionalidades:

- Ambas as plataformas operam nos mercados de Gestão Ativa de Metadados e Governança de Dados e Analytics.
- **Alation** foca na ingestão e tradução de metadados, enquanto **Collibra** é mais diversificada, com funcionalidades adicionais em qualidade de dados aumentada (Gartner, 2024).

Com base no relatório da Gartener (2024), podemos verificar que as duas ferramentas são líderes no mercado de governança de dados e oferecem soluções robustas para diferentes necessidades organizacionais. No entanto, a escolha entre uma ou outra pode depender das prioridades específicas de uma organização, como a facilidade de integração, suporte ao cliente e funcionalidades de governança de dados.

TEMA 5 – TENDÊNCIAS FUTURAS EM BIG DATA E IA

As tendências futuras em Big Data e Inteligência Artificial (IA) apontam para avanços significativos que transformarão a forma como as organizações utilizam dados. A ética em IA e a regulamentação estão se tornando questões centrais, à medida que as tecnologias de IA evoluem e se tornam mais integradas nas operações diárias, levantando preocupações sobre privacidade, viés e responsabilidade. Além disso, tecnologias emergentes como computação quântica e *neuromorphic computing* prometem revolucionar a capacidade de processamento e análise de dados em uma escala sem precedentes. Esses avanços não apenas impulsionarão inovações tecnológicas, mas também terão um impacto profundo em setores como saúde, finanças e manufatura, redefinindo padrões e criando novas oportunidades.



Crédito: Thantaree/Shutterstock.

5.1 A lei da União Europeia sobre a Inteligência Artificial (IA)

A lei da União Europeia sobre Inteligência Artificial (IA) representa um marco histórico na regulamentação global dessa tecnologia, sendo a primeira legislação abrangente a abordar os diversos aspectos da IA, desde a sua concepção até a sua aplicação. A lei busca garantir que a IA seja desenvolvida e utilizada de forma ética, segura e transparente, protegendo os direitos fundamentais dos cidadãos europeus (Parlamento Europeu, 2024).

Principais pontos da lei

- **Classificação de risco:** A lei classifica os sistemas de IA em diferentes categorias de risco, desde os de risco inaceitável (proibidos) até os de risco elevado (sujeitos a rigorosas avaliações).
- **Transparência:** Exige que os sistemas de IA sejam transparentes, permitindo que os usuários saibam quando estão interagindo com uma IA.
- **Proteção de dados:** A lei reforça a proteção de dados pessoais e garante que a IA seja desenvolvida de forma a não discriminar.
- **Responsabilidade:** Estabelece responsabilidades claras para os desenvolvedores e usuários de sistemas de IA (Parlamento Europeu, 2024).

Atualização com a Legislação Brasileira

A legislação brasileira sobre IA ainda está em desenvolvimento. Embora o Brasil tenha reconhecido a importância de regular a IA e esteja discutindo propostas de lei, ainda não há uma legislação abrangente como a da UE.

Pontos em comum e diferenças

- **Objetivo:** Tanto a UE quanto o Brasil buscam criar um ambiente favorável à inovação em IA, ao mesmo tempo em que garantem a proteção dos direitos dos cidadãos.
- **Abordagem:** As propostas brasileiras tendem a seguir a linha da lei europeia, com a classificação de risco dos sistemas de IA e a exigência de transparência.
- **Especificidades:** A legislação brasileira pode ter particularidades relacionadas ao contexto nacional, como questões relacionadas à proteção de dados pessoais, à propriedade intelectual e à inclusão digital (Antunes de Miranda; Menezes de Souza, 2022; Lucas; Santos, 2021; Parlamento Europeu, 2024).

Desafios para a legislação brasileira

- **Equilíbrio entre inovação e regulação:** É preciso encontrar um equilíbrio que incentive a inovação em IA, sem comprometer a segurança e os direitos dos cidadãos.
- **Complexidade técnica:** A IA é uma tecnologia em constante evolução, o que exige que a legislação seja flexível e capaz de se adaptar às novas tecnologias.
- **Cooperação internacional:** A regulamentação da IA é um desafio global que exige a cooperação entre os países para evitar fragmentação e garantir a interoperabilidade dos sistemas (Antunes de Miranda; Menezes de Souza, 2022; Lucas; Santos, 2021).

Importância da comparação

- **Identificar as melhores práticas:** A lei europeia pode servir como referência para a elaboração da legislação brasileira, permitindo a adoção de soluções já testadas e eficazes.

- **Adaptar a legislação ao contexto nacional:** A legislação brasileira deve considerar as particularidades do país, como o tamanho do mercado, o nível de desenvolvimento tecnológico e as necessidades da sociedade.
- **Promover a convergência internacional:** A harmonização das legislações sobre IA é fundamental para facilitar a cooperação internacional e o comércio global.

A lei da UE sobre IA representa um avanço significativo na regulamentação global dessa tecnologia. A legislação brasileira, ainda em desenvolvimento, deve se inspirar nessa experiência para criar um marco regulatório sólido e eficaz, capaz de garantir o desenvolvimento responsável e ético da IA no país.

5.2 Tecnologias emergentes (quantum neuromorphic computing)

Marković e Grollier (2020), publicaram um artigo em um momento de grande avanço no campo da inteligência artificial, introduz o GPT-3, que na época representava um avanço significativo no campo da inteligência artificial, especialmente no processamento de linguagem natural (Marković; Grollier, 2020). Com a evolução contínua da tecnologia, foram desenvolvidos modelos subsequentes como o GPT-4 e o GPT-4 Turbo (GPT-4o), que expandem as capacidades introduzidas pelo GPT-3.

GPT-3

No artigo, o GPT-3 é um modelo de linguagem com 175 bilhões de parâmetros que revolucionou a área ao demonstrar a capacidade de aprendizado de poucos exemplos (*few-shot learning*). Ele consegue realizar tarefas complexas com apenas alguns exemplos, o que o torna versátil e útil em diversas aplicações sem a necessidade de re-treinamento específico para cada tarefa (Marković; Grollier, 2020).

Evolução para o GPT-4

- **Aumento de Escala e Precisão:** O GPT-4 é uma versão aprimorada do GPT-3, com melhorias significativas em termos de escala, capacidade de compreensão e geração de texto. O GPT-4 não só aumenta o número de parâmetros, mas também incorpora avanços na arquitetura do modelo, permitindo uma compreensão mais profunda e respostas mais coerentes e contextualmente precisas (OpenAI, 2024; Ray, 2023; Tlili et al., 2023).

- **Melhorias em Tarefas Complexas:** O GPT-4 continua a melhorar em tarefas de aprendizado de poucos exemplos, com capacidades expandidas para lidar com tarefas mais complexas, como interpretação de texto técnico, resolução de problemas matemáticos e compreensão de múltiplos idiomas com maior acurácia (OpenAI, 2024).

GPT-4 Turbo (GPT-4o)

- **Eficiência e Acessibilidade:** O GPT-4 Turbo, também conhecido como GPT-4o, é uma versão otimizada do GPT-4. Ele é projetado para ser mais rápido e eficiente em termos de uso de recursos computacionais, tornando-o mais acessível para uma gama mais ampla de aplicações. O GPT-4 Turbo mantém muitas das capacidades do GPT-4, mas é ajustado para oferecer um desempenho mais ágil, ideal para cenários em que a rapidez de resposta é crítica.
- **Aplicações Práticas:** O GPT-4 Turbo é frequentemente usado em ambientes onde o equilíbrio entre desempenho e custo é essencial, como em assistentes virtuais em tempo real, chatbots avançados e sistemas de recomendação personalizados. Ele é capaz de lidar com cargas de trabalho intensas enquanto oferece respostas de alta qualidade (OpenAI, 2024; Ray, 2023; Tlili et al., 2023).

A transição do GPT-3 para o GPT-4 e GPT-4 Turbo exemplifica a evolução contínua dos modelos de linguagem natural. Enquanto o GPT-3 estabeleceu as bases para o aprendizado de poucos exemplos, o GPT-4 e sua versão Turbo expandem essas capacidades, oferecendo maior precisão, escalabilidade e eficiência. Essas inovações reforçam o potencial desses modelos em transformar a maneira como interagimos com a tecnologia, ampliando suas aplicações em áreas como educação, negócios, saúde e entretenimento (OpenAI, 2024; Ray, 2023; Tlili et al., 2023).

5.3 Impacto das inovações em diferentes setores

A computação em nuvem está redefinindo os limites da inovação tecnológica, impulsionando uma nova era de transformação digital. Líderes do setor convergem na visão de que a nuvem é o alicerce para a construção de um futuro mais inteligente e conectado. A capacidade de escalar recursos computacionais sob demanda, aliada à flexibilidade e à eficiência operacional,

torna a nuvem uma ferramenta indispensável para organizações de todos os portes. A integração com tecnologias emergentes, como inteligência artificial e aprendizado de máquina, está impulsionando a personalização em massa e abrindo novas fronteiras para a inovação. Setores como saúde, finanças e manufatura estão sendo profundamente transformados pela nuvem, que também desempenha um papel crucial na segurança e na conformidade regulatória.

5.4 ODS Relevantes

Para esta etapa, os seguintes Objetivos de Desenvolvimento Sustentável (ODS) da ONU são especialmente relevantes:

1. **ODS 4:** Educação de Qualidade - A aplicação de Big Data, IA e Machine Learning na nuvem pode ajudar a personalizar a educação, criar materiais didáticos mais eficazes e ampliar o acesso ao conhecimento por meio de plataformas educacionais avançadas.
2. **ODS 8:** Trabalho Decente e Crescimento Econômico - Essas tecnologias impulsionam a inovação e a produtividade, criando novas oportunidades de emprego e promovendo o crescimento econômico sustentável em diversos setores.
3. **ODS 9:** Indústria, Inovação e Infraestrutura - Big Data, IA e Machine Learning são fundamentais para a modernização da infraestrutura industrial e tecnológica, promovendo a inovação e a construção de infraestruturas resilientes e sustentáveis.
4. **ODS 11:** Cidades e Comunidades Sustentáveis - O uso de IA e Big Data pode melhorar o planejamento urbano, a gestão de recursos e a sustentabilidade das cidades, contribuindo para a construção de comunidades mais inteligentes e sustentáveis.
5. **ODS 12:** Consumo e Produção Responsáveis - Essas tecnologias podem otimizar a cadeia de suprimentos, reduzir desperdícios e promover padrões de consumo e produção mais sustentáveis.
6. **ODS 13:** Ação contra a Mudança Global do Clima - Big Data e IA são ferramentas poderosas para monitorar o impacto das mudanças climáticas e desenvolver soluções baseadas em dados para mitigação e adaptação.

Esses ODS refletem o potencial transformador de Big Data, IA e Machine Learning na nuvem para promover o desenvolvimento sustentável em diversas áreas.

REFERÊNCIAS

AWS. (n.d.). **Data Warehouse vs. Data lake Data mart** – Comparação entre soluções de armazenamento em nuvem. AWS. Retrieved March 26, 2023. Disponível em: <<https://aws.amazon.com/pt/compare/the-difference-between-a-data-warehouse-data-lake-and-data-mart/>>. Acesso em: 3 set. 2024.

AWS. (2023a). **O que é processamento em lote?** AWS. Disponível em: <<https://aws.amazon.com/pt/what-is/batch-processing/>>. Acesso em: 3 set. 2024.

AWS. (2023b). **Qual é a diferença entre o Hadoop e o Spark?** AWS. Disponível em: <<https://aws.amazon.com/pt/compare/the-difference-between-hadoop-vs-spark/#:~:text=O%20Hadoop%20oferece%20processamento%20distribu%C3%A4do,armazenamento%20externo%20para%20as%20an%C3%A1lises>>. Acesso em: 3 set. 2024.

BARBON, S.; AKABANE, T. **Análise de Performance dos Modelos Gerais de Aprendizado de Máquina Pré-Treinados: BERT vs DistilBERT**. 2022. Disponível em: <https://doi.org/10.5753/sbrc_estendido.2022.223391>. Acesso em: 3 set. 2024.

BRASIL. **Política de Governança de Dados do Ministério das Comunicações**. 2023. Disponível em: <https://www.gov.br/mcom/pt-br/aceso-a-informacao/governanca/Politica_de_Governanca_de_Dados.pdf>. Acesso em: 3 set. 2024.

COMPONENTES DE DATA WAREHOUSE PARALELOS - Parallel Data Warehouse. **Microsoft Learn**. 2023. Disponível em: <<https://learn.microsoft.com/pt-br/sql/analytics-platform-system/parallel-data-warehouse-overview?view=aps-pdw-2016-au7>>. Acesso em: 3 set. 2024.

EDUCAUSE. **EDUCAUSE Horizon Action Plan: Data Governance**. Retrieved April 13, 2023. Disponível em: <<https://library.educause.edu/resources/2023/3/2023-educause-horizon-action-plan-data-governance>>. Acesso em: 3 set. 2024.

ENG. **Guia sobre a implementação de MLOps**: ferramentas, processos e desafios comuns. 2024. Disponível em: <<https://blog.engdb.com.br/mlops-como-implementar/>>. Acesso em: 3 set. 2024.

FIVEACTS. **ETL**: o que é, importância e como aplicar na sua estratégia BI. FiveActs. 2023. Disponível em: <<https://www.fiveacts.com.br/etl>>. Acesso em: 3 set. 2024.

GARTNER. Alation vs Collibra. **Gartner**. 2024. Disponível em: <<https://www.gartner.com/reviews/market/active-metadata-management/compare/alation-vs-collibra>>. Acesso em: 3 set. 2024.

HASHTAG. **Power BI vs Tableau, qual é o melhor?** Comparativo completo. Power BI. 2022. Disponível em: <https://www.hashtagtreinamentos.com/power-bi-vstableau?gad_source=1&gclid=CjwKCAjw5Ky1BhAgEiwA5jGujrvMg74D2FYv7SAGNY5pMGAI2SCqM2LHK237FTIVxgo8zT5FostwFBoCZU4QAvD_BwE>. Acesso em: 3 set. 2024.

KREUZBERGER, D., KUHL, N.; HIRSCHL, S. (2023). Machine Learning Operations (MLOps): Overview, Definition, and Architecture. **IEEE Access**, 11, 2023. Disponível em: <<https://doi.org/10.1109/ACCESS.2023.3262138>>. Acesso em: 3 set. 2024.

LUCAS, B.; SANTOS, O. Considerações sobre os desafios jurídicos do uso da inteligência artificial na medicina. **Revista de Direito**, v. 13, n. 1, 2021. Disponível em: <<https://doi.org/10.32361/2021130112292>>. Acesso em: 3 set. 2024.

MARKOVIĆ, D., GROLLIER, J. Quantum neuromorphic computing. **App. Phys. Lett.**, 117, 2020. Disponível em: <<https://doi.org/10.1063/5.0020014>>. Acesso em: 3 set. 2024.

MENEZES, M. Storytelling de Dados: saiba a importância e como aplicar em sua empresa. **Leansolutions**, 2024. Disponível em: <<https://www.leansolutions.com.br/blog/storytelling-com-dados/>>. Acesso em: 3 set. 2024.

MICROSOFT. **What is a Data Lake?** Microsoft, 2024. Disponível em: <<https://azure.microsoft.com/en-us/resources/cloud-computing-dictionary/what-is-a-data-lake#:~:text=While%20a%20data%20lake%20holds,source%20analytic%20or%20operational%20reporting>>. Acesso em: 3 set. 2024.

NOGARE, D. **Ferramentas e plataformas essenciais para projetos de IA e ML.** 2024. Disponível em: <<https://diegonogare.net/2024/02/ferramentas-e-plataformas-essenciais-para-projetos-de-ia-e-ml/>>. Acesso em: 3 set. 2024.

OPENAI. **Models.** OpenAI Plataform. 2024 Disponível em: <<https://platform.openai.com/docs/models/gpt-4-and-gpt-4-turbo>>. Acesso em: 3 set. 2024.

PARK, S., YANG, S., KIM, W. Design of Vessel Data Lakehouse with Big Data and AI Analysis Technology for Vessel Monitoring System. **Electronics**, v. 12, n. 8, 2023. Disponível em: <<https://doi.org/10.3390/electronics12081943>>. Acesso em: 3 set. 2024.

PARLAMENTO EUROPEU. **Lei da UE sobre IA:** primeira regulamentação de inteligência artificial. 2024. Disponível em: <<https://www.europarl.europa.eu/topics/pt/article/20230601STO93804/lei-da-ue-sobre-ia-primeira-regulamentacao-de-inteligencia-artificial>>. Acesso em: 3 set. 2024.

RAMOS, M. **O que é Pretrained Model** (Modelo Pré-Treinado)? 2024. Disponível em: <<https://glossario.maiconramos.com/glossario/o-que-e-pretrained-model-modelo-pre-treinado/>>. Acesso em: 3 set. 2024.

RAY, P. ChatGPT: A comprehensive review on background, applications, key challenges, bias, ethics, limitations and future scope. **Internet of Things and Cyber-Physical Systems**, v. 3, p. 121-154, 2023. Disponível em: <<https://doi.org/10.1016/j.iotcps.2023.04.003>>. Acesso em: 3 set. 2024.

TESTI, M.; BALLABIO, M.; FRONTONI, E.; IANNELLO, G.; MOCCIA, S.; SODA, P.; VESSIO, G. MLOps: A Taxonomy and a Methodology. **IEEE Access**, v. 10, 2022. Disponível em: <<https://doi.org/10.1109/ACCESS.2022.3181730>>. Acesso em: 3 set. 2024.

TLILI, A.; SHEHATA, B.; ADARKWAH, A.; BOZKURT, A.; HICKEY, T.; HUANG, R.; AGYEMANG, B. What if the devil is my guardian angel: ChatGPT as a case study of using chatbots in education. **Smart Learning Environments**, v. 10, n. 1, 2023. Disponível em: <<https://doi.org/10.1186/s40561-023-00237-x>>. Acesso em: 3 set. 2024.