

Aula 2

Inteligência Artificial

Prof. Luciano Frontino de Medeiros

1

Introdução à ciência de dados

2

Um "tsunami" de dados

- Com a explosão no uso de redes sociais, o comércio eletrônico em rápida expansão e a ascensão da Internet, a web está criando um tsunami de dados estruturados e não estruturados, gerando bilhões em gastos em tecnologia da informação



BeWei / Shutterstock

3

Um novo tipo de negócio


- Evidências recentes indicam um declínio no uso de plataformas de inteligência de negócios padrão, na medida em que as empresas são forçadas a considerar uma massa de dados não estruturados com valor incerto no mundo real (Battiti; Brunato, 2017)



G-Stock Studio / Shutterstock

4

Ciclo de vida do dado



5

Definição de ciência de dados


- Pode-se definir *ciência de dados* como o conjunto de processos e tecnologias que estudam os dados durante todas as fases do seu ciclo de vida



whiteMocca / Shutterstock


6

Framework da ciência de dados



Análise exploratória

- Incumbe-se do estudo inicial de um conjunto de dados, na busca da identificação de categorias nas quais os dados se encaixam e que podem empregar técnicas quantitativas ou ainda visuais



Actor / Shutterstock

Análise explícita

- A informação e o conhecimento estão disponíveis de forma explícita nos dados, sendo necessária alguma operação de baixa complexidade para ressaltar a característica-alvo de análise e produzir a informação



Puchong Art / Shutterstock

Análise implícita

- A informação não está disponível de forma clara, devendo ser produzida com o uso de alguma técnica sofisticada



whiteMocca / Shutterstock

IA e ciência de dados

- A Inteligência Artificial fornece como subsídio para a ciência de dados uma série de tecnologias que tornam possíveis as análises implícitas, intimamente relacionadas com o aprendizado de máquina: classificação, agrupamentos (*clustering*) ou regras de associação


Atividade	Tipos de algoritmos	Algoritmos
Classificação	Bayes	NaiveBayes
	Rules	Party, DecisionTable
	Árvores de decisão	Random Forest J48 ID3
	Redes neurais artificiais	Perceptron Multicamada (MLP) Máquina de Vetores de Suporte (SVM)
Agrupamentos	Por densidade	DBSCAN
	Baseado em Protótipo	K-Means K-Medoids
Regras de associação		Apriori FP Growth

Big Data

13

“Dados grandes”

- O conceito de Big Data está associado a grandes volumes de dados e sua definição envolve um conjunto de três a cinco V: volume, velocidade, variedade, veracidade e valor
- Big Data é o fenômeno em que dados são produzidos a partir de vários formatos e armazenados em uma grande quantidade de diferentes dispositivos ou equipamentos



alphaspirit / Shutterstock

14

Datafication

- Registro de qualquer fenômeno, natural ou não, e sua transformação em dados, que são persistidos para que sejam reproduzidos ou analisados, imediatamente ou no futuro



Lightspring / Shutterstock

15

Tecnologias para Big Data

- Para se beneficiar desses colossais recursos de armazenamento, os gigantes da web tiveram que desenvolver novas tecnologias para suas próprias necessidades, particularmente em termos de paralelismo de processamento, operando em volumes de dados que totalizam várias centenas de terabytes




alphaspirit / Shutterstock

16

Map Reduce

- Map Reduce surgiu no Google para processar os dados recuperados pelos rastreadores de seu mecanismo de pesquisa e indexar toda a web
- Modelo de design que automatiza a paralelização de uma grande classe de tratamentos



BIG DATA

Swill Kilich / Shutterstock


17

Hadoop Apache

- Sistema de processamento paralelo
- Tecnologia transferida para o mundo do código aberto
- Diante dos novos requisitos de escalabilidade e disponibilidade, surgiu uma nova classe de sistema de gerenciamento de banco de dados não relacional
- Esses sistemas são geralmente designados pelo acrônimo NoSQL

18

Evolução dos preços dos recursos de TI



19

Internet das Coisas

20

IoT

- Uma das razões para o aumento crescente de dados disponíveis para o Big Data
- Os dados hoje em dia podem ser gerados por uma série de dispositivos, como mouses, telas *touch screen*, leitores de códigos de barras e QRCode, identificação por radiofrequência, mesas digitalizadoras, dentre outros



metametwork / Shutterstock

21

- Refere-se à integração, por meio dos protocolos da Internet, de todo ou qualquer dispositivo, com o intuito de torná-lo mais inteligente, capaz de coletar e processar informações do ambiente ou das redes às quais está conectado
- A implantação do IoT está revolucionando a forma como as pessoas se relacionam com as coisas ao seu redor, com relação à segurança, energia, ao meio ambiente, trânsito, à mobilidade ou logística



Jamesteehart / Shutterstock

22

Queda dos custos

- Foi um fator determinante para a produção massiva de dados, microcontroladores e componentes eletrônicos mais baratos, influenciando a proliferação dos dispositivos conectados à Internet
- O conceito de IoT não é novo
- Com a popularização da Internet, na década de 1990, foram vislumbradas novas formas de interligar equipamentos de uso diário a ela



Jamesteehart / Shutterstock

23

Conectividade

- As tecnologias de comunicação e redes de computadores se desenvolveram e se popularizaram desde o seu surgimento
- A Internet, por meio da família de protocolos TCP/IP, e as redes Wi-Fi tornaram possível a mobilidade e dispensaram a fixação típica da conectividade de rede
- Aliadas a esse fato, as redes de telefonia celular 2G, 3G e 4G foram fundamentais para aumentar o rol de equipamentos a serem conectados

24

Smartphones

- A designação de smartphones tipifica a diversidade de sensores que são disponibilizados ao longo da sua evolução
- Além de ser telefone, pode incluir acelerômetro, touch screen, GPS, giroscópio e magnetômetro, além dos dispositivos voltados à comunicação: Bluetooth, Wi-Fi, dentre outros



Andrey Suslov / Shutterstock

Tendências do IoT

- A tendência do crescimento do IoT é que a tecnologia irá se disseminar, tornando as casas e os escritórios autônomos, repletos de sensores e efetadores que irão, por sua vez, abrir e fechar toldos ou cortinas, ligar a iluminação e irrigar as plantas e jardins por comandos em smartphones conectados aos dispositivos de IoT




Zapp2Photo / Shutterstock

25

26

Microcontroladores



zozola / Shutterstock

27



Denis Uline / Shutterstock

28

Armazenamento analítico

Modelos de armazenamento

- Como vimos no tema referente ao Big Data, o armazenamento dos dados é um dos componentes principais para a adoção de análises de dados baseadas em ferramentas de aprendizado de máquina



graphic3motion / Shutterstock

29

30

Modelo relacional

Código	Nome	Salário	Quantidade
001	Joãozinho	200.000,00	100000
002	Antônio	250.000,00	100000
003	Luiz Eduardo	210.000,00	100000
004	Roberto Carlos	200.000,00	100000
005	Carlos Silva	300.000,00	100000

Código	Quantidade	Salário	Quantidade
001	100000	40	100000
002	100000	40	100000
003	100000	2	100000
004	100000	2	100000
005	100000	2	100000
006	100000	2	100000
007	100000	2	100000
008	100000	2	100000
009	100000	2	100000
010	100000	2	100000
011	100000	2	100000
012	100000	2	100000
013	100000	2	100000
014	100000	2	100000


```

graph TD
    Produto[Produto] -.-> Fornecedor[Fornecedor]
    Fornecedor -.-> Item[Item]
  
```

21/50

Data Warehouse

The diagram illustrates a Data Warehouse schema. At the center is an oval containing the **Fato** (Fact) table, labeled *Vendas*. This central table is connected by dashed lines to five surrounding dimension tables, each consisting of a **Dimensão** (Dimension) header and a **Medida** (Measure) header. The dimensions are: *Produto* (top), *Região* (bottom-left), *Vendedor* (bottom-right), *Valor* (top-left), and *Lucro* (top-right). Below the oval, there is an additional dimension table for *Quantidade*.

```
graph TD; Fato[Fato: Vendas] -.- Dim1[Dimensão: Produto]; Fato -.- Dim2[Dimensão: Região]; Fato -.- Dim3[Dimensão: Vendedor]; Fato -.- Dim4[Dimensão: Valor]; Fato -.- Dim5[Dimensão: Lucro]; Dim6[Dimensão: Quantidade];
```

Medida
Valor

Dimensão
Produto

Medida
Lucro

Fato
Vendas

Dimensão
Região

Dimensão
Vendedor

Medida
Quantidade

32
50

Componentes de um DW

```
graph LR; DO[Dados Operacionais] --> ET[Extração e Transformação]; DC[Dados de clientes] --> ET; DP[Dados de produção] --> ET; DE[Dados de estoques] --> ET; DX[Dados externos] --> ET; ET --> DW[(DW)]; DW <--> AA{{Acesso e análise de dados}}; DW <--> DI[Diretório de informações]; AA --- CL[Consultas e relatórios]; AA --- OLAP[OLAP]; AA --- DM[Data Mining];
```

O diagrama ilustra a arquitetura de um Data Warehouse (DW). No lado esquerdo, cinco fontes de dados operacionais (Dados Operacionais, Dados de clientes, Dados de produção, Dados de estoques e Dados externos) alimentam um processo centralizado de Extração e Transformação. Este processo, por sua vez, carrega os dados para o núcleo do DW, representado por um cilindro. O núcleo do DW está conectado bidirecionalmente a dois componentes de interface: o Acesso e análise de dados (representado por um hexágono) e o Diretório de informações (representado por um retângulo). O Acesso e análise de dados permite a execução de consultas e relatórios, OLAP (Análise Multidimensional) e Data Mining.

23/25

OLAP

The diagram illustrates the transition from a flat table to a cube structure. At the top, a table with 25 columns (ID, Name, Age, Sex, Height, Weight, Blood Pressure, Heart Rate, Cholesterol, Glucose, Hemoglobin, Hematocrit, Red Blood Cells, White Blood Cells, Platelets, Neutrophils, Lymphocytes, Monocytes, Eosinophils, Basophils, Prothrombin Time, Partial Thromboplastin Time, Fibrinogen, Creatinine, Urea Nitrogen, Sodium, Potassium, Calcium, Magnesium, Phosphorus) is shown. An arrow points from this table to a cube structure below. The cube has three dimensions: 'Age' (ranging from 18 to 80), 'Sex' (Male, Female), and 'Height' (ranging from 150 to 200). The cube is labeled 'OLAP' and 'Cube'.

24
25

MapReduce

```

graph LR
    subgraph Entrada
        E1[Urgente Problema]
        E2[Problema Urgente Problema]
        E3[Ajuda Gostei Legal Retorno]
        E4[Ajuda Legal Retorno]
        E5[Retorno Ajuda Problema]
        E6[Ajuda Legal Retorno]
    end

    subgraph Mapeamento
        M1[Map]
        M2[Map]
        M3[Map]
    end

    subgraph Redução
        R1[Map]
        R2[Map]
        R3[Map]
    end

    subgraph Saída
        S1[Urgente, 2  
Problema, 4  
Gostei, 1  
Legal, 1  
Ajuda, 5  
Retorno, 4]
    end

    E1 --> M1
    E2 --> M1
    E3 --> M2
    E4 --> M2
    E5 --> M3
    E6 --> M3

    M1 --> R1
    M2 --> R2
    M3 --> R2
    M3 --> R3

    R1 --> S1
    R2 --> S1
    R3 --> S1
  
```

Entrada

- Urgente Problema
- Problema Urgente Problema
- Ajuda Gostei Legal Retorno
- Ajuda Legal Retorno
- Retorno Ajuda Problema
- Ajuda Legal Retorno

Mapeamento

- Map: Urgente, 1, Ajuda, 1, Problema, 1, Problema, 1, Urgente, 1, Problema, 1
- Map: Ajuda, 1, Gostei, 1, Legal, 1, Retorno, 1, Ajuda, 1, Legal, 1, Retorno, 1
- Map: Retorno, 1, Ajuda, 2, Problema, 2, Ajuda, 2, Legal, 2, Retorno, 1

Redução

- Map: Urgente, 2, Problema, 4, Gostei, 1, Legal, 1, Ajuda, 5, Retorno, 4
- Map: (receives input from the second and third Map boxes)
- Map: (receives input from the second and third Map boxes)

Saída

- Urgente, 2
- Problema, 4
- Gostei, 1
- Legal, 1
- Ajuda, 5
- Retorno, 4

352

The diagram illustrates the difference in syntax between XML and JSON for representing a person object. On the left, an XML snippet shows a person with attributes like name, email, and address, with nested elements for details like phone and website. On the right, a JSON snippet shows the same data in a key-value format, with nested objects for details like phone and website. The XML version is more verbose, while the JSON version is more compact and readable.

```
<?xml version="1.0" encoding="utf-8" ?>
<person>
  <id>10</id>
  <nome>alexandre</nome>
  <nomecomletras>alexandre gomes alexandre</nomecomletras>
  <telefone>1120451111</telefone>
  <email>alex@br.com</email>
  <caracteristicas>[{"descricao": "descricao 1",
    "url": "http://www.gcp.com.br/primeiro/primeiro-de-
    ur-site.php"}, {"descricao": "descricao 2",
    "url": "http://www.gcp.com.br/segundo/segundo-de-
    ur-site.php"}]</caracteristicas>
  <urlwebsite>http://www.gcp.com.br/primeiro/primeiro-de-
  ur-site.php</urlwebsite>
  <latitude> -23.4466667</latitude>
  <longitude> -46.6361111</longitude>
</person>

{
  "id": 10,
  "nome": "alexandre",
  "nomecomletras": "alexandre gomes alexandre",
  "telefone": "1120451111",
  "email": "alex@br.com",
  "caracteristicas": [
    {
      "descricao": "descricao 1",
      "url": "http://www.gcp.com.br/primeiro/primeiro-de-
      ur-site.php"
    },
    {
      "descricao": "descricao 2",
      "url": "http://www.gcp.com.br/segundo/segundo-de-
      ur-site.php"
    }
  ],
  "urlwebsite": "http://www.gcp.com.br/primeiro/primeiro-de-
  ur-site.php",
  "latitude": -23.4466667,
  "longitude": -46.6361111
}
```

Análise de dados

37

Avanços na área da computação

- A análise de dados visa identificar algum tipo de transformação nos dados em busca de informação ou conhecimento
- Em termos de análise, pode-se aplicar uma gama de técnicas ou ferramentas, dependendo do objetivo de análise em questão



whiteMocca / Shutterstock

38

Análise exploratória

- A análise exploratória é uma primeira abordagem aos dados sobre os quais há pouco ou nenhum conhecimento
- O objetivo é buscar conhecer os dados antes de tentar fazer uma análise deles, utilizando técnicas explícitas ou implícitas. A análise exploratória se utiliza tanto de técnicas quantitativas quanto visuais

39

Técnicas estatísticas

- Técnicas quantitativas podem fazer uso de medidas de tendência central, como média, mediana e moda, e medidas de dispersão, como variância e desvio padrão
- O uso de softwares estatísticos, como o R, é recomendável nessa fase, de maneira a tornar produtiva a análise exploratória

40

Banco de dados de exemplo: Íris

- Esse banco de dados foi coletado nos anos 1930, sendo composto de um conjunto de 150 amostras da planta íris, separadas em três espécies diferentes
- Assim, são 50 amostras de cada espécie (*setosa*, *versicolor* e *virginica*)

41

- Cada amostra se refere a uma planta em que se obteve as medições de quatro atributos distintos: comprimento da sépala, largura da sépala, comprimento da pétala e largura da pétala

42

Sumário de informações quantitativas

Sepal.Length	Sepal.Width	Petal.Length	Petal.Width
Min. :4.300	Min. :2.000	Min. :1.000	Min. :0.100
1st Qu.:5.100	1st Qu.:2.800	1st Qu.:1.600	1st Qu.:0.300
Median :5.800	Median :3.000	Median :4.350	Median :1.300
Mean :5.843	Mean :3.057	Mean :3.758	Mean :1.199
3rd Qu.:6.400	3rd Qu.:3.300	3rd Qu.:5.100	3rd Qu.:1.800
Max. :7.900	Max. :4.400	Max. :6.900	Max. :2.500

43

Diagrama de dispersão

The diagram is a scatter plot titled "Diagrama de dispersão". The vertical axis (y-axis) is labeled "Sepalo" and ranges from 4.5 to 8.0 with increments of 0.5. The horizontal axis (x-axis) is labeled "Comprimento" and ranges from 2.0 to 4.0 with increments of 0.5. The plot area is shaded gray and contains many small black dots representing data points. Above the plot area, the word "Íris" is written in a box. Below the plot area, the word "Comprimento" is written in a box.

44

Boxplot

Iris

Y-axis: 0, 2, 4, 6, 8

X-axis: Sepal.Length, Sepal.Width, Petal.Length, Petal.Width

Variables

45

Histograma

A histogram titled 'Histograma' showing the frequency distribution of 'Comprimento' (Iris petal length). The x-axis is labeled 'Comprimento' and ranges from 4 to 8. The y-axis is labeled 'Frequência' and ranges from 0 to 30. The histogram consists of seven bars with the following approximate frequencies: 4-5: 5, 5-6: 25, 6-7: 28, 7-8: 18, 8-9: 5, 9-10: 5, 10-11: 5.

Comprimento (Intervalo)	Frequência
4 - 5	5
5 - 6	25
6 - 7	28
7 - 8	18
8 - 9	5
9 - 10	5
10 - 11	5

46

[illegible]

47

Análises explícitas

- A diferença com relação à análise exploratória reside mais nos objetivos do que nas técnicas
- A análise explícita busca exemplos mais específicos, como resumir vendas em um mês, verificar notas que faltam, verificar cálculo de imposto a pagar etc.
- Junções ou antijunções, SQL


Joe Techapanurenda / Shutterstock]

-

48

Análises implícitas

- Deseja-se conhecer com profundidade características que existem nos dados e que não são facilmente identificadas pela observação direta
- Aqui entram as diversas técnicas estudadas na IA para a descoberta de padrões existentes nos dados




Lightspring/ Shutterstock

49

- A partir de técnicas de aprendizado de máquina (*machine learning*), pode-se encontrar padrões que estejam ocultos em um conjunto de dados

50



51