

Aula 6

Inteligência Artificial

Prof. Luciano Frontino de Medeiros

1

Redes Neurais Artificiais

2

- O cérebro é um computador altamente complexo, não linear e paralelo
- Possui a capacidade de organizar seus constituintes estruturais, os neurônios, de forma a realizar certos processamentos, tais como reconhecimento de padrões, percepção e controle motor, de forma mais rápida que o mais rápido computador existente (Haykin, 2004, p. 27)




sdecoret/SHUTTERSTOCK

3

Neurônios

- São as unidades fundamentais dos tecidos do sistema nervoso
- Cada neurônio consiste em um corpo celular, também designado como *soma*, o qual contém um núcleo
- Partindo do corpo da célula existem um número de filamentos, denominados *dendritos*, e um filamento mais longo, denominado *axônio*




Fonte: Elaborado pelo autor

4

Propriedades

- Não linearidade
- Mapeamento entrada-saída
- Adaptabilidade
- Resposta a evidências
- Informação contextual
- Tolerância a falhas




sdecoret/SHUTTERSTOCK

5

Arquitetura

- Número de camadas
- Quantidade de neurônios por camada
- Tipo de função de transferência
- Método de treinamento




Evannostro/SHUTTERSTOCK

6

Formas de aprendizado

- Aprendizagem por correção de erros
- Aprendizagem baseada em memória
- Aprendizagem hebbiana
- Aprendizagem competitiva
- Aprendizagem de Boltzmann




Tipos de tarefas

- Associação de padrões
- Reconhecimento de padrões
- Aproximação de funções
- Controle
- Filtragem




O Perceptron

- Dispositivo eletrônico inventado em 1957 por Frank Rosenblatt (1928-1971), psicólogo estadunidense
- Foi construído de acordo com princípios biológicos e mostrava a capacidade de aprendizado




Estrutura

- Unidades sensoriais (S)
- Unidades associativas (A)
- Unidades responsivas (R)



- O *perceptron* obtém os sinais do ambiente por meio das entradas, onde são apresentados os valores correspondentes aos padrões que queremos classificar, como valores de *pixels* de imagem ou características de um produto



- 23/4

$$d = x_1w_1 + x_2w_2 + x_3w_3 + x_4w_4 + x_5w_5 + w_0$$

12
45
$$\frac{26}{45}$$

13/45

- | Panel | N_1 | N_2 |
|-------|-------|-------|
| 1 | 4 cm | 3 mm |
| 2 | 1 cm | 1 mm |
| 3 | 2 cm | 2 mm |
| 4 | 2 cm | 3 mm |
| 5 | 5 cm | 3 mm |
| 6 | 3 cm | 2 mm |
-

Fonte: Elaborado pelo autor.

 $\frac{26}{48}$ 

- 1

1248

W_1	W_2	W_0
0,21	0,22	-1


Fonte: Elaborado pelo autor.

11
45

-
- A scatter plot with 'Diámetro' on the vertical axis and 'Comprimento' on the horizontal axis. There are six data points labeled 1 through 6. Points 1 and 5 are at the top right, point 4 is slightly below them, point 3 is below 4, point 2 is on the left, and point 6 is at the bottom center.
- | Point | Comprimento (approx) | Diámetro (approx) |
|-------|----------------------|-------------------|
| 1 | 8.5 | 9.5 |
| 2 | 1.5 | 4.5 |
| 3 | 3.5 | 7.5 |
| 4 | 4.0 | 9.0 |
| 5 | 9.0 | 9.5 |
| 6 | 4.5 | 3.5 |

Fonte: Elaborado pelo autor.


- Os valores a serem buscados para o aprendizado do *perceptron* permitem a obtenção das classes corretas a partir dos valores dos pesos
- O processo de aprendizagem ou treinamento deverá se encarregar de encontrar esses valores para que a rede classifique corretamente



Aprendizagem do Perceptron

Treinamento do perceptron

- Começa-se o processo de treinamento adotando valores aleatórios para os pesos
- Ao proceder à primeira alimentação de valores à entrada, acontece o erro de classificação após as amostras terem sido apresentadas ao *perceptron*



$$e_i = (o_i - f_i)$$

$$E = \frac{1}{2} \sum_{i=1}^n e_i^2$$

$$\Delta_j = \eta e_i x_j$$

η = taxa de aprendizado;
 Δ_j = delta calculado;
 e_i = erro ou diferença;
 x_j = neurônio de entrada;
 n = número de amostras.

- Durante o treinamento e de forma gradativa, um pequeno percentual desse erro é propagado de volta ao *perceptron*
- Esse percentual é denominado taxa de aprendizagem
- No que se refere aos erros, introduziremos dois conceitos: o erro individual e o erro global

Regra delta


- Os deltas são calculados multiplicando-se o erro de cada amostra pela entrada referente ao delta
- Logo após, é feita uma média dos valores calculados para os deltas
- Após o cálculo, os pesos são atualizados com os valores dos deltas

$$w_j(n+1) = w_j(n) + \Delta_j(n)$$


Passo: n = 1

Simulador de Perceptron Simples											
Parâmetros			η	0.01	Passo	0	Limite	100			
Pesos			w_1	1.000	w_2	1.000	w_0	-1			
No.	x_1	x_2	d	f	ϕ	e	e^2	Δ_1	Δ_2		
1	4	3	6.00	1	1	0.00	0.00	0.00	0.00		
2	1	1	1.00	1	-1	-2.00	4.00	-0.02	-0.02		
3	2	2	3.00	1	-1	-2.00	4.00	-0.04	-0.04		
4	2	3	4.00	1	1	0.00	0.00	0.00	0.00		
5	5	3	7.00	1	1	0.00	0.00	0.00	0.00		
6	3	2	4.00	1	-1	-2.00	4.00	-0.06	-0.06		
Tempo(s)			10	*	Σ / Δ	12	-0.02	-0.02			


Fonte: Elaborado pelo autor.




Fonte: Elaborado pelo autor.




25



26



27




28

Comentários sobre o treinamento


- Nem sempre um *perceptron* consegue classificar corretamente um dado conjunto de amostras
- Para funcionar corretamente, o *perceptron* deve trabalhar com classes que sejam separáveis linearmente
- Os padrões ou amostras pertencentes a uma classe devem estar suficientemente separados da outra classe para uma correta classificação

Fonte: Elaborado pelo autor.


29




30




31




32




33



34



35



36

Deep learning

- Abrange o estudo de uma série de técnicas e algoritmos de RNA, aprofundando conceitos de redes neurais alimentadas à frente (*feed forward*), camadas de entrada, ocultas e de saída, função custo



37

Tipos de redes e algoritmos de treinamento

- Redes convolutivas (convolutional neural networks – CNN)
- Redes neurais recorrentes (*recurrent neural networks* – RNN)
- Descida estocástica de gradiente (*stochastic gradient descent*)



38

Velocidade de processamento


- Uso de *hardware* contendo unidades de processamento gráfico (*graphical processing units* – GPU)
- Computação baseada em GPU como tecnologia central para possibilitar o aprendizado profundo



39

Exemplo: OCR


- RNA com camadas ocultas
- O banco de dados de caracteres escritos à mão *MNIST* contém 60 mil amostras de treinamento e 10 mil amostras de teste (Lecun et al., 1998)
- As imagens dos caracteres estão dispostas em matrizes de *pixels* 28x28



40


Abordagem: *perceptron* multicamada

- Os caracteres do banco de dados *MNIST*, com um tamanho de 28x28, totalizam 784 *pixels*
- Pode-se elaborar um *perceptron* multicamada de 784 entradas e 10 saídas
- Supondo 3 camadas de 784 neurônios e uma camada de saída de 10 neurônios: $784 \times 784 \times 784 \times 10 = 3.778.019.983.360$ pesos!



41


Abordagem: redes convolucionais



42

Redes convolucionais

- As redes convolucionais profundas ou alguma variante próxima são usadas na maioria das redes neurais para reconhecimento de imagens
- Três ideias básicas: campos receptivos locais, pesos compartilhados e camadas de aglutinação



(Nielsen, 2018)

43

Campos receptivos locais

- Na conexão dos *pixels* de entrada a uma camada de neurônios ocultos, não serão conectados todos os *pixels* de entrada a todos os neurônios ocultos
- Em vez disso, fazem-se apenas conexões em pequenas regiões localizadas da imagem de entrada



44


Pesos compartilhados

- É onde acontece o processo de convolução propriamente dito, também denominado *camada convolucional*
- Todos os neurônios da primeira camada oculta irão detectar exatamente o mesmo recurso apenas em locais diferentes na imagem de entrada



45

Camadas de aglutinação (*pooling*)



- As camadas de aglutinação geralmente são usadas imediatamente ao final da rede convolucional
- O que essas camadas fazem é simplificar as informações na saída da camada anterior

46


Perceptron multicamada

- Ao final, a camada de aglutinação servirá de entrada para a rede *perceptron* multicamada
- Os pesos dessa rede poderão ser treinados para o conjunto de caracteres que fizer parte da amostra
- A rede híbrida obtida no exemplo precisará treinar apenas 51.840 pesos



47

48



49