


| MINERAÇÃO DE DADOS

TEMA 1 – O QUE É *DATA MINING*? QUE TIPO DE DADOS MINERAR?

Dado o crescente aumento do volume de dados produzido e armazenado, podemos observar a possibilidade e capacidade de se obter um maior volume de informações valiosas para os gestores. Porém, em muitos casos, o enorme volume gerado inviabiliza tanto a percepção quanto a avaliação ao ultrapassar os limites da capacidade humana de efetuar essas ações.



Crédito: Aleutie/Shutterstock.

A mineração de dados, ou do inglês *data mining*, pode ser entendida como um grupo de técnicas que possibilita a estratificação de conhecimento baseado em grandes volumes de dados. Consiste em uma extração baseada em padrões que simbolizam o conhecimento armazenado de maneira implícita em diferentes bancos de dados, *data warehouses* e até mesmo repositórios informacionais com grandes volumes de dados.

1.1 Entendendo *data mining*

A capacidade atual para gerar dados e coletá-los está em constante aumento de velocidade. O volume gerado está se tornando impossível de ser analisado por um ser humano, sendo necessários recursos de tecnologia para seu processamento. As áreas de estatística, inteligência artificial e banco de dados destacam-se em proporcionar soluções necessárias à análise de dados.

A mineração de dados, somada à área de gestão e descoberta do conhecimento em bases de dados, se destaca na formação de uma nova área importante e promissora. A junção dessas áreas diz respeito à quantidade elevada de dados na atualidade e também à carência das organizações na transformação desse volume de dados em informação útil.

1.2 Tipologia dos dados a minerar

São inúmeros os tipos de dados que encontramos atualmente, tanto por sua aplicação compartilhada em diversas áreas quanto aqueles específicos de algumas áreas. Diferentes dados científicos – médicos, financeiros, demográficos ou mesmo dados gerados a partir de sensores provenientes da internet das coisas (IoT), por exemplo – são gerados quase que constantemente.

Assim, o volume de dados disponível vem aumentando exponencialmente. A grande dificuldade encontrada na análise desses dados, no entanto, está na utilização de ferramentas de uso tradicional para gerenciá-los. Ao gerarmos um modelo ou uma estrutura de mineração de dados, precisamos definir os tipos de dados para cada uma das colunas em uma estrutura de mineração.

Os tipos de dados comunicam ao instrumento de análise quando um dado é do tipo numérico ou textual, por exemplo. Assim, podemos averiguar diretamente na fonte de dados a forma como os dados numéricos serão tratados, se inteiros ou com casas decimais.

Outra classificação para definir os tipos de dados diz respeito à sua estruturação. Nessa linha, podemos encontrar dados estruturados e não estruturados.

1.2.1 Dados estruturados

Dados estruturados são dados formatados, com a devida organização em diferentes tabelas com linhas e colunas. Esses dados possuem maior facilidade em seu processamento pela ordem em que se apresentam. Usualmente são utilizados sistemas de gerenciamento de banco de dados (SGBD) com a finalidade de armazenar os dados. Aplicações empresariais como ERP (Enterprise Resource Planning) ou sistema integrado de gestão empresarial fazem uso desse tipo de dado.

1.2.2 Dados não estruturados

Dados não estruturados não possuem formatação específica, o que dificulta sua capacidade de processamento. Similarmente aos dados estruturados, os não estruturados requerem processamento e análise para serem apresentados como informação. São encontrados em imagens, mensagens de e-mail, documentos de textos, planilhas e mensagens postadas em redes sociais.

1.2.3 Dados armazenados pelo formato

Os dados armazenados requerem diferentes tipos de técnicas de extração baseadas em seu formato. Esse formato ou tipo de dado pode ser caracterizado em textual ou literal, numérico, booleano ou de lógica booleana (verdadeiro ou falso) ou data (período temporal).

- Textuais ou literais: esses dados são constituídos em uma sequência de caracteres com letras, dígitos e símbolos especiais em seu conteúdo. Usualmente, também são conhecidos como dados alfanuméricos ou cadeia de caracteres, e no inglês são chamados de *string*. O tamanho desse tipo de dado é determinado por sua quantidade de caracteres. Em geral, são encontrados em uma chamada de algoritmo por uma coleção de caracteres delimitada tanto no início como no final pelo caractere aspas (“);
- Numéricos: são basicamente subdivididos em inteiros e reais. Os dados numéricos inteiros não apresentam nenhum componente decimal ou fracionário, sendo positivos ou negativos. Já os dados numéricos reais têm capacidade de armazenar decimais e fracionários, além da capacidade de serem negativos ou positivos;
- Booleanos: são utilizados para representar apenas dois valores possíveis, sendo ou verdadeiro ou falso. Os valores possíveis são: 0 ou 1; sim ou não; verdadeiro ou falso; 0 ou 1;
- Data: o propósito desse tipo de dado está na capacidade de proporcionar uma série de cálculos e operações de ordem cronológica, por exemplo a quantidade de dias entre duas datas, somar ou subtrair períodos contendo dias, meses ou anos.

TEMA 2 – FASES DO PROCESSO DE DESCOBERTA DE CONHECIMENTO EM BANCO DE DADOS

O volume de dados estruturados e não estruturados em larga escala encontrado hoje fornece por meio de um processo de análise informações úteis a serem utilizadas pelas organizações. Estas, por sua vez, passam a evoluir frente ao desenvolvimento tecnológico. Como exemplos dessas empresas utilizadoras da tecnologia da mineração de dados, destacam-se:

- a) Bancos: beneficiam-se de informações que venham a identificar padrões auxiliando no processo de gerenciamento das relações com o mercado e clientes;
- b) Cobrança: pode extrair como benefício as ações de agilização e detecção de fraudes financeiras, evitando desgastes e prejuízos;
- c) Medicina: utiliza a indicação de resultados em diagnósticos com precisão, proporcionando ampla análise de dados com cruzamento de informações que venham a ampliar a qualidade da área como um todo no que diz respeito às suas funções;
- d) Recursos humanos: o destaque pode estar na capacidade de identificar as competências de indivíduos baseadas em currículos;
- e) Comércio de varejo: uma das maiores vantagens é ampliar a potencialidade de aprimorar a disposição de seus produtos em gôndolas e prateleiras observando padrões de consumo de seus clientes.

Para tornar possível a melhoria proporcionada pela análise de dados nessas áreas, alguns aspectos relevantes à tecnologia de mineração de dados precisam ser considerados, como as questões de descoberta de conhecimento em bases de dados, a exemplo do uso do *Knowledge Discovery in Database* (KDD), com suas etapas e modelo funcional.

2.1 Apoio à tomada de decisões

A experiência profissional possibilita um efetivo processo de gestão do conhecimento, o qual demanda elevada quantidade de decisões em relação às atividades presentes em uma organização. Isso impacta diretamente na cadeia produtiva de uma organização de maneira geral.

O volume de dados a serem geridos vem se tornando numeroso e dificultoso quanto à sua organização, extração e análise. Com o objetivo de auxiliar o processo de gestão, inúmeras ferramentas computacionais têm sido criadas para efetuar a estratificação e o armazenamento de dados. Essas

ferramentas atuam principalmente no processo de análise de dados de maneira a gerar informações que gerem conhecimento. O processo de gerar o conhecimento ocorre pela mineração de dados, tornando-se vital no apoio à tomada de decisão.

A informação é um dos ativos mais importantes para os negócios das organizações, além de ser um diferencial na competitividade. As estratégias que assumem estão baseadas em informações factíveis, minimizando erros que possam ser cometidos por gestores na tomada de decisão. A evolução tecnológica possibilitou a criação de processos como o Knowledge Discovery in Database (KDD), que possibilita a descoberta de conhecimento em banco de dados.

2.2 Métodos de *data mining*

Existem vários métodos de *data mining* para descobrir respostas ou extrair conhecimento de diferentes e numerosos repositórios de dados. Entre eles podemos citar o KDD, de classificação; modelos de relacionamento entre variáveis, *cluster* ou agrupamento, sumarização, dependência e associação.

2.2.1 Classificação

A classificação utiliza uma técnica estatística denominada análise discriminante, buscando o envolvimento de uma descrição gráfica ou algébrica das características de diferenciação das diversas populações – dessa forma classificando as observações em diferentes classes predefinidas.

2.2.2 Relacionamento entre variáveis

Esse tipo de modelo efetua uma associação entre um ou mais itens às variáveis de predição de valores reais. As variáveis utilizadas podem ser independentes ou exploratórias. As técnicas utilizadas para esse fim são de regressão linear simples, múltipla e modelos lineares atuantes por transformação.

2.2.3 Cluster ou agrupamento

Esse modelo opera por associação de um item a uma ou mais classes categorizadas, que se chamam *clusters*. Essas classes são classificadas pelos tipos de dados contidos independentemente de uma pré-classificação.

A definição dos *clusters* se estabelece mediante a formação de grupos de dados fundamentados em medidas de similaridade ou em modelos probabilísticos. O objetivo é detectar a existência de grupos diferenciados inseridos em um conjunto de dados.

2.2.4 Sumarização

A utilização do modelo de sumarização está essencialmente nas medidas de posição e variabilidade. Por sumarização é estabelecida uma descrição com dispersão reduzida em determinado subconjunto de dados.

2.2.5 Dependência

Como o próprio nome sugere, neste modelo é descrita a dependência entre as variáveis. Esses modelos são classificados em dois tipos: quantitativo ou estruturado, sendo que o primeiro define o grau de interdependência utilizando uma escala numérica, enquanto o segundo, estruturado, apresenta em forma de gráfico as variáveis localmente dependentes.

2.2.6 Regras de associação

Esse modelo opera pela forma como ocorrem as relações entre diferentes campos de um banco de dados, portanto associando valores correlatos que venham a se tornar significantes.

TEMA 3 – PROCESSO KDD E SUAS ETAPAS

O termo *Knowledge Discovery in Database* (KDD), apesar de ser considerado por diversos autores como um sinônimo de *data mining*, tem distinção clara em sua forma de operação. Enquanto a mineração de dados está no processo de busca pelo conhecimento em dados, enfatizando uma aplicação de grande porte, o KDD se apresenta como um processo de descoberta do conhecimento útil dos dados. Nessa linha, a mineração de dados aponta para a aplicação de algoritmos que extraem modelos de dados.

Como ambos os conceitos se distinguem, o KDD faz surgir uma nova demanda por ferramentas e técnicas de análise de dados. Essa demanda contempla uma série de etapas que representam melhor sua aplicação. Nelas podemos entender melhor a forma de extração de conhecimento de dados e entender como os elementos de dados e padrões se relacionam. Dessa maneira, a mineração de dados pressupõe as fases do descobrimento do processo de KDD, que visa descobrir o conhecimento em banco de dados, sendo esse processo dividido em etapas.

3.1 Etapa de seleção

A etapa de seleção é fundamental para o sucesso do processo pois nela deverão ser selecionados quais os conjuntos de dados são de fato relevantes para que sejam obtidos os resultados baseados em informações úteis.

3.2 Etapa de pré-processamento

Nessa etapa ocorre a limpeza dos dados além da seleção de atributos. É efetuada uma correção de dados de forma que informações ausentes, inconsistentes ou que possuam erros sejam corrigidas, de maneira que não venham a comprometer a qualidade dos modelos de conhecimento que serão extraídos ao final do processo de KDD.

3.3. Etapa de transformação

É também conhecida como etapa de formatação, na qual os dados obtidos na etapa de pré-processamento são analisados. Aqui os dados são reorganizados de forma que possam se tornar interpretáveis pela etapa de mineração.

3.4. Etapa de mineração

Nessa etapa ocorrem as ações que resultaram na efetiva atividade do KDD. Depois da transformação dos dados, eles precisam ser lidos e interpretados. Aqui, os dados serão convertidos em informações de fato, sendo indicadas por força bruta em um procedimento de leitura individual de regras com interpretação em cada uma.

3.5. Etapa de interpretação

A última etapa do processo KDD refere-se à interpretação da informação com atividade de avaliação. Uma vez que os dados tenham sido interpretados poderão ser encontrados novos padrões, além de novos relacionamentos e descobertas de fatos antes não encontrados. Essas novas informações poderão ser utilizadas em novas pesquisas ou otimização da atual.

TEMA 4 – mineração de regras de associação

Entre as tarefas a serem executadas no processo de mineração de dados está a busca por tendências que possam ser utilizadas para o entendimento e exploração de padrões de comportamento de dados.

Em *data mining* temos atividades **preditivas** e **descritivas**. A atividade descritiva possui três fases: regras de associação, *clustering* e sumarização. A atividade preditiva contém duas fases: classificação e regressão.

4.1 Situação prática

De forma a exemplificar a associação de dados dentro do processo de mineração de dados, vamos aplicá-la em uma situação prática. Para melhor entendimento, precisamos ter em mente o conceito de *itemset*, um conjunto de atributos ou itens ordenados lexicograficamente. Como exemplos, temos: {a,b,c,d}; {9,10,11,12}; {Ana, Clara, Maria, Zélia}.

O cenário que utilizaremos será o de uma rede de lojas que possui como regra o fato de que 70% dos clientes que comprem o produto X adquirem no mesmo momento o produto Z. Nessa situação, o fator de confiabilidade da regra se encontra em 70%.

Precisamos definir de maneira clara o nosso problema, que é, neste caso, analisar um enorme volume de conhecimento extraído em um formato de regras.

4.2 Funcionamento da associação

Para entendermos o funcionamento da associação, vamos utilizar uma definição exemplo. Assim, adotamos uma base de dados BD com um conjunto de itens $CJ = \{it1, it2, it3...itz\}$ ordenados lexicograficamente e também um conjunto de transações $T = \{t1, t2, t3...tz\}$, em que cada uma das transações tn é composta por um conjunto de itens de forma que tn está contido em CJ .

Assim, podemos ter um conjunto de itens:

$CJ = \{\text{produto1}, \text{produto2}, \text{produto3}, \text{produto4}\}$

Conjunto de transações:

t1: produto1, produto2

t2: produto1, produto2, produto3, produto4

t3: produto2, produto4

4.2.1 Entendimento conceitual

Os *itemsets* frequentes correspondem àqueles que possuem maior suporte do que o suporte mínimo especificado pelo usuário. Para uma associação, deve-se utilizar esses *itemsets* frequentes, criando, assim, as regras de associação com confiança mínima superior à que o usuário especificou inicialmente.

TEMA 5 – ANÁLISE ESTATÍSTICA DE DADOS

O procedimento de análise estatística de dados é, além de necessário, importante para a validação desses dados. Além disso, a análise possibilita extrapolar os resultados obtidos para a população estudada.

Diversos aspectos são relevantes dentro de uma análise estatística, mas destaca-se como ponto-chave a escolha do teste estatístico. Essa escolha exige do usuário alguns conhecimentos necessários para o entendimento e execução do processo como um todo:

- a) Classificação do tipo de dado para estudo, podendo ser ordinal ou nominal, categórico ou contínuo;
- b) Conhecimento sobre os tipos de amostras a serem examinadas, se dependentes ou independentes;
- c) A maneira em que os dados estarão dispostos ao final de sua coleta, se com distribuição normal ou anormal.

Dessa forma, é importante que o usuário conheça bem esses aspectos para que a análise estatística dos dados ocorra da maneira correta.

5.1 Tipologia de dados

Existem duas classificações básicas para os dados: qualitativos ou quantitativos. Os dados quantitativos são apresentados normalmente de maneira

contínua em formato escalar. Como exemplo temos os números que podem ser fracionados, como o diâmetro de um objeto ou sua inclinação.

Após efetuar a coleta de dados, pode-se identificar uma curva de tendência ou medida de tendência central, além de um indicador para a variação dos dados. Os dados em formato numérico em geral utilizam essa medida de tendência central para o posicionamento de uma média, sendo a variação ou a variabilidade definida como um desvio padrão, que normalmente é atribuído a variáveis do tipo paramétrica ou contínua.

Para uma variável do tipo qualitativa para dados, é atribuído um número limitado de valores ou de categorias. Esses valores podem ser classificados de modo ordinal ou nominal. Para uma classificação ordinal, a escala deverá ser determinada sempre de forma crescente entre as diversas categorias. Podemos citar como exemplo desse tipo de classificação um índice qualquer que possua uma escala ordinal de 0 a 4.

5.2 Distribuição dos dados

No que se refere à distribuição dos dados, ela é efetuada de duas formas: normal ou anormal. Uma distribuição normal também é conhecida como distribuição gaussiana, apresentando um formato similar a uma curva em forma de sino ao encontrarmos os dados contínuos dispostos em uma curva de distribuição. Pode ser verificado, nesse caso, que os dados estão concentrados próximos a uma média, dispersando-se simetricamente, tendo como centro a curva da média.

Os outros casos, ou seja, em que a curva não apresenta o formato de sino, são denominados assimétricos ou de forma anormal, podendo ainda serem chamados de dados de livre distribuição. Os testes efetuados para esses tipos de dados possuem a denominação de dados estatísticos não paramétricos.

A utilização de dados paramétricos possibilita melhor detecção de diferença real entre as amostras, destacando-as como estatisticamente significativas. Contudo, quando não ocorre uma distribuição normal, o teste paramétrico não é considerado confiável quanto à execução de uma análise estatística.

REFERÊNCIAS

AMARAL, F. **Introdução à ciência de dados: mineração de dados e big data**. São Paulo: Alta Books, 2016.

ARAUJO, G. et al. Exploração do paralelismo em algoritmos de mineração de dados com Pthreads, OpenMP, FastFlow, TBB e Phoenix++. In: **Anais da XVII Escola Regional de Alto Desempenho do Estado do Rio Grande do Sul**, SBC, 2017.

BECKER, K.; TUMITAN, D. Introdução à mineração de opiniões: Conceitos, aplicações e desafios. **Simpósio brasileiro de banco de dados**, v. 75, 2013.

BRAGA, L. P. V. B. **Introdução à mineração de dados**: edição ampliada e revisada. Editora E-papers, 2005.

CALIL, L. A. de A. et al. **Mineração de dados e pós-processamento em padrões descobertos**. Ponta Grossa: UEPG, 2008.

DANTAS, E. R. G. et al. O uso da descoberta de conhecimento em base de dados para apoiar a tomada de decisões. **V Simpósio de Excelência em Gestão e Tecnologia**, p. 1-10, 2008.

DOS SANTOS, B. S. et al. Data Mining: Uma abordagem teórica e suas aplicações. **Revista ESPACIOS**, 37(5), 2016.

GOLDSCHMIDT, R.; PASSOS, E. **Data mining**: um guia prático. Gulf Professional Publishing, 2005.

GRINSTEIN, U. M. F. G. G.; WIERSE, A. **Information visualization in data mining and knowledge discovery**. Burlington: Morgan Kaufmann, 2002.

HAND, D. J. Data Mining. **Encyclopedia of Environmetrics**, v. 2, 2006.

HANG, J.; KAMBER, M. **Data mining**: concepts and techniques. 2006.

SANTOS, M. F.; AZEVEDO, C. S. **Data mining**: descoberta de conhecimento em bases de dados". Lisboa: FCA, 2005.

STEINER, M. T. A. et al. Abordagem de um problema médico por meio do processo de KDD com ênfase à análise exploratória dos dados. **Gest Prod**, v. 13, n. 2, p. 325-37, 2006.

WITTEN, I. H.; FRANK, E.; HALL, M. A. **Practical machine learning tools and techniques**. Burlington: Morgan Kaufmann, 2005.
