

Aula 1

Mineração de Dados

Prof. Roberson Cesar Alves de Araújo

1

O que é *Data Mining*? Que Tipo de Dados Minerar?

2

Volume de dados

- Aumento crescente do volume de dados



- Produção
- Armazenamento
- Capacidade de obtenção de informação



3

Data mining

- "Grupo de técnicas que possibilitam uma estratificação de conhecimento com base em grandes volumes"
- Extração baseada em padrões
 - Diferentes bases de dados
 - *Data warehouses*
 - Repositórios informacionais de grande volume

4

Entendendo *data mining*

- Características
- Aumento da velocidade na geração e coleta de dados
 - Dificuldade na análise para um ser humano
 - Necessidade de uso de recursos de tecnologia

5

- Áreas que compõem a mineração de dados
 - Estatística
 - Inteligência artificial
 - Banco de dados

6

Tipologia dos dados a minerar

- ▀ Diferentes dados
 - Médicos
 - Financeiros
 - Demográficos
 - Baseados em sensores e câmeras
 - IoT

7

Análise de dados

- ▀ Modelo para análise
 - Consideração do tipo de dado pelo formato
 - ✓ Variáveis textuais
 - ✓ Variáveis lógicas
 - ✓ Variáveis data
 - ✓ Variáveis numéricas
 - Inteiro
 - Com casas decimais

8

Tipologia dos dados a minerar

- ▀ Tipos de dados quanto à origem
 - Dados estruturados
 - ✓ SGBD
 - ✓ ERP

9

- Dados não estruturados
 - ✓ Imagens
 - ✓ Documentos de e-mail
 - ✓ Documentos de texto
 - ✓ Planilhas
 - ✓ Mensagens em redes sociais

10

Fases do Processo de Descoberta de Conhecimento em Banco de Dados

11

Volume de dados e recursos tecnológicos

- ▀ Análise de dados
- ▀ Dados estruturados e não estruturados
- ▀ Evolução tecnológica
- ▀ Vantagens em diversas áreas



Monster Zstudio/SHUTTERSTOCK

12

Principais áreas beneficiadas com mineração de dados

- Destaque por área de atividade
- Bancos
 - Pode se beneficiar de informações que venham a efetuar a identificação de padrões que auxiliem no processo de gerenciamento das relações com mercado e clientes



3iCasas/SHUTTERSTOCK

13

- Destaque por área de atividade
- Cobrança
 - A área de cobrança pode extrair como benefício as ações de agilização e detecção de fraudes financeiras, evitando desgastes e prejuízos



Viktoria Kurpas/shutterstock

14

- Destaque por área de atividade
- Medicina
 - Essa área tem como um grande resultado vantajoso a indicação de resultados em diagnósticos com precisão, proporcionando uma ampla análise de dados com cruzamento de informações que venham a ampliar a qualidade da área como um todo no que diz respeito às suas funções



Sergey Nivens/shutterstock

15

- Destaque por área de atividade
- Recursos Humanos
 - Quanto ao processo de recrutamento de pessoal, o destaque pode estar na capacidade de identificar as competências de indivíduos com base em currículos



Alexander Supertramp/SHUTTERSTOCK

16

- Destaque por área de atividade
- Comércio de varejo
 - Uma das maiores vantagens para esta área se encontra na ampliação da potencialidade de organizações aprimorarem a disposição de seus produtos em gôndolas e prateleiras, observando padrões de consumo de seus clientes



suppansorn/SHUTTERSTOCK

17

Apoio à tomada de decisão

- A informação é hoje um dos mais importantes ativos para os negócios das organizações, destacando-se como um diferencial na competitividade
- As estratégias que elas assumem para isso estão baseadas em informações factíveis, minimizando erros que possam ser cometidos por gestores na tomada de decisão

18

Métodos de *data mining*

- Métodos de *data mining* para descobrir respostas ou extrair conhecimento em diferentes e numerosos repositórios de dados

19

- Classificação
 - Utiliza uma técnica estatística denominada *análise discriminante*, buscando o envolvimento de uma descrição gráfica ou algébrica das características de diferenciação das diversas populações
- As observações são classificadas em diferentes classes predefinidas

20

- Relacionamento entre variáveis
 - Efetua uma associação entre um ou mais itens a variáveis de predição de valores reais
 - As variáveis utilizadas podem ser tanto independentes como exploratórias
- As técnicas utilizadas para esse fim são de regressão linear simples, múltipla e modelos lineares atuantes por transformação

21

- *Cluster* ou agrupamento
 - Associa um item a uma ou mais classes categorizadas, a qual denomina-se *cluster*
 - Essas classes são classificadas pelos tipos de dados contidos independente de uma pré-classificação

22

- A definição dos *clusters* se estabelece mediante a formação de grupos de dados fundamentados em medidas de similaridade ou em modelos probabilísticos
- O objetivo está na detecção da existência de diferenciados grupos inseridos em um conjunto de dados

23

- Sumarização
 - A utilização de modelo de sumarização está essencialmente nas medidas de posição e variabilidade
- Por sumarização é estabelecida uma descrição com uma dispersão reduzida em um determinado subconjunto de dados

24

- **Dependência**
 - Descreve a dependência entre as variáveis
 - Esses modelos ou métodos são basicamente classificados em dois tipos
 - ✓ Quantitativo – define o grau de interdependência utilizando uma escala numérica
 - ✓ Estruturado – Apresenta em forma de gráfico as variáveis que são localmente dependentes

25

- **Associação:** esse modelo opera pela forma em que ocorrem as relações entre diferentes campos de um banco de dados, associando valores correlatos que venham a se tornar significantes

26

Processo KDD e suas Etapas

27

KDD (*Knowledge Discovery in Database*) versus *Data mining*

- Mineração de dados está no processo de busca pelo conhecimento em dados, enfatizando uma aplicação de grande porte
- KDD se apresenta como um processo de descoberta do conhecimento útil dos dados

28

- Como ambos os conceitos se distinguem, o KDD faz surgir uma nova demanda por ferramentas e técnicas de análise de dados
- Divisão por etapas



Song_about_summer/SHUTTERSTOCK

29

KDD (*Knowledge Discovery in Database*) Etapa de seleção

- Fundamental para o sucesso de todo o processo, pois nela deverão ser selecionados quais os conjuntos de dados são de fato relevantes para que sejam obtidos os resultados com base em informações úteis

30

KDD (*Knowledge Discovery in Database*) Etapa de Pré-processamento

- Limpeza dos dados além da seleção de atributos
- É efetuada uma correção de dados de forma que informações ausentes, inconsistentes ou que possuam erros sejam corrigidas, de maneira que não venham a comprometer a qualidade dos modelos de conhecimento que serão extraídos ao final do processo de KDD

31

KDD (*Knowledge Discovery in Database*) Etapa de Transformação

- Também chamada de *etapa de formatação*
- Os dados obtidos na etapa de pré-processamento são analisados
- São reorganizados de uma forma específica de modo que possam se tornar interpretáveis pela etapa de mineração

32

KDD (*Knowledge Discovery in Database*) Etapa de Mineração

- Ocorrem as ações que resultaram na efetiva atividade do KDD
- Os dados serão convertidos em informações de fato, sendo elas indicadas por força bruta
 - Procedimento de leitura individual de regras com interpretação em cada uma

33

Mineração de Regras de Associação em Grandes Volumes de Dados

34

Padrões e tendências

- Entre as tarefas a serem executadas no processo de mineração de dados está a busca por tendências que possam ser utilizadas para o entendimento e a exploração de padrões de comportamento de dados



VICW/SHUTTERSTOCK

35

Atividades em *data mining*

- Dividido em dois tipos de atividades
 - Preditiva – classificação e regressão
 - Descritiva – regras de associação, *clustering* e sumarização



36

Associação

Banco de dados

- Conjunto de itens (CJ) = $\{it1, it2, \dots, itz\}$
- Conjunto de transações (CT) = $\{t1, t2, \dots, tz\}$
 - CJ = {produto1, produto2, produto3, produto4}
 - CT = {t1, t2, t3}



VicW/SHUTTERSTOCK

37

Sendo

- t1 = {produto1, produto2}
- t2 = {produto1, produto2, produto3, produto4}
- t3 = {produto2, produto4}

38

Análise Estatística dos Dados

39

Procedimento de análise de dados

- A análise possibilita extrapolar os resultados obtidos para a população estudada
- Fator importante
 - Escolha do teste estatístico



Puntao/SHUTTERSTOCK

40

Escolha de teste estatístico para análise de dados

- Para que a análise seja correta, é necessário
 - Classificação do tipo de dado para estudo, podendo ser ordinal ou nominal, categórico ou contínuo
 - Conhecimento sobre os tipos de amostra a serem examinadas, se dependentes ou independentes
 - A maneira em que os dados estarão dispostos ao final de sua coleta, se distribuição normal ou anormal

41

Classificação Tipologia de dados para análise

- 2 classificações básicas
 - Quantitativo
 - Apresentados normalmente de uma maneira contínua em formato escalar
 - A exemplo disso temos os números que podem ser fracionados como o diâmetro de um objeto ou sua inclinação (medida de tendência)

42

- **Qualitativo**
 - ✓ É atribuído um número limitado de valores ou de categorias
 - Esses valores podem ter sua classificação como sendo de modo ordinal ou nominal
 - ✓ Para uma classificação ordinal, a escala deverá ser determinada sempre de forma crescente entre as diversas categorias
 - ✓ Como exemplo
 - Índice qualquer que possua uma escala ordinal de 0 a 4

43

Classificação Tipologia de dados para análise Quantitativo *versus* qualitativo



Alhovik/SHUTTERSTOCK



Artur Szczybylo/SHUTTERSTOCK

44

Distribuição dos dados

- Efetuada de duas formas
 - Distribuição normal – formato similar a uma curva em forma de sino ao encontrarmos os dados contínuos dispostos em uma curva de distribuição

(...)

Iamnee/SHUTTERSTOCK

45

(...)

- ✓ Pode ser verificado nesse caso que os dados estão concentrados próximos a uma média, dispersando-se simetricamente, tendo como centro a curva da média

46

Distribuição dos dados

- Distribuição anormal – curva não apresenta o formato de sino, dados denominados assimétricos, podendo ainda serem chamados de *dados de livre distribuição*
 - ✓ Os testes que são efetuados para estes tipos de dados possuem a denominação de *dados estatísticos não paramétricos*

Iamnee/SHUTTERSTOCK

47

- A utilização de dados paramétricos possibilita a melhor detecção de diferença real entre as amostras, destacando-as como estatisticamente significativas
- Quando não ocorre uma distribuição normal, o teste paramétrico não é considerado confiável quanto à execução de uma análise estatística

Iamnee/SHUTTERSTOCK

48

