

| MINERAÇÃO DE DADOS

TEMA 1 – ABORDAGEM SIMBÓLICA

O desenvolvimento tecnológico está inserido nas transformações mais profundas da sociedade atual. Dentre seus elementos, os que mais se destacam são o processo de comunicação e o de troca de informações. O uso de diferentes dispositivos eletrônicos vem transformando a capacidade de interação e relações entre as pessoas. As redes de computadores estão se tornando mais interativas e criam novas formas e novos canais de comunicação, redesenhando a forma de vida das pessoas.

Nesse “universo” informacional, novas áreas de pesquisa vêm surgindo, com sua atenção voltada à criação e desenvolvimento de diferentes métodos para explorar os conjuntos de dados coletados. Para isso, existem diferentes tipos de algoritmos classificadores.

A denominação de *classificadores* é dada aos algoritmos com aplicação em atividades de classificação automática de dados com capacidade de gerar informações para auxílio na tomada de decisão. Assim, eles utilizam informações pretéritas em diversas áreas, focando no objetivo a ser atingido.

1.1 Análise simbólica

Frente a uma inadequação da análise estatística por não considerar a variabilidade e incerteza inerente dos novos formatos de dados, a análise simbólica surge como opção a um resultado mais assertivo. A utilização de dados simbólicos pode se dar pela extração direta ou por agregação de dados clássicos.

Para o uso de agregação de dados, duas formas diferentes podem ser utilizadas.

1.1.1 Agregação temporal de dados

Partindo da mesma origem ou entidade, os dados são extraídos ao longo do tempo. Para isso, todos os conjuntos de valores ou as respectivas distribuições devem ser considerados linearmente para as agregações. Para o tipo de dado oriundo da agregação temporal, devem permanecer inalteradas as unidades estatísticas, ou seja, invariantes para antes e depois da análise.

1.1.2 Agregação contemporânea

Nesse formato de agregação, são recolhidos os dados em um único momento definido. As entidades estatísticas são analisadas em um nível mais aprofundado em comparação ao ponto original de extração dos dados. De forma diferente à agregação temporal, nesse formato de agregação as informações não são mais as mesmas antes e depois da agregação. Assim, após a agregação, as unidades estatísticas são transformadas em grupos específicos das unidades originalmente utilizadas por extração.

1.2 Função da abordagem simbólica

Devido ao crescente aumento do volume de informações que vivenciamos diariamente, a extração de dados vem destacando a importância de se buscar dados relevantes. Dessa maneira, o uso de dados simbólicos, ou seja, dados mais complexos, se apresenta como uma nova forma de tratar o que se busca.

As variáveis inseridas nesse novo tipo de dado podem ser determinadas por um conjunto finito de valores ou categorias; e ainda de intervalos e distribuições probabilísticas e de frequência. Assim, a abordagem simbólica de dados ou a análise tem a necessidade do uso de técnicas estatísticas apropriadas à função desse novo formato de dados.

1.3 Dados composicionais

No ambiente em que surgem os classificadores, encontramos também dados composicionais. Esses dados são vetores em que os componentes que não são negativos representam proporções ou percentagens relativas ao todo, destacando sua soma a um valor sempre constante.

1.3.1 Generalização

Nos diferentes problemas de análise de dados encontramos cada variável relacionada com as outras, sendo apresentadas como partes de um todo. Encontramos nesse problema duas propriedades fundamentais:

- a) para cada variável é utilizado um valor não negativo;
 - b) quando somados os valores das variáveis de um indivíduo, o valor é sempre constante.
-

Dessa maneira, todos os indivíduos terão uma composição individual que os descreve individualmente. Os dados que se originam dessa forma são denominados *dados composicionais*.

TEMA 2 – TIPOS DE CLASSIFICADORES

A classificação é uma das tarefas da mineração de dados. Encontramos na classificação um dos pontos mais importantes para a análise de dados. O agrupamento de dados executado na classificação é vital para o resultado da análise, a qual vem sendo aplicada em diversos campos de investigação, como nas ciências sociais, economia, medicina, engenharia e *data mining*.

O processo de classificação permite gerar uma descrição, ou mesmo um modelo para cada classe, originário de um conjunto de dados de exemplo. É evidenciada a existência de dois tipos de classificação, a supervisionada e a não supervisionada.

2.1 Classificação supervisionada

É também conhecida como análise discriminante. Apresenta um conjunto de indivíduos previamente classificados, objetivando encontrar uma regra que possibilite efetuar a classificação de um novo indivíduo.

2.2 Classificação não-supervisionada

Nesse formato de classificação, são agrupados diferentes elementos que possuem características comuns, por classes. Esse tipo de agrupamento é composto por cinco etapas.

2.2.1 Etapa de representação de objeto

Nesta etapa são identificadas as características de maior relevância encontradas nas características originais.

2.2.2 Etapa de seleção de medida de similaridade

É fundamentalmente uma etapa que visa destacar um conjunto de medidas de similaridade para os dados simbólicos e composicionais.

2.2.3 Etapa de agrupamento de dados

Existem diferentes modos de se realizar o agrupamento de dados, podendo resultar na obtenção de uma partição rígida. Dessa maneira, cada elemento é alocado em uma única classe, e cada um tem um grau de similaridade à classe.

Os algoritmos utilizados para esse fim são classificados como de agrupamento hierárquico. Seu funcionamento baseia-se na construção de um conjunto de partições encaixadas com origem na fusão ou divisão de grupos baseando-se na similaridade existente entre eles.

2.2.4 Etapa de abstração dos dados

É baseada na extração de uma descrição básica para cada grupo. Em geral, esses grupos são representados por modelos.

2.2.5 Etapa de validação

A etapa de validação ocorre de três formas diferentes:

- a) externa: a saída do algoritmo é comparada com uma partição previamente conhecida;
- b) interna: visa determinar de maneira intrínseca se a estrutura está apropriada aos dados;
- c) testes relativos: efetuam a comparação de duas estruturas, avaliando e medindo sua relatividade.

TEMA 3 – CRITÉRIOS DE AVALIAÇÃO

O processo de utilização de um algoritmo para *data mining* resulta em um modelo. Não é incomum a utilização de mais de um algoritmo sobre os mesmos dados, em que cada um produz seu respectivo modelo. O que se espera é encontrar o modelo que gere os melhores resultados, sejam eles derivados de um ou mais algoritmos, priorizando sua efetividade. Para medir essa efetividade, precisamos de métodos para avaliação dos modelos que possibilitem efetuar essa medição.

3.1 Matriz de confusão

A matriz de confusão é utilizada em classificação, permitindo uma visualização clara dos resultados de um modelo. Nela, os resultados são demonstrados como uma tabela de duas entradas. Enquanto uma entrada se constitui pelos resultados das classes desejados, a outra apresenta as classes previstas pelo modelo analisado. O exemplo apresentado na Tabela 1 ilustra uma matriz de confusão e sua operação. As entradas efetuadas nas colunas demonstram as classificações obtidas pelo modelo, enquanto as linhas apresentam as classificações originalmente obtidas para os dados.

Tabela 1 – Matriz de confusão

	A	B	C	D
A	100	0	0	0
B	0	55	40	5
C	0	0	99	1
D	0	12	0	88

Conforme a Tabela 1, podemos ver que a classe **B** demonstrou uma classificação correta em 55 instâncias, e incorretamente em 45, da mesma forma que as classes **C** e **D** apresentaram consecutivamente 99 e 88 instâncias classificadas corretamente. A classe que se destacou foi a **A**, apresentando todas as instâncias classificadas de forma correta.

3.2 Matriz de regressão

Ao utilizarmos a matriz de regressão, buscamos utilizar um modelo que venha a produzir valores que estejam mais adjacentes aos dados. O contraste entre o valor real (r) e o previsto (p) é apresentado por erro ou resíduo (e_i), e pode ser calculado um erro total ou global, sendo desse modo calculados todos os valores que foram presumidos. Para isso podem ser utilizadas as medidas (Witten; Frank; Hall, 2005):


- Mean Absolute Deviation (MAD): $MAD = \frac{1}{N} \sum_i^N e_i$
- Sum Squared Error (SSE): $SSE = \sum_i^N e_i^2$
- Mean Squared Error (MSE): $MSE = \frac{SSE}{N}$

- Root Mean Squared Error (RMSE): $RMSE = \sqrt{MSE}$
- Root Relative Squared Error (RRSE): $RRSE = \frac{RMSE}{RMSE_{\bar{p}}}$

Temos então que $RMSE_{\bar{p}}$ apresenta o valor para RMSE com o cálculo efetuado em uma simples previsão para p baseado em sua média ($\bar{p}$). Já para o caso do RRSE, ocorre uma operação com valores distintos a uma escala de valores apresentados para p , ou seja, quando obtido valor abaixo de 100%, o método utilizado para uma previsão que está sob análise demonstra ser mais efetivo que o método simples baseado na média.

TEMA 4 – MÉTODO DA ÁRVORE DE DECISÃO

Uma árvore de decisão visa auxiliar decisões complexas. Ela é na verdade um mapa que apresenta as possibilidades de resultados para uma sequência de escolhas relacionadas.



Crédito: Rvector/Shutterstock.

Esse método permite que uma pessoa ou organização efetue comparações entre as possíveis ações baseadas em custos, benefícios, probabilidade de ocorrência e metas para lucros. Pode também ser utilizado na condução de diálogos informais ou mesmo no mapeamento de um algoritmo para previsão da melhor escolha de forma matemática.

A estrutura apresentada por uma árvore de decisão tem sua representação formalizada com quatro elementos:

- a) nó raiz – nó ou ponto que apresenta o primeiro teste;
- b) nós internos – cada nó ou ponto deste tipo apresenta um teste a um atributo de dados e duas ou mais subárvores que indicam as respostas possíveis;

- c) ramos – contêm os valores relativos aos atributos;
- d) folhas – efetuam a representação das classes.




Crédito: Mila Supinskava Glashchenko/Shutterstock.

Em geral, a árvore de decisão inicia-se por um nó único que se subdivide em possíveis resultados. Para cada resultado vão surgindo novos nós adicionais que geram outras possibilidades representadas por novas ramificações.

Podemos encontrar três tipos de nós ilustrados na Figura 1, que são: nó de probabilidade, nó de decisão e nó de finalização ou término.

- a) Probabilidade: é representado por um círculo e apresenta as probabilidades dos resultados.
- b) Decisão: é representado por um quadrado, apresentando uma decisão a ser tomada.
- c) Finalização: apresenta-se em formato triangular e indica o resultado final de um caminho de decisão.

Figura 1 – Exemplo de árvore de decisão



Fonte: Autor.

O algoritmo a ser selecionado para desenvolver a árvore de decisão depende do objetivo. Existem diferentes algoritmos para construção da árvore, conforme demonstrado na Tabela 2.

Tabela 2 – Objetivos de *data mining* e algoritmos de decisão

Objetivos de DM	Vantagens	Desvantagens	Algoritmos
Classificação	Construção simples e rápida. Adequada a problemas com muitas dimensões. Fácil representação e visualização.	Necessários muitos dados para descobrir estruturas complexas.	CART
Segmentação			CHAID
Previsão			AID
Visualização			See5
			ID4
			ID6
			C4.5
			C5

Fonte: Adaptado de Santos; Azevedo, 2005.

4.1 Algoritmos de indução

Os algoritmos de indução de árvore de decisão ou de regressão constroem a árvore de forma recursiva. Essa construção ocorre com base em dados de treinamento, pela divisão contínua dos dados em subconjuntos. Ela é finalizada quando esses dados venham a representar apenas uma classe ou valor, ou ainda, quando encontrem critérios predeterminados.

Contudo, em diversos casos, esses algoritmos desenvolvem estruturas com ramificações desnecessárias que devem ser cortadas da estrutura. Essa ação é denominada de *poda* e pode ser efetuada durante o processo de aprendizagem, aumentando a complexidade do processo.

4.2 Benefícios com árvore de decisão


As árvores de decisão vêm sendo bastante utilizadas pelas diferentes vantagens que oferecem. Podemos salientar entre elas a facilidade de compreensão e análise. Além disso, outros benefícios para sua utilização são:

- a) possibilidade de uso com ou sem dados concretos – os dados utilizados precisam de pouca preparação para serem utilizados;
- b) a inclusão de novas opções poderá ocorrer sobre as árvores já existentes;
- c) capacidade de escolha do melhor caminho entre as diversas opções possíveis;
- d) fácil integração a outras ferramentas que auxiliam o processo de tomada de decisão.

Apesar disso, as árvores de decisão podem chegar a um grau de complexidade elevado. Nesses casos, é aconselhada a utilização de um diagrama de influência mais compacto como alternativa para atingir o objetivo desejado. Os diagramas de influência têm seu foco em decisões críticas, entradas e nos objetivos, sendo efetivos nessas situações.

TEMA 5 – ALGORITMOS ID3

Existem diversos tipos e métodos para se gerar uma árvore de decisão. Na literatura podemos encontrar Id3, J48, BFTree, SimpleCart, entre outros. Vamos entender um dos mais utilizados, que é o Id3 pela facilidade e simplicidade de uso além do dinamismo e abrangência.



Crédito: Polygraphus/Shutterstock.

5.1 Algoritmo ID3

A implementação do algoritmo ID3 se baseia no conceito estatístico de entropia (E) e também no conceito de informação de ganho (IG).

5.1.1 Ganho de informação

O ganho de informação ou *information gain* é uma medida que apresenta a quantidade de vezes em que um atributo será separado por exemplos de aprendizado conforme sua função objetivo ou classe. Essa quantificação deve ser representada em valor numérico, quantificando o ganho. De forma a determinar esse ganho, necessitamos efetuar primeiramente o cálculo da entropia dos dados.

5.1.2 Entropia

O cálculo da entropia resulta na apresentação da homogeneidade dos exemplos inseridos em um conjunto de dados. Possibilita a caracterização pura e impura de determinada compilação arbitrária de exemplos.

Para melhor entendimento, vamos adotar um conjunto C , com exemplos positivos (+) e negativos (-), que deverão definir os conceitos a serem aprendidos.

Para calcularmos a entropia relativa dos dados desse conjunto **C**, utilizamos a fórmula:

$$Entropia(C) = -QP_+ \cdot \log_2 QP_+ - QP_- \cdot \log_2 QP_-$$

Pela fórmula apresentada, temos QP_+ como sendo a quantidade proporcional entre os exemplos positivos e o total de exemplos do conjunto – dessa forma: $\frac{No.de\ casos\ positivos}{No.total\ de\ casos}$

É considerada para QP_- a quantidade de exemplos negativos em relação ao conjunto total. Nesse caso: $\frac{No.de\ casos\ negativos}{No.total\ de\ casos}$

Para essa relação, deve ser considerado que: $0 \cdot \log_2 0 = 0$

Assim sendo, a entropia relacionada a um problema de classificação binária demonstra uma curva que apresenta a variação à medida que a quantidade proporcional de positivos e negativos variam. A entropia/Shannon apresenta uma quantidade de bits que se faz necessária para o envio de uma mensagem dada uma proporção ou probabilidade de ocorrência de um dado em relação a outro.

5.1.3 Entendendo o ID3

Vamos utilizar um exemplo mais prático. Consideremos um conjunto de possibilidades: Sintoma ['Ansiedade', 'Espasmos', 'Desmaio'], em que Sintoma[1] = número de casos de ansiedade, Sintoma[2] = número de casos de espasmos, e Sintoma[3] = número de casos de desmaio. Consideremos ainda que Sintoma[1] + Sintoma[2] + Sintoma[3] = número total de casos registrados para o conjunto.

Já a proporção de uma possibilidade de 'QP' é $QP(1) = \text{Sintoma}[1]/(\text{Sintoma}[1]+\text{Sintoma}[2]+\text{Sintoma}[3])$.

Para calcularmos a entropia do Sintoma, é preciso utilizar a fórmula:

$$S(\text{Sintoma}) = \sum_{i=1}^3 -QP(i) \log_2 QP(i)$$

O valor calculado para determinar qual variável estará a uma distância maior da árvore da variável final escolhida pelo pesquisador é denominada *ganho*.

5.2 Praticando o ID3

Para vermos o ID3 na prática, vamos considerar o conjunto S anterior e dinamizá-lo para um formato mais complexo com outros conjuntos. Dessa forma,

consideramos as variáveis: Característica ['Sonolência', 'Relaxado', 'Alterado'], IMC ['< 18', '> 18'], Pulsação ['Forte', 'Enfraquecida'], Sintoma ['Ansiedade', 'Espasmos', 'Desmaio'], Internamento ['Sim', 'Não'].

Observando a Tabela 3, temos um exemplo mais complexo e completo.

Tabela 3 – Valores de exemplo para algoritmo ID3

Caso	Sintoma	Característica	IMC	Pulso	Internar
C1	Ansiedade	Alterado	>18	Enfraquecido	Não
C2	Ansiedade	Alterado	>18	Forte	Não
C3	Espasmos	Alterado	>18	Enfraquecido	Sim
C4	Desmaio	Sonolência	>18	Enfraquecido	Sim
C5	Desmaio	Relaxado	<18	Enfraquecido	Sim
C6	Desmaio	Relaxado	<18	Forte	Não
C7	Espasmos	Relaxado	<18	Forte	Sim
C8	Ansiedade	Sonolência	>18	Enfraquecido	Não
C9	Ansiedade	Relaxado	<18	Enfraquecido	Sim
C10	Desmaio	Sonolência	<18	Enfraquecido	Sim
C11	Ansiedade	Sonolência	<18	Forte	Sim
C12	Espasmos	Sonolência	>18	Forte	Sim
C13	Espasmos	Alterado	<18	Enfraquecido	Sim
C14	Desmaio	Sonolência	>18	Forte	Não

Fonte: Autor.

Com base na tabela de aprendizado, o algoritmo pode calcular uma definição para casos de internação.

REFERÊNCIAS

SANTOS, M. F.; AZEVEDO, C. S. **Data mining**: descoberta de conhecimento em bases de dados. Lisboa: FCA, 2005.

WITTEN, I. H.; FRANK, E.; HALL, M.A. **Practical machine learning tools and techniques**. Burlington: Morgan Kaufmann, 2005.