

Aula 2

Mineração de Dados

Prof. Roberson Cesar Alves de Araujo



1

Abordagem simbólica

2

Cenário tecnológico de pesquisa de dados

- **Desenvolvimento tecnológico é um acontecimento fundamental inserido nas transformações mais profundas da nossa atual sociedade**
- **Elementos que mais se destacam é o processo de comunicação e o de troca de informações**

3

- **As redes de computadores**
 - **Estão se tornando mais interativas com importante função nesse novo cenário que vem crescendo de forma exponencial**
 - **Criam novas formas e novos canais de comunicação, redesenhando a forma de vida das pessoas, ao mesmo tempo que também é redesenhada por elas**

4

- **Novo "universo" informacional**
 - **Surgem novas áreas de pesquisa que têm sua atenção voltada para a criação e o desenvolvimento de diferentes métodos**
 - **Os métodos visam a exploração de conjuntos de dados que são coletados**
 - **Para isso, tem sido desenvolvidos diferentes tipos de algoritmos classificadores**

5

Classificadores

- **Algoritmos com aplicação em atividades de classificação automática de dados com capacidade de gerar informações para auxílio na tomada de decisão**
- **Para isso, eles utilizam informações pretéritas em diversas áreas, focando no objetivo a ser atingido**

6

Análise simbólica

- Frente a uma inadequação da análise estatística por não considerar a variabilidade e incerteza inerente aos novos formatos de dados
 - Surge como opção a um resultado mais assertivo
 - Utilização de dados simbólicos pode se dar pela extração direta ou por agregação de dados clássicos
- Para o uso de agregação de dados, duas formas diferentes podem ser utilizadas

7

Agregação temporal de dados

- Partindo da mesma origem
- Dados são extraídos ao longo do tempo
- Todos conjuntos de valores ou as respectivas distribuições devem ser considerados linearmente para as agregações
- Tipo de dado oriundo da agregação temporal – devem permanecer inalteradas as unidades estatísticas, ou seja, invariantes para antes e depois da análise

8

- Agregação contemporânea
 - São recolhidos os dados em um único momento definido
 - As entidades estatísticas são analisadas em um nível mais aprofundado em comparação ao ponto original de extração dos dados

9

- De forma diferente, a agregação temporal, nesse formato de agregação às informações, não são mais as mesmas antes e depois da agregação
- Após a agregação, as unidades estatísticas são transformadas em grupos específicos das unidades originalmente utilizadas por extração

10

Função da abordagem simbólica

- Crescente aumento do volume de informações que vivenciamos diariamente em diferentes áreas, a extração de dados vem destacando a importância de se buscar dados relevantes
- O uso de dados simbólicos, ou seja, dados mais complexos, se apresenta como uma nova forma de tratar o que se busca

11

- As variáveis inseridas nesse novo tipo de dado podem ser determinadas por um conjunto finito de valores ou categorias
- Intervalos e distribuições probabilísticas e de frequência
- Carência de uso de técnicas estatísticas apropriadas à função deste novo formato de dados

12

Dados composicionais

- No ambiente em que surgem os classificadores, encontramos também dados composicionais
- Esses dados são vetores nos quais componentes que não são negativos representam proporções ou percentagens relativas ao todo, destacando sua soma a um valor sempre constante

13

- Generalização
- Nos diferentes problemas de análise de dados encontramos cada variável relacionada com as outras, sendo apresentadas como partes de um todo
- Duas propriedades fundamentais
 - Para cada variável é utilizado um valor não negativo
 - Quando somados os valores das variáveis de um indivíduo o valor é sempre constante

14

- Todos os indivíduos terão uma composição individual que os descreve individualmente
- Os dados que se originam dessa forma são denominados dados composicionais

15

Tipos de classificadores


16

Classificação

- O processo de classificação permite gerar uma descrição, ou mesmo um modelo para cada classe, originário de um conjunto de dados de exemplo

17

Classificação



18

Tipos de classificadores

- **Classificação supervisionada**
 - Também conhecida como análise discriminante
 - Apresenta um conjunto de indivíduos previamente classificados, objetivando encontrar uma regra que possibilite efetuar a classificação de um novo indivíduo

19

- **Classificação não supervisionada**
 - Neste formato de classificação são agrupados diferentes elementos que possuem características comuns, por classes
 - Esse tipo de agrupamento é composto por cinco etapas

20

Etapas da classificação não supervisionada

- **Etapa de representação de objeto**
 - São identificadas as características de maior relevância encontradas nas características originais
- **Etapa de seleção de medida de similaridade**
 - Visa destacar um conjunto de medidas de similaridade para os dados simbólicos e composicionais

21

- **Etapa de agrupamento de dados**
 - Os algoritmos utilizados para esse fim são classificados como de agrupamento hierárquico
 - Construção de um conjunto de partições encaixadas com origem na fusão ou divisão de grupos com base na similaridade existente entre eles

22

- **Etapa de abstração dos dados**
 - É baseada na extração de uma descrição básica para cada grupo
 - Em geral, esses grupos são representados por modelos

23

- **Etapa de validação**
 - Ocorre de três formas diferentes
 - ✓ Externa
 - É comparada a saída do algoritmo com uma partição previamente conhecida

24

- 36
-
- 59

26
59

24

22
50

- 27

28
59

- 28

20
50

- 29

26/25

- 30

	A	B	C	D
A	100	0	0	0
B	0	55	40	5
C	0	0	99	1
D	0	12	0	88

- Classe B demonstrou uma classificação correta em 55 instâncias, e incorretamente em 45
- Classes C e D apresentaram consecutivamente 99 e 88 instâncias classificadas corretamente
- Classe A, todas instâncias classificadas de forma correta

- 31

Matriz de regressão

- Modelo gerador de valores mais adjacentes aos dados

- 32

- O contraste entre o valor real (r) e o previsto (p) é apresentado por erro ou resíduo (e_i), e pode ser calculado um erro total ou global, sendo desse modo calculado todos os valores que foram presumidos

 - Desvio Médio Absoluto: $MAD = \frac{1}{N} \sum_{i=1}^N e_i$
 - Soma Dos Erros Quadráticos: $SSE = \sum_{i=1}^N e_i^2$
 - Erro Quadrático Médio: $MSE = \frac{SSE}{N}$
 - Raiz Quadrada Do Erro Quadrático Médio (Desvio Padrão Das Distâncias Entre A Predição E Os Dados Corretos): $RMSE = \sqrt{MSE}$
 - Raiz Quadrada Do Erro Relativo: $RRSE = \frac{RMSE}{PMSE}$

33

- RMSEp
 - Apresenta o valor para RMSE com o cálculo efetuado em uma simples previsão para p baseado em sua média ($\bar{p}$)
- RRSE
 - Operação com valores distintos a uma escala de valores apresentados para p , ou seja, quando obtido valor abaixo de 100%, o método utilizado para uma previsão que está sob análise demonstra ser mais efetivo que o método simples com base na média

- 34

- ## Árvore de decisão
- Uma árvore de decisão visa auxiliar em decisões complexas
 - Ela é, na verdade, um mapa que apresenta as possibilidades de resultados para uma sequência de escolhas relacionadas
- 
- Vector/Shutterstock

Decision Tree

Extractor/Shutterlock

- 35

- 36

-

microtic/Shutterstock

```

graph LR
    A[ ] --- B[trabalhar]
    A --- C[ir pescar]
    B --- D[Perder o emprego]
    C --- E[Pegar peixe]
    C --- F[Falhar em pegar peixe]
    
```

Diagrama de árvore de decisão para a escolha entre trabalhar e pescar. A raiz é um retângulo vazio. O ramo superior é 'trabalhar' (73%) e o inferior é 'ir pescar' (25%). O ramo 'trabalhar' leva a um retângulo 'Perder o emprego' (25%). O ramo 'ir pescar' leva a um retângulo 'Pegar peixe' (64%) e a um retângulo 'Falhar em pegar peixe' (36%).

Objetivos de DM	Vantagens	Desvantagens	Algoritmos
- Classificação - Previsão - Visualização	- Construção simples e rápida. - Adequada a problemas com muitas dimensões. - Fácil representação e visualização.	Necessários muitos dados para descobrir estruturas complexas.	- CART - CHAID - AID - SeeS - ID4 - ID6 - C4.5 - C5

7

Algoritmos de indução

- Também chamados de algoritmos de regressão
- Constroem a árvore de uma forma recursiva (com base em dados de treinamento, pela divisão contínua dos dados em subconjuntos, finalizando quando esses dados venham a representar apenas uma classe ou valor, ou ainda, que encontrem critérios pré-determinados)

43

- Podem desenvolver estruturas com ramificações desnecessárias que precisam ser cortadas da estrutura
- Essa ação é denominada *poda* e pode ser efetuada durante o processo de aprendizagem, aumentando, dessa forma, a complexidade do processo

44

Árvore de decisão – benefícios

- Destacam-se pela possibilidade de seu uso com ou sem dados concretos. Os dados utilizados precisam de pouca preparação para serem utilizados
- A inclusão de novas opções poderá ocorrer sobre as árvores já existentes
- Tem a capacidade de escolha do melhor caminho entre as diversas opções possíveis
- Integram-se facilmente a outras ferramentas que auxiliam o processo de tomada de decisão

45

Aspectos importantes – árvore de decisão

- Podem atingir um grau de complexidade elevado
- Nesses casos, é aconselhada a utilização de um diagrama de influência mais compacto como alternativa para atingir o objetivo desejado
- Os diagramas de influência têm seu foco em decisões críticas, entradas e nos objetivos, sendo efetivos nessas situações

46

Algoritmos ID3

47

- Existem diversos tipos e métodos para se gerar uma árvore de decisão
 - Na literatura podemos encontrar Id3, J48, BFTree, SimpleCart, entre outros
- O ID3 destaca-se por ser um dos mais utilizados
- Facilidade e simplicidade de uso além do dinamismo e abrangência



polygraphus/Shutterstock

48

- A implementação do algoritmo ID3 se baseia no conceito estatístico para entropia (E) e também no conceito de informação de ganho (IG)



Bakhtiar Zehn/Shutterstock

49

- **Ganho de informação (Information Gain)**
 - Medida que apresenta a quantidade de vezes em que um atributo irá ser separado por exemplos de aprendizagem conforme sua função, objetivo ou classe
 - ✓ Essa quantificação deve ser representada em valor numérico, quantificando o ganho
 - ✓ De forma a determinar esse ganho, necessitamos efetuar primeiramente o cálculo da entropia dos dados

50


- **Entropia**
 - Resulta na apresentação da homogeneidade dos exemplos inseridos em um conjunto de dados
 - ✓ Possibilita a caracterização pura e impura de uma determinada compilação arbitrária de exemplos



Zurijeta/Shutterstock

51

- O ID3 utiliza a entropia para efetuar o cálculo da homogeneidade de uma determinada amostra
- Quando a amostra for inteiramente homogênea a entropia terá o valor de zero
- Se a amostra for dividida da mesma maneira, a entropia será determinada com valor 1



Entropia = $-0.5 \log_2 0.5 - 0.5 \log_2 0.5$

52

- Para entendermos melhor, vamos adotar um conjunto C, com exemplos positivos (+) e negativos (-), que deverão definir os conceitos a serem aprendidos
- Para calcularmos a entropia relativa dos dados desse conjunto C, utilizamos a fórmula

53

- $Entropia(C) = -QP_+ \cdot \log_2 QP_+ - QP_- \cdot \log_2 QP_-$
- QP_+ sendo a quantidade proporcional entre os exemplos positivos e o total de exemplos do conjunto
- Dessa forma, sendo
 - ✓ $\frac{N^\circ \text{ de casos positivos}}{N^\circ \text{ total de casos}}$
- Considerando que
 - ✓ $0 \cdot \log_2 0 = 0$

54

