


| MINERAÇÃO DE DADOS

TEMA 1 – REDES NEURAIS E CLASSIFICADORES ESTATÍSTICOS



Crédito: -imassimo82/Shutterstock.

1.1 Algoritmo de retro propagação (*backpropagation*)

O algoritmo de retro propagação (*backpropagation*) é um dos algoritmos mais importantes quando falamos em redes neurais. Ele tem a capacidade de treinar redes de aprendizagem profunda com efetividade. O algoritmo de *backpropagation* possui duas fases: *forward pass*, ou passo à frente, e *backward pass*, ou passo para trás.

1.1.1 Fase 1: *forward pass* (passo à frente)

Essa fase é também denominada fase de propagação. Nela é efetuada o envio das entradas e previsões obtidas por meio da rede. Sendo assim, a existência do passo à frente está na propagação das entradas pela rede com a aplicação de multiplicação entre vetores (*dot products*) e ativações, consecutivamente, até o atingimento da camada de saída da rede, ou seja, o atingimento das previsões.

1.1.2 Fase 2: *backward pass* (passo para trás)


Nessa fase é efetuado o cálculo do gradiente da função de perda que ocorre na camada de previsão, ou camada de finalização na rede. Esse gradiente é utilizado de maneira recursiva à regra da cadeia, ou *chain rule*, com a finalidade de efetuar uma atualização dos pesos na rede.

1.1.3 Funcionamento do algoritmo *backpropagation*

Em redes neurais encontramos basicamente dois itens: neurônios e pesos. Assim, enquanto os neurônios efetuam o armazenamento dos valores a serem calculados para definir os pesos, o peso é a peça-chave para todo o funcionamento da rede. Por meio do peso, a rede neural é capaz de reconhecer que determinado objeto é de formato x e não de formato y.

Esse algoritmo opera em multicamada por possuir sempre um mínimo de três camadas, como apresentado na Figura 1. P1, P2, P3 e P4 são neurônios que representam as entradas, ligando-se a todos os valores, aqui determinados como 1, 2 e 3. Eles representam os resultados em uma camada oculta (*hidden layer*) que se conectam a todas as saídas, apresentando em Z1 e Z2 os resultados.

Figura 1 – Funcionamento do algoritmo *backpropagation*



1.1.4 Classificadores bayesianos

O objetivo de se efetuar uma classificação de dados está na previsão de categorias ou etiquetas para os dados. Uma vez que sejam extraídos dados na forma de um conjunto e de categorias definidas, a função do classificador é elaborar um modelo com capacidade de efetuar a correta atribuição de uma categoria a cada dado individualmente.

Entre os classificadores estatísticos podemos destacar os bayesianos, que efetuam a classificação de um objeto em determinada classe com base na probabilidade de que este objeto deve pertencer a esta classe. A rapidez com que os resultados são gerados é característica de efetividade no processo de execução.


Para a classificação, esses algoritmos utilizam o teorema de Bayes, classificando uma instância em determinada classe e tendo por base a

probabilidade. A capacidade de produção de dados desses algoritmos quando aplicados a grandes volumes de dados é comparável aos resultados produzidos por árvores de decisão e redes neurais.

1.1.5 Entendendo o classificador Naive Bayes

Esse classificador atua por meio de probabilidade, baseado no teorema de Bayes (Thomas Bayes). Inicia-se fundamentado na proposição de que todos os atributos têm autonomia, ou seja, têm independência entre eles.

Figura 2 – Modelo probabilístico Naive Bayes



A Figura 2 exemplifica o funcionamento do modelo em que os atributos Z1, Z2 e Z3 influenciam a classe Y, contudo, nenhum deles exerce qualquer influência sobre os outros. Por efetuar uma classificação probabilística, o modelo efetua o cálculo das probabilidades da classe Y, com base nos atributos Z1, Z2 e Z3. É definido por: $p(Y | Z1, Z2, Z3 \dots)$.

Com base nisso, ao aplicarmos o teorema de Bayes, a probabilidade ficaria definida dessa forma: $p(Y)p(Z_1|Y)p(Z_2|Z_1, Y)p(Z_3|Z_2, Z_1 Y) \dots$

Para facilitar, retornamos à proposição do atributo da autonomia como premissa. Dessa maneira, o cálculo se torna simplificado para a forma:

$$p(Y)p(Z_1|Y)p(Z_2|Y)p(Z_3|Y)\dots = p(Y) \prod_i p(Z_i|Y)$$

O que torna esse classificador propenso ao uso é exatamente a questão da independência dos atributos, sendo simples e efetiva.

TEMA 2 – MÉTODO kNN


Com o crescimento e evolução da internet, o volume de informações vem alcançando altas proporções, dificultando que o usuário consiga atingir a informação desejada. Começam a surgir, então, os sistemas de recomendação como alternativa para essa dificuldade, pela sugestão de um conteúdo de maneira personalizada.

Nesse contexto, o modelo ou técnica de classificação *k-Nearest Neighbors* (kNN) se apresenta como um método simples e com a capacidade de fornecer excelentes resultados. Seu funcionamento possibilita a geração de recomendações a partir de avaliações dos usuários. Esse método de *machine learning* tem por objetivo efetuar a classificação de um elemento atribuindo a ele um rótulo que se apresenta mais frequente dentre as k amostras mais próximas, utilizando um sistema de eleição. Para determinar a proximidade relativa aos vizinhos, é calculado por uma distância ou por instâncias entre eles. Para isso, as fórmulas mais utilizadas são de cálculo de distância euclidiana e cálculo de distância Manhattan.

2.1 Funcionamento do método kNN


Para efetuar o cálculo necessário para definir o rótulo de classificação de um elemento, o kNN necessita de uma definição de k , sendo k o número de elementos vizinhos mais próximos a serem utilizados pelo algoritmo. Além disso, também é necessário definir um conjunto de treinamento que deve ser acessado para inserção do rótulo de classificação baseado em k .

O valor a ser utilizado para a definição de k varia conforme a base de dados. Quando utilizado um valor muito baixo para k , podemos ter uma classificação suscetível a ruídos ou vizinhos dissemelhantes. Por outro lado, ao utilizarmos um valor muito elevado para k , podemos estar efetuando a inclusão de elementos pertencentes a outras classes.



Crédito: Maikon Lucian Lenz/Shutterstock.

A forma mais comum para definição de k consiste na utilização inicial do resultado do cálculo da raiz quadrada do número de amostras. Na sequência, efetuar um aprimoramento do valor, desde que este se apresente como um número primo.



Crédito: Maikon Lucian Lenz/Shutterstock.

2.2 Implementando um algoritmo kNN

Para implementação do algoritmo kNN, é necessário seguir três ações para cada amostra a ser classificada:

- efetuar o cálculo da distância entre a amostra a ser classificada e as amostras similares inseridas em um conjunto de treinamento;
- uma vez calculada a distância, definir quais são os k vizinhos mais próximos;

c) a última etapa consiste na classificação por meio da rotulação da classe que apresente um maior número de representantes conforme os k vizinhos definidos, ou seja, ocorre uma votação para a definição da classe.

Para melhor entendimento, assumimos como exemplo uma classificação com 150 amostras, definindo um k com valor 13. O objetivo está em efetuar uma classificação da classe conforme a utilização de um conjunto de treinamento.


Para a criação do conjunto de treinamento, vamos utilizar uma parcela das amostras, por exemplo, 60%. O restante das amostras terá a função de testar os resultados da classificação.

Para realizar o teste, o algoritmo efetua a classificação da amostra e o resultado é, então, comparado a um resultado conhecido. Caso a classe que foi anteriormente prevista seja igual à observada, determina-se como certa a classificação.

TEMA 3 – PREVISÃO: REGRESSÃO LINEAR

Extraír informações relevantes que auxiliem diferentes processos, como o de tomada de decisão, viabilizando o acompanhamento efetivo de resultados com uso de tecnologia, ainda se apresenta como um desafio. Diferentes pesquisas vêm sendo efetuadas na área de mineração de dados para facilitar esses processos.

A regressão linear se destaca como sendo uma proposta de modelar uma equação matemática linear que descreve o relacionamento entre variáveis. Existem diversas formas de utilização desse tipo de equação de regressão em situações envolvendo variáveis. A aplicação da regressão possibilita como resultado a predição de valores futuros a uma variável.



Crédito: Dan White 1000/Shutterstock.

Os modelos de regressão efetuam a modelagem do relacionamento de diferentes variáveis preditoras e uma variável resposta. A modelagem por função linear ou não linear pode ser usada para efetuar esse relacionamento.

Podemos entender que a regressão linear é uma equação que tem como função estimar a condicional, ou seja, prever o valor esperado com base em uma variável z qualquer. Isso ocorre com base em valores de outras variáveis w . Pode-se, por exemplo, utilizar a regressão linear para saber o custo de indisponibilidade em uma organização, que tenha sido ocasionada por falhas em sistemas.

3.1 Método dos Mínimos Quadrados (MMQ)

O método dos mínimos quadrados pode ser descrito como uma técnica de otimização matemática que busca localizar a melhor forma de ajustar um conjunto de dados. Ele minimiza a soma dos quadrados das diferenças entre os valores estimados e os dados relativos à observação em que essas diferenças são consideradas resíduos de pesquisa.

O MMQ é uma forma de efetuar uma estimativa de maneira mais ampla, como na econometria. Sua estimativa baseia-se na observação de outras diferentes variáveis. Ele consiste basicamente em um estimador, ou seja, uma regra para cálculo estimado com base nos dados, que reduz a soma dos

quadrados dos resíduos da regressão, ampliando o grau de ajuste do modelo para com os dados observados.

Para que o modelo seja linear, os parâmetros precisam se apresentar da mesma forma. Sendo assim, as variáveis devem ter uma relação linear entre si, evitando que o modelo se apresente como de regressão não linear.

Vejam os o exemplo da Figura 3 sobre o processo de regressão linear simples.

Figura 3 – Tabela exemplo de regressão linear simples

► Na tabela a seguir X corresponde ao número de anos de experiência de um engenheiro e Y corresponde ao seu salário.

X	Y
Anos de experiência	Salário (em R\$1000)
3	30
8	57
9	64
13	72
3	36
6	43
11	59
21	90
1	20
16	83

► O gráfico dos dados da tabela anterior sugere um relacionamento linear entre as variáveis X e Y .

Fonte: Merschmann, 2015.

Ao adotarmos o modelo de regressão linear simples, temos: $y = a + bx$. A partir dos dados apresentados na Figura 3, calculamos $\bar{x} = 9,1$ e

$$\bar{y} = 55,4$$

Calculando os coeficientes:

$$b = \frac{3(30-55,4)+8(57-55,4)+9(64-55,4)+13(72-55,4)+3(36-55,4)+6(43-55,4)+11(59-55,4)+21(90-55,4)+1(20-55,4)+16(83-55,4)}{3(3-9,1)+8(8-9,1)+9(9-9,1)+13(13-9,1)+3(3-9,1)+6(6-9,1)+11(11-9,1)+21(21-9,1)+1(1-9,1)+16(16-9,1)} = 3,54.$$

$$a = \bar{y} - b\bar{x} = 55,4 - (3,54).(9,1) = 23,19.$$

Dessa forma: $y = 23,19 + 3,54x$

Utilizando essa equação, podemos prever que o salário de um engenheiro com 10 anos de experiência é de R\$ 58.590,00.

3.2 Especificação de um modelo de regressão

A definição de um padrão ideal de modelo de análise de regressão é fundamental para atingir os objetivos pretendidos. Com base nisso, pode-se especificar o modelo e determinar quais serão as variáveis preditoras a serem incluídas nele, assim como se haverá necessidade de modelar a curvatura e as interações entre as variáveis preditoras.

Essa ação de especificação do modelo de regressão ocorre de maneira iterativa, necessitando de uma análise para afirmar a correta opção pelo modelo, bem como a necessidade de ajustes com base nos resultados.

A definição das variáveis que deverão ser utilizadas, tanto as preditoras como as de resposta, determina o melhor ou o mais adequado modelo a ser utilizado. Deve-se definir matematicamente a relação entre essas variáveis, que apesar de serem muitas em um primeiro momento, em geral apenas uma parcela tem de fato seu uso. Para essa definição de variáveis baseada no relacionamento existente entre elas, devem ser considerados três aspectos:

- a) utilização de um baixo número de variáveis: quando um modelo é especificado abaixo do necessário, tende a criar estimativas tendenciosas;
- b) utilização de um elevado número de variáveis: ao se super-dimensionar um modelo, tende-se a obter estimativas com pouca precisão;
- c) utilização de um modelo equilibrado: ao se dimensionar corretamente o número de variáveis, um modelo apresenta os termos corretos e resulta em estimativas efetivamente precisas e sem viés.

3.3 Problemas na definição de modelos

Para a definição e escolha de um modelo, podem ser adotados diversos métodos, mas existem outros fatores preocupantes para garantir o sucesso na utilização. Podemos destacar seis problemas mais comuns que remetem ao erro na definição do modelo:

- a) A não inclusão de variáveis significativas pode gerar resultados que demonstram que o modelo é o melhor. A análise das variáveis precisa ser conferida de forma a garantir a sua inclusão.
 - b) A ocorrência de resultados como falso positivo ou falso negativo pode ser gerada por problemas na coleta de dados. Quando utilizamos uma amostra
-

incomum podemos direcionar os resultados para um erro devido à origem dos dados.

- c) O erro na adoção da variável preditora pode alterar os resultados. A multicolinearidade pode gerar um erro de significado, dificultando a determinação do papel de cada preditor.
- d) A promoção de dados aleatórios em valores significativos é outro problema comum. Ao avaliarmos diversos modelos, podemos nos deparar com variáveis que possam parecer significativas, contudo seu relacionamento pode estar ocorrendo por mero acaso.
- e) Ajustes nos valores de variáveis podem promover a sugestão de utilização de outros tipos de modelos. Deve-se avaliar bem os ajustes nos valores de modo a não incorrer nesse problema.
- f) O uso de regressão do tipo *stepwise* e regressão de subconjuntos, apesar de serem consideradas ótimas ferramentas para determinar corretamente o modelo, em muitos casos determinam o contrário.

3.4 Análise e resultado

Para evitar erros em uma possível definição no formato do modelo a ser adotado, é sugerível descobrir o que outros já fizeram para descoberta dos tipos de modelos. O desenvolvimento de um cenário para visualizar de que forma as variáveis importantes estão se relacionando, sinais de coeficientes e magnitudes de efeito, deve ser gerado antes do início da análise de regressão.

Apesar da possibilidade de uso de técnicas estatísticas para definição do modelo, as considerações teóricas podem servir de auxílio na definição do melhor modelo, juntamente com a experiência de outros. Dessa forma, inclusive depois de ajustes ao modelo, o alinhamento à teoria pode servir como validador.

Mesmo parecendo que os problemas de maior complexidade devem exigir modelos complexos, diversos estudos apontam que modelos mais simples têm maior precisão nas previsões. Dessa forma, iniciar com um modelo mais simples, aumentando seu grau de complexidade, tem um resultado mais satisfatório.

Ao ampliar a complexidade do modelo, podemos incorrer no erro de adaptá-lo aos dados de maneira específica, direcionando em partes os resultados. Ainda, a observação dos resíduos pode auxiliar no descarte de modelos inadequados, possibilitando melhor ajuste no modelo e melhores resultados.

TEMA 4 – TÉCNICAS DE AMOSTRAGEM


As técnicas de amostragem muitas vezes são erroneamente comparadas a recortes de dados. Os recortes de dados atuam como filtros elaborados para reduzir o tamanho de uma base de dados, auxiliando no atingimento dos objetivos de uma pesquisa. Quando aplicados, alteram o conteúdo e formato de um conjunto de dados.

As técnicas de amostragem, ao contrário, criam um retrato minimizado do conjunto total dos dados, possibilitando o descobrimento de padrões.



Crédito: Bakhtiar Zein/Shutterstock.

Enquanto uma amostra (*sample*) representa o total da amostra ou a população (*target population*), o recorte de dados representa apenas alguns exemplos da população, não considerando outras possíveis variações inseridas nela. Existem diferentes tipos de amostragem que representam a população de maneira a considerar algumas especificidades.



Crédito: amgun/Shutterstock.

A amostra representa a população de forma que sejam mantidas suas características fundamentais.

4.1 Amostragem simples aleatória

Existe uma probabilidade equilibrada de selecionar igualmente qualquer item particular.

4.2 Amostragem sem reposição

Opera com a seleção de itens que são removidos da população.

4.3 Amostragem com reposição

Os objetos nunca são retirados da população ao serem selecionados para fazerem parte da amostra. Nesse caso, pode ocorrer que o mesmo objeto seja adicionado em mais de uma ocorrência.

4.4 Amostragem estratificada

Ocorre a divisão dos dados em diferentes partições. Uma vez que os dados estejam alocados nessas partições, são retiradas amostras de maneira aleatória, originárias de cada uma das partições.

4.5 Seleção de subconjuntos de características

Outra abordagem que visa diminuir a dimensionalidade dos dados se encontra baseada em duas características: redundantes e irrelevantes.

- a) Características redundantes – referem-se à duplicação de muita ou de toda a informação contida em atributos. Temos como exemplo o preço de venda de determinado produto e a quantidade de taxas sobre as vendas pagas desse mesmo produto.
- b) Características irrelevantes – caracterizam-se pelo desprovimento de informação de fato útil para os objetivos a serem atingidos pela execução da mineração de dados. Para exemplificar, podemos utilizar um ID de um estudante em que o objetivo seja efetuar a previsão de seu desempenho.

4.6 Técnicas para seleção de subconjuntos de características

Quatro técnicas se destacam na operação do processo de seleção de subconjuntos de características: força bruta, embutida, filtro e *wrapper*.

4.6.1 Abordagem de força bruta

Gera entrada para o algoritmo de mineração de dados por meio de tentativa de utilizar todos os possíveis subconjuntos de características.

4.6.2 Abordagem embutida

Ocorre de maneira natural dentro do algoritmo de mineração de dados, selecionando as características.

4.6.3 Abordagem de filtro

Diferentemente da abordagem embutida, efetua uma pré-seleção das características previamente à execução do algoritmo de mineração de dados.

4.6.4 Abordagem *wrapper*

Conhecida também como *caixa preta*, utiliza-se do algoritmo de mineração de dados para encontrar o melhor subconjunto de atributos.

TEMA 5 – AVALIAÇÃO DE CLASSIFICADORES: CURVAS ROC

Suponha que tenhamos um classificador operando em uma base de dados de nossa organização, impactando na utilização de recursos computacionais por demasiados períodos de tempo e que pode gerar informações irrelevantes. Buscando minimizar essa utilização e proporcionar maior assertividade nas informações geradas, necessitamos avaliar seu desempenho.

Inicialmente, poderíamos adotar como forma de avaliação a quantidade de acertos sobre as amostras, contudo, essa métrica não identifica os pontos fortes ou fraquezas do classificador utilizado.

5.1 Avaliação de classificadores por precisão de classificação

Para a apuração do resultado de uma análise de classificadores, podemos utilizar a precisão ou acurácia no processo de classificação. Essa avaliação baseia-se na constatação do percentual de assertividade do classificador.

Em um exemplo em que existam 500 amostras da base de dados e o classificador acertou 398, teremos uma precisão final de $(398/500) \times 100 = 79,6\%$. Apesar de conseguirmos determinar a precisão, não podemos ainda dizer se esse classificador é ou não eficiente. Possuindo apenas o valor da precisão não se pode diagnosticar a qualidade do classificador.

De maneira a comprovar essa afirmação, vamos considerar a situação de um paciente hospitalar aguardando o diagnóstico de uma doença grave. Se o classificador errar para a situação em que diz que “existe a doença” quando na verdade não existe, essa situação seria menos grave pois o paciente passaria a efetuar novos exames que demonstrariam o erro na existência da doença. Contudo, em uma situação em que o erro fosse “não existe a doença”, o paciente não teria ciência de estar portando essa doença. Isso comprova a necessidade de identificar outras métricas que possam apontar essa situação.

5.2 Avaliação de classificadores por métrica *precision*

Também conhecida como *métrica de valor de predição positiva*, a métrica *precision* tem como objetivo a identificação do número de amostras classificadas positivamente. Essa métrica busca medir a exatidão da classificação para as amostras positivas. Para isso, ela utiliza o resultado da divisão da quantidade de verdadeiros positivos pelo somatório de verdadeiros e falsos positivos.

$$V = \frac{VP}{VP + FP}$$

V indica o resultado atribuído à métrica, VP indica os verdadeiros positivos e VF indica os falsos positivos. Dessa forma, quando obtemos um baixo valor para V, obtemos um grande número de falsos positivos na classificação geral.

Para exemplificar, no caso de um VP = 90 e um FP = 44, obtemos:

$$0,67 = \frac{90}{90 + 44}$$

Ao aplicarmos esse cálculo sobre a situação do paciente com uma doença grave, queremos evitar que o diagnóstico seja de que não existe a doença, quando

na verdade existe. Para isso, obtemos que o valor V indica que em $\sim 67\%$ das vezes o diagnóstico foi positivo para doença, e esse fato foi identificado pelo classificador.

5.3 Avaliação de classificadores por métrica *recall*

Essa métrica opera sobre a mesma linha da métrica *precision*, contudo utiliza as amostras falsas negativas. Sua fórmula utiliza a razão da quantidade de verdadeiros positivos pela soma de verdadeiros positivos falsos negativos:

$$V = \frac{VP}{VP + FN}$$

A métrica *recall* mede a completude do classificador, em que um valor baixo para V indica um alto índice de falsos positivos. Seguindo o exemplo anterior, encontramos:

$$0,86 = \frac{90}{90 + 15}$$

O valor V indica que $\sim 86\%$ dos verdadeiros positivos são encontrados pelo classificador.

5.4 Avaliação de classificadores: curvas ROC (*Receiver Operating Characteristics*)

Muito utilizada em aprendizagem de máquina, a curva ROC pode ser entendida como uma técnica que possibilita visualizar e selecionar classificadores, tendo como base seu desempenho. De maneira geral, efetua uma avaliação somente da taxa de acerto de um classificador, demonstrando sua simplicidade.

Destaca-se pela utilização no tratamento de domínios em que as classes estejam desbalanceadas, apresentando custos de classificação diferenciados por classe.

Essa métrica utiliza uma taxa de verdadeiro positivo (TVP) juntamente com uma taxa de verdadeiro negativo (TVN) e taxa de falso positivo (TFP) para plotar uma curva em um gráfico, pelo qual apresenta a assertividade do classificador.

REFERÊNCIAS

AMARAL, F. **Introdução à ciência de dados**: mineração de dados e big data. São Paulo: Alta Books, 2016.

ARAUJO, G. et al. Exploração do paralelismo em algoritmos de mineração de dados com Pthreads, OpenMP, FastFlow, TBB e Phoenix++. In: **Anais da XVII Escola Regional de Alto Desempenho do Estado do Rio Grande do Sul**, SBC, 2017.

BECKER, K.; TUMITAN, D. Introdução à mineração de opiniões: Conceitos, aplicações e desafios. **Simpósio brasileiro de banco de dados**, v. 75, 2013.

BRAGA, L. P. V. B. **Introdução à mineração de dados**: edição ampliada e revisada. Editora E-papers, 2005.

CALIL, L. A. de A. et al. **Mineração de dados e pós-processamento em padrões descobertos**. Ponta Grossa: UEPG, 2008.

DANTAS, E. R. G. et al. O uso da descoberta de conhecimento em base de dados para apoiar a tomada de decisões. **V Simpósio de Excelência em Gestão e Tecnologia**, p. 1-10, 2008.

DOS SANTOS, B. S. et al. Data Mining: Uma abordagem teórica e suas aplicações. **Revista ESPACIOS**, 37(5), 2016.

GOLDSCHMIDT, R.; PASSOS, E. **Data mining**: um guia prático. Gulf Professional Publishing, 2005.

GRINSTEIN, U. M. F. G. G.; WIERSE, A. **Information visualization in data mining and knowledge discovery**. Burlington: Morgan Kaufmann, 2002.

HAND, D. J. Data Mining. **Encyclopedia of Environmetrics**, v. 2, 2006.

HANG, J.; KAMBER, M. **Data mining**: concepts and techniques. 2006.

SANTOS, M. F.; AZEVEDO, C. S. **Data mining**: descoberta de conhecimento em bases de dados". Lisboa: FCA, 2005.

STEINER, M. T. A. et al. Abordagem de um problema médico por meio do processo de KDD com ênfase à análise exploratória dos dados. **Gest Prod**, v. 13, n. 2, p. 325-37, 2006.

WITTEN, I. H.; FRANK, E.; HALL, M. A. **Practical machine learning tools and techniques**. Burlington: Morgan Kaufmann, 2005.
