

Aula 3

Mineração de Dados

Prof. Roberson Cesar Alves de Araújo



1

Redes Neurais e Classificadores Estatísticos

2

Algoritmo de retropropagação (*Backpropagation*)

- Um dos algoritmos mais importantes quando falamos em redes neurais
- Capacidade de treinar redes de aprendizagem profunda com efetividade
- Possui 2 fases que são
 - *Forward pass* ou passo à frente
 - *Backward pass* ou passo para trás

3

- Fase 1 – *Forward pass* – passo à frente
 - Denominada também de *fase de propagação*
 - Envio das entradas e previsões obtidas por meio da rede
 - Passo à frente está na propagação das entradas pela rede com a aplicação de multiplicação entre vetores (*dot products*) e ativações, consecutivamente até alcançar a camada de saída da rede, ou seja, o atingimento das previsões

4

Redes neurais – Algoritmo de retro propagação (*Backpropagation*)


- Visa treinar redes de aprendizagem profunda com efetividade
- Fase 2 – *Backward pass* – passo para trás
 - Efetuado o cálculo do gradiente da função de perda que ocorre na camada de previsão
 - Esse gradiente é utilizado de maneira recursiva à regra da cadeia ou *chain rule*, com a finalidade de efetuar uma atualização dos pesos na rede

5

Funcionamento do *Backpropagation*

- Em redes neurais, encontramos basicamente 2 itens: neurônios e pesos
- Esse algoritmo opera em multicamada por possuir sempre um mínimo de 3 camadas

6



7


Classificadores Bayesianos – Dados

- O objetivo de se efetuar uma classificação de dados está na previsão de categorias ou etiquetas para os dados
- Uma vez que sejam extraídos dados na forma de um conjunto de categorias definidas, a função do classificador é de elaborar um modelo com capacidade de efetuar uma correta atribuição de uma categoria a cada dado individualmente

8

- Atua por meio de probabilidade com base no teorema de Bayes (Thomas Bayes)
- Todos os atributos têm autonomia, ou seja, têm independência entre eles

9



10

Método kNN

11


kNN – *k*-Nearest Neighbors

- Gera recomendações a partir de avaliações dos usuários
- Método de *machine learning* que efetua uma classificação de um elemento atribuindo a ele um rótulo que se apresenta mais frequente dentre as *k* amostras mais próximas a ele, utilizando um sistema de eleição


12

- Proximidade relativa aos vizinhos é calculado por uma distância ou por instâncias entre eles
- Para isso, as fórmulas mais utilizadas são de cálculo de distância Euclidiana e cálculo de distância Manhattan


13



14



15



16

Previsão – Regressão Linear

17


- Proposta de modelar uma equação matemática linear que descreve o relacionamento entre variáveis
- Diferentes formas de utilização desse tipo de equação de regressão em situações envolvendo variáveis
- Possibilita como resultado a predição de valores futuros a uma variável

18

Método dos mínimos quadrados (MMQ)

- Técnica de otimização matemática que busca localizar a melhor forma de ajustar um conjunto de dados, minimizando a soma dos quadrados das diferenças entre os valores estimados e os dados relativos à observação onde essas diferenças são consideradas como resíduos de pesquisa

- Para que o modelo seja linear, os parâmetros precisam se apresentar da mesma forma
- As variáveis devem apresentar uma relação linear entre si, evitando que o modelo se apresente como de regressão não linear



19

20

- Na tabela a seguir X corresponde ao número de anos de experiência de um engenheiro e Y corresponde ao seu salário
- O gráfico dos dados da tabela anterior sugere um relacionamento linear entre as variáveis X e Y

X	Y
Anos de experiência	Salário (em R\$1000)
3	30
8	57
9	64
13	72
3	36
6	43
11	59
21	90
1	20
16	83

- Ao adotarmos o modelo de regressão linear simples, temos: $y = a + bx$
- A partir dos dados apresentados na tabela, calculamos $\bar{x} = 9,1$ e $\bar{y} = 55,4$
- Podemos prever que o salário de um engenheiro com 10 anos de experiência é de R\$ 58.590,00

X	Y
Anos de experiência	Salário (em R\$1000)
3	30
8	57
9	64
13	72
3	36
6	43
11	59
21	90
1	20
16	83

21

22

$$b = \frac{3(30-55,4) + 8(57-55,4) + 9(64-55,4) + 13(72-55,4) + 3(36-55,4) + 6(43-55,4) + 11(59-55,4) + 21(90-55,4) + 1(20-55,4) + 16(83-55,4)}{3(3-9,1) + 8(8-9,1) + 9(9-9,1) + 13(13-9,1) + 3(3-9,1) + 6(6-9,1) + 11(11-9,1) + 21(21-9,1) + 1(1-9,1) + 16(16-9,1)} = 3,54$$

$$a = \bar{y} - b\bar{x} = 55,4 - (3,54)(9,1) = 23,19$$

Problemas na definição de modelos

- A não inclusão de variáveis significativas pode gerar resultados que demonstrem que o modelo é o melhor
- A análise das variáveis precisa ser conferida de forma a garantir a inclusão dessas variáveis

23

24

- A ocorrência de resultados como falso-positivo ou falso-negativo pode ser gerada por problemas na coleta de dados
 - Quando utilizamos uma amostra incomum podemos direcionar os resultados para um erro devido à origem dos dados
- O erro na adoção da variável preditora pode alterar os resultados
 - A multicolinearidade pode gerar um erro de significado, dificultando a determinação do papel de cada preditor

25

- A promoção de dados aleatórios em valores significativos é outro problema comum
 - Ao avaliarmos diversos modelos, podemos nos deparar com variáveis que possam parecer significativas, contudo, seu relacionamento pode estar ocorrendo por mero acaso

26

- Ajustes nos valores de variáveis podem promover a sugestão de utilização de outros tipos de modelos
 - Deve-se avaliar bem os ajustes nos valores de modo a não incorrer nesse problema
- O uso de regressão do tipo *Stepwise* e regressão de subconjuntos, apesar de serem consideradas ótimas ferramentas para determinar corretamente o modelo, em muitos casos determinam o contrário

27

Técnicas de Amostragem

28


- Técnicas de amostragem versus recorte de dados**
- Erroneamente comparadas
 - Técnicas de amostragem e recortes de dados



29

- Enquanto uma amostra (*Sample*) representa o total da amostra ou a população (*Target Population*), o recorte de dados representa apenas alguns exemplos da população
- A amostra representa a população de forma que sejam mantidas as características fundamentais da população

30



31

Tipos de amostragem

- **Amostragem simples aleatória**
 - Utiliza probabilidade equilibrada de selecionar igualmente qualquer item particular
- **Amostragem sem reposição**
 - Seleção de itens que uma vez selecionados, são removidos da população

32

- **Amostragem com reposição**
 - Os objetos nunca são retirados da população ao serem selecionados para fazer parte da amostra
 - Podem ocorrer casos em que o mesmo objeto seja adicionado em mais de uma ocorrência

33

- **Amostragem estratificada**
 - Divisão dos dados em diferentes partições
 - Uma vez que os dados estejam alocados nessas partições, são retiradas amostras de maneira aleatória, originárias de cada uma das partições

34

Seleção de subconjuntos de características

- **Visa diminuir a dimensionalidade dos dados**
- **Baseada em 2 características**
 - **Características redundantes**
 - ✓ Duplicação de muita ou de toda a informação contida em atributos
 - ✓ Exemplo: o preço de venda de um determinado produto e a quantidade de taxas sobre as vendas pagas desse mesmo produto

35

- **Características irrelevantes**
 - ✓ Desprovisionamento de informação de fato útil para os objetivos a serem atingidos pela execução da mineração de dados
 - ✓ Exemplo: um ID de um estudante onde o objetivo seja efetuar a previsão de seu desempenho

36

Técnicas a serem adotadas para seleção de características

- Abordagem de força bruta
 - Gera entrada para o algoritmo de mineração de dados por meio de tentativa de utilizar todos os possíveis subconjuntos de características
- Abordagem embutida
 - Ocorre de maneira natural, sendo executada dentro do algoritmo de mineração de dados, selecionando as características

37

- Abordagem de filtro
 - Diferentemente da abordagem embutida, efetua uma pré-seleção das características previamente à execução do algoritmo de mineração de dados
- Abordagem *wrapper*
 - Conhecida também como “caixa-preta”, esta abordagem se utiliza do algoritmo de mineração de dados para encontrar o melhor subconjunto de atributos

38

Avaliação de Classificadores Curva ROC

39

Avaliação de classificadores

- Motivos
 - Desempenho
 - Assertividade



40

Avaliação de classificadores por precisão de classificação

- Para a apuração do resultado de uma análise de classificadores podemos utilizar a precisão ou acurácia no processo de classificação
- Essa avaliação baseia-se na constatação do percentual de assertividade do classificador
 - Exemplo: 500 amostras da base de dados
 - Acertos do classificador = 398
 - Precisão final = $(398/500) \times 100 = 79,6\%$

41

- Pode não ser suficiente para avaliar (Situação 1)
 - 500 amostras (diagnósticos de doença grave)
 - Acertos do classificador = 398
 - Precisão final = $(398/500) \times 100 = 79,6\%$
 - Se o erro = “existe a doença”, então não existe a doença
 - Situação “menos grave”, pois o paciente passaria a efetuar novos exames que demonstrariam o erro na existência da doença

42

- 49

