

| MINERAÇÃO DE DADOS

TEMA 1 – CONCEITOS BASE

As redes neurais artificiais (RNAs) se inspiram no sistema nervoso biológico em sua constituição. Os componentes determinados como neurônios artificiais são modelos simplificados originados dos neurônios biológicos. A ideia principal surgiu da análise da geração e disseminação de impulsos elétricos pela membrana celular dos neurônios. Como característica principal das RNAs, temos a capacidade que possuem de efetuar um aprendizado baseado em exemplos. Isso acontece mediante uma etapa de aprendizagem, que consiste em um processo contínuo de ajustes dos pesos sinápticos. Ao final desse processo, é guardado o conhecimento acumulado adquirido pela rede referente ao ambiente externo.

1.1 Vantagens na utilização de RNA


As técnicas fundamentadas em redes neurais artificiais apresentam como vantagem preponderante a capacidade de modelar diferentes relações de entrada e saída de maneira não linear. Isso se apresenta como sendo uma forte característica dos processos de mineração de dados, em que não ocorre a necessidade de se conhecer todos os detalhes dos processos e suas interações.

As RNAs operam conforme parâmetros preestabelecidos. Esses parâmetros impactam diretamente os resultados, influenciando o processo de obtenção de dados. A vantagem está na possibilidade de customização desses parâmetros de maneira a garantir a confiabilidade desses dados.

Quanto à sua arquitetura, as redes neurais artificiais possibilitam seu agrupamento. Esses agrupamentos se fundamentam na forma como os neurônios se conectam no cérebro humano, assim, as informações são processadas de forma dinâmica ou interativa. Na forma biológica, as redes neurais se encontram organizadas e elaboradas em um formato tridimensional mediante componentes microscópicos.

Existe uma rígida restrição quanto à quantidade de camadas que a rede pode conter, gerando um limite considerável ao tipo e ao escopo do uso da mesma no computador. Mesmo tendo a capacidade de possuir diversas camadas, as RNAs podem possuir apenas uma camada, sendo redes que possuem um nó localizado entre uma entrada e uma saída dessa rede, conforme Figura 1. Esse formato de rede é indicado na solução de problemas linearmente separáveis.


Figura 1 – Estrutura de rede neural com uma camada



Fonte: ShadeDesign/Shutterstock.

Outros formatos de redes com mais de uma camada são denominados de *multicamada*, possuindo uma ou mais camadas localizadas entre as camadas de entrada e saída. Outra denominação para essas camadas, conforme a Figura 2, é de camadas escondidas (*hidden*, ocultas ou intermediárias).

Figura 2 – Estrutura de rede neural multicamada



Fonte: ShadeDesign/Shutterstock.

1.2 Quantidade de camadas escondidas

Em um primeiro momento, podemos imaginar que um modelo com uma grande quantidade de camadas apresenta melhores resultados. Contudo, não se recomenda o uso de um grande número de camadas. Em cada rodada em que ocorre a atualização dos pesos das sinapses da camada imediatamente anterior por erro médio durante o treinamento, este torna-se menos preciso ou menos útil. Apenas a camada de saída possui a capacidade de nortear de maneira precisa o erro cometido. Nesse sentido, o que ocorre é que a última camada escondida obtém uma estimativa acerca do erro. A penúltima camada obtém uma estimativa da estimativa, seguindo assim de maneira cíclica.

Diferentes experimentos em pesquisas foram realizados com o uso de diferentes quantidades de camada. Porém, a utilização de duas ou mais camadas na resolução de problemas menores não apresentaram vantagem significativa. Na resolução da maioria dos problemas, é usual a utilização de apenas uma camada escondida, sendo em poucos casos utilizada duas camadas apenas.

1.3 Quantidade de neurônios na camada escondida

De modo geral, a quantidade de neurônios nas camadas escondidas tem sua definição de forma empírica. O cuidado está nos extremos, para não serem nem poucos nem muitos os neurônios.

Quando se utiliza uma baixa quantidade de neurônios, pode ocorrer uma necessidade de que a rede venha a dispende muito tempo buscando obter uma representação ótima.

Quando se utiliza uma alta quantidade de neurônios, a rede pode necessitar efetuar uma memorização de dados de treinamento (*overfitting*), contrariamente a ação de extração das características gerais que possibilitam a generalização.

Entre as diferentes propostas para a definição dos neurônios, duas se destacam, sendo por dimensão de camadas e por número de sinapse.

1.3.1 Definição de neurônios por dimensão de camadas

Essa forma de definição da quantidade de neurônios ocorre em função da dimensão das camadas de entrada e saída em uma rede, podendo ser definida a quantidade de neurônios na camada escondida por uma equação baseada na média aritmética ou utilizar a média geométrica considerando o tamanho da entrada e da saída da rede.

1.3.2 Definição de neurônios por número de sinapse

Este modelo de definição se baseia no percentual de 10% do número de exemplos disponíveis para treinamento. Dessa forma, o *overfitting* se torna pouco provável quando a quantidade de exemplos superar o número de sinapses. Contudo, pode ocorrer a situação em que a rede pode não convergir durante seu treinamento (*underfitting*).

1.4 Parâmetro taxa de aprendizado

Durante o processo de treinamento de uma rede neural, o parâmetro relativo à taxa de aprendizado atua como um influenciador de resultado. Quando a taxa de aprendizado se apresenta com valor extremamente baixo, ocorrem oscilações no treinamento, impedindo a convergência do processo de aprendizado.

Os valores assumidos para essa taxa oscilam entre 0.1 a 1.0. Existem diversos *softwares* que operam com este parâmetro adaptativo, sendo que a definição de um valor inicial não implica em problemas. Contudo, na ferramenta PRW (*Pattern Recognition Workbench*), esse parâmetro relativo à taxa de aprendizagem vem parametrizado como um valor fixo. O valor sugerido na literatura para este parâmetro é 0.4.

TEMA 2 – USO DE FERRAMENTA (MODELOS/TIPOS)

As RNAs do tipo MLP (*Multilayer Perceptron*) e RBF (*Radial Basis Function*) compreendem funcionalidades que se destacam na mineração de dados, sendo amplamente utilizadas nesse tipo de atividade. Na literatura, são encontrados diversos autores apresentando resultados satisfatórios na geração de informação derivada de diferentes fontes de dados, caracterizando seu uso na mineração de dados.

2.1 *Multilayer Perception* (MLP)

Para entender as RNAs do tipo MLP (*Multilayer Perceptron*), precisamos observar sua estrutura-base de funcionamento. Dessa forma, compreender sua característica intrínseca que contém ao menos uma camada intermediária ou escondida. O poder computacional apresentado nessas redes é amplamente superior em relação às redes sem camadas escondidas por possuírem a capacidade de tratar dados que se apresentam como não linearmente separáveis.

Para seu funcionamento, é utilizado o algoritmo *backpropagation* convencional. Com isso, ocorre uma tendência a uma convergência de maneira extremamente lenta, exigindo ainda um alto esforço computacional.

Como possíveis soluções para esses casos, transformando o processo de convergência da rede em um processo mais efetivo, podem ser utilizadas a

inserção do termo *momentum*; ou ainda utilizar variações do *backpropagation*, tais como o algoritmo de Levenberg-Marquardt ou a Regularização Bayesiana.

2.1.1 Problemas e soluções

As redes neurais do tipo MLP que fazem uso de treinamento *backpropagation* apresentam problemas principalmente no quesito de definição de parâmetros. A utilização de diferenças, mesmo que mínimas, impacta em elevadas diferenças em tempo de treinamento e em resultados como na generalização obtida.

É necessário entender que o modelo ideal não deve ser muito rígido ao ponto de não ser capaz de modelar os dados de maneira fiel. Da mesma maneira, o modelo não deve ser demasiadamente flexível em um nível de efetuar uma modelagem que venha a incluir ruídos presentes nos dados. O ideal é que o funcionamento da rede apresente resultados conforme as características encontradas nos dados de entrada, e não pontualmente iguais aos dados de entrada.

Dessa forma, os parâmetros para se gerar e treinar uma rede neural MPL *backpropagation* devem ser ajustados, visando atingir uma melhor generalização dentro de um determinado problema.

2.1.2 Momentum


Apesar de encontrarmos uma grande quantidade de pesquisas que visam determinar um procedimento “ideal” para determinar a melhor configuração em uma rede neural aplicada a um dado problema, o que temos de fato são sugestões baseadas em experiências realizadas.

O processo de inclusão do termo *momentum* busca ampliar a velocidade de treinamento de uma rede neural, reduzindo o risco de instabilidade. Esse termo não é obrigatório na etapa de treinamento, tendo seu valor variando entre 0.0, que representa a não utilização, até 1.0 em uma escala. Em sua utilização, o valor indicado para o termo é 0.3.

2.2 Radial Basis Function (RBF)

O modelo de rede RBF (*Radial Basis Function*), ou funções de base radial, pode ser utilizado quase em todos os tipos de problemas tratados pelo MLP. Contudo, enquanto as redes MLP podem possuir mais de uma camada oculta. A configuração padrão da RBF contempla apenas uma camada intermediária, onde a função de ativação é de base radial, em que a de maior utilização é a função gaussiana.

Figura 3 – Estruturas de rede neural artificial: categorias




Fonte: Adaptado de Rodrigues, 2020.

As funções denominadas *base radial* são funções não lineares capazes de serem utilizadas como funções-base nos diferentes tipos de modelo de regressão não linear, com parâmetros lineares ou não. São características da RFB:

- apresentam sempre apenas uma camada intermediária;
- os neurônios de saída são sempre lineares;
- na camada intermediária, os neurônios possuem apenas funções de base radial, como função de ativação e não funções sigmoidais ou outras similares.

Figura 4 – Funcionamento RNAs



TEMA 3 – UTILIZAÇÃO PRÁTICA

Os estudos relativos à utilização de modelos neurais e a computação não são novidade. O primeiro modelo de rede neural foi elaborado por Warren McCulloch e Walter Pitts no ano de 1943 com a criação de uma rede neural simples, utilizando circuitos elétricos para isso. Em 1950, foi criado o primeiro neurocomputador por Mavin Minsky, chamado de *Snark*. Esse equipamento era capaz de efetuar ajustes de pesos de conexões de maneira automática. Contudo, não tinha ainda a capacidade de efetuar interpretações acerca das informações de real interesse.

No ano de 1958, o psicólogo americano Frank Rosenblatt criou um neurocomputador denominado *Perceptron*, o qual possuía uma única camada de neurônios virtuais que tinham como função cognitiva aprender sobre tudo o que tivesse capacidade de ser representado. Uma vez feito isso, eram ajustadas conexões com pesos distintos até que fosse criado um condicionamento. Essa tecnologia foi posteriormente aperfeiçoada, originando o Multilayer Perception (MPL), possibilitando que o Perceptron operasse com três ou mais camadas neuronais de modo paralelo.

3.1 Relevância na utilização de redes neurais

Um dos propósitos mais significativos na utilização de redes neurais está na proposição de ajudar as pessoas na resolução de problemas complexos nas inúmeras situações da vida real: sua capacidade de aprendizado e modelagem de relações entre entradas e saídas de dados não lineares e complexos; a realização de generalizações e inferências; a capacidade de apresentar relacionamentos ou padrões e previsões em estado oculto; a capacidade de efetuar modelagem de dados que são altamente voláteis, a exemplo dos dados de séries temporais financeiras; além de variâncias imprescindíveis na previsão de eventos raros em diversas situações, como a detecção de fraudes. Em decorrência de sua utilização, as estruturas de redes neurais são capazes de implementar melhorias em processos de decisão em diferentes áreas.

Os modelos de redes neurais podem ser utilizados em:

- área médica, com diagnósticos médicos e assistência médica;
- área ambiental, com avaliação de ecossistema;
- área da qualidade, com controle de qualidade e de processos;
- área de *compliance*, efetuando detecção de fraudes em cartões de crédito;
- área de logística, atuando na melhoria da logística para redes de transporte;
- área financeira, efetuando previsões financeiras acerca do mercado de ações, moeda e classificação de títulos;
- área de geração de energia elétrica, prevendo demandas de energia e carga necessária;
- área química, possibilitando a identificação de compostos;
- área de reconhecimento de pessoas e objetos, atuando de forma a reconhecer caracteres, vozes, processamento de linguagem neural, reconhecimento facial e de estruturas como tipos de veículos e placas;
- área de automação, com sistemas de controle no meio robótico.

3.2 Funcionamento prático de RNAs

As redes neurais artificiais operam de maneira diferente aos inúmeros programas para computadores tradicionais. A programação dessas redes não é realizada apenas por seres humanos, que mesmo efetuando o seu treinamento têm acesso apenas aos dados de entrada e saída.

Assim, podemos entender que seu funcionamento opera como uma caixa preta, ou seja, somos capazes apenas de acessar as entradas e saídas, não sendo possível saber de fato o que ocorre em seu interior. Esse fato dificulta a depuração de possíveis erros, impossibilitando encontrar os motivos pelos quais algumas saídas resultaram de suas respectivas entradas. A incompreensão relativa ao funcionamento por parte dos próprios desenvolvedores se dá pela forma de funcionamento das redes neurais.

3.2.1 Compreendendo o funcionamento de RNAs

A estrutura das redes neurais é composta por diversas camadas de neurônios que representam um conjunto de sinais de entrada e saída. O sinal inicial para essa estrutura é dado por uma imagem, foto, texto ou som, que dá entrada na primeira camada de neurônios, denominada *camada de entrada*. Como resultado, temos as saídas dessa primeira camada, encontrando-se conectadas às entradas da próxima camada, seguindo-se assim consecutivamente.

Essa ação ocorre até que se alcance a última camada, a qual denominamos de *camada de saída*, sendo esta responsável pelo reconhecimento do sinal. Essa camada de saída obtém das outras camadas a informação processada por todas elas e, com base nessa informação, apresenta uma conclusão, como a identificação de uma imagem, apresentando uma face ou a identificação de um som como sendo de uma determinada pessoa.

3.2.2 Detalhamento do processo de funcionamento de RNAs

Ao observarmos as ações que ocorrem dentro dos neurônios, vemos que cada uma das entradas é multiplicada por um valor específico. O próximo passo é efetuar a soma de todos os valores das entradas, sendo o resultado convertido para uma saída do neurônio. Após a soma, esse valor é enviado para o próximo neurônio e é compreendido pela rede por meio de um processo de treinamento.

O treinamento consiste na introdução de uma série de dados de entrada pelo programador, resultando em saídas em um padrão já esperado. Após essa saída, a rede efetua uma comparação das informações disponíveis e fortalece os valores da multiplicação das entradas, gerando as saídas que são inesperadas. Uma vez que podem possuir inúmeras camadas de neurônios, ao possuírem um grande número de camadas são denominadas de *redes profundas* (*deep*

learning), sendo utilizadas na referência aos processos de aprendizagem de máquina, que utilizam essas redes.

Dessa forma a rede aprende e reforça os valores que geram saída adequada, amenizando os que geram saídas inesperadas, baseada em um conjunto de valores de entrada. Uma vez realizado o treinamento, a rede terá a capacidade de apresentar um resultado com uma maior precisão para novas entradas com base em entradas anteriormente realizadas.

TEMA 4 – RESULTADOS

Para obtenção dos resultados, a rede neural cria conexões entre as saídas de um neurônio e a entrada de outro durante o processo de treinamento. Essas conexões são desconhecidas pelos programadores, uma vez que não são eles a determinar os valores de multiplicação das entradas para os neurônios. Quem determina isso é a rede, baseada nos dados tanto de entrada como de saída esperada.

Para resultados precisos, é primordial o processo de treinamento de uma rede neural. O problema se encontra na descoberta de métodos efetivos de treinamento que executem sua função, visando a obtenção de resultados que apresentem a menor taxa de erros possível.

4.1 Diversificação de resultados

Uma das vantagens apresentadas pelas redes neurais está na capacidade de aprenderem com exemplos, podendo ser capazes de generalizar. Dessa forma, elas podem lidar com situações com as quais não foram preparadas.

Assim, podemos ter resultados diversificados com base em situações anteriormente não previstas. Como exemplo, podemos dizer que em rede treinada com figuras geométricas terá a capacidade de reconhecer outras que não tenham sido aprendidas, classificando por similaridade. Da mesma forma, ocorre com o reconhecimento facial, em que um rosto consegue ser identificado mesmo que em ângulo diferente ou em ambiente de fundo diferenciado.

A capacidade de obtenção de resultados diversificados deve-se também ao fato do desenvolvimento tecnológico apresentado pelo *hardware* de computação. Por meio da ampliação da capacidade de processamento computacional, é possível utilizar uma quantidade maior de dados de entrada.

4.2 Aplicações das redes neurais artificiais

Uma forte utilização de RNAs está no trabalho de reconhecimento de imagens e caracteres. Esse fato ocorre devido à capacidade que essas redes têm de receber diferentes entradas de dados, com a capacidade de efetuar um processamento, inferindo relações não lineares ocultas e complexas.

Esse trabalho é fundamental, por exemplo, na detecção de fraudes financeiras e bancárias, em que a caligrafia pode ser identificada, alcançando ações fraudulentas no que se refere à segurança nacional. Da mesma forma, o reconhecimento de imagem encontra-se em expansão nas mídias sociais, ainda, no campo da medicina, especificação na detecção de câncer, alcançando as áreas agrícolas e de defesa por meio de imagens de satélites.

A interação homem *versus* computador também é beneficiada com o uso das RNAs no processo de comunicação. Da mesma forma que a fala se destaca como função central nas interações humanas, no processo de comunicação com dispositivos de tecnologia ocorre igualmente. A melhoria das interfaces de fala com computadores vem proporcionando um maior uso desse recurso.

Devido à implementação das redes neurais, vem ocorrendo um avanço significativo nesse campo. Essas redes estão possibilitando que robôs possam aprender quando encontram diferentes linguagens.

4.3 Capacidades de RNAs nas organizações

No cenário organizacional, as previsões se apresentam como vitais para a tomada de decisões. A exemplo disso, temos as expectativas de vendas ou o planejamento de produção. O mesmo ocorre com relação a previsões econômicas e monetárias. Esses exemplos se destacam como desafios complexos para previsibilidade. Os diferentes fatores envolvidos podem influenciar uma previsão de forma a se apresentarem como um problema que dificulta esta ação.

Apesar da existência de diversos modelos de previsão, estes apresentam diferentes limitações no que tange à consideração de relacionamentos complexos e não lineares. Por isso, as RNAs, quando aplicadas corretamente, têm a capacidade de modelar e estratificar determinadas características e relacionamentos não previstos anteriormente, sendo uma alternativa considerável na apresentação de previsões.

Para as organizações, as RNAs vêm cada vez mais se apresentando como um diferencial não apenas de competitividade, mas também como fator de sobrevivência. A transformação digital se aproxima de um cenário disruptivo, no qual as redes neurais têm um papel fundamental de proporcionar um elevado nível de desenvolvimento.

TEMA 5 – VISÃO: PRÓXIMOS PASSOS

De modo a entender quais serão os próximos passos na linha de redes neurais, precisamos compreender primeiramente as vantagens e desvantagens que cada tipo de rede nos oferece. Podemos encontrar basicamente cinco tipos de redes neurais com funcionamento baseado em características diferenciadas.

5.1 Redes neurais recorrentes (RNRs)

Existem diferentes formas de implementação de redes neurais recorrentes. Para um entendimento prático, vamos usar o exemplo da seguinte frase:

Família nossa de legado o ser nenhuma a transmiti não, filhos tive não.

Essa frase não apresenta muita coisa por não fazer sentido. Contudo, ao ordenarmos corretamente, seremos capazes de interpretá-la.

Não tive filhos, não transmiti a nenhum ser o legado de nossa família.

As duas frases representam experimentos que demonstram que informações se fazem presentes não apenas pela composição de seu conteúdo, mas pela forma como está a disposição dele. Isso demonstra a existência de informações sequenciais por natureza.

Desse modo, podemos entender que as RNRs utilizam informações de maneira sequencial, como as palavras e frases do exemplo ou registro de data e hora de um sensor. De maneira diferente às redes neurais tradicionais, em uma rede neural recorrente, as entradas não são independentes entre si. Os resultados para cada componente dependem do processamento executado pelos componentes que o precedem.

A utilização mais comum de RNRs ocorre em previsões e aplicações de séries temporais, em análises de sentimento e em aplicações textuais.

5.2 Redes neurais convolucionais (RNCs)

A rede neural convolucional (*convolutional neural network-CNN-ConvNet*) pode ser entendida como aquela que utiliza um algoritmo de aprendizado profundo, capaz de captar uma imagem de entrada, atribuindo importância (pesos e similares que podem ser aprendidos) a diferentes aspectos ou objetos da imagem, sendo capaz de diferenciá-los.

Uma característica que destaca esse tipo de rede está na exigência de capacidade de pré-processamento, a qual é consideravelmente inferior quando comparado a outros algoritmos de classificação. A RNC é capaz de aprender os filtros ou características, enquanto em outros métodos primitivos eles são realizados à mão, baseados em treinamento.

As RNCs possuem cinco tipos de camadas sendo:

- entradas;
- convolução;
- agrupamento;
- completamente conectadas;
- de saída.

Cada camada possui um objetivo específico, a exemplo de resumo, conexão ou ativação. As redes neurais convolucionais dinamizam a classificação de imagens do processo de detecção de objetos. Além disso, elas também têm aplicação em diferentes áreas como a de previsão e processamento de uma linguagem natural.

5.3 Redes neurais autoencoder

O entendimento de autoencoder se dá como uma técnica de aprendizado não supervisionado, em que utilizamos redes neurais para executar a tarefa de aprendizado de representação. Esse tipo de rede neural visa efetuar uma cópia de suas entradas em suas saídas. Operam compactando a entrada em uma representação de espaço latente. Depois disso, reconstroem a saída dessa representação.

Sua utilização está na criação de abstrações denominadas *encoders*, geradas a partir de um conjunto estipulado de entradas. Mesmo sendo similares aos modelos tradicionais de redes neurais, as redes neurais autoencoder buscam

efetuar uma modelagem das entradas de maneira autônoma. Dessa forma, o método é considerado não supervisionado.

Essas redes têm como objetivo a redução da sensibilidade do que for irrelevante, aumentando aquilo que de fato é relevante. À medida que novas camadas são adicionadas, diferentes abstrações são formuladas em camadas mais elevadas (camadas adjacentes ao local onde uma camada decodificador é inserida). As abstrações poderão então ter sua utilização em classificadores tanto lineares como não lineares.

5.4 Redes neurais *feedforward*

Uma rede neural *feedforward* possui a característica de que cada camada se encontra conectada à próxima camada. Contudo, não existe caminho de volta. Dessa forma, todas as conexões seguem a mesma direção a partir da camada de entrada, indo em direção à camada de saída.

Diferentes formas de se estruturar uma rede *feedforward* podem ser encontradas. O que se precisa fazer nesse modelo de rede é:

- camada de entrada;
- camada intermediária;
- camada de saída.

Mesmo existindo algumas técnicas básicas, são necessários alguns experimentos de maneira a definir a estrutura da rede.

Podemos entender que essas redes possuem cada perceptron localizado em uma camada, conectado a todo perceptron da próxima camada. Uma informação sempre é entregue de forma antecipada de uma camada seguinte, em um sentido único de fluxo. Nessas redes não ocorrem loops de feedback.

5.5 Visão das redes neurais artificiais

Apesar dos avanços nas pesquisas com redes neurais, ainda podem ser identificados problemas que não podem ser ensinados aos computadores devido ao elevado nível de complexidade. Em alguns casos, podemos utilizar métodos menos elaborados, os quais se apresentam como mais eficientes na execução de tarefas.

De uma maneira geral, ao final de uma etapa de treinamento, ocorre o desligamento do aprendizado, interrompendo o aperfeiçoamento da rede neural.

Entretanto, podem ser encontrados alguns sistemas de recomendação como os utilizados pelo Spotify e pelo Netflix, em que as redes neurais realizam uma constante adaptação, fornecendo sugestões aos usuários sobre músicas e filmes.

Quanto ao funcionamento das redes neurais, por não conhecermos ainda muito bem o funcionamento do cérebro humano, vemos nas redes neurais virtuais uma semelhança com o que se observa em ambos. Dessa forma, podemos destacar que alguns modelos de redes neurais são mais plausíveis que outros, segundo as funções biológicas.

As redes neurais se apresentam como sistemas inteligentes, uma vez que podemos ver em modelos multicamadas que a capacidade de reconhecimento e classificação são superiores se comparadas com a dos seres humanos. Da mesma forma que estamos observando o mundo a todo momento, capturando imagens, analisando e efetuando a tomada de decisões com base nos sinais que estamos recebendo, os sistemas de redes neurais possibilitam aos sistemas computacionais um desenvolvimento para que se tornem mais inteligentes.