

| MINERAÇÃO DE DADOS

TEMA 1 – CONCEITOS E USO

A mineração de dados (*data mining*) pode ter seu entendimento como sendo um conjunto de técnicas e procedimentos que visam estratificar informações em nível semântico elevado, partindo de dados brutos. Ela possibilita a análise de enormes bases de dados para geração de conhecimento, podendo ser em um formato de regras descritivas de dados por meio de modelos que possibilitem uma classificação de dados não conhecidos, partindo de uma análise prévia de dados conhecidos. Pode ainda utilizar modelos de previsões ou de detecção de anomalias.

É ampla a quantidade e a variedade de informações disponíveis em um ambiente de redes como a internet. Essas informações, mesmo que sejam de fácil acesso, em muitos casos apresentam dificuldades em sua localização. Existem, por exemplo, sites na internet que efetuam uma indexação de informações categorizadas de forma controlada e organizada, exigindo uma certa demanda computacional e/ou humana. Nesse modelo de site de internet, temos os exemplos do Internet Movie Database¹ ou mesmo o SourceForge². Existem também sites que efetuam uma indexação de conteúdo externo. Isso possibilita uma busca pela utilização de palavras-chave ou outras formas mais complexas de busca. Nesse formato, temos os exemplos do Google³ ou Bing⁴.

Além dessas, outras formas de funcionamento são encontradas, a exemplo dos portais que apresentam informações externas, ou seja, inseridas em outros sites, de maneira categorizada e com personalização do conteúdo.

Nessa visão, podemos entender que os dados são rapidamente coletados, de uma maneira simples e de forma automática, sendo armazenados em enormes volumes com custo baixo. Por outro lado, as informações encontram-se em um nível semântico mais elevado, podendo ter sua obtenção oriunda de dados mediante técnicas de interpretação, classificação, anotação, sumarização, agrupamento, associação, entre outras.

A mineração de dados contempla muitas delas por meio de um conjunto de técnicas, procedimentos, ferramentas ou ainda algoritmos:

¹ Disponível em: <<https://www.imdb.com/>>. Acesso em: 25 mar. 2020.

² Disponível em: <<https://sourceforge.net/>>. Acesso em: 25 mar. 2020.

³ Disponível em: <<https://www.google.com/>>. Acesso em: 25 mar. 2020.

⁴ Disponível em: <<https://www.bing.com/>>. Acesso em: 25 mar. 2020.

-
- a) Classificação: constrói um modelo qualquer com possibilidade de aplicação em dados não classificados, buscando efetuar uma categorização em classes. Os objetos são avaliados e classificados conforme uma classe previamente definida. Pode ter seu uso na classificação de solicitações de crédito, ou ainda, na elucidação de fraudes contra o imposto de renda.
 - b) Regressão: consiste na aprendizagem de uma função que realize o mapeamento de um determinado item de dado para uma variável de predição estimada. Sua utilização pode ocorrer na prevenção de futuras demandas por novos produtos ou na estimativa sobre a expectativa de vida de uma população.
 - c) Associação: visa identificar grupos de dados em que ocorram concorrência entre eles. A aplicabilidade desta técnica pode ocorrer na busca de informações que levem a aproximar produtos distintos em carrinhos de supermercado.
 - d) Detecção de desvios ou *outliers*: tem por objetivo identificar dados que se distanciam de um padrão previsto. Pode ser utilizada em sistemas de segurança para identificação de possível tentativa de invasão.
 - e) Segmentação, agrupamento ou *clustering*: se baseia em particionar uma população heterogênea, efetuando sua distribuição em subgrupos ou mesmo grupos nos quais se identifiquem de maneira mais homogênea. Sua utilização pode ser aplicada para avaliar o comportamento de clientes nas compras que realizam pela internet para futura utilização. Pode ainda ser utilizada para identificar clientes que apresentem um comportamento de compras semelhante.

1.1 Agrupamento

Os métodos de análise de agrupamentos permitem extrair características interessantes a partir de dados, classificando-os em grupos funcionais ou hierarquizados para posterior estudo. A análise de agrupamento também é conhecida como *clustering* e pode ser entendida como um conjunto de técnicas computacionais que tem como objetivo separar objetos em grupos, com base em características desses objetos.

O princípio básico está em colocar em um mesmo grupo os objetos que se apresentam como similares conforme algum critério preestabelecido. Em diversos casos, esse critério é baseado em uma função de dissimilaridade, a qual recebe

dois objetos e calcula a distância que existe entre eles. Assim, esse método de análise deve agrupar em um conjunto os elementos mutuamente similares, e que se apresentem extremamente diferentes dos elementos de outros conjuntos.

Os objetos para classificação recebem a denominação de *exemplos*, *registros* e/ou *tuplas*, sendo que cada um representa uma entrada de dados, podendo existir em sua constituição um vetor de atributos, sendo este composto por campos numéricos ou categóricos. O campo categórico pode assumir um entre um conjunto de valores preestabelecidos.

Entre alguns exemplos de dados numéricos, estão:

- idade (número inteiro);
- temperatura (número real);
- salário (número real).

Já entre exemplos de dados categóricos, temos:

- bases de DNA (valores possíveis: A, C, G ou T);
- pessoa doente (valor Booleano que pode ser Verdadeiro ou Falso);
- patente militar (soldado, cabo, sargento, tenente, capitão etc.).

A análise de agrupamento se apresenta como uma ferramenta produtiva no processo de análise de dados em diversas situações, sendo capaz de efetuar uma redução na dimensão de um conjunto de dados. Ela tem a capacidade de efetuar a redução de uma elevada quantidade de objetos em informação central de seu conjunto.

Diferentemente do processo de classificação, que opera com aprendizado supervisionado, o *clustering* é uma técnica de aprendizado não supervisionado que pode ter a função de extrair características ocultas nos dados, desenvolvendo as hipóteses acerca de sua natureza.

1.2 Associação

As regras de associação têm a função de descobrir elementos encontrados em comum, inseridos em um determinado conjunto de dados. O objetivo dessas regras é localizar elementos que implicam na presença de outros encontrados em uma mesma transação. Para isso, efetua uma busca para localizar relacionamentos ou padrões frequentemente presentes entre os conjuntos de dados.

No ano de 1993, foi idealizado o primeiro problema de mineração de regras de associação. Essas regras foram mineradas de bases de dados de transações, ou bases transacionais.

Para entender melhor o conceito e funcionamento dessas regras, podemos exemplificar, sendo $I = \{I_1, I_2, \dots, I_n\}$ um conjunto de itens e D uma base de dados de transações, onde cada transação T é composta por um conjunto de itens onde $T \subseteq I$. As transações possuem um identificador chamado TID , individualmente. Nesse contexto, podemos entender que uma regra de associação é uma pressuposição da forma $A \rightarrow B$, onde A e B poderiam ser conjuntos compostos por um ou mais itens, $A \subseteq I$, $B \subseteq I$, e $A \cap B = \emptyset$. A é denominado de *antecedente* da regra e o B é denominado de *consequente*.

1.2.1 Funcionamento da regra de associação

A utilização de algoritmos que operam por meio de regras de associação está relacionada diretamente à enorme quantidade de aplicações possíveis para essas regras. Diferentes questões inerentes a características relacionadas ao consumo já são muito analisadas, visando a maximização da quantidade de vendas, indo mais além, com a quantidade de vendas de produtos específicos. Com a mineração de dados com regras de associação, surgem questões como:

- Quais as características de quem está comprando o produto Z ?
- Além do produto W , o que usualmente é comprado junto?
- Nas compras conjuntas, quais os componentes que normalmente são adquiridos simultaneamente?
- Os clientes que adquirem um produto X ou Y , na sequência compra qual produto?

O exemplo mais utilizado para funcionamento da regra de associação encontrado na literatura se refere à compra de fraldas e cerveja em conjunto. Nesse exemplo, um determinado supermercado elevou a venda de cervejas apenas, realocando-as próximas ao local de fraldas. Para esse exemplo, as regras de associação avaliadas indicaram que os clientes que efetuavam a compra de fraldas adquiriam também cervejas, considerando uma margem de erro, e colocando estes dois produtos em conjunto, aumentariam as vendas.

O algoritmo utilizado efetuou apenas a indicação da relação existentes entre os dois produtos e, com base nisso, uma ação foi tomada. A regra nesse exemplo poderia ser:

- Se um cliente compra o produto X1 e o produto X9, ele também comprou o produto X3 em 75% dos casos. Esta regra considera seu uso em 25% dos casos que foram estudados.

Conforme o exemplo, poderíamos formalizar em dois conjuntos que poderiam conter apenas um ou mais elementos. Consideremos os conjuntos 1 e 2 com regras de associação em que cada uma contém 2 parâmetros.

Logo, o primeiro parâmetro define o suporte, apresentando um percentual da quantidade de vezes em que é encontrado o conjunto 1 em um conjunto de transações C. No exemplo, o valor seria de 25% para esse suporte, isso significa que a regra tem aplicação em 25% dos casos que sofreram estudos.

Como segundo parâmetro, temos um indicador relativo à confiança, indicando um percentual em que essa regra é encontrada. Ainda para o exemplo, o valor estaria em 75%, indicando que em 20% dos casos em que os produtos X1 e X9 aparecem ocorre também a existência do produto X3.

Esses parâmetros de suporte e confiança evidenciam o funcionamento do algoritmo de maneira vital, determinando não apenas a quantidade, mas também a qualidade das regras que forem geradas. A necessidade de entender e utilizar esses parâmetros é imprescindível na criação das regras de associação.

Esse formato de análise de produtos elaborado na transação, mais comumente conhecido como *carrinho de compras* ou *cesta de produtos*, é classificada como *Market Basket Analysis*.

1.3 Outliers

A detecção de *outliers* ou de anomalias pode ser entendida como um processo de observação de itens e eventos como dados raros que são diferentes da maioria dos outros dados. Também conhecida como *detecção de desvios*, identifica dados que deveriam seguir um padrão esperado, mas não seguem. Um exemplo de sua utilização está na detecção de intrusão em redes de computadores.

Conforme esse exemplo, podemos dizer que os objetos de interesse usualmente não se classificam como raros. Ao contrário disso, aparecem da mesma forma que uma atividade viral em uma epidemia; ou seja, surgem como

surtos inesperados de atividades. Para esses casos, a identificação de uma anomalia seria capaz de identificar essas irregularidades referentes a esses objetos.

De maneira geral, podem existir diferentes técnicas para detecção de anomalias:

- Detecção de anomalia supervisionada: necessita que seja previamente informado um conjunto de dados como padrão de normalidade e como padrão de anormalidade, requisitando um treinamento de um classificador.
- Detecção de anomalia semi-supervisionada: parte da construção de um modelo que representa o comportamento normal de um conjunto de dados de treinamento, efetuando testes de probabilidade em uma instância de teste gerada.
- Detecção de anomalia não supervisionada: efetua a detecção de anomalias em um conjunto de testes não rotulado, pressupondo que em sua maioria as instâncias no conjunto de dados estão classificadas como normal. Dessa forma, busca instâncias diferenciadas que se distanciam de um padrão do restante do conjunto de dados.

TEMA 2 – ALGORITMOS DE *CLUSTERING* CONVENCIONAIS (K-MEANS)

O k-means é um dos algoritmos mais utilizados na área de agrupamento. Ele pode ser considerado como uma heurística de agrupamento não hierárquico, que visa minimizar a distância entre os diferentes elementos em relação a um conjunto de k centros, baseado em $\chi = \{X_1, X_2 \dots, X_{1k}\}$ de uma maneira iterativa. A distância entre um ponto P_i e um conjunto de *clusters*, é dada por $d(XP_i, \chi)$ sendo definida pela distância do ponto ao seu centro adjacente. Minimizando a função temos:

$$D(P, \chi) = \frac{1}{n} \sum_{i=1}^n d(P_i, \chi)^2$$

Existe a necessidade da definição do parâmetro k (número de *clusters*) pelo usuário de maneira *ad hoc*, que é uma dificuldade encontrada devido a não se saber quantos *clusters* existem.

2.1 Descrevendo o algoritmo K-Means

Para um entendimento funcional sobre o funcionamento do algoritmo K-Means, podemos destacar quatro etapas que são:

- a) estabelecer o valor k , determinando diferentes valores para os centros dos grupos, sendo a forma mais comum a aleatória;
- b) definir a associação, relacionando cada ponto ao centro mais próximo;
- c) refazer os cálculos, recalculando o centro de cada grupo;
- d) efetuar um laço de etapas de maneira repetitiva, pelo processo de repetição das etapas b) e c), enquanto houver elementos que estejam alterando seu grupo.

A característica apresentada neste algoritmo está na rapidez, usualmente convergindo para poucas iterações em uma configuração estável, em que não existem elementos designados a um *cluster* com centro não sendo o mais próximo.

2.2 Utilização do algoritmo K-Means (método particional)

O método particional é uma categorização dos métodos de *clustering*. Para seu entendimento, temos que partindo de um conjunto de dados com n instâncias, o método gera k partições de dados, em que cada partição representa individualmente um grupo e $k \leq n$. Uma partição inicial é gerada pelo método que utiliza então uma técnica de realocação iterativa buscando a melhoria do particionamento.

O algoritmo K-Means é um algoritmo de método por particionamento que visa agrupar produtos ou objetos baseado em características comuns a ambos. Diversos problemas cotidianos podem sofrer o uso do K-means como possível solução.

Para um melhor entendimento, vamos utilizar como exemplo uma loja de roupas em que produtos se encontram organizados por sessões. Essas sessões poderiam ser calças, calçados, camisas, facilitando o acesso a produtos com base em suas características.

Outro exemplo estaria em um grupo de pessoas no qual podemos encontrar um grupo de homens, um grupo de mulheres e outro de crianças.

A atividade de agrupar objetos e outras coisas se apresenta como extremamente útil em nossas vidas. No campo de *data science*, ocorre da mesma

forma. Com base no agrupamento, podemos, por exemplo, oferecer uma campanha de marketing mais precisa, personalizando o conteúdo aos clientes. Outro exemplo que podemos ter aplica-se ao setor médico, em que pacientes que apresentem sintomas de doença semelhantes podem se beneficiar por diagnósticos em situações similares.

TEMA 3 – ALGORITMOS HIERÁRQUICOS (DENDOGRAMAS)

A definição de algoritmos hierárquicos compreende que em sua função organizam os dados conforme uma estrutura hierárquica. Essa estrutura poderá ser interpretada similarmente a uma sucessão de partições rígidas de forma aninhada.

Os resultados obtidos para esse algoritmo não representam apenas uma partição do conjunto de dados inicial, sendo uma hierarquia que demonstra um particionamento diferenciado por nível analisado. No conjunto ou agrupamento hierárquico, os dados são agrupados de maneira em que dois exemplos se encontram agrupados em algum momento. Para as próximas iterações, eles continuarão participando do mesmo grupo, ainda que ocorram suas participações em diferentes novos grupos genéricos. Esse agrupamento hierárquico pode ser apresentado como um dendograma, sendo este um diagrama do tipo árvore, em que os nós pais centralizam os exemplos que os filhos representam.

3.1 Métodos hierárquicos

Um método hierárquico para análise de *cluster* caracteriza-se como um algoritmo que fornece diferentes tipos de partição de dados. Ele tem a capacidade de criar diversos agrupamentos em que um *cluster* pode ser somado a outro em algum passo do algoritmo.

Para execução do método, não se faz necessário uma quantidade inicial de *clusters*, sendo considerados inflexíveis por impossibilitarem a troca de um elemento do grupo. Eles são classificados em dois tipos ou dois métodos:


- Aglomerativo: inicialmente, todos os elementos estão desanexados, sendo agrupados por etapas até que exista apenas um *cluster* contendo esses elementos. Para a quantidade de *clusters*, ocorre uma escolha entre as opções possíveis.

- Divisivos: todos os elementos iniciam agrupados em um único *cluster*, e separados individualmente até que ocorra o cenário em que cada um dos elementos se torne seu próprio *cluster*. Da mesma maneira que no método aglomerativo, deve ser indicado o melhor número de *clusters* entre as combinações possíveis.

3.2 Dendograma

Um dendograma é utilizado para a visualização de um processo de clusterização passo a passo analisando diferentes níveis de distância dos *clusters* que se formarem.

Figura 1 – Exemplo de dendograma



Assim, o dendograma pode ser entendido como sendo um diagrama do tipo árvore que apresenta os grupos formados por um agrupamento de observações para cada etapa e em seus níveis de semelhança. O nível de semelhança ou similaridade é demonstrado pelo eixo vertical e as observações são apresentadas no eixo horizontal.

TEMA 4 – ALGORITMO DE REGRAS DE ASSOCIAÇÃO

Os softwares que iniciaram a mineração de dados utilizando regras de associação tiveram seu desenvolvimento em meados da década de 90 em ambiente acadêmico. Hoje, diversas empresas de grande porte desenvolvem sistemas comerciais com essa característica. Esses sistemas operam de maneira que o usuário especifique qual a base de dados se deseja minerar, estabelecendo

os padrões mínimos para as medidas de interesse. Dessa forma, fornecendo o *lift*, a estrutura e a segurança.

Nesse contexto, após realizadas essas ações, o sistema efetua a execução de um algoritmo que efetua a análise da base de dados, gerando um conjunto de regras de associação com valores de suporte e confiança acima dos padrões mínimos fornecidos pelo usuário. Assim, o sistema extrai de forma automática as hipóteses e os padrões encontrados na base de dados.

4.1 Exemplo prático do uso da regra de associação

O funcionamento da regra de associação opera sobre a execução de um processo. Para melhor entendê-lo, vamos adotar um exemplo utilizando uma base de dados que contém as compras de clientes que foram efetuadas em um supermercado.

Quadro 1 – TID: Produtos Comprados

1 biscoito, cerveja, chá, alcatra	2 cerveja, alface, salsicha, pão, queijo
3 café, cebola, alface, pão	4 cebola, café, cerveja, alface, pão, alcatra
5 cebola, café, alface, pão, refrigerante	6 alface, salsicha

Cada uma das entradas no banco de dados contém a relação dos produtos adquiridos por cliente. Utilizando a regra de associação nessa base de dados poderíamos ter: $\{cerveja\} \Rightarrow \{alcatra\}$.

- Das seis transações da base de dados, duas contêm $\{cerveja\}$ e $\{alcatra\}$.
- Suporte da regra: $2 / 6 = 33,33\%$.
- Duas transações contêm $\{cerveja\}$ e $\{alcatra\}$ e três transações contêm o produto $\{cerveja\}$.
- A confiança da regra $\{cerveja\} \Rightarrow \{alcatra\}$ pode então ser calculada da seguinte maneira: $2 / 3 = 66,67\%$.

Este índice percentual demonstra que 66,67% dos consumidores que compraram $\{cerveja\}$ também compraram $\{alcatra\}$.

4.2 Regra de associação transacional

Para a mineração de dados, podem ser utilizadas regras de associação para extração em bases de dados de transações. Quando isso ocorre, essas regras têm a nomenclatura de regras de associação transacionais ou regras de associação convencionais.

Quadro 2 – Exemplo de uma base de dados transacional

1	biscoito, cerveja, chá, alcatra
2	cerveja, alface, salsicha, pão, queijo
3	café, cebola, alface, pão
4	cebola, café, cerveja, alface, pão, alcatra
5	cebola, café, alface, pão, refrigerante
6	alface, salsicha

Ao analisar esse exemplo de base de dados transacional, poderíamos minerar conforme: $\{alface\} \rightarrow \{cebola\}$. O destaque dessa regra está no valor de 50% referente ao suporte, ou seja, metade dos clientes efetuou a compra dos dois produtos ao mesmo tempo. Esse fato ocorre com 60% de confiança, indicando que 60% dos clientes que levaram a alface também levaram a cebola.

4.3 Regra de associação híbrida

Quando utilizamos um tipo diferenciado de regra multidimensional, na qual uma de suas dimensões tem possibilidade de ser encontrada de maneira repetida na própria regra, estamos utilizando uma regra de associação híbrida. Para entender melhor podemos ter:

$(Sexo = "M") \wedge (Casado = "N") \wedge (Produto = "cerveja") \rightarrow (Produto = "alcatra")$

Uma regra assim indicaria que os consumidores solteiros do sexo masculino que levam cerveja têm uma possibilidade maior de levar também alcatra. Foram envolvidas nessa regra três dimensões, ocorrendo a incidência do produto em aparecer mais de uma vez. É importante salientar que esta regra utiliza dados pessoais dos clientes, envolvendo os produtos adquiridos por eles.

TEMA 5 – OUTLIERS: DETECÇÃO DE ANOMALIAS

A detecção de anomalias constitui-se da utilização de técnicas que identificam padrões de comportamento inesperado, sendo estes considerados eventos ou observações que criam uma suspeita de problema. Essa técnica de detecção possibilita uma ampla gama de aplicações possíveis. Dentre elas, está o marketing digital, em que enorme quantidade de informações é gerada e coletada em ambiente on-line. Nesse cenário, as anomalias ou *outliers* são de fundamental interesse. As anomalias ou eventos raros podem impactar tanto positivamente quanto negativamente aos objetivos desejados. Com uso de técnicas de detecção, é possível antecipar essas ocorrências, proporcionando maior efetividade para a tomada de decisão, impactando, por exemplo, em ganhos para um negócio.

5.1 Entendendo anomalia e outliers

Observando um agrupamento de dados reais, não é raro o aparecimento de casos com comportamento diferente da maioria. Esses casos são denominados de *anomalias* em *machine learning* (aprendizado de máquina). Na área da estatística, esse mesmo fenômeno é denominado de *outliers*. Na prática, não existe uma diferença entre os dois termos utilizados, podendo ser utilizado qualquer dos termos de maneira equivalente para diferentes situações.

5.2 Tipos de anomalias

Para determinar qual a técnica de detecção de anomalia deverá ser utilizada, deve-se primeiramente identificar a natureza ou a origem da anomalia que se pretende estudar. De maneira geral, existem três categorias, sendo elas pontuais, de contexto e coletivas.

5.2.1 Anomalias pontuais (*point anomalies*)

Esse tipo de anomalia acontece na situação onde um caso individual dos dados é tido como anômalo em comparação ao restante dos dados. Na maioria das pesquisas acerca de detecção de anomalias, é utilizado este tipo simplificado de anomalia.

As fraudes nas transações de *e-commerce* são um exemplo para o uso da detecção de anomalia pontual. Abordando o valor da transação como uma

característica, quando existir uma ocorrência de transação com valor elevado em comparação à média de gastos que uma pessoa realiza, ocorre uma anomalia pontual.

5.2.2 Anomalias de contexto (*contextual anomalies*)

Esse tipo de anomalia é conhecido também como *anomalia condicional*, na qual encontra-se uma ocorrência de um caso de maneira individual em um contexto. Como exemplo, podemos evidenciar a quantidade de sessões abertas no Google Analytics em uma determinada série temporal. Nesse caso, pode acontecer de dois pontos da série obterem o mesmo volume de sessões. Contudo, o contexto em um dos pontos poderia indicar uma anomalia.

Nesse exemplo, poderíamos considerar de forma um pico de sessões em uma Black Friday como não sendo uma anomalia. Ao observarmos esse critério, não podemos deixar de avaliar que um pico elevado de sessões em outra sexta-feira comum, poderia sim ser uma anomalia.

5.2.3 Anomalias coletivas (*collective anomalies*)

Este tipo de anomalia caracteriza um conjunto de dados anômalo. É necessária uma relação para o conjunto de dados sendo ele espacial, sequencial ou grafo. Para melhor entendermos, podemos exemplificar com uma anomalia decorrente da queda inesperada de vendas em um *e-commerce* por um período de algumas horas. Dentro de um padrão de normalidade, podemos dizer que é natural que as vendas sejam baixas em algumas horas do dia, como no período da madrugada. Porém, ao serem identificados diversos pontos estagnados nesse cenário de poucas vendas, existe um indicativo de ocorrência de uma anomalia.