

Aula 5

Mineração de Dados

Prof. Roberson Cesar Alves de Araújo

Conceitos e Uso

Conceito fundamental

- Conjunto de técnicas e procedimentos que visam a estratificar informações em nível semântico elevado, partindo de dados brutos



Conceito fundamental



Técnicas de mineração de dados

- Utiliza basicamente 5 conjuntos de técnicas, procedimentos, ferramentas ou ainda algoritmos:
 - Classificação:** constrói um modelo qualquer com possibilidade de aplicação em dados não classificados, buscando efetuar uma categorização em classes. Usado na classificação de solicitações de crédito, ou ainda, na elucidação de fraudes contra o imposto de renda
- (...)

(...)

- Regressão:** aprendizagem de uma função que realize o mapeamento de um determinado item de dado para uma variável de predição estimada. Utilizada na prevenção de futuras demandas por novos produtos ou na estimativa sobre a expectativa de vida de uma população
 - Associação:** identifica grupos de dados que concorram entre si. Utilizada na busca de informações que levem a aproximar produtos distintos em carrinhos de supermercado
- (...)

(...)

4. Detecção de desvios ou *outliers*: identifica dados que se distanciam de um padrão previsto. Pode ser utilizada em sistemas de segurança para identificação de possível tentativa de invasão


(...)

(...)

5. Segmentação, agrupamento ou *clustering*: particiona uma população heterogênea, efetuando sua distribuição em subgrupos ou mesmo grupos com os quais se identifiquem de maneira mais homogênea. Pode avaliar o comportamento de clientes nas compras que realizam pela internet para futura utilização. Pode ainda ser utilizada para identificar clientes que apresentem um comportamento de compras semelhante

Agrupamento (método de análise)

- Também chamada de *clustering*, visa a extrair características interessantes a partir de dados, classificando-os em grupos funcionais ou hierarquizados para posterior estudo



Agrupamento (método de análise)

- Princípio básico: colocar, em um mesmo grupo, os objetos que se apresentam como similares conforme algum critério pré-estabelecido. Em diversos casos, esse critério é baseado em uma função de dissimilaridade, a qual recebe dois objetos e calcula a distância que existe entre eles



Associação

- Tem a função de descobrir elementos encontrados em comum, inseridos em um determinado conjunto de dados



Associação

- Questões que busca resolver:
 - Quais as características de quem está comprando o produto Z?
 - Além do produto W, o que usualmente é comprado junto?

(...)


(...)

- Nas compras conjuntas, quais os componentes que normalmente são adquiridos simultaneamente?
- Os clientes que adquirem um produto X ou Y na sequência compram qual produto?

- Exemplos de dados numéricos:
 - Idade (número inteiro)
 - Temperatura (número real)
 - Salário (número real)
- Exemplos de dados categóricos:
 - Bases de DNA (valores possíveis: A, C, G ou T)
 - Pessoa doente (valor booleano que pode ser verdadeiro ou falso)
 - Patente militar (soldado, cabo, sargento, tenente, capitão...)

Outliers ou detecção de anomalias

- Processo de observação de itens e eventos como dados raros que se apresentam como diferenciados da maioria dos outros dados
- Detecção de anomalia supervisionada: necessita que seja previamente informado um conjunto de dados como padrão



- Detecção de anomalia semissupervisionada: parte da construção de um modelo que representa o comportamento normal de um conjunto de dados de treinamento
- Detecção de anomalia não supervisionada: efetua a detecção de anomalias em um conjunto de testes não rotulado pressupondo que em sua maioria as instâncias no conjunto de dados estão classificadas como normal

Algoritmos de *Clustering* Convencionais

K-means


- Algoritmos mais utilizados na área de agrupamento
- Heurística de agrupamento não hierárquico que visa a minimizar a distância entre os diferentes elementos em relação a um conjunto de k centros, baseado em $\chi = \{X_1, X_2, \dots, X_{1k}\}$ de uma maneira iterativa

- A distância entre um ponto P_i e um conjunto de *clusters* é dada por $d(X^{P_i}, \chi)$, sendo definida pela distância do ponto ao seu centro adjacente. Minimizando a função, temos:

- $D(P, \chi) = \frac{1}{n} \sum_{i=1}^n d(P_i, \chi)^2$

Quatro etapas do *k-means*

- Estabelecer o valor k , determinando diferentes valores para os centros dos grupos
- Definir a associação, relacionando cada ponto ao centro mais próximo
- Refazer os cálculos, recalculando o centro de cada grupo
- Efetuar um laço de etapas de maneira repetitiva, pelo processo de repetição das etapas (b) e (c), enquanto houver elementos que estejam alterando seu grupo



ShadeDesign / Shutterstock

K-means – método particional

- Categorização dos métodos de *clustering*
- Exemplos:
 - Uma loja de roupas em que produtos se encontram organizados por sessões. Essas sessões poderiam ser calças, calçados, camisas, facilitando o acesso a produtos com base em suas características
 - Um grupo de pessoas no qual podemos encontrar um grupo de homens, um grupo de mulheres e outro de crianças



Designincolor / Shutterstock

Algoritmos Hierárquicos (Dendogramas)

Algoritmos hierárquicos (dendogramas)

- Organizam os dados conforme uma estrutura hierárquica
- Resultados obtidos pelo algoritmo:
 - Mais que uma partição do conjunto de dados inicial
 - Hierarquia que demonstra um particionamento diferenciado por nível analisado


Algoritmos hierárquicos (dendogramas)

- Conjunto ou agrupamento hierárquico: dados são agrupados de maneira com que dois exemplos encontram-se agrupados em algum momento
- Para as próximas iterações, eles continuarão participando do mesmo grupo, mesmo participando de diferentes novos grupos genéricos

- O agrupamento hierárquico pode ser apresentado como um dendograma, sendo esse um diagrama do tipo árvore em que os nós pais centralizam os exemplos que os filhos representam

Métodos hierárquicos


- Capacidade de criar diversos agrupamentos, em que um *cluster* pode ser somado a outro em algum passo do algoritmo



Classificação dos métodos hierárquicos

- Aglomerativo: todos os elementos se iniciam desanexados, sendo agrupados por etapas até que exista apenas um *cluster* contendo esses elementos
- Divisivos: todos os elementos iniciam agrupados em um único *cluster* e separados individualmente até que ocorra o cenário em que cada um dos elementos se torne seu próprio *cluster*


Agrupamento (método de análise)



Dendograma

- Utilizado para a visualização de um processo de clusterização passo a passo, analisando diferentes níveis de distância dos *clusters* que se formarem
- Tipo árvore: apresenta os grupos formados por um agrupamento de observações para cada etapa e em seus níveis de semelhança
- O nível de semelhança ou similaridade é demonstrado pelo eixo vertical, e as observações são apresentadas no eixo horizontal

Dendrograma



Elaborado pelo autor Roberson Cesar Alves de Araujo (2020)

Algoritmos de Regras de Associação

Regras de associação - algoritmos

- Os **softwares** que iniciaram a mineração de dados utilizando regras de associação tiveram seu desenvolvimento em meados da década de 90 em ambiente acadêmico
- Evoluíram hoje em larga escala comercial (**softwares**)



amolaw / Shutterstock

Regras de associação - algoritmos

- Efetuem análise da base de dados gerando um conjunto de regras de associação com valores de suporte e confiança acima dos padrões mínimos fornecidos pelo usuário
- Assim, o sistema extrai, de forma automática, as hipóteses e os padrões encontrados na base de dados

Exemplo prático - regras de associação

- Base de dados que contém as compras de clientes que foram efetuadas em um supermercado

TID - Produtos Comprados

1 biscoito, cerveja, chá, alcatra	2 cerveja, alface, salsicha, pão, queijo
3 café, cebola, alface, pão	4 cebola, café, cerveja, alface, pão, alcatra
5 cebola, café, alface, pão, refrigerante	6 alface, salsicha

- Cada uma das entradas no banco de dados contém a relação dos produtos adquiridos por um cliente. Utilizando a regra de associação nessa base de dados poderíamos ter:
 - {cerveja} $\Rightarrow$ {alcatra}
 - Das 6 transações da base de dados, 2 contém {cerveja} e {alcatra}
 - Suporte da regra: $2 / 6 = 33,33\%$
 - 2 transações contém {cerveja} e {alcatra} e 3 transações contém o produto {cerveja}
 - (...)

(...)

- A confiança da regra {cerveja} $\rightarrow$ {alcatra} pode então ser calculada da seguinte maneira:
 - ✓ $2 / 3 = 66,67\%$
 - ✓ Este índice percentual demonstra que 66,67% dos consumidores que compraram {cerveja} também compraram {alcatra}

Regras de associação transacional

- Regras de associação para extração em bases de dados de transações. Quando isso ocorre, essas regras têm a nomenclatura *de regras de associação transacionais* ou *regras de associação convencionais*
- Exemplo de uma base de dados transacional:

1	biscoito, cerveja, chá, alcatra
2	cerveja, alface, salsicha, pão, queijo
3	café, cebola, alface, pão
4	cebola, café, cerveja, alface, pão, alcatra
5	cebola, café, alface, pão, refrigerante
6	alface, salsicha

- Ao analisar esse exemplo de base de dados transacional, poderíamos minerar conforme: {alface} $\rightarrow$ {cebola}
- O destaque dessa regra está no valor de 50% referente ao suporte, ou seja, a metade dos clientes efetuou a compra dos dois produtos ao mesmo tempo
- Esse fato ocorre com 60% de confiança, indicando que 60% dos clientes que levaram a alface levaram também a cebola

Regras de associação híbrida


- Tipo diferenciado de regra multidimensional, na qual uma de suas dimensões tem possibilidade de ser encontrada de maneira repetida na própria regra
- (Sexo = "M") $\rightarrow$ (Casado = "N") $\rightarrow$ (Produto = "cerveja") $\rightarrow$ (Produto = "alcatra")

- Uma regra assim indicaria que os consumidores solteiros, do sexo masculino e que levam cerveja, têm uma possibilidade maior de levar também alcatra
- Foram envolvidas nessa regra três dimensões, ocorrendo a incidência do produto mais de uma vez
- Essa regra utiliza dados pessoais dos clientes, envolvendo os produtos adquiridos por eles

Outliers – Detecção de Anomalias

Outliers - Técnicas

- Detecção de anomalias constitui a utilização de técnicas que identificam padrões de comportamento inesperado, sendo eles considerados eventos ou observações que criam uma suspeita de problema



Outliers – exemplo do uso das técnicas de detecção

- **Marketing digital:**
 - Enorme quantidade de informações gerada e coletada em ambiente digital
- (...)

(...)

- Anomalias, *outliers* ou eventos raros são de fundamental interesse, pois podem impactar tanto positiva quanto negativamente os objetivos desejados
- É possível antecipar essas ocorrências, proporcionando maior efetividade para a tomada de decisão, gerando, por exemplo, ganhos para um negócio

Dados importantes - anomalia e outliers

- Observando um agrupamento de dados reais, não é raro o aparecimento de casos com comportamento diferente da maioria
- Esses casos são denominados de *anomalias* em *machine learning* (aprendizado de máquina)

- Na área da estatística, esse mesmo fenômeno é denominado de *outliers*
- Na prática, não existe uma diferença entre os dois termos utilizados, podendo ser utilizado qualquer um dos termos de maneira equivalente para diferentes situações

Tipos - anomalia e outliers

- Anomalias pontuais (*point anomalies*)
 - Acontecem na situação em que um caso individual dos dados é tido como anômalo em comparação ao restante dos dados. Na maioria das pesquisas acerca de detecção de anomalias, é utilizado esse tipo simplificado de anomalia

- Exemplo: as fraudes nas transações de *e-commerce*. Abordando o valor da transação como uma característica, quando existir uma ocorrência de transação com valor elevado em comparação à média de gastos que uma pessoa realiza, ocorre uma anomalia pontual

Tipos - anomalia e *outliers*

- Anomalias de *Contexto* (*contextual anomalies*), conhecidas também como *anomalias condicionais*
 - Ocorrência de um caso de maneira individual em um contexto
- (...)

(...)

- Exemplo: quantidade de sessões abertas no Google Analytics em uma determinada série temporal
 - Pode acontecer de dois pontos da série obterem o mesmo volume de sessões; contudo, o contexto em um dos pontos poderia indicar uma anomalia

(...)

(...)

- Nesse exemplo, poderíamos considerar um pico de sessões em uma Black Friday como não sendo uma anomalia
 - Ao observarmos esse critério, não podemos deixar de avaliar que um pico elevado de sessões em outra sexta-feira comum poderia sim ser uma anomalia

Tipos - anomalia e *outliers*

- Anomalias coletivas (*collective anomalies*)
 - Caracterizam um conjunto de dados anômalos
 - É necessária uma relação para o conjunto de dados, sendo ele espacial, sequencial ou grafo

- Exemplo: uma anomalia decorrente da queda inesperada de vendas em um *e-commerce* por um período de algumas horas
 - Dentro de um padrão de normalidade, podemos dizer que é natural que as vendas sejam baixas em algumas horas do dia, como no período da madrugada
 - Porém, ao serem identificados diversos pontos estagnados nesse cenário de poucas vendas, existe um indicativo de ocorrência de uma anomalia

