

## Aula 6

### Mineração de Dados

Prof. Roberson Cesar Alves de Araujo

1

### Entendendo técnicas exploratórias – tipos de *clusters*

2


#### Técnicas exploratórias – tipos de *clusters*

- Voltadas aos tomadores de decisão e aos pesquisadores cujo interesse não esteja na criação de um modelo preditivo para outras observações não presentes na amostra



3

- Capacidade interpretativa de dados, de elaboração de gráficos e de interpretação visual



4

#### Análise de *clusters*

- Objetivo principal
  - Efetuar agrupamento de observações que sejam similares conforme critérios estabelecidos, considerando apenas variáveis quantitativas para classificação e critérios dessas observações




5

#### Clustering

- A análise de *clusters* não pode ser confundida como sendo um algoritmo com funções específicas


6

- Classe de problemas que necessitam de solução por um conjunto de algoritmos que diferem entre si, sendo:
  - Forma de gerarem os *clusters*
  - Eficiência com que realiza essa atividade



7

- Grupos ou agrupamentos, inserindo objetos dispersos de maneira que os objetos inseridos no mesmo *cluster* sejam mais semelhantes entre si



8

### Ponderação arbitrária

- Efetuar uma atribuição de pesos diferenciados a diversos casos, respostas ou entrevistas sobre uma observação que aparece em determinados grupos
- Operação com valores quantitativos, distribuição de pesos



9

### Métodos por particionamento *K-means* e *K-medoides* (PAM-CLARA)

10

### Técnicas de análise de agrupamento ou *clustering*

- Métodos de particionamento, hierárquicos, com base na densidade, em *grid*, em modelos por meio de uma abordagem de redes neurais e estatística
- Objetivo
  - Detectar a existência de diferentes grupos inseridos em um conjunto de dados


11

- Grupos para classificação



12

- Função de similaridade em que esse *clustering* particiona um grupo de informações em pequenos conjuntos



13

### *K-means* ou k-médias

- Algoritmos que utilizam *clusters*
- Função de particionar  $n$  observações dentro de  $k$  grupos, sendo cada uma das observações pertencente ao grupo ou conjunto mais próximo da média
- Com base em uma análise e um processo de comparações envolvendo os valores numéricos dos dados

14

- Tabela com colunas como dimensões e as linhas como dados para cada dimensão, ou ainda, pontos ou ocorrências

#### Exemplo

| Dimensão 1 | Dimensão 2 | Dimensão 3 | Dimensão 4 |
|------------|------------|------------|------------|
| Dado A     | Dado B     | Dado C     | Dado D     |
| Dado W     | Dado X     | Dado Y     | Dado Z     |

15

### Resultados com K-medoides (PAM-CLARA)

- Não utiliza uma média como valor central de um conjunto
- Avalia um problema em que busca o centro do próprio grupo, denominado *objeto representativo* ou *medoid*

16

- Dessa forma, sendo  $0_j \in$  ao conjunto  $X$ ,  $k$  é a quantidade de *medoids* e  $M = \{med_1, med_2, \dots, med_k\}$  são os objetos *medoids* que caracterizam os grupos

- Um algoritmo muito utilizado nesse método é o PAM (*Partitioning Around Medoids*), que busca solucionar o problema dos k-medoides em enormes bases de dados

$$f = \text{Minimizar} \sum_{i=1}^k \sum_{0_j \in med_i} d_{ij}$$


17

### Métodos hierárquicos *Cure/Birch*

18

## Métodos de análise de agrupamentos

- Dois métodos que podem ser adotados: hierárquicos e não hierárquicos, sendo que a opção por um deles deve impactar diretamente os conjuntos resultantes




19

## Cure (clustering using representatives)

- Proposta de análise de grandes conjuntos de dados
- Opera com uma estratégia diferenciada, em que os *clusters* são representados individualmente por uma quantidade  $\rho$  de exemplos, subdividida de maneira que descreva a forma do *cluster*
- Pode ter sua execução delineada em seis etapas

20

### Seis etapas do algoritmo Cure (Clustering Using REpresentatives)



21

## Birch (balanced iterative reducing and clustering using hierarchies)


- Método hierárquico
- Elaborado para atender à demanda de análise de um grande conjunto de dados numéricos
- Problemas que ocorrem com métodos de *clustering* aglomerativos são superados, como o problema de escalabilidade e de inabilidade em desfazer aquilo que já foi realizado em passos anteriores

22

- Opera com um resumo de estatísticas para os dados em um *cluster*
- Esses resumos têm a capacidade de efetuar os cálculos de todas as medidas necessárias para as tomadas de decisão realizadas pelo algoritmo *Birch*
- Algoritmo busca criar *clusters* melhores com base nos recursos disponibilizados
- Composto por quatro etapas

23

## Birch (balanced iterative reducing and clustering using hierarchies)



24

## Métodos baseados em densidade (DBSCAN)

## Métodos baseados em densidade

- Assumem que os *clusters* podem ser considerados regiões de alta densidade desmembradas por regiões de baixa densidade no espaço exemplo
- O foco principal está em manter cada exemplo do *cluster* junto a uma vizinhança que contém uma quantidade mínima de vizinhos inseridos em uma esfera com raio R

## Entendendo o DBSCAN (Density-Based Spatial Clustering of Applications With Noise)

- Agrupamento Especial Baseado em Densidade de Aplicações com Ruído
- Densidade associada a um ponto
  - Ocorre mediante a contagem da quantidade de pontos ou nós vizinhos em uma região que se encontra ao redor deste ponto



- Utiliza duas variáveis vitais para sua execução


| Raio da vizinhança ( $\epsilon$ )                                                                                  | Número de vizinhos (MinPts)                                                                                          |
|--------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------|
| Representa a distância máxima para considerar dois elementos como vizinhos, podendo ser utilizada qualquer métrica | Representa a quantidade mínima de vizinhos, incluindo o próprio ponto, para considerar uma concentração ou densidade |

- Classificação ocorre de três formas

| Núcleo (core)                                                 | Borda (border)                                                                                                   | Ruído (noise)                                                                                                 |
|---------------------------------------------------------------|------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------|
| Um ponto c é chamado de núcleo se $ N(c)  \geq \text{minPts}$ | Um ponto b é chamado de borda se $ N(b)  < \text{minPts}$ , mas faz parte da $\epsilon$ -vizinhança de um núcleo | Um ponto n é considerado ruído se $ N(n)  < \text{minPts}$ e não compõe a $\epsilon$ -vizinhança de um núcleo |

## Na prática

- Nesse cenário, o ponto D não está atendendo aos critérios, assim como também não está no raio de nenhum elemento de outro grupo, sendo considerado um ponto de ruído



Fonte: Araujo, 2020

## A avaliação de *clusters*

- Estuda as relações de interdependência existentes entre um conjunto de variáveis interdependentes, possibilitando agrupar elementos conforme suas similaridades e proximidades, considerando esse conjunto de variáveis

## O objeto de avaliação – técnicas de *clustering*

- Tarefa de aprendizado não supervisionada, na qual um conjunto finito de categorias é identificado como agrupamento com base na similaridade intraclasses presente nos dados
- Aplicada para identificar o agrupamento intrínseco entre um conjunto de dados que não são rotulados ou agrupados

## Processo de avaliação ou validação


O que deve ser avaliado?

Os dados a serem utilizados são de fato "clusterizáveis"? Ocorre a existência de estruturas não randômicas nos dados?

Os clusters observados realmente têm relação com os clusters "reais"?

Quando forem dados dois conjuntos de clusters para serem aplicados aos mesmos dados, qual deles apresenta melhor resultado?

## Estrutura para avaliação – etapas de *clustering*



## Aplicações da análise de *cluster*


- Grupos de clientes com base nos padrões de compra
- Biologia
  - Pode ser usado para derivar taxonomias de plantas e animais, categorizar genes com funcionalidades semelhantes e obter informações sobre estruturas inerentes às populações

- Identificação de áreas de uso similar da terra em um banco de dados de observação da terra
- Além disso, também auxilia na identificação de grupos de casas em uma cidade, de acordo com o tipo de casa, valor e localização geográfica

37

- Classificação de documentos na web para descoberta de informações
- Usado em aplicativos de detecção de *outlier*, como detecção de fraude no cartão de crédito
- Na mineração de dados, a análise de *cluster* serve como uma ferramenta para obter informações sobre a distribuição de dados e observar as características de cada *cluster*

38



39