

| MINERAÇÃO DE DADOS

TEMA 1 – ENTENDENDO TÉCNICAS EXPLORATÓRIAS: TIPOS DE *CLUSTERS*

As técnicas exploratórias, também são conhecidas como técnicas de diagnóstico ou técnicas de interdependência, são voltadas principalmente aos tomadores de decisão e aos pesquisadores cujo interesse não esteja na criação de um modelo preditivo para outras observações não presentes na amostra. Essas técnicas têm a função de efetuar um diagnóstico das observações já contidas em uma amostra, não apresentando capacidade preditiva ou inferencial.

Contudo, as técnicas exploratórias são úteis para a tomada de decisão por apresentarem uma capacidade interpretativa de dados, de elaboração de gráficos e de interpretação visual. Dessa forma, podem servir como entradas (INPUTS) para outras técnicas como as de modelos confirmatórios ou inferenciais, como modelos de regressão e modelos de regressão logística. Essas técnicas exploratórias podem ser divididas em outras, como a de *clusters*, também chamadas de “técnicas de aglomerado ou de agrupamento”, análise fatorial por componentes principais (PCA), bem como análise de correspondência simples e de correspondência múltipla (ANACOR e MCA, respectivamente).

O objetivo principal da análise de *clusters* está no agrupamento de observações que sejam similares conforme critérios estabelecidos, considerando apenas variáveis quantitativas para classificação e critérios dessas observações.

1.1 *Clustering*


Clustering é hoje uma das técnicas que mais se destacam na mineração de dados nos casos de análise de dados estatísticos em diferentes áreas, a exemplo do reconhecimento de padrões, aprendizado de máquina, recuperação de informações, bioinformática e análise e tratamento de imagens.

É comum o uso de *clusters* em mineração de dados, ou seja, *clustering*, que pode ser entendido como o uso de grupos ou agrupamentos, inserindo objetos dispersos neles de maneira que os objetos inseridos no mesmo *cluster* sejam mais semelhantes entre si em comparação a objetos contidos em outros *clusters*, conforme algum critério estabelecido.

A análise de *clusters* não pode ser confundida como um algoritmo com funções específicas. Ela deve ser tida como uma classe de problemas que necessitam de solução por um conjunto de algoritmos que diferem entre si, seja

pela forma de gerarem os *clusters*, seja pela eficiência com que realizam essa atividade.

Figura 1 – *Clusters*



Créditos: Astibuag/Shutterstock.

1.2 Ponderação arbitrária

A ponderação de dados tem como entendimento a operação com valores quantitativos, a distribuição de pesos. Ponderar os dados em uma pesquisa, por exemplo, é efetuar uma atribuição de pesos diferenciados em diversos casos, respostas ou entrevistas sobre uma observação que aparece em determinados grupos. Dessa forma, ocorre um aumento ou diminuição do impacto de certos casos da amostra de dados. É fundamental a definição dos critérios a serem adotados para a ponderação de dados conforme os objetivos a serem atingidos.

Por exemplo, podemos dizer que um grupo de clientes de um determinado mercado será entrevistado acerca de um produto específico. Nesse grupo, encontram-se clientes que adquiriram o produto uma única vez apenas; clientes que compram com uma baixa frequência e clientes frequentes, sendo que estes terão mais conhecimento sobre o produto.

Conforme esse exemplo, podemos aplicar a ponderação para efetuar uma análise dos dados sobre a pesquisa, dando maior ênfase aos consumidores

frequentes. Se utilizarmos uma escala para a satisfação do cliente com valores de 0 a 10, poderíamos dizer que os clientes frequentes possuem peso 3 quanto à sua resposta, os usuários menos frequentes, peso 2, e aqueles que adquiriram apenas uma vez teriam peso 1 sobre o valor dado às suas respostas. Com isso, os clientes com maior domínio sobre o produto teriam uma relevância maior para a pesquisa.

Na análise de *cluster*, temos sempre entradas de dados quantitativos, nunca qualitativos, uma vez que, para seu funcionamento, as técnicas de análise de *cluster* calculam a distância entre as observações, por exemplo, a distância euclidiana. Ao tentarmos utilizar variáveis qualitativas, incorremos em uma ponderação arbitrária, ou seja, em erro, o qual comumente vemos por parte de alguns estudantes e cientistas de dados.

TEMA 2 – MÉTODOS POR PARTICIONAMENTO: K-MEANS – K-MEDOIDES (PAM-CLARA)

Entre as técnicas de análise de agrupamento ou *clustering*, encontram-se os métodos de particionamento, hierárquicos, com base na densidade, em *grid*, em modelos por meio de uma abordagem de redes neurais e estatística. Esses métodos podem ser entendidos como compreendendo um conjunto de técnicas de análise de agrupamento (*clustering*) com o objetivo de efetuar uma detecção da existência de diferentes grupos inseridos em um conjunto de dados. Quando ocorrer o caso de uma existência, essas técnicas devem determinar quais são esses grupos.

O *clustering* utiliza as técnicas de mineração de dados visando efetuar uma *identificação* e *classificação*. A categorização dos dados pode ser disjunta (separada) ou sobreposta (não disjunta) com possibilidade de ser organizada em árvores.

O objetivo do *clustering* está baseado na resolução de um problema por meio do uso de uma função de similaridade, na qual esse *clustering* particiona um grupo de informações em pequenos conjuntos os quais devem conter informações semelhantes entre si, denominados *cluster*, em que devem ser dissemelhantes apesar de internamente, entre eles, conterem informações similares.

Entre meados da década de 1960 e 1970, começaram a ser desenvolvidos os primeiros algoritmos que utilizam *clusters*, entre eles, o k-means.

2.1 Resultados com k-means

O algoritmo de Lloyd, k-means, ou k-médias, como também é conhecido, pode ser entendido como um método de *clustering* com a função de particionar **n** observações dentro de **k** grupos, em que cada uma das observações seja pertencente ao grupo ou conjunto mais próximo da média. Como resultado obtemos uma divisão do espaço de dados em um diagrama denominado de Voronoi.

O k-means oferece uma classificação das informações conforme os próprios dados, baseada em uma análise e um processo de comparações envolvendo os valores numéricos dos dados. De maneira automática, o algoritmo fornece uma classificação intuitiva em modo automático, não ocorrendo a obrigatoriedade de qualquer controle humano, sendo dessa forma desconsiderada qualquer pré-classificação anterior. Isso classifica o k-means como sendo um algoritmo de mineração de dados de modo não supervisionado.

Podemos utilizar a tabela a seguir como um exemplo.

Tabela 1 – K-means

Dimensão 1	Dimensão 2	Dimensão 3	Dimensão 4
Dado A	Dado B	Dado C	Dado D
Dado W	Dado X	Dado Y	Dado Z

A tabela dada apresenta as colunas como dimensões e as linhas como dados para cada dimensão, ou ainda, pontos ou ocorrências. Os dados trabalhados por esse algoritmo usualmente são dados contínuos, contudo, podem ser também utilizados dados discretos, sendo primeiramente estruturados em uma sequência numérica correspondente.

Os dados discretos demonstram uma sequência ou uma contagem sequencial, enquanto os dados contínuos demonstram medidas em um intervalo contínuo, as quais podem assumir diferentes valores. Por exemplo, podemos ter uma produção em linha de montagem industrial, na qual um equipamento é finalizado em sequência de outro, possibilitando a contagem. Para os dados contínuos, podemos exemplificar por meio de uma produção de mel por um enxame, o qual necessita de um intervalo contínuo de quantificação, apresentando dois limites.

2.2 Resultados com k-medoides (pam-clara)

O método k-medoides funciona diferentemente do k-means, pois não utiliza uma média como valor central de um conjunto, mas sim avalia um problema em que busca do centro do próprio grupo, denominado objeto representativo ou medoide. Pela determinação do medoide de cada grupo, é possível definir **k** grupos em que podem ser distribuídos os **n** elementos a serem particionados. Dessa forma, os elementos são alocados conforme sua proximidade com o medoide do grupo mais próximo. A fórmula utilizada para isso é:

$$f = \text{Minimizar} \sum_{i=1}^k \sum_{j \in med_i} d_{ij}$$

Nessa equação, $0_j \in$ ao conjunto X , **k** é a quantidade de medoides e, $M=\{med_1, med_2, \dots med_k\}$, os objetos medoides que caracterizam os grupos.

Um algoritmo muito utilizado nesse método é o PAM (*Partitioning Around Medoids*), que busca solucionar o problema dos k-medoides em enormes bases de dados.

TEMA 3 – MÉTODOS HIERÁRQUICOS: CURE, BIRCH

Existem diferentes métodos de análise de agrupamentos, que podem conter mais de um algoritmo distinto. Existem dois métodos que podem ser adotados: hierárquicos e não hierárquicos, sendo que a opção por um destes deve impactar diretamente sobre os conjuntos resultantes.

Os métodos hierárquicos estabelecem um contínuo agrupamento com recorrentes divisões de elementos, ocorrendo uma agregação ou uma desagregação desses elementos. Os conjuntos resultantes da utilização de um método hierárquico usualmente são apresentados por meio de um diagrama bidimensional chamado de dendograma ou de diagrama de árvore.

Quanto à sua estruturação, os métodos hierárquicos estão subdivididos em dois, existindo para cada um deles algoritmos específicos. Esses métodos são denominados método divisivo e método aglomerativo.

A diferença entre os métodos hierárquicos e os métodos não hierárquicos consiste na utilização de um valor **k** pelos não hierárquicos para determinar uma quantidade específica de conjuntos de maneira prévia.

3.1 Cure (*Clustering Using Representatives*)


O Cure apresenta-se como uma proposta de análise de grandes conjuntos de dados. Seu funcionamento opera com uma estratégia diferenciada em que os *clusters* são representados individualmente por uma quantidade p de exemplos, subdividida de maneira que descrevem a forma do *cluster*.

No próximo passo, há uma efetiva aproximação dos exemplos em direção ao centro do *cluster* mediante um fator de aproximação. Em seguida, os p exemplos escolhidos são eleitos como representantes do *cluster*, permitindo o cálculo da distância entre dois *clusters* pela distância entre o par de representantes mais adjacentes. Para isso, não são utilizados todos os exemplos contidos nos *clusters*, sendo considerados somente os p exemplos eleitos como representantes.

Na análise de grandes conjuntos de dados, é executada pelo Cure uma seleção de maneira aleatória sobre uma amostra dos dados. Em seguida, é particionada essa amostra em subconjuntos para a execução do *clustering* de cada partição desses subconjuntos de dados. Por fim, são utilizados os múltiplos representantes de cada *cluster*, de forma a efetuar uma definição sobre o agrupamento de dados restante.

O Cure pode ter sua execução delineada em seis etapas, conforme disposto na Figura 2.

Figura 2 – Seis etapas de execução do Cure



3. 2 *Balanced Iterative Reducing and Clustering Using Hierarchies (Birch)*


Esse método hierárquico foi elaborado para atender à demanda de análise de um grande conjunto de dados numéricos. No método Birch, problemas que ocorrem com métodos de *clustering* aglomerativos são superados, como o problema de escalabilidade e de inabilidade em desfazer aquilo que já foi realizado em passos anteriores.

O Birch opera com resumos de estatísticas para os dados em um *cluster*, os quais têm a capacidade de efetuar os cálculos de todas as medidas necessárias para as tomadas de decisão realizadas pelo algoritmo Birch. Desse modo, os dados não precisam ser manipulados durante todo o tempo.

O algoritmo busca criar *clusters* melhores baseado nos recursos disponibilizados. É aplicada uma técnica multifase com uma carga única do conjunto de dados, com cargas adicionais se houver necessidade de melhoria na qualidade do resultado.

O algoritmo Birch é composto por quatro etapas, conforme disposto na Figura 3 a seguir.

Figura 3 – Quatro etapas do algoritmo Birch



A primeira etapa tem a função de efetuar a leitura do conjunto de dados e a construção de uma árvore na memória principal denominada CF. Seu conteúdo contém a descrição do conjunto de dados de forma detalhada conforme limitações

de espaço e memória, ficando armazenados em seus nós somente um resumo de cada um dos *clusters*, com informações como a quantidade de exemplos apresentados no *cluster*.

A segunda etapa analisa a árvore CF, reestruturando-a de forma a reduzir seu espaço de memória, otimizando a execução do conjunto para a terceira etapa. Nesse processo, alguns *outliers* são excluídos e *subclusters* menores podem ser agrupados. A terceira etapa apresenta o resultado dessa operação.

A quarta etapa efetua uma atribuição dos *clusters* restantes encontrados na terceira etapa.

TEMA 4 – MÉTODOS BASEADOS EM DENSIDADE: DBSCAN

Esses métodos de *clustering* baseados em densidade assumem que os *clusters* podem ser considerados regiões de alta densidade desmembradas por regiões de baixa densidade no espaço exemplo. O foco principal está em manter cada exemplo do *cluster* junto de uma vizinhança que contém uma quantidade mínima de vizinhos inseridos em uma esfera com raio R . Dessa forma, quando os exemplos apresentam uma vizinhança com densidade mínima, e encontram-se a uma distância inferior a R , fazem parte do mesmo *cluster*.

Assim, um conjunto ou agrupamento baseado em densidade identificará as áreas no espaço amostral em que se encontrem concentrações de elementos e cada uma dessas áreas formará um novo *cluster*.

4.1 Entendendo o DBSCAN

O DBSCAN (*Density-Based Spatial Clustering of Applications With Noise*, ou “agrupamento especial baseado em densidade de aplicações com ruído”) visa encontrar agrupamentos com base na vizinhança dos objetos, em que a obtenção da densidade associada a um ponto ocorre mediante a contagem da quantidade de pontos ou nós vizinhos em uma região que se encontra ao redor desse ponto.

Esse algoritmo possui um modelo de *clustering* bem definido denominado *density-reachability* ou “alcance de densidade”, o qual é similar ao agrupamento baseado em ligação. Esse agrupamento se baseia em pontos de conexão inseridos em limites de distância.

A operação do DBSCAN se dá pela conexão de pontos que venham a satisfazer um critério de densidade, no qual é necessário ocorrer um número

mínimo de diferentes pontos inseridos em um raio limite de alcance. Os objetos conectados por essa densidade, assim como todos os objetos inseridos em seu raio de alcance, formam um *cluster*.

4.2 Funcionamento prático do DBSCAN

Uma vez que o DBSCAN é um algoritmo baseado em densidade, a densidade é igual ao número de pontos dentro de um raio específico (Eps). Um ponto pode ser considerado um ponto núcleo caso ele possua mais que um número especificado de pontos (MinPts) inseridos no Eps, ou seja, os pontos que estão no interior de um conjunto ou um grupo.

Um ponto de fronteira é entendido como tendo menos que MinPts inserido em Eps, mas se encontra na vizinhança de um ponto núcleo. A definição de ponto ruído baseia-se em um ponto não caracterizado como ponto núcleo nem ponto de fronteira.

O DBSCAN utiliza duas variáveis vitais para sua execução, conforme disposto no Quadro 1 a seguir.

Quadro 1 – Duas variáveis do DBSCAN

Raio da vizinhança (ϵ)	Número de vizinhos (MinPts)
Representa a distância máxima para considerar dois elementos como vizinhos, podendo se utilizar qualquer métrica.	Representa a quantidade mínima de vizinhos, incluindo o próprio ponto, para considerar uma concentração ou densidade.

Com essas variáveis, podemos descrever outro conceito: a ϵ – **vizinhança** relativa a um ponto **p** na amostra D é representada por:

$$N(p) = \{d \in D \mid \text{distância}(p, d) \leq \epsilon\}$$


Com isso, a classificação de um ponto pode ocorrer de três formas, conforme exposto no Quadro 2 a seguir.

Quadro 2 – Três formas de classificação de um ponto

Núcleo (<i>core</i>)	Borda (<i>border</i>)	Ruído (<i>noise</i>)
Um ponto c é denominado núcleo se $ N(c) \geq \text{minPts}$	Denomina-se um ponto b de borda se $ N(b) < \text{minPts}$, mas faz parte da ϵ -vizinhança de um núcleo	Um ponto n é considerado ruído se $ N(n) < \text{minPts}$ e não compõe a ϵ -vizinhança de um núcleo

Na sequência, a Figura 4 ilustra o funcionamento prático do DBSCAN.

Figura 4 – Funcionamento prático do DBSCAN



Conforme a Figura 4, trabalhando com um $\text{MinPts}=4$ podemos perceber que os círculos representam um raio de cada ponto e os azuis são os núcleos formando um agrupamento ou *cluster*. Nessa figura, podemos notar que $D(B) = 2 = D(C)$, contudo, B e C fazem parte do agrupamento por se localizarem na *–vizinhança* de outros núcleos.

Nesse cenário, o ponto D não está atendendo aos critérios, assim como também não está no raio de nenhum elemento de outro grupo, sendo considerado como um ponto de ruído.

TEMA 5 – AVALIAÇÃO DE CLUSTERS

A avaliação ou análise de *cluster* tem como finalidade estudar as relações de interdependência existentes entre um conjunto de variáveis interdependentes, possibilitando agrupar elementos conforme suas similaridades e proximidades,

considerando esse conjunto de variáveis. Assim, os elementos que compõe cada *cluster* tendem a ser análogos entre si, sendo diferentes dos outros elementos presentes em outros *clusters*. O processo de avaliação do resultado obtido com base em um algoritmo é também denominado “validação”.

Dessa forma, a análise de *cluster* ou *clustering* é a tarefa de agrupar um conjunto de objetos de forma que os objetos do mesmo grupo (chamado *cluster*) sejam mais semelhantes (em algum sentido) entre si do que os de outros grupos (*clusters*). É uma das principais tarefas da mineração exploratória de dados e uma técnica comum para análise estatística de dados, usada em muitos campos, incluindo aprendizado de máquina, reconhecimento de padrões, análise de imagens, bioinformática, recuperação de informações, compactação de dados e computação gráfica.

É importante destacar que a análise de *cluster* em si não é um algoritmo específico, mas a tarefa geral a ser executada. Essa tarefa pode ser realizada por vários algoritmos que diferem significativamente na compreensão do que constitui um *cluster* e na forma de encontrá-los com eficiência. Noções populares de *clusters* incluem grupos com pequenas distâncias entre membros do *cluster*, áreas densas do espaço de dados, intervalos ou distribuições estatísticas específicas.

5.1 Objeto de avaliação: técnicas de *clustering*

Observando as técnicas de *clustering*, visando à sua avaliação, podemos dizer que um *clustering* ou agrupamento de dados é uma tarefa de aprendizado não supervisionada, na qual um conjunto finito de categorias é identificado como agrupamentos com base na similaridade intraclasse presente nos dados. Entre cada *cluster* há semelhança máxima entre classes e semelhança mínima entre classes.

Assim, a técnica de agrupamento é aplicada para identificar o agrupamento intrínseco entre um conjunto de dados que não são rotulados ou agrupados. Essa técnica pode ser usada quando as classes não são conhecidas e não analisam instâncias rotuladas como usadas na classificação. O atributo que fornece a boa similaridade deve ser identificado para aumentar a métrica de similaridade entre os *clusters*. As propriedades do *cluster* podem ser analisadas para identificar os perfis que distinguem um *cluster* do outro. O desempenho de uma boa técnica de agrupamento é medido por sua capacidade de identificar os padrões que estão

ocultos e gerar uma semelhança máxima intraclasse, bem como diminuir a semelhança entre classes, entre outros objetos e entre os *clusters*.

Quando falamos em um processo de avaliação ou validação, levantamos primeiramente alguns questionamentos que precisam ser atendidos para o atendimento dessa proposição, conforme Quadro 3 a seguir.


Quadro 3 – Levantamento de alguns questionamentos

O que deve ser avaliado?
Os dados a serem utilizados são de fato “clusterizáveis”? Ou seja, ocorre a existência de estruturas não randômicas nos dados?
Os <i>clusters</i> observados realmente tem relação a <i>clusters</i> “reais”?
Quando forem dados dois conjuntos de <i>clusters</i> para serem aplicados aos mesmos dados, qual deles apresenta melhor resultado?

5.2 Estrutura para avaliação: etapas de *clustering*

As técnicas adotadas no *clustering* são categorizadas em três métodos, a saber, métodos hierárquicos, métodos de particionamento e métodos baseados em densidade. O método de particionamento pode ser usado para determinar **k** *clusters*, que podem otimizar cada um deles com base na função de distância. Métodos hierárquicos criam um dendrograma por decomposição do banco de dados. Os métodos baseados em densidade descobrem as regiões densas disponíveis no espaço de dados que são separadas umas das outras por regiões de ruído de baixa densidade.

Figura 5 – Etapas de *clustering*



5.2.1 Aplicações da análise de *cluster*

A análise ou avaliação de *clustering* é amplamente utilizada em diversas aplicações, como pesquisa de mercado, reconhecimento de padrões, análise de dados e processamento de imagens. O *clustering* também pode ajudar os profissionais de *marketing* a descobrir grupos distintos em sua base de clientes. Eles podem caracterizar seus grupos de clientes com base nos padrões de compra.

Além dessas utilizações, outras aplicações podem ter seu uso.

- No campo da biologia, pode ser usado para derivar taxonomias de plantas e animais, categorizar genes com funcionalidades semelhantes e obter informações sobre estruturas inerentes às populações.

-
- Por servir na identificação de áreas de uso similar da terra em um banco de dados de observação da terra. Além disso, também auxilia na identificação de grupos de casas em uma cidade de acordo com o tipo de casa, valor e localização geográfica.
 - Ajuda na classificação de documentos na *web* para descoberta de informações.
 - Também é usado em aplicativos de detecção de *outlier*, como detecção de fraude no cartão de crédito.
 - Como função de mineração de dados, a análise de *cluster* serve como uma ferramenta para obter informações sobre a distribuição de dados e observar as características de cada *cluster*.