

REDES NEURAIS ARTIFICIAIS E *MACHINE LEARNING*

TEMA 1 – INTELIGÊNCIA ARTIFICIAL E REDES NEURAIS ARTIFICIAIS

O desenvolvimento das redes neurais artificiais (RNA) como um ramo de estudos e pesquisas da inteligência artificial (IA) foi um fator determinante para o advento de softwares e hardwares que possam desempenhar a capacidade de aprendizagem. Desde os últimos anos do século XX, o aumento da capacidade de processamento e armazenamento dos computadores proporcionou o desenvolvimento e o aperfeiçoamento de algoritmos de aprendizagem de tal forma que pudessem ser utilizados em aplicações com crescentes quantidades de dados.

Atualmente, as áreas de *machine learning* e *deep learning* estão na vanguarda da utilização de redes neurais artificiais que são mais e mais aplicadas a cenários reais com grandes quantidades de dados e imitando as estruturas existentes nos organismos biológicos para executar cada vez melhor as tarefas de reconhecimento de padrões.

Esta aula demonstra a importância do estudo da área das RNA para o desenvolvimento tecnológico dos dias atuais.

1.1 Definição de redes neurais artificiais

Uma RNA é inspirada em redes neurais biológicas, no sentido do entendimento atual de que as coleções de neurônios dentro de um sistema nervoso interagem de maneira a produzir certos comportamentos necessários ao reconhecimento de padrões a partir do processamento de sinais que chegam até ele. Entretanto, apesar do conhecimento de certos mecanismos locais relacionados aos neurônios, ainda não se tem ideia do funcionamento global em como uma rede consegue armazenar as informações do mundo externo, de forma a recuperá-las eficientemente conforme a demanda das atividades biológicas. Ainda assim, o pouco conhecimento obtido permite que se criem estruturas e algoritmos capazes de aprender sobre o ambiente externo.

De acordo com Haykin (2001, p. 28), as redes neurais empregam uma interconexão maciça de neurônios ou unidades de processamento, no sentido de se lidar com uma máquina adaptativa:

Uma rede neural é um processador maciçamente paralelamente distribuído constituído de unidades simples, que têm a propensão natural para armazenar conhecimento experimental e torná-lo disponível para o uso. Ela se assemelha ao cérebro em dois aspectos: 1) O conhecimento

é adquirido pela rede a partir do seu ambiente através de um processo de aprendizagem; 2) Forças de conexão entre neurônios, conhecidas como pesos sinápticos, são utilizadas para armazenar o conhecimento adquirido.

Kopec (2019, p. 177) questiona se as RNA são eficazes como técnica computacional, ainda que as redes neurais biológicas não tenham sido compreendidas em sua totalidade. Por isso, é importante ressaltar uma linha divisória no que se entende como RNA e sua fonte de inspiração, as redes neurais biológicas, pois é nessa inspiração que as semelhanças entre elas se encerram. Muito do funcionamento biológico ainda espera por explicações sobre como vários dos mecanismos neuroeletroquímicos se entrelaçam para produzir o fenômeno da mente e do pensamento.

É importante salientar que uma RNA possui dois elementos: uma **estrutura** e um **algoritmo de aprendizagem**. A estrutura se relaciona com a forma com a qual a RNA é construída, como os neurônios interagem e como disseminam a informação entre seus pares. O algoritmo de aprendizagem, por sua vez, se baseia no modo como a estrutura é dada, de maneira a fazer com que o conhecimento experimental seja armazenado nessa estrutura, ou melhor dizendo, nas conexões sinápticas entre os neurônios (Haykin, 2001, p. 28).

Outro elemento importante a considerar com relação ao aprendizado é a capacidade de **generalização** de uma RNA. O aprendizado envolve o desenvolvimento de um **conhecimento experimental**: uma RNA aprende a partir de uma série de exemplos ou amostras provenientes de seu ambiente. Para que uma RNA desempenhe bem sua tarefa, é necessário que seja robusta o suficiente para poder inferir sobre uma série de exemplos semelhantes ou distintos entre si ou mesmo sobre novos exemplos adicionados ao contexto que não tenham feito parte do desenvolvimento do conhecimento experimental:

É evidente que uma rede neural extrai seu poder computacional através, primeiro, de sua estrutura maciçamente paralelamente distribuída e segundo de sua habilidade de aprender e portanto de generalizar. A generalização se refere ao fato de a rede neural produzir saídas adequadas para entradas que não estavam presentes durante o treinamento (aprendizagem). Estas duas capacidades de processamento de informação tornam possível para as redes neurais resolver problemas complexos (de grande escala) que são atualmente intratáveis. (Haykin, 2001, p. 28)

Ao longo dos anos, os pesquisadores de IA se interessaram pelas propriedades das RNA como a habilidade para executar a computação distribuída e a capacidade de aprender considerando-se padrões com ruído. Ainda que

outros tipos de redes, tais como as bayesianas, possuam tais propriedades (Russell; Norvig, 2004, p. 713-714), as RNA se sobressaem demonstrando uma série de elementos que as tornam uma abstração diferenciada de outras abordagens com capacidade de aprendizagem.


A área de RNA contribui de maneira significativa com a de *machine learning* (ML) (ou aprendizagem de máquina). Conforme destaca Mitchell (1997), ML é uma área de pesquisa que objetiva o desenvolvimento de programas que tenham capacidade de melhorar o seu desempenho com a experiência. O desenvolvimento dela conta com várias áreas do conhecimento como estatística, inteligência artificial, teoria da informação, complexidade computacional e outras.

Portanto, a ML visa à extração automatizada de informações a partir de dados e está intimamente relacionada com a área de RNA, além de outras como mineração de dados, estatística e teoria da computação (Castro; Ferrari, 2016). As técnicas de RNA como perceptron multicamada, mapas auto-organizáveis e redes recorrentes se juntam a outras como árvores de decisão, teorema de Bayes e regras de associação para prover um conjunto de ferramentas a partir das quais seja possível a atividade de ML em ambientes com conjuntos de dados massivos.

TEMA 2 – O SISTEMA NERVOSO

Uma abstração útil para o entendimento das RNA é imaginar o sistema nervoso humano como aquele que apresenta três estágios (Haykin, 2001, p. 32). O ambiente externo oferece uma diversidade de estímulos que são captados pelo sistema sensorial, constituído de uma estrutura que os processa e os converte em sinais que, por sua vez, são alimentados às redes neurais no córtex cerebral. A partir do processamento dos sinais por meio dos neurônios interconectados, produzindo os sinais de saída, os atuadores são acionados, convertendo os impulsos elétricos em ações propriamente caracterizadas como, por exemplo, o movimento muscular (Figura 1).


Figura 1 – Representação do sistema nervoso



Fonte: elaborado com base em Haykin, 2001, p. 32.

Na Figura 2, é possível observar um diagrama dos componentes principais de um **neurônio**, que pode ser considerado como a unidade fundamental dos tecidos do sistema nervoso. Ele contém um **corpo celular**, também designado como **soma**, no qual se encontra também um **núcleo**. Os neurônios se conectam uns aos outros por meio de filamentos denominados **dendritos**. Um dos prolongamentos que saem do corpo celular é chamado **axônio**. Os dendritos ligam-se ao redor da célula a outras células, e o axônio faz uma conexão mais longa. Tais conexões também se denominam **sinapses**.


Figura 2 – Ilustração de um neurônio biológico



Crédito: logika600/Shutterstock.

A base de comunicação de um neurônio com seus vizinhos se dá por meio de reações eletroquímicas. As substâncias químicas denominadas **neurotransmissores** são lançadas para as sinapses e canalizam pelos dendritos, e a concentração iônica (principalmente íons de sódio e potássio) proporcionada por essas substâncias permite aumentar ou diminuir o potencial elétrico existente no corpo do neurônio em relação ao exterior da célula. Quando esse potencial chega a um limiar, um pulso elétrico ou potencial de ação se propaga dos dendritos em direção ao axônio. O pulso se espalha ao longo das conexões existentes pelo axônio, eventualmente chegando a outras sinapses e lançando transmissores ao corpo de outras células. Nesse mecanismo do potencial de ação (Figura 3) é inspirada a função de ativação existente nas RNA.

Figura 3 – Potencial de ação de um neurônio



Fonte: Wikimedia.

As sinapses também podem ser classificadas conforme sua função. Aquelas que aumentam o potencial de outras células são denominadas **excitatórias**, e as que diminuem, **inibitórias**. Portanto, os neurônios podem formar novas sinapses com outros neurônios, e por meio de tais mecanismos se forma a base para que o conhecimento se fixe no sistema nervoso.

TEMA 3 – O NEURÔNIO ARTIFICIAL

No processo de modelagem de um neurônio artificial inspirado em seu correlato biológico, é interessante constatar que o processo de aprendizagem de um neurônio celular ocorre pela modulação das sinapses, e essa é a base também para os neurônios artificiais. A variação diferenciada dos pesos sinápticos sobre os sinais de entrada possibilita a alteração do comportamento das saídas dos neurônios (Castro, 2010, p. 81).

Portanto, a menor unidade de processamento de informação existente em um sistema nervoso é o neurônio. Um modelo de neurônio artificial pode ser elaborado com base na estrutura e dinâmica de um neurônio biológico e pode ser

visto na Figura 4. Sinais podem ser alimentados à rede por meio das entradas x_i , as quais são propagadas à frente por pesos sinápticos w_{ki} que ponderam esses sinais e que são somados na junção aditiva Σ , produzindo a saída intermediária v_k (Haykin, 2001, p. 36):

$$v_k = \sum_{i=1}^m w_{ki} x_i$$

A saída do neurônio y_k é calculada por


$$y_k = f(v_k + b_k)$$

Pode-se identificar três elementos essenciais para o modelo neural adotado:

1. um conjunto de sinapses que modulam os sinais de entrada;
2. um somador ou combinador linear;
3. uma função de ativação para efetuar o “disparo” do neurônio na saída.

Pode-se identificar um fator de bias (desvio) b_k , necessário para fazer o ajuste fino do comportamento do neurônio, como um fator constante a ser adicionado à saída intermediária v_k .

Figura 4 – Um modelo não linear de um neurônio artificial



Fonte: elaborado com base em Haykin, 2001, p. 36.

A função de ativação, denominada também função de transferência, insere a característica não linear no comportamento do neurônio, sendo análoga ao

potencial de disparo existente na dinâmica do neurônio biológico. Várias funções de ativação podem ser utilizadas em um neurônio artificial:

- **Função de limiar:** assume um valor constante quando próximo de um valor limite (Figura 5.a):

$$f(v) = \begin{cases} 1, & v \geq 0 \\ 0, & v < 0 \end{cases}$$

- **Função linear por partes:** apresenta um comportamento linear crescente dentro de uma faixa de valores intermediários (Figura 5.b):

$$f(v) = \begin{cases} 1, & v > +0,5 \\ v, & -0,5 < v < +0,5 \\ 0, & v \leq -0,5 \end{cases}$$

- **Função sigmoide:** bastante utilizada, exibe um balanceamento entre um comportamento linear e não linear. Por exemplo, a função logística exibe o comportamento de uma função sigmoide (Figura 5.c):

$$f(v) = \frac{1}{1 + \exp(v)}$$

Outro exemplo de função sigmoide é a função tangente hiperbólica (Figura 5.d):

$$f(v) = \tanh(v)$$


Esse modelo é considerado um modelo **determinístico**, por lidar com valores precisos para o comportamento e entrada e saída. Existem RNA nas quais o modelo adotado é **estocástico** ou **probabilístico** (por exemplo, redes recorrentes de Boltzmann) em que o disparo do neurônio está relacionado com uma probabilidade de transição (Haykin, 2001, p. 41).

O modelo de neurônio artificial evidencia sua estrutura e tem impacto na arquitetura de RNA com vários neurônios e camadas. A partir dessa estrutura, algoritmos de treinamento ou aprendizagem podem ser utilizados para modular os valores dos pesos sinápticos, de acordo com a tarefa a ser executada pela RNA. Os algoritmos tendem a explorar a informação de saída como retroalimentação para calcular valores que irão atualizar os pesos sinápticos, minimizando uma função de erro.

Figura 5 – Exemplos de funções de ativação




(a) Função limiar



(b) Função linear por partes



(c) Função logística



(d) Função tangente hiperbólica

Da mesma forma que as redes neurais biológicas, para a execução de uma tarefa complexa de classificação são necessários muitos neurônios conectados entre si, que podem estar divididos em camadas dentro das RNA. Castro (2010, p. 80) reforça o aspecto de que o neurônio é a única célula capaz de armazenar e processar informação, além de estabelecer interconexão com outros neurônios. Os aspectos de arquitetura são bem importantes, tanto com relação às redes biológicas quanto à estrutura de uma RNA.

Uma característica importante da estrutura organizacional do cérebro é que as redes neurais geralmente apresentam uma arquitetura bem definida. Por exemplo, é sabido que o córtex, fina camada mais externa que envolve o cérebro, apresenta uma estrutura em camadas, sendo que a primeira camada mais externa é responsável por receber estímulos do ambiente; camadas intermediárias recebem sinais de outras camadas; e camadas de saída apresentam sinais para o ambiente. (Castro, 2010, p. 80)

TEMA 4 – PROPRIEDADES DAS RNA

As RNA apresentam uma série de propriedades e capacidades. Haykin (2001, p. 29-30) assim as identifica:

- **Não linearidade:** as entradas de uma RNA e as saídas podem se manifestar seguindo uma relação não linear; isso é importante, pois muitos mecanismos físicos responsáveis pela geração dos sinais (por exemplo, sons ou sinais biométricos) são em suma não lineares.
- **Mapeamento de entrada-saída:** na concepção da aquisição de conhecimento experimental de uma RNA, um exemplo com seus sinais de entrada é apresentado à RNA, a qual reage com uma resposta desejada nas suas saídas. A aprendizagem de uma RNA indica que um conjunto de exemplos usados como estímulos desenvolve um comportamento de respostas associadas a esses estímulos. Em um aprendizado de classificação, uma RNA deve associar as entradas com as respectivas classes. Essa associação indica que há um mapeamento a ser alcançado entre as entradas e saídas de uma RNA: quando esse mapeamento é obtido, pode-se afirmar que a RNA aprendeu.
- **Adaptabilidade:** existe uma capacidade inerente às RNA relativa à adaptação das sinapses de acordo com os sinais fornecidos a partir do ambiente. Redes treinadas em um ambiente, com conjuntos de amostras que tenham certas características, podem passar por um retreinamento para acondicionar pequenas mudanças ou variações desses conjuntos. Isso é importante em ambientes denominados não estacionários (que se modificam com o tempo), nos quais uma RNA pode se adaptar de forma on-line.
- **Resposta a evidências:** para uma RNA, além de fornecer informação sobre a que classe determinado padrão pertence, mas também o nível de crença ou confiança que fundamenta essa informação. Em casos nos quais

exista ambiguidade, esse critério de confiança pode melhorar o desempenho da RNA e sua capacidade de generalização.

- **Informação contextual:** o conhecimento experimental é representado na própria estrutura da rede a partir dos pesos sinápticos e dos mecanismos de sua ativação. Dessa forma, um neurônio não atua de forma individual, interagindo com outros neurônios e sendo potencialmente afetados pelas ativações em conjunto de todos os outros neurônios da RNA, possibilitando o tratamento da informação contextual de maneira natural, própria da sua estrutura.
- **Tolerância a falhas:** relacionada com a robustez de uma RNA. Ainda que o desempenho da rede venha a se degradar, com falhas na alimentação dos sinais às entradas ou ainda na estrutura quanto às conexões entre os neurônios, ainda é capaz de fazer generalizações sobre as amostras apresentadas nas entradas, mesmo que com menor qualidade. A natureza distribuída da informação faz com que tal degradação seja suavizada.
- **Implementação em hardware:** a natureza da estrutura de uma RNA maciçamente paralela permite o uso de tecnologias de implementação em processadores, construídos especificamente para esse propósito.
- **Analogia neurobiológica:** a engenharia da computação olha para a neurobiologia em busca de novas ideias e formas como a contrapartida biológica das RNA faz para resolver problemas complexos e inspirar novos modelos.

TEMA 5 – BREVE HISTÓRICO

Na Figura 6, é mostrada uma linha do tempo com alguns eventos relacionados ao desenvolvimento do campo das RNA. Os neurônios biológicos foram descobertos no início do século XX pelo neurofisiologista espanhol Santiago Ramon y Cajal (1852-1934), mas em 1943 a área de estudo de redes neurais artificiais nasceu, com a primeira modelagem de McCulloch e Pitts de um neurônio artificial. As RNA se popularizam a partir da pesquisa de Frank Rosenblatt, com a criação do **perceptron**, um classificador binário baseado em entradas provenientes de sensores e que podia decidir se tais entradas pertenciam a uma classe específica.


Entretanto, em 1969, os pesquisadores de IA Marvin Minsky e Seymour Papert lançaram o livro *Perceptrons*, no qual expõem as limitações do perceptron

simples em executar classificações tais como a tabela-verdade do XOR. O interesse, bem como os financiamentos em pesquisa com RNA, sofreu um hiato na década de 1970, mas algumas pesquisas nesse período começaram a colocar em evidência o potencial das RNA com algoritmos de treinamento para camadas de neurônios interconectados, como os trabalhos de Seppo Linnainmaa e Paul Werbos.

Na década de 1980, as RNA ressurgiram potencializadas por novos modelos, como a rede recorrente de Hopfield, e ainda pelo aumento de capacidade de processamento e memória dos computadores, permitindo a construção de RNA complexas como, por exemplo, a rede NETtalk de Sejnowski, que continha 300 neurônios para a síntese de fala. O trabalho de Rumelhart, Hinton e Williams é significativo no sentido de propor um algoritmo de retropropagação para treinamento das RNA com múltiplas camadas (Haykin, 2001, p. 65-68).

A partir daí, as RNA fixaram-se como base teórica e prática para a construção de máquinas com capacidade de aprendizado, sendo utilizadas também para o processamento de dados massivos na área de *big data* e *machine learning*, bem como no desenvolvimento das áreas de pesquisa atuais relativas ao *deep learning* (aprendizado profundo).

Figura 6 – Linha do tempo com alguns eventos relativos à linha conexionista da IA



Fonte: Medeiros, 2018, p. 27.

REFERÊNCIAS

CASTRO, L. N. **Computação natural**. São Paulo: Livraria da Física, 2010.

CASTRO, L. N.; FERRARI, D. G. **Introdução à mineração de dados**: conceitos básicos, algoritmos e aplicações. São Paulo: Saraiva, 2016.

HAYKIN, S. **Redes neurais**: princípios e prática. Porto Alegre: Bookman, 2001.

KOPEC, D. **Classic Computer Science Problems in Python**. Shelter Island-NY: Manning Publications Co., 2019.

MEDEIROS, L. F. **Inteligência artificial aplicada**: uma abordagem introdutória. Curitiba: InterSaberes, 2018.

_____. **Redes neurais em Delphi**. 2. ed. Florianópolis: Visualbooks, 2007.

MITCHELL, T. M. **Machine Learning**. New York: McGraw-Hill, 1997.

RUSSELL, S.; NORVIG, P. **Inteligência artificial**. Tradução da segunda edição. Rio de Janeiro: Campus, 2004.