

Aula 3

Redes Neurais Artificiais e *Machine Learning*

Prof. Luciano Frontino de Medeiros

1


Perceptron de Camada Única

2

- Refere-se a um único neurônio artificial que pode conter várias entradas e uma única saída
- As entradas são ponderadas por pesos sinápticos e somadas para produzir um sinal que será processado por uma função de ativação (função sinal)
- O perceptron de camada única utiliza o modelo de neurônio artificial de McCulloch-Pitts

3

Exemplo




4

Cálculo da ativação do perceptron

$$v = \sum_{i=1}^m w_i x_i + b$$

$$y = f(v)$$

$$f(v) = \begin{cases} +1, & v \geq 0 \\ -1, & v < 0 \end{cases}$$



5

Separação linear

- Neste caso, com apenas duas entradas, o hiperplano é uma reta que divide o espaço das duas classes, $\mathcal{C}_1$ e $\mathcal{C}_2$
- O somatório para as duas entradas pode ser simplificado para:

$$v = w_1 x_1 + w_2 x_2 + b$$

6

Separação das classes

- Quando v é positivo ($v > 0$), as amostras de entrada pertencem à classe C_1 e estão acima da reta $w_1x_1 + w_2x_2 + b > 0$
- Quando v é negativo ($v < 0$), as amostras de entrada pertencem à classe C_2 e estão abaixo da reta $w_1x_1 + w_2x_2 + b < 0$

Visualizando a reta


- Quando $v = 0$, os valores coincidem exatamente com a reta que divide as duas classes $w_1x_1 + w_2x_2 + b = 0$
- Se isolarmos x_2 na equação $x_2 = \frac{-w_1}{w_2}x_1 - \frac{b}{w_2}$

Equação da reta

- Variável independente x'
 - Variável dependente y'
 - m é o coeficiente angular
 - l é o coeficiente linear
- $$y' = mx' + l$$

Comparação

- Fazendo $y' = x_2$ e $x' = x_1$
- Coeficiente angular $m = -w_1/w_2$
- Coeficiente linear $l = -b/w_2$
- O treinamento do perceptron buscará, portanto, encontrar os melhores valores de w_1 e w_2



Algoritmo LMS

Algoritmo LMS


- Algoritmo do mínimo quadrado médio (*least mean square*, ou LMS)
- Permite o aprendizado de forma gradativa do perceptron, atualizando os valores dos pesos sinápticos a cada época de treinamento
- O algoritmo LMS foi criado por Widrow e Hoff ainda em 1960

$$E = \frac{1}{2} \sum_{i=1}^m e_i^2$$


$$w_j(n+1) = w_j(n) + \Delta_j(n)$$

Simulação do Perceptron

- Adota-se um conjunto de seis amostras, com três amostras para cada classe, e cria-se uma tabela para mostrar a alimentação adiante de cada neurônio, bem como o cálculo dos novos valores dos pesos sinápticos conforme o algoritmo LMS
- Considera-se um problema de classificação em duas classes distintas, A e B
- <http://professorfrontino.com.br/ia/simulator.html>

[illegible]

Passo	32 w1	w2	w0							
	0,39	0,54	-1							
No.	x1	x2	v	y	o	Atual	Alvo	e	delta1	delta2
1	1	3	1,01	1	1	A	A	-	-	-
2	1	1	(0,07)	-1	-1	B	B	-	-	-
3	2	1,5	0,59	1	-1	A	B	(2,00)	(0,04)	(0,03)
4	2	3,5	1,67	1	1	A	A	-	-	-
5	3	4	2,33	1	1	A	A	-	-	-
6	3	2	1,24	1	-1	A	B	(2,00)	(0,06)	(0,04)
						Soma		(4,00)	(0,02)	(0,01)
						Error global		8,00		




19


Treinamento: passo 53

Passo	53									
1	0,10	0,34	-1							
No.	x1	x2	v	y	o	Atual	Alvo	e	delta1	delta2
1	1	3	0,12	1	1	A	A	-	-	-
2	1	1	(0,56)	-1	-1	B	B	-	-	-
3	2	1,5	(0,29)	-1	-1	B	B	-	-	-
4	2	3,5	0,39	1	1	A	A	-	-	-
5	3	4	0,66	1	1	A	A	-	-	-
6	3	2	(0,03)	-1	-1	B	B	-	-	-
						Soma		-	-	-
						Erro global		-	-	-


20



21



22




23

- Adaptative linear element
- No adaline, não há uma função de ativação: o resultado da junção aditiva é a própria saída do neurônio
- Por isso, o adaline é considerado um neurônio artificial linear, enquanto o perceptron de camada única é não linear

24

Diagrama esquemático



Atualização dos eses

- A dinâmica do adaline é bastante semelhante ao processamento de sinais por um filtro linear
- A adaptação dos pesos é feita por meio da retroalimentação de parte do sinal de saída, da mesma forma que o perceptron
- No entanto, por não ter uma função de ativação que opera sobre o sinal da junção aditiva, o valor da saída y será um valor distinto para cada amostra, ao invés dos valores $+1$ e -1

Calculando a melhor reta

- Conforme a geometria analítica, bastam dois pontos para se compor uma equação de reta
- Pega-se dois pontos: $P(1,2)$ e $R(3,3)$
- Substituindo em

$$y' = mx' + l$$

$$\begin{cases} 2 = m + l \\ 3 = 3m + l \end{cases}$$

Resolvendo para m e l

- Resolvendo-se para as incógnitas m e l (coeficientes angular e linear, respectivamente), chega-se aos valores $m = 0.5$ e $l = 1.5$. Ou


$$y' = 0.5x' + 1.5$$

Ou

$$-0.5x_1 + x_2 - 1.5 = 0$$

Reta ótima

- Desde que $w_1 = -0.5$ e $w_2 = 1$, com bias $w_0 = -1.5$, a reta será ótima no sentido de separar as duas classes, A e B




Simulação de um Adaline

Passo	1								
	w1	w2	w0						
	1	1	-1,5						
No.	x1	x2	y	o	Classe	Desejado	e	delta1	delta2
1	1	3	2,50	1	A	A	(1,50)	(0,038)	(0,113)
2	1	1	0,50	-1	A	B	(1,50)	(0,038)	(0,038)
3	2	1,5	2,00	-1	A	B	(3,00)	(0,150)	(0,113)
4	2	3,5	4,00	1	A	A	(3,00)	(0,150)	(0,263)
5	3	4	5,50	1	A	A	(4,50)	(0,338)	(0,450)
6	3	2	3,50	-1	A	B	(4,50)	(0,338)	(0,225)
						Erro	(18,00)		
						Erro global	63,0000		


31

Treinamento: passo 93										
Passo	93									
	w1	w2	w0							
1	0,50	1,00	-1,5							
Amostra	x1 (cm)	x2 (mm)	y	d	Classe	Desejado	e1	delta1	delta2	
1	1	3	1,00	1	A	A	0,00	0,000	0,000	
2	1	1	(1,00)	-1	B	B	(0,00)	(0,000)	(0,000)	
3	2	1,5	(1,00)	-1	B	B	(0,00)	(0,000)	(0,000)	
4	2	3,5	1,00	1	A	A	0,00	0,000	0,000	
5	3	4	1,00	1	A	A	0,00	0,000	0,000	
6	3	2	(1,00)	-1	B	B	(0,00)	(0,000)	(0,000)	
							(0,00)	(0,000)	0,000	

32



33




34

Adaline versus perceptron

- Quanto ao problema da classificação binária, o perceptron parece ser mais robusto
- Com a função de ativação, ele manifesta uma característica não linear, e qualquer reta que divida um conjunto separável de amostras em duas classes irá servir para caracterizar a classificação
- O adaline, por sua vez, demonstra um comportamento linear e tenderá a fornecer uma aproximação

35



36