

Aula 4

Redes Neurais Artificiais e Machine Learning

Prof. Luciano Frontino de Medeiros

1

O Perceptron de Múltiplas Camadas

2

Perceptron

- No estudo do *perceptron* de camada única, foi possível perceber o potencial deste tipo de RNA para tarefas de classificação
- O algoritmo de aprendizagem LMS, em particular, forneceu um método poderoso de descida de gradiente para a redução gradativa do erro, ainda que os padrões não sejam linearmente separáveis


3

Perceptron de múltiplas camadas

- Amplia consideravelmente o número de pesos, o que por sua vez permite uma aprendizagem que possa contemplar também a classificação em conjuntos de forma não linear
- O algoritmo de retropropagação de erro (*error backpropagation*) possibilita que uma parte do sinal de saída da rede seja alimentado em sentido contrário das camadas

4


Diagrama esquemático




5

Características de um MLP

- O uso de função de ativação não linear
- A existência de camadas ocultas, que não fazem parte nem da entrada e nem da saída
- O alto grau de conectividade que o MLP apresenta em função da sua arquitetura e da população de pesos sinápticos



6



7

Convenção simbólica

Variável	Descrição
i, j, k	Índices dos neurônios. Usando a notação onde o sinal funcional se propaga da esquerda para a direita, O neurônio i está numa camada mais à esquerda; o índice j nas camadas ocultas e o índice k na camada de saída
E	Erro global; a soma dos erros quadráticos
e_j	Sinal de erro na saída do neurônio j
d_j	Sinal desejado no neurônio de saída j
y_j	Sinal funcional que aparece na saída do neurônio j
x_j	Sinal da amostra apresentada no neurônio j da camada de entrada


8

Variável	Descrição
w_{ji}	Peso sináptico conectando a entrada do neurônio i à saída do neurônio j
Δw_{ji}	Correção aplicada ao peso sináptico que conecta a entrada do neurônio i à saída do neurônio j
v_j	Soma ponderada de todas as entradas sinápticas no neurônio j acrescida do bias
δ_j	Gradiente local para o neurônio j
f	Função de ativação
η	Taxa de aprendizado
α	Taxa de momentum

9

Algoritmo de Retropropagação

10



11

- Etapas do algoritmo de retropropagação**
- Construa uma rede MLP com arquitetura totalmente conectada, com N neurônios na camada de entrada, M neurônios na camada de saída e P neurônios na camada oculta, adaptado às características do problema em questão
 - Os pesos sinápticos devem ser inicializados com valores aleatórios e os pesos w_0 (bias) com valor $+1$

12

- Escolha uma amostra na forma de um par entrada-saída desejada (x_i, d_i) . Na camada de entrada os valores do neurônio y_i coincidem com os x_i

13

- Faça a propagação do sinal de cada neurônio da camada de entrada y_i para a camada oculta intermediária, efetuando o somatório ponderado pelos pesos sinápticos w_{ji} para calcular v_j (denominado de campo local induzido) e utilize a função de ativação para calcular os valores de entrada y_j para a camada intermediária

$$v_j = \sum_{i=0}^N w_{ji} y_i$$

$$y_j = f(v_j)$$

14

- Faça a propagação do sinal dos neurônios da camada intermediária y_j para a camada de saída por meio do somatório ponderado pelos pesos sinápticos w_{kj} para calcular o campo local induzido v_k , utilizando a função sigmoide para calcular os valores de entrada y_k para a camada de saída

$$v_k = \sum_{j=0}^P w_{kj} y_j$$

$$y_k = f(v_k)$$

15

- Calcule o gradiente local para os neurônios da camada de saída δ_k de acordo com a fórmula (no caso de se utilizar a função sigmoide)
- Calcule o gradiente local para os neurônios da camada intermediária δ_j conforme a fórmula

$$\delta_k = a y_k (d_k - y_k) (1 - y_k)$$

$$\delta_j = a y_j (1 - y_j) \sum_{k=0}^M \delta_k w_{kj}$$

16

- Atualize o valor dos pesos conforme os valores dos gradientes locais calculados para a camada de saída e a camada intermediária
- O índice sobrescrito $t+1$ indica o próximo valor das atualizações dos pesos, sendo o índice sobrescrito t o valor atual

$$\Delta w_{kj}^{t+1} = \alpha \Delta w_{kj}^t + \eta \delta_k y_k$$

$$\Delta w_{ji}^{t+1} = \alpha \Delta w_{ji}^t + \eta \delta_j y_j$$

17

- O valor de atualização compõe-se de duas partes
 - Uma relativa ao valor atual do peso, multiplicado pela taxa de momento α
 - Outra referente à modificação calculada pelo gradiente local, multiplicada pela taxa de aprendizagem η

$$w_{kj}^{t+1} = w_{kj}^t - \Delta w_{kj}^t$$

$$w_{ji}^{t+1} = w_{ji}^t - \Delta w_{ji}^t$$


18

- Retorne ao passo 3 e escolha outro par entrada-saída
- Quando todos os pares forem apresentados à rede, significa que uma época de treinamento foi alcançada
- Dessa forma, refaz-se o processo para várias épocas até que o valor global de erro alcance um valor que possibilite a classificação ótima pela rede MLP

$$E = \frac{1}{2} \sum_c e_k^2$$


$$= \frac{1}{2} \sum_c (d_k - y_k)^2$$

Descida de gradiente




Fonte: MEDEIROS, L. F. de. Inteligência Artificial Aplicada. Curitiba: Ed. Intersaberes, 2018.

Treinamento



Taxa de aprendizagem



Python e Jupyter Notebook

Linguagem de programação Python

- Surgiu em 1991
- Linguagem de programação interpretada
- Possui uma grande comunidade ativa de processamento científico e análise de dados
- Uma das linguagens mais importantes na área de Ciência de Dados

API

- Python possui uma implementação básica de comandos de programação
- Mas a linguagem é enriquecida por um grande número de bibliotecas ou API (criadas por desenvolvedores que formam uma grande comunidade ativa de processamento científico e análise de dados)
- Além das bibliotecas padrão, outras bibliotecas podem ser instaladas de acordo com a necessidade de processamento do usuário

25

Linguagem de *scripts*

- A linguagem Python implementa estruturas de dados de alto nível, orientadas para o processamento eficiente dos dados e possui ainda uma implementação simples, porém eficaz, de programação orientada a objetos
- A partir de uma sintaxe elegante e com menos símbolos, a linguagem é ideal para a execução de pequenos e rápidos códigos para atingir objetivos específicos (*scripts*)

26

Bibliotecas utilizadas

- NumPy**
- Pandas**
- Matplotlib**
- Scipy**
- Scikit-learn**
- Statsmodels**

27

Jupyter notebook

```
In [1]: # Python é uma linguagem interpretada, o interpretador Python roda um programa, executando as instruções uma por vez,
# os comentários em Python são dados por "#"

In [2]: # Associando um valor a uma variável inteira
a = 1
out[2]: 1

In [3]: # Associando um valor a uma variável string
s = "Hello World"
s
out[3]: 'Hello World'

In [4]: # Imprimindo o conteúdo da variável
print(s)
Hello World


In [5]: # Utilizando elos para o recurso de auto-completar
exemplo = "Exemplo"
out[5]: 'Exemplo'
```

28

Construção de um Modelo

29

Fluxo do modelo



30

Wine quality


- Classificação de qualidade de vinhos a partir de suas características químicas tais como acidez volátil, alcalinidade, presença de substâncias químicas e também outras características como a cor
- No total, são 1.599 instâncias (amostras) de vinhos, contendo 12 atributos ou características (considerando somente o *dataset* de vinhos tintos)

Recorte do dataset

	Características:												Rótulo:
	fixed acidity	volatile acidity	citric acid	residual sugar	chlorides	free sulfur dioxide	total sulfur dioxide	density	pH	sulphates	alcohol	quality	
0	7.4	0.70	0.00	1.9	0.076	11.0	34.0	0.9978	3.51	0.56	9.4	5	
1	7.8	0.88	0.00	2.6	0.068	25.0	67.0	0.9960	3.20	0.68	9.8	5	
2	7.8	0.76	0.04	2.3	0.062	16.0	34.0	0.9979	3.26	0.65	9.8	5	
3	11.2	0.28	0.56	1.9	0.075	17.0	60.0	0.9980	3.16	0.55	9.8	6	
4	7.4	0.70	0.00	1.9	0.076	11.0	34.0	0.9978	3.51	0.56	9.4	5	

31

32



Matriz de confusão

		Predição de Classe	
		Predição Positiva	Predição Negativa
Classe Original	Condição Positiva	Verdadeiro Positivo	Falso Negativo (Erro Tipo I)
	Condição Negativa	Falso Positivo (Erro Tipo II)	Verdadeiro Negativo

33

34

Avaliação de desempenho

$$ACC = \frac{VP + VN}{VP + VN + FP + FN} \quad Pr = \frac{VP}{VP + FP} \quad Re = \frac{VP}{VP + FN}$$

		Classe Predita	
		+	-
Classe Original	+	VP	FN
	-	FP	VN

		Classe Predita	
		+	-
Classe Original	+	VP	FN
	-	FP	VN

		Classe Predita	
		+	-
Classe Original	+	VP	FN
	-	FP	VN

Experimentação do Modelo

35

36

Qualidade de vinhos (*wine*)

- Ambiente do *Jupyter Notebook* (Google Colaboration)
- O conteúdo de cada célula será mostrado, de forma a apresentar uma estrutura geral sobre como outros problemas de classificação podem ser adaptados para o caso do problema de qualidade de vinhos

- ## Qualidade de vinhos (*wine*)
- Ambiente do *Jupyter Notebook* (Google Colaboration)
 - O conteúdo de cada célula será mostrado, de forma a apresentar uma estrutura geral sobre como outros problemas de classificação podem ser adaptados para o caso do problema de qualidade de vinhos

Qualidade de vinhos (*wine*)

- Ambiente do *Jupyter Notebook* (Google Colaboration)
- O conteúdo de cada célula será mostrado, de forma a apresentar uma estrutura geral sobre como outros problemas de classificação podem ser adaptados para o caso do problema de qualidade de vinhos

