

Aula 6

Redes Neurais Artificiais e *Machine Learning*


Prof. Luciano Frontino de Medeiros

1

Aprendizado profundo (*deep learning*)

2

Histórico da pesquisa em redes neurais artificiais (RNA) – ondas



3

Evidências neurológicas

- O cérebro desenvolve os conceitos de nível superior em estágios, primeiro extraindo informação de várias camadas de representações úteis, passando gradualmente para as mais complexas



4


Aprendizado profundo

- Resolve o problema central no aprendizado de representação, introduzindo representações que são expressas em termos de outras representações mais simples



5

Tamanho dos *datasets*



6

Deep learning

- Tem melhorado também a habilidade das RNA no reconhecimento com acurácia ou em tarefas de predição
- As imagens de entrada não precisam ser recortadas nos objetos dos quais se deseja fazer o reconhecimento de padrões
- As RNA atuais reconhecem normalmente pelo menos 1.000 categorias diferentes de objetos



Zapp2Photo / Shutterstock

7


ImageNet large scale visual recognition challenge – ILSVRC

- Maior concurso de reconhecimento de objetos
- Uma rede convolucional venceu esse desafio pela primeira vez e por uma margem muito alta, reduzindo a taxa de erro dos cinco principais modelos de 26,1% para 15,3%

(Krizhevsky; Sutskever; Hinton, 2012)

8

Evolução da quantidade de neurônios (unidades)



Fonte: Elaborado com base em Goodfellow et al., 2016.

Deep learning


- Redes convolucionais ou convolutivas (CNN)
- Redes neurais recorrentes (RNN)
- Long short-term memory (LSTM)
- Máquinas de Boltzmann Restritas (RBM)
- Autoencoders

9

10

Redes convolutivas

Diagrama esquemático de uma rede convolucional



11

12


Convolução

- Operação linear que atua sobre duas funções dadas, gerando uma terceira, que é a soma do produto que se desloca ao longo de uma região entendida como a superposição entre elas, em um domínio contínuo

1D: $(f * g)(k) = \sum_{l=-\infty}^{\infty} f(l)g(k-l)$

2D: $S(l, j) = (K * I)(l, j) = \sum_m \sum_n I(m, n)K(l-m, j-n)$

Exemplo de convolução



Fonte: Medeiros, 2021.

13

14

- Saída de uma camada de convolução com um banco de oito filtros a partir da imagem, da rede ConvNetJS do dataset CIFAR-10



Fonte: Elaborado com base em Stanford, [5.4].

Retificação linear (ReLU)

- Consiste em uma função de ativação aplicada sobre a saída da operação de convolução

$f(x) = \max(0, x)$




15

16

Exemplo de aplicação (ReLU)


- Comparação entre uma camada de convolução e uma camada com retificador linear a partir da imagem, de um exemplo da rede ConvNetJS do dataset CIFAR-10



Fonte: Elaborado com base em Stanford, [5.4].

Pooling

- Produz, na sua saída, uma estatística dos vizinhos próximos que são considerados como entrada



17

18

Exemplo de *pooling*

- Saída de uma sequência convolução – retificador linear – *pooling*, a partir da imagem, da rede ConvNetJS do dataset CIFAR-10

Fonte: Elaborado com base em Stanford, [S.d.].

19

Achatamento (*flatten*)

- Alinhamento das camadas bidimensionais em uma camada com uma dimensão apenas

Fonte: Medeiros, 2021.

20

Fully connected + Softmax

$$f_j(z) = \frac{e^{z_j}}{\sum_{k=1}^N e^{z_k}}$$

Fonte: Medeiros, 2021.

21

Bibliotecas e APIs para *deep learning* (Tensorflow e Keras)

22

Tensorflow

- Desenvolvida pelo Google Brain Team, é uma API de baixo e alto nível para diversas operações (adição, multiplicação e diferenciação) e ainda fornece diversos modelos de ML

zizou7 / Shutterstock

23

Tensor

- Estrutura que generaliza vetores ou matrizes para dimensões mais altas

Fonte: Medeiros, 2021.

24

Keras

- Biblioteca de alto nível baseada em Tensorflow, que permite a criação de modelos em *machine learning* e *deep learning* com bastante flexibilidade

Model

Layer

Core modules

25

Métodos – Sequential()

Método	Descrição	Exemplo
add	Adiciona uma camada ao modelo criado com Sequential	<code>model.add(Conv2D, 32, (3, 3))</code>
compile	Compila o modelo, informando a função custo, algoritmo de treinamento (otimizador) e métrica a ser utilizada	<code>model.compile(loss='mean_squared_error', optimizer='sgd', metrics=[metrics.categorical_accuracy])</code>
fit	Treina o modelo, sendo informados diversos parâmetros, como conjunto de entrada e saída, tamanho do lote, dados para teste e validação	<code>model.fit(x_train, y_train, batch_size=128, epochs=20, verbose=1, validation_data=(x_test, y_test))</code>
predict	Faz a predição com o modelo treinado de um conjunto de validação	<code>predict(x, batch_size=32)</code>
evaluate	Avalia a performance do modelo construído	<code>model.evaluate(x_test, y_test)</code>

26

Construção do modelo em Python e Jupyter Notebook


27

Prática de rede convolutiva

- Será construída uma rede convolutiva para classificação de um *dataset* popular denominado Fashion MNIST (Xiao; Rasul; Vollgraf, 2017)
- Conjunto de treinamento de 60.000 imagens e um conjunto de teste de 10.000 imagens
- As imagens têm dimensões 28x28 em escala de cinza, associadas a dez classes

28

Visão parcial do Fashion MNIST




Fonte: GitHub, [5.d.].

29


Estrutura da rede convolutiva

`model.summary()`

30



31




32

A slide with a white background and a black border. It displays a Python code snippet for generating a classification report using sklearn. The code is as follows:

```
In [25]: from sklearn.metrics import classification_report
target_names = ['class 0', 'class 1', 'class 2']
print(classification_report(test_y, predicted_classes, target_names=target_names))
```

The output of the code is a classification report showing precision, recall, and f1-score for each class, as well as overall averages. The slide is numbered "33" in the bottom left corner.

33



34